



**“PREDICCIÓN DEL PRESUPUESTO DE ABASTECIMIENTO MEDIANTE APRENDIZAJE
AUTOMÁTICO: EVALUACIÓN COMPARATIVA EN UNA MICROEMPRESA DE
REPOSTERÍA”**

**TESIS PARA OBTENER EL GRADO DE MAESTRO EN
INTELIGENCIA ARTIFICIAL**

PRESENTADA POR:

RODRIGO ADRIÁN MARTÍNEZ FLORES

**DIRECTOR DE TESIS:
LUIS EDUARDO URBAN RIVERO**

Tolcayuca, Hidalgo. 28, agosto 2025.

DEDICATORIA

A mi amada esposa, mi compañera de vida, mi mejor complemento, quien me ha impulsado para alcanzar cada nuevo reto.

A mis hijos que han sido inspiración avanzar en mi formación académica y que con su espontaneidad han llenado mi vida de entusiasmo por seguir adelante.

A mis padres que siempre me han apoyado.

AGRADECIMIENTOS

A la Universidad Politécnica Metropolitana de Hidalgo

ÍNDICE

Contenido

RESUMEN	13
ABSTRACT	13
1. INTRODUCCIÓN.....	15
1.1 Estado del Arte	17
1.1.1 Aplicaciones de la inteligencia artificial en la cadena de suministro.....	17
1.1.2 Modelos de aprendizaje automático para el pronóstico de demanda.....	18
1.1.3 La repostería creativa como sector económico especializado	18
1.1.4 Innovación y transformación digital en la industria pastelera	19
1.1.5 Adopción de inteligencia artificial en microempresas	20
1.1.6 Investigaciones en México y América Latina.....	21
1.1.7 Síntesis del estado del arte y vacío de investigación	25
1.2 El planteamiento del problema	25
1.2.1 Contexto del caso de estudio	27
1.2.2 Pregunta de Investigación.....	28
1.2.3 Objetivo	28
1.3 Justificación.....	29
1.4 Hipótesis.....	31

2	MARCO TEÓRICO	32
2.1	Microempresa, intuición y el conocimiento tácito.....	32
2.1.1	Caracterización Estructural y Ontología de la Microempresa en Economías Emergentes	32
2.1.2	El Conocimiento Tácito y la Experiencia Empírica como Activos Operativos....	33
2.1.3	El Paradigma de la Intuición y el "Pensamiento de Sistema 1" en la Toma de Decisiones	34
2.1.4	Sesgos Cognitivos y Heurísticas en la Gestión del Abastecimiento y la Planeación Financiera	35
2.1.5	Limitaciones Epistemológicas de la Intuición frente a la Variabilidad Compleja del Mercado	37
2.1.6	Conclusión.....	¡Error! Marcador no definido.
2.2	Inteligencia de Negocios y Analítica Predictiva en la Planeación Financiera	38
2.2.1	Evolución Epistemológica de la Inteligencia de Negocios y los Sistemas de Soporte a la Decisión (DSS).....	39
2.2.2	El Paradigma del Data-Driven Decision Making (DDDM) como Activo Estratégico	40
2.2.3	Taxonomía Analítica: Del Análisis Descriptivo a la Frontera de la Analítica Predictiva	41
2.2.4	La Intersección Estratégica entre Analítica Predictiva, Planeación Financiera y Gestión del Flujo de Efectivo	42

2.2.5	Sincronización Operativa: S&OP, Gestión de Inventarios y Mitigación de Costos en Productos Perecederos	44
2.2.6	Conclusión.....	¡Error! Marcador no definido.
2.3	Modelos de pronóstico: Enfoques estadísticos y Aprendizaje Automático	46
2.3.1	Fundamentos Epistemológicos y Matemáticos de los Enfoques Estadísticos Clásicos	46
2.3.2	El Paradigma del Aprendizaje Automático (Machine Learning) en el Pronóstico de Demanda	48
2.3.3	Arquitecturas de Aprendizaje Profundo (Deep Learning) y Redes Neuronales Recurrentes	49
2.3.4	Confrontación Empírica: Métodos Estadísticos Avanzados vs. Algoritmos de Machine Learning	51
2.3.5	Aplicación Crítica al Sector de Productos Perecederos y Repostería Creativa	53
2.3.6	Conclusión.....	¡Error! Marcador no definido.
2.4	Pronóstico en productos perecederos	55
2.4.1	Ontología del Producto Perecedero en la Cadena de Suministro y su Complejidad Analítica	55
2.4.2	El Problema del Vendedor de Periódicos (<i>Newsvendor Problem</i>) y la Asimetría del Costo de Error.....	56
2.4.3	Variabilidad de la Demanda y Micro-estacionalidad en la Repostería Creativa	58
2.4.4	Impacto Financiero y Medioambiental de la Integración de Modelos Predictivos..	59

2.4.5	Desafíos de Integración: Del Algoritmo Matemático a la Ejecución Operativa ..	60
2.4.6	Conclusión.....	¡Error! Marcador no definido.
2.5	Fundamentos técnicos del modelado predictivo en entornos de <i>Small Data</i>	62
2.5.1	La Paradoja de la Dimensionalidad y el Fenómeno del <i>Small Data</i> en la Microempresa	62
2.5.2	El Equilibrio Sesgo-Varianza (<i>Bias-Variance Tradeoff</i>) y el Riesgo de Sobreajuste (<i>Overfitting</i>).....	63
2.5.3	Estrategias de Regularización y Contracción Matemática para la Parsimonia ..	64
2.5.4	Ingeniería de Características (<i>Feature Engineering</i>): La Incorporación Heurística del Conocimiento Tácito	66
2.5.5	Validación Temporal Estricta: Metodología de Ventanas Deslizantes (<i>Rolling-Origin</i>)	67
2.5.6	Conclusión.....	¡Error! Marcador no definido.
2.6	Métricas de evaluación de modelos predictivos	69
2.6.1	Fundamentos Epistemológicos de la Medición del Error Predictivo	70
2.6.2	Error Absoluto Medio (<i>MAE</i>) y la Magnitud Lineal del Riesgo Operativo	71
2.6.3	Raíz del Error Cuadrático Medio (<i>RMSE</i>) y la Penalización de Errores Catastróficos.....	72
2.6.4	Error Porcentual Absoluto Medio (<i>MAPE</i>) y la Relatividad Comercial	73
2.6.5	Validación de Modelos en Series Temporales: Metodología de Ventanas Deslizantes (<i>Rolling-Origin Cross-Validation</i>).....	74

2.6.6	Fusión Multicriterio y Evaluación Contra la Línea Base Empírica	76
2.6.7	Conclusión.....	¡Error! Marcador no definido.
2.7	Limitaciones en la adopción de Inteligencia Artificial en microempresas	78
2.7.1	Asimetrías Tecnológicas y de Conocimiento en el Estrato Microempresarial ...	78
2.7.2	Barreras de Infraestructura y el Fenómeno de los Silos Informáticos Analógicos	79
2.7.3	Restricciones Presupuestarias y el Costo Total de Propiedad (TCO) de la Analítica Avanzada	80
2.7.4	Analfabetismo de Datos (<i>Data Literacy</i>) y la Brecha Organizacional de Capital Humano	81
2.7.5	La Democratización de la Ciencia de Datos y el Enfoque <i>Lean Data Science</i> como Vía de Solución.....	82
2.8	Conclusión del Marco Teórico	83
3	METODOLOGÍA.....	85
3.1	Tipo de investigación según el objetivo de ésta	85
3.2	Según el nivel de profundización en el objeto de estudio.....	86
3.3	Según el tipo de datos empleados	87
3.4	Según el grado de manipulación de las variables	88
3.5	Diseño evaluativo y comparación contra la línea base.....	89
3.6	Según el tipo de inferencia	89

3.7	Temporalidad de la investigación	90
3.8	Procedimiento Metodológico	90
3.8.1	Recolección y estructuración de los conjuntos de datos (<i>Datasets</i>).....	90
3.8.2	Ingeniería de características y variables exógenas.....	91
3.8.3	Selección y configuración de modelos predictivos	91
3.8.4	Estrategias de partición temporal y validación	92
3.8.5	Métricas de evaluación del desempeño	92
3.8.6	Integración en Inteligencia de Negocios y simulación financiera.....	93
4	DESARROLLO	94
4.1	El repositorio.....	94
4.2	El contexto del negocio	94
4.2.1	El registro de ventas y compra de insumos.....	94
4.2.2	Conjuntos de datos de variables exógenas temporales y comerciales	100
4.3	El proceso de construcción del dataset maestro	107
4.3.1	Análisis Exploratorio de Datos (EDA).....	107
4.3.2	Ingeniería de Características (Feature Engineering).....	114
4.4	Diagnóstico de la Línea Base y Evaluación del Método Empírico (Preprueba).....	123
4.5	Auditoría, Depuración e Integración del Conjunto de Datos (Dataset)	124
4.6	Ingeniería de Características (Feature Engineering) y Variables Exógenas	125

4.7	Desarrollo, Configuración y Entrenamiento de los Modelos Predictivos.....	126
4.8	Evaluación Comparativa de Rendimiento Analítico (Posprueba vs. Control)	127
4.9	Arquitectura e Integración del Tablero de Inteligencia de Negocios (DSS)	128
	Arquitectura tecnológica	128
	Integración de los resultados predictivos.....	129
	Filtros e indicadores para la decisión.....	129
	Resultados incorporados al DSS.....	130
	Interpretación operativa y salvaguardas.....	131
	Alcance actual de la integración	132
4.10	Alcance de la simulación financiera y de abastecimiento	133
5	RESULTADOS	134
	Calidad, cobertura e integración de datos.....	134
	Reducción dimensional	134
	Rendimiento comparativo de los modelos.....	135
	Resultados de redes neuronales recurrentes.....	136
	Contraste de hipótesis.....	136
	Resultados del tablero DSS	137
6	DISCUSION.....	139
	Interpretación de los hallazgos.....	139

Demanda intermitente y selección de métricas	139
Implicaciones operativas y financieras	139
Validez y limitaciones	140
7 CONCLUSIONES	141
Recomendaciones.....	141
Trabajo futuro	141
GLOSARIO	142
REFERENCIAS	143

TABLAS, IMÁGENES Y ECUACIONES

Tabla 1 - Investigaciones relevantes sobre inteligencia artificial, analítica de datos y adopción tecnológica en la gestión empresarial.....	23
(1)	58
(2)	63
(3)	65
(4)	67
Imagen 1 - Repositorio github	94
Tabla 2 - Conjuntos de datos de Ventas y Compras	95
Tabla 3 - Conjunto de datos de variables exógenas (Contexto Tizayuca, Hgo.)	100
Tabla 4 - Inflación histórica en México (INPC).....	102
Imagen 2 - Temperatura Media por Entidad Federativa y Nacional, contenido en PDF	105
Tabla 5 - Temperatura mensual (Tizayuca, Hgo.)	106
Figura 27 - Trazabilidad del pipeline analítico de la investigación.	107
Tabla 6 - Síntesis de fuentes de datos y transformaciones aplicadas	110
Tabla 7 - Operacionalización de la línea base y la posprueba.....	123
Tabla 8 - Trazabilidad de los conjuntos analíticos	124
Figura 24 - Expansión dimensional producida por la ingeniería de características.	125
Tabla 9 - Dimensiones principales de las variables modeladas.....	125

Figura 25 - Arquitecturas recurrentes consideradas para el modelado temporal.....	126
Tabla 10 - Familias de modelos y configuración evaluada	126
Figura 26 - Esquema de validación temporal Rolling-Origin.....	127
Figura 28 - Arquitectura funcional del sistema de soporte a la decisión.	128
Figura 29 - Interfaz funcional del tablero DSS implementado para Cup&Cake.	132
Figura 30 - Flujo de decisión operativa asistido por el DSS.....	133
Figura 31 - Mejora relativa del RMSE frente a la línea base empírica.	135
Figura 32 - Mejor modelo por objetivo y representación de datos.	136
Tabla 11 - Modelos ganadores y desempeño temporal.....	138

RESUMEN

La investigación desarrolló y evaluó modelos predictivos para anticipar el presupuesto de abastecimiento de Cup&Cake, microempresa de repostería ubicada en Tizayuca, Hidalgo. Se integraron registros diarios de ventas y compras con variables calendáricas, económicas y climáticas; posteriormente se construyeron rezagos, ventanas móviles y características cíclicas bajo controles de fuga de información. La evaluación se realizó mediante validación temporal Rolling-Origin y comparación contra una línea base empírica y modelos estadísticos de referencia.

El dataset maestro quedó conformado por 1,612 observaciones y 65 variables, mientras que el conjunto de modelado reunió 1,584 días y 276 columnas. ARIMA resultó más competitivo para ventas, mientras que Random Forest obtuvo el mejor desempeño para el importe y la frecuencia de compras. En compras, la reducción relativa del RMSE fue de 28.3 % y 22.8 % frente a la línea base; por ello, la hipótesis se respaldó para el presupuesto de abastecimiento. Los resultados se integraron en un sistema de soporte a la decisión con indicadores, filtros y salvaguardas de interpretación humana.

Palabras clave: presupuesto de abastecimiento, microempresa, series temporales, aprendizaje automático, Rolling-Origin, inteligencia de negocios.

ABSTRACT

This research developed and evaluated predictive models to anticipate the procurement budget of Cup&Cake, a small bakery located in Tizayuca, Hidalgo. Daily sales and purchasing records were integrated with calendar, economic and weather variables. Lagged variables, moving windows and cyclical encodings were generated under information-leakage controls. Models were assessed through Rolling-Origin temporal validation against an empirical baseline and statistical reference models. ARIMA was more competitive for sales, whereas Random Forest achieved the best performance for purchasing amount and frequency. For purchases, relative RMSE reductions were 28.3% and 22.8% against the baseline. Results were incorporated into a business-intelligence decision-support dashboard.

Keywords: procurement budget, microenterprise, time series, machine learning, Rolling-Origin, business intelligence.

1.INTRODUCCIÓN

Un emprendimiento surge a partir de una idea que resuelve alguna necesidad básica o simplemente permite hacer más sencilla la vida de otras personas ofreciendo productos y/o servicios útiles para alguna comunidad. Suele ser una alternativa para situaciones complejas como la pérdida de empleo o con la intención de generar una utilidad que sirva para mejorar la calidad de vida familiar. El Global Entrepreneurship Monitor (**GEM, 2023**) indica que los emprendimientos contribuyen al bienestar económico y social, generando ingresos y mejorando la calidad de vida tanto de los emprendedores como de sus comunidades.

Los emprendimientos o microempresas enfrentan importantes desafíos dado que en la mayoría de los casos surgen sin una adecuada planeación. **Minniti y Bygrave (2018)** explican que el proceso emprendedor es dinámico y se basa en el aprendizaje continuo derivado de la interacción con el entorno y la toma de decisiones bajo incertidumbre. Asimismo, **Ries (2017)**, desde la perspectiva del *lean startup*, sostiene que muchos emprendimientos comienzan con supuestos no validados y van ajustando su modelo de negocio mediante prueba y error. El emprendedor va generando experiencia sobre el negocio a partir del conocimiento de su entorno y del mercado.

La Organización para la Cooperación y el Desarrollo Económicos (**OCDE, 2021**) señala que las pequeñas empresas enfrentan restricciones de información y capacidades, lo que dificulta prever la demanda y optimizar la gestión de inventarios. La compra de materia prima se realiza con cautela sin tener certeza de si se logrará vender los productos que se elaboran, en muchos casos el mismo crecimiento orgánico provoca un caos y desperdicio de materia prima y recursos que limitan el crecimiento, todo este aprendizaje se obtiene generalmente de manera empírica conforme va evolucionando el negocio y aumentando las ventas. **Kantis, Federico y García (2020)** indican que la falta de capacidades de gestión en etapas tempranas puede provocar problemas en la organización interna, uso ineficiente de recursos y limitaciones para escalar el negocio.

Cuando se observa que el producto o servicio ofrecido recibe una aceptación del mercado se presentan nuevos retos, principalmente la alta variabilidad de la demanda, el reto de predecir la compra de materia prima o la creación de planes de crecimiento del negocio que lo lleven hacia un nuevo nivel y participación del mercado, lo anterior genera incertidumbre y poca claridad para el emprendedor. **Banco Interamericano de Desarrollo (BID, 2019)** destaca que los emprendedores en contextos latinoamericanos suelen aprender haciendo, lo que implica un proceso de mejora progresiva, aunque con costos asociados como errores, desperdicio y baja productividad inicial.

Las microempresas representan el núcleo del aparato productivo en México y América Latina. De acuerdo con el Instituto Nacional de Estadística y Geografía (INEGI), **en México existen más de 4.9 millones de micro, pequeñas y medianas empresas, de las cuales el 95% corresponde a microempresas, generando aproximadamente el 41.8% del empleo nacional (INEGI, 2023)**. A pesar de su relevancia económica y social, estas organizaciones enfrentan serias limitaciones estructurales, particularmente en materia de planeación financiera, gestión de inventarios y administración de la cadena de suministro.

Uno de los principales retos que enfrentan las microempresas es la escasa adopción de tecnologías avanzadas para la toma de decisiones. Según **la OCDE (OCDE, 2022)**, **menos del 25% de las microempresas en países en desarrollo utilizan herramientas analíticas avanzadas**, lo que implica que la mayoría de ellas basa sus decisiones estratégicas en la experiencia empírica del propietario, en promedios históricos simples o en la intuición. Este enfoque incrementa la incertidumbre financiera, dificulta la previsión de ingresos y eleva el riesgo de sobre inventarios o desabasto, especialmente en sectores con alta variabilidad de la demanda. En el sector alimentario y de productos perecederos, como la repostería, estos desafíos se intensifican.

Una planificación inadecuada de la demanda en el sector de panadería puede generar niveles significativos de merma, con tasas de devolución que oscilan entre el 1.5% y el 19%, lo cual tiene implicaciones económicas y operativas relevantes para las empresas del sector (Hübner et al., 2024). Asimismo, la falta de pronósticos confiables limita la capacidad de las

microempresas para diseñar estrategias de crecimiento, expandirse a nuevos mercados o realizar inversiones con menor riesgo financiero.

La literatura reciente destaca que los modelos predictivos basados en aprendizaje automático superan consistentemente a los métodos tradicionales en problemas de pronóstico de ventas e ingresos, al capturar patrones no lineales, estacionalidades y efectos de variables externas (Makridakis et al., 2018; Spiliotis et al., 2025). En particular, el uso de modelos de ML ha permitido mejorar la precisión de los pronósticos hasta en un 30%, reduciendo costos operativos y mejorando la toma de decisiones estratégicas (Cao et al., 2025).

Frente a este escenario, el aprendizaje automático (ML por sus siglas en inglés, Machine Learning) como rama de la Inteligencia Artificial (AI por sus siglas en inglés, Artificial Intelligence) ha emergido como herramienta clave para transformar la planeación financiera y la gestión de la cadena de suministro.

1.1 Estado del Arte

1.1.1 Aplicaciones de la inteligencia artificial en la cadena de suministro

El uso de la inteligencia artificial (IA) en la cadena de suministro ha demostrado ser una herramienta eficaz para mejorar la eficiencia operativa y la toma de decisiones, especialmente en industrias con productos perecederos. Distintos estudios han explorado su aplicación desde enfoques variados, ofreciendo evidencia empírica, conceptual y técnica que fundamenta su utilidad en contextos empresariales.

Uno de los estudios más relevantes es el de Hübner et al. (2024), quienes analizaron la implementación de un sistema de aprendizaje automático en la nube denominado *Foodforecast* en panaderías de Berlín, Alemania. El objetivo del estudio fue evaluar el impacto del uso de modelos predictivos en la reducción del desperdicio de alimentos. La investigación adoptó un enfoque cuantitativo basado en datos históricos de ventas y producción, utilizando modelos de aprendizaje automático para pronosticar la demanda diaria de productos. Los resultados mostraron una reducción significativa del desperdicio alimentario y una mejora en

la precisión de los pronósticos de demanda. El principal aporte radica en demostrar que los sistemas de predicción basados en inteligencia artificial pueden contribuir a mejorar la eficiencia operativa y la sostenibilidad en industrias con productos perecederos.

Sin embargo, el modelo *Foodforecast* presenta como limitación el hecho de que fue desarrollado en organizaciones con infraestructura tecnológica avanzada, lo cual dificulta la extrapolación de sus resultados a microempresas con recursos limitados.

1.1.2 Modelos de aprendizaje automático para el pronóstico de demanda

Huber y Stuckenschmidt (2020) desarrollaron un estudio orientado al pronóstico diario de ventas en el sector minorista, utilizando algoritmos de aprendizaje automático capaces de incorporar variables calendáricas y eventos especiales. La metodología consistió en comparar distintos modelos predictivos utilizando datos históricos de ventas de una cadena comercial. Los resultados evidenciaron que los modelos de aprendizaje automático lograron mejorar la precisión de los pronósticos, especialmente en periodos asociados a eventos especiales o festividades.

En la literatura reciente también se observa un creciente interés por el desarrollo de modelos híbridos y técnicas avanzadas de predicción. Un ejemplo de ello es el estudio de Abrar et al. (2024) quienes propusieron un modelo híbrido denominado *Multi-Channel Data Fusion Network (MCDFN)* para el pronóstico de la demanda en cadenas de suministro. Este modelo integra redes neuronales convolucionales, redes LSTM y mecanismos de interpretabilidad basados en inteligencia artificial explicable (XAI). Los resultados del estudio evidencian una mejora significativa en la precisión de los pronósticos.

1.1.3 La repostería creativa como sector económico especializado

La industria de la repostería ha experimentado una evolución significativa durante las últimas décadas, pasando de modelos tradicionales de producción a esquemas altamente personalizados orientados a nichos específicos de mercado. Dentro de esta evolución destaca la denominada repostería creativa o *cake design*, caracterizada por la elaboración de

productos personalizados para celebraciones, eventos sociales y ocasiones especiales. Esta transformación ha permitido que los productos de repostería trasciendan su función alimentaria para incorporar componentes estéticos, simbólicos y experienciales que agregan valor a la oferta comercial (Borsato, 2023).

La repostería contemporánea combina elementos gastronómicos, artísticos y comerciales, donde la diferenciación mediante el diseño, la personalización y la experiencia del cliente constituyen factores clave para la competitividad empresarial. En este contexto, la creatividad se ha convertido en un recurso estratégico para los profesionales de la pastelería, integrando conocimientos técnicos, innovación estética y comprensión de las preferencias del consumidor (Ab Karim et al., 2020). Asimismo, la innovación en productos representa uno de los principales factores que contribuyen al desempeño y posicionamiento competitivo de las empresas del sector pastelero (Ben Abdallah et al., 2022).

A diferencia de la panadería tradicional, la demanda en este tipo de negocios suele presentar una mayor variabilidad debido a factores estacionales, eventos sociales y preferencias particulares de los consumidores. Esta dinámica genera desafíos importantes para la planeación de la producción, la gestión de inventarios y la estimación de ingresos, especialmente en microempresas que operan con recursos limitados y productos altamente perecederos. En consecuencia, la capacidad para anticipar cambios en la demanda y optimizar la toma de decisiones se ha convertido en un factor crítico para la sostenibilidad y competitividad de este tipo de organizaciones.

1.1.4 Innovación y transformación digital en la industria pastelera

La innovación tecnológica ha adquirido un papel relevante dentro de la industria alimentaria y, particularmente, en los sectores de panadería y repostería. La incorporación de herramientas digitales para la gestión de pedidos, control de inventarios, planificación de la producción y análisis de datos ha permitido mejorar la eficiencia operativa y la capacidad de respuesta ante cambios en la demanda. Mikalef et al. (2019) y Dubey et al. (2021) señalan en sus artículos que la digitalización de procesos facilita la optimización de recursos, incrementa la

productividad y fortalece la capacidad de adaptación de las organizaciones ante entornos cada vez más dinámicos.

Hübner et al. (2024) demostraron que la implementación de modelos de aprendizaje automático para el pronóstico de la demanda en panaderías permitió disminuir significativamente el desperdicio alimentario y mejorar la planificación de la producción. De manera complementaria, estudios recientes sobre la digitalización del sector panadero destacan que las tecnologías asociadas a la Industria 4.0 facilitan la integración de datos operativos, la automatización de procesos y la mejora continua en la gestión de la cadena de suministro (**Aprodu et al., 2025**).

No obstante, gran parte de estas innovaciones han sido implementadas en organizaciones medianas y grandes que cuentan con infraestructura tecnológica avanzada y capacidades analíticas consolidadas. En contraste, existe una limitada evidencia sobre la aplicación de estas herramientas en microempresas dedicadas a la repostería creativa, donde las restricciones financieras, tecnológicas y de personal especializado continúan representando barreras importantes para la adopción de tecnologías basadas en datos (**Alekseeva et al., 2021**).

1.1.5 Adopción de inteligencia artificial en microempresas

Diversos estudios han analizado los factores que influyen en la adopción de tecnologías basadas en inteligencia artificial dentro de pequeñas y medianas empresas.

Alekseeva, Ginevičius y Stankevičienė (2021) identifican que las principales barreras para la adopción de inteligencia artificial en PYMES están relacionadas con la falta de recursos financieros, infraestructura tecnológica limitada y escasez de capital humano especializado.

De manera similar, **Mikalef et al. (2019)** señalan que la capacidad de las organizaciones para aprovechar el potencial del análisis de datos depende en gran medida de sus capacidades analíticas y de su orientación hacia la innovación tecnológica.

Por otra parte, **Dubey et al. (2021)** destacan que la integración de analítica avanzada y herramientas de inteligencia artificial contribuye significativamente al desempeño operativo de las organizaciones cuando se combina con capacidades dinámicas y estrategias de innovación.

1.1.6 Investigaciones en México y América Latina

En el contexto mexicano, diversos estudios han analizado el impacto de la adopción tecnológica y la digitalización en el desempeño de las pequeñas y medianas empresas.

Por ejemplo, **Maldonado-Guzmán, Pinzón-Castro y García-Pérez-de-Lema (2018)** analizaron la relación entre innovación tecnológica y desempeño empresarial en PYMES mexicanas, encontrando que las empresas que adoptan tecnologías digitales presentan mayores niveles de competitividad y eficiencia organizacional.

De manera similar, **Cuevas-Vargas, Estrada y Larios-Gómez (2016)** examinaron el efecto de la adopción de tecnologías de información y comunicación en pequeñas y medianas empresas mexicanas. Sus resultados indican que la digitalización de procesos y el uso de herramientas analíticas contribuyen significativamente a mejorar el desempeño organizacional.

En la misma línea, **Maldonado-Guzmán y Garza-Reyes (2020)** analizaron los procesos de transformación digital en PYMES mexicanas, concluyendo que la incorporación de tecnologías basadas en datos permite fortalecer los procesos de toma de decisiones y mejorar la capacidad de adaptación al entorno competitivo.

Asimismo, **Saavedra-García y Tapia-Sánchez (2020)** señalan que las tecnologías de información desempeñan un papel clave en la competitividad de las PYMES mexicanas; sin embargo, su adopción se ve limitada por restricciones financieras y por la falta de personal especializado.

Finalmente, **Romero-Hidalgo et al. (2021)** destacan que la gestión del conocimiento y el uso de datos en las organizaciones favorecen los procesos de innovación empresarial, lo que

resulta particularmente relevante en el contexto de pequeñas empresas que buscan mejorar su desempeño mediante el uso de tecnologías digitales.

Con el propósito de sintetizar las principales contribuciones de la literatura revisada, en la Tabla 1 se presentan los estudios más relevantes relacionados con la aplicación de inteligencia artificial, analítica de datos y adopción tecnológica en la gestión empresarial y el pronóstico de demanda.

Tabla 1 - Investigaciones relevantes sobre inteligencia artificial, analítica de datos y adopción tecnológica en la gestión empresarial

Num	Autor(es)	Contexto de estudio	País de origen	Año	Palabras clave	Metodología	Principales aportaciones	Limitaciones
1.	Alekseeva, Ginevičius y Stankevičienė	Adopción de IA en PYMES	Lituania	2021	AI Adoption, SMEs, Digital Transformation	Estudio cuantitativo europeo	Identifica barreras financieras, tecnológicas y de talento	No evalúa resultados predictivos
2.	Bertsimas & Kallus	Analítica predictiva y prescriptiva	EE.UU.	2020	Predictive Analytics, Prescriptive Analytics, DSS	Cuantitativa	Vincula predicción con toma de decisiones financieras	No enfocado en microempresas
3.	Cao et al.	Analítica predictiva	Reino Unido	2025	Predictive Analytics, Forecasting	Revisión prospectiva	Identifica tendencias futuras en analítica predictiva	No enfocado en microempresas
4.	Cuevas-Vargas, Estrada y Larios-Gómez	PYMES mexicanas	México	2019	TIC, Digitalización, SMEs	Modelo cuantitativo	Las TIC mejoran la eficiencia organizacional	No aborda modelos predictivos
5.	Dubey et al.	Empresas manufactureras	Reino Unido / India	2021	Big Data, AI, Operational Performance	Modelos estructurales sobre big data e IA	La analítica avanzada mejora el desempeño operativo	Contexto industrial
6.	Estrada & Romero	Estrada & Romero	Estrada & Romero	Estrada & Romero	Estrada & Romero	Estrada & Romero	Estrada & Romero	Estrada & Romero
7.	García-Pérez et al.	Gestión del conocimiento organizacional	Reino Unido	2020	Knowledge Management, Intellectual Capital	Revisión teórica	Explica la importancia del conocimiento organizacional	No estudia IA ni pronósticos
8.	García-Sánchez et al.	Machine Learning financiero	España	2023	Financial Forecasting, ML	Cuantitativa	Aplica ML a proyección financiera	Escasa aplicación a microempresas
9.	Huber y Stuckenschmidt	Pronóstico diario de ventas retail	Alemania	2020	Retail Forecasting, Calendric Features, ML	Comparación de modelos con variables calendáricas	Mejora la predicción durante festividades y eventos especiales	Basado en grandes volúmenes de datos
10.	Hübner et al.	Panaderías y desperdicio alimentario	Alemania	2024	Bakery, Food Waste, Demand Forecasting, ML	Estudio de caso con sistema Foodforecast	Reduce desperdicio y mejora la planificación de producción	Requiere infraestructura tecnológica avanzada
11.	Hyndman et al.	Forecast continuo empresarial	EE.UU.	2023	Forecasting, Time Series	Cuantitativa	Actualiza prácticas modernas de forecasting	Aplicación genérica
12.	Hyndman y Athanasopoulos	Pronóstico estadístico	Australia	2021	Forecasting, Time Series	Desarrollo metodológico	Referencia fundamental para métricas y modelos de pronóstico	No aborda IA aplicada a PYMES

13.	López & Torres	IA para gestión financiera	México	2024	AI, Financial Management	Mixta	Evidencia mexicana reciente	Alcance limitado
14.	Makridakis et al.	Forecasting automatizado con IA	Reino Unido	2021	Automated Forecasting, ML	Cuantitativa	Evidencia superioridad de enfoques híbridos	No analiza pequeñas empresas
15.	Makridakis, Spiliotis y Assimakopoulou	Pronóstico empresarial en múltiples industrias	Grecia	2018	Forecasting, Machine Learning, Series de tiempo	Comparación de métodos estadísticos y ML	Demuestran que ML captura patrones no lineales y mejora la precisión predictiva	No enfocado en microempresas
16.	Maldonado-Guzmán, Pinzón-Castro y colaboradores	PYMES mexicanas	México	2018-2021	Innovation, SME Performance	Estudios empíricos cuantitativos	La innovación tecnológica mejora competitividad y desempeño	No analiza IA específicamente
17.	Mikalef et al.	Organizaciones orientadas a datos	Noruega	2019	Big Data Analytics, Innovation	Modelos estructurales sobre capacidades analíticas	Las capacidades analíticas impulsan la innovación	No enfocado en microempresas
18.	Petropoulos et al.	Forecast continuo automatizado	Suiza	2020	Rolling Forecast, Forecasting	Revisión	Fundamenta el concepto de forecast continuo	No estudia IA aplicada a PYMES
19.	Ramírez-Montoya et al.	Organizaciones Data-Driven	Portugal	2022	BI, Analytics, Decision Making	Mixta	Marco de madurez analítica	No aborda forecasting
20.	Saavedra-García y Tapia-Sánchez	PYMES mexicanas	México	2020	Information Technology, SMEs	Análisis de adopción tecnológica	Las tecnologías digitales fortalecen la competitividad	Enfoque descriptivo
21.	Sánchez y Terrazas	Inteligencia de Negocios en PYMES	México	2020	Business Intelligence, Decision Making	Estudio aplicado	BI mejora la toma de decisiones empresariales	No incorpora Machine Learning
22.	Spiliotis et al.	Forecast continuo en organizaciones	Suiza	2025	Business Forecasting, AI	Cuantitativa	Estado del arte más reciente	No enfocado en PYMES
23.	Sun et al.	Análítica predictiva avanzada	Reino Unido	2024	Predictive Analytics, AI	Cuantitativa	Técnicas modernas de IA para predicción	Contexto empresarial amplio
24.	Verma et al.	Madurez analítica organizacional	Suiza	2023	Analytics Maturity	Cuantitativa	Explica capacidades analíticas necesarias	No enfocado en ML
25.	Viteri y Murillo	Inteligencia de Negocios organizacional	Ecuador	2022	Business Intelligence	Revisión conceptual	Marco general para BI en organizaciones	Sin validación empírica

Fuente: Elaboración propia con base en la literatura revisada

1.1.7 Síntesis del estado del arte y vacío de investigación

El análisis de la literatura evidencia que los modelos de aprendizaje automático han demostrado un alto potencial para mejorar la precisión de los pronósticos de demanda, optimizar la gestión de inventarios y fortalecer la planeación financiera en diversos sectores empresariales.

Sin embargo, la mayoría de las investigaciones existentes se ha desarrollado en empresas medianas o grandes que cuentan con infraestructura tecnológica avanzada y grandes volúmenes de datos.

En contraste, existe una limitada evidencia empírica sobre la aplicación de modelos de aprendizaje automático en microempresas, particularmente en sectores como la repostería artesanal o creativa.

Asimismo, aunque algunos estudios han abordado el uso de inteligencia de negocios y analítica de datos en pequeñas empresas, son escasas las investigaciones que integran simultáneamente el pronóstico de ingresos, la planeación financiera y la gestión de la cadena de suministro mediante modelos predictivos.

En este sentido, se identifica un vacío de investigación relacionado con el análisis de cómo los modelos de aprendizaje automático pueden contribuir a mejorar la planeación financiera y la gestión de la cadena de suministro en microempresas con recursos limitados. La presente investigación busca contribuir a la reducción de este vacío mediante el análisis del caso de la empresa Cup&Cake, microempresa dedicada a la repostería creativa en Tizayuca, Hidalgo.

1.2 El planteamiento del problema

Las microempresas operan en entornos caracterizados por alta incertidumbre financiera, variabilidad en la demanda y limitaciones en recursos tecnológicos y analíticos. En la mayoría de los casos, la planeación financiera y la gestión de la cadena de suministro se sustentan en la experiencia empírica del propietario, en estimaciones intuitivas o en el análisis retrospectivo de resultados históricos, sin el apoyo de modelos predictivos formales que permitan anticipar escenarios futuros con mayor precisión (Góngora Chonillo, 2023).

Esta situación resulta especialmente crítica en microempresas del sector alimentario, donde la demanda presenta fuertes componentes estacionales y donde una planeación inadecuada impacta directamente en el control de inventarios, la gestión de ingresos y la rentabilidad del negocio. Hyndman y Athanasopoulos (2021) explican que la calidad de los pronósticos impacta directamente en la planificación estratégica, la gestión de inventarios y la toma de decisiones financieras, señalando que errores sistemáticos generan sobrecostos y desabastecimientos.

A pesar de la creciente disponibilidad de soluciones basadas en Inteligencia Artificial (IA) y analítica avanzada, su adopción en micro y pequeñas empresas continúa siendo limitada. Estudios como el de Alekseeva et al. (2021), evidencian que estas organizaciones enfrentan barreras estructurales asociadas a restricciones financieras y limitaciones en infraestructura tecnológica, lo que dificulta la implementación de herramientas digitales avanzadas.

Asimismo, la literatura señala que la carencia de capital humano especializado y de capacidades analíticas internas reduce significativamente la posibilidad de integrar soluciones basadas en datos en los procesos estratégicos empresariales (Mikalef et al., 2019). Esta limitación se vincula directamente con la baja capacidad de absorción tecnológica característica de las empresas de menor tamaño.

En el ámbito de la gestión operativa y de la cadena de suministro, se ha identificado que la incorporación de tecnologías de analítica avanzada e IA depende del desarrollo de capacidades dinámicas y de una orientación estratégica clara hacia la innovación, condiciones que no siempre están presentes en microempresas (Dubey et al., 2021).

Asimismo, la literatura evidencia que la mayoría de las investigaciones sobre analítica avanzada e Inteligencia Artificial se han desarrollado en organizaciones medianas y grandes o en entornos industriales altamente estructurados, lo que limita la comprensión de su aplicabilidad en microempresas (Mikalef et al., 2020; Alekseeva et al., 2021). Esta concentración ha generado un vacío en el análisis empírico acerca de cómo los modelos de aprendizaje automático pueden incidir en la planeación financiera y operativa de empresas de menor escala.

Dicho vacío se profundiza cuando se examina la integración simultánea del pronóstico de ingresos y la gestión de inventarios como procesos interdependientes dentro de la cadena de suministro, dimensión que la literatura reconoce como crítica para el desempeño organizacional, pero escasamente abordada en microempresas (Dubey et al., 2021; Hyndman & Athanasopoulos, 2021).

1.2.1 Contexto del caso de estudio

En el contexto de las micro, pequeñas y medianas empresas (MIPYMES), la toma de decisiones suele caracterizarse por una fuerte dependencia del conocimiento tácito, la experiencia acumulada del propietario o directivo y prácticas organizacionales poco formalizadas. Este enfoque, predominantemente empírico, si bien aporta flexibilidad y rapidez en entornos de alta incertidumbre, limita la estructuración sistemática del conocimiento y la consolidación de procesos estratégicos basados en información analítica (García-Pérez et al., 2020).

Cup&Cake, es una empresa fundada en 2014, con más de diez años de operación el crecimiento orgánico le ha permitido subsistir gracias a las predicciones que actualmente se realizan con base en el empirismo del empresario ya que lo único que conoce son las fechas de eventos importantes como el Día de San Valentín (14 de febrero), el día del niño (30 de abril), el día de la madre (10 de mayo), entre otros que son los picos de venta que año con año se repiten.

Con el paso del tiempo, Cup&Cake ha incrementado sus ventas de manera orgánica, producto de un proceso mercadológico pasado, donde clientes que han depositado su confianza en la empresa recomiendan sus productos por su sabor y alta calidad en la decoración y personalización de sus productos, provocando el aumento constante en las ventas.

El reto de Cup&Cake es mejorar su capacidad de predicción de consumo de materia prima, predecir el volumen de venta orgánica y de fechas clave para anticipar la compra de insumos.

Adicionalmente, al pronosticar metodológicamente con un alto grado de certeza, el emprendedor pretende conocer anticipadamente las ventas para prever la inversión futura en nuevos puntos de venta, sin comprometer la operación actual. Todo lo anterior permitirá a los

dueños **aumentar la utilidad operativa del negocio aumentando ingresos y reduciendo costos**, reduciendo la incertidumbre del empresario y logrando los mejores resultados con el mayor grado de certeza.

1.2.2 Pregunta de Investigación

¿En qué medida los modelos de aprendizaje automático, entrenados con registros históricos de ventas y compras, mejoran la precisión de la predicción diaria del monto de compras de una microempresa de repostería creativa en Tizayuca, Hidalgo, frente a reglas empíricas y modelos estadísticos de referencia?

1.2.3 Objetivo

Objetivo general

Evaluar el desempeño de modelos de aprendizaje automático para predecir el monto diario de compras de una microempresa de repostería creativa, utilizando registros históricos de ventas y compras, y compararlo con reglas empíricas y modelos estadísticos de referencia.

Objetivos específicos

1. **Caracterizar los registros históricos de ventas y compras, así como operacionalizar una línea base empírica reproducible de pronóstico.**
2. **Construir un dataset maestro diario a partir de los registros de ventas y compras, incorporando variables temporales y exógenas disponibles para el modelado predictivo.**
3. **Entrenar y evaluar métodos estadísticos y modelos de aprendizaje automático para predecir el importe y la frecuencia diaria de compras.**
4. **Comparar el desempeño de los modelos mediante partición temporal y validación Rolling-Origin, con el fin de identificar la alternativa con mayor precisión y estabilidad predictiva.**
5. **Seleccionar la configuración predictiva con base en ajuste de hiperparámetros, selección de características, desempeño fuera de muestra e interpretabilidad.**
6. **Contrastar los modelos de aprendizaje automático con la línea base empírica y los modelos estadísticos mediante MAE y RMSE; usar MAPE sólo como diagnóstico complementario debido a la intermitencia de las series.**

7. Integrar los resultados en un tablero de inteligencia de negocios para apoyar la consulta del presupuesto de abastecimiento y la toma de decisiones basada en datos.

1.3 Justificación

1.1. Relevancia social

La relevancia social de esta investigación radica en su potencial para contribuir al fortalecimiento y sostenibilidad de las microempresas, las cuales representan una fuente importante de empleo y desarrollo económico local. La falta de acceso a herramientas analíticas avanzadas limita la capacidad de estos negocios para crecer, competir y adaptarse a entornos cada vez más dinámicos. En este sentido, estudiar la incorporación de aprendizaje automático en una microempresa permite discutir mecanismos de apropiación tecnológica más allá de los grandes corporativos y aporta evidencia sobre cómo reducir la brecha digital en unidades económicas pequeñas (Alekseeva et al., 2021; Verhoef et al., 2021).

Al mostrar la viabilidad de aplicar modelos de aprendizaje automático en una microempresa como Cup&Cake, el estudio promueve la democratización del uso de la Inteligencia Artificial, mostrando que estas tecnologías no son exclusivas de grandes corporaciones. De esta manera, se genera un referente que puede ser replicado por otros emprendedores, reduciendo la brecha tecnológica y fomentando una toma de decisiones más informada y responsable. Además, en sectores con productos perecederos, una mejora en la calidad del pronóstico puede contribuir a disminuir desperdicio, merma y compras ineficientes, con efectos económicos y ambientales relevantes (Hübner et al., 2024).

1.2. Conveniencia

La presente investigación resulta conveniente debido a que aborda una problemática real y vigente en el contexto de las microempresas, particularmente aquellas que se encuentran en una etapa de crecimiento y expansión, responde a una necesidad concreta de Cup&Cake: fortalecer su planeación para sostener crecimiento y evaluar la apertura de nuevos puntos de venta sin comprometer la operación vigente. La literatura muestra que los enfoques de analítica avanzada y aprendizaje automático permiten mejorar la calidad del pronóstico, capturar

patrones complejos de la demanda y ofrecer soporte cuantitativo para decisiones operativas y financieras (Makridakis et al., 2018; Huber & Stuckenschmidt, 2020).

En este escenario, la toma de decisiones basada únicamente en la experiencia previa o en estimaciones empíricas resulta insuficiente para evaluar la factibilidad de expansión, ya que incrementa la incertidumbre financiera y el riesgo operativo. Por ello, la aplicación de modelos de aprendizaje automático para el pronóstico de ingresos se presenta como una alternativa conveniente, al permitir anticipar escenarios futuros y apoyar decisiones estratégicas con base en evidencia cuantitativa, reduciendo tiempos de análisis y márgenes de error. En consecuencia, la investigación puede traducirse en una herramienta útil para compras, presupuestación y evaluación de escenarios de expansión.

1.3. Valor teórico

Desde el punto de vista teórico, la investigación contribuye a un espacio menos explorado la aplicación de modelos predictivos en microempresas con series relativamente pequeñas, recursos acotados y fuerte dependencia del conocimiento tácito, un segmento que ha sido menos estudiado en comparación con grandes organizaciones. La bibliografía ha mostrado la relevancia de las capacidades analíticas para la innovación y el desempeño organizacional, pero gran parte de esa evidencia proviene de empresas medianas o grandes (Gupta & George, 2016; Mikalef et al., 2019; Dubey et al., 2020).

El caso propuesto permite discutir hasta qué punto esas ideas pueden adaptarse a una microempresa de repostería creativa y cómo se articula la relación entre pronóstico, planeación financiera y abastecimiento, asimismo, el estudio permite contrastar la planeación empírica tradicional con un enfoque predictivo basado en Inteligencia Artificial, fortaleciendo la discusión teórica sobre la transformación digital en pequeñas unidades económicas.

1.4. Implicaciones prácticas

En términos prácticos, ofrece un procedimiento replicable para pequeñas empresas que desean pasar de la intuición a la evidencia analítica sin requerir infraestructuras corporativas complejas. La combinación de datos históricos, variables calendáricas y validación rigurosa

permite construir un modelo de decisión útil para estimar ingresos, programar compras y reducir incertidumbre operativa.

Adicionalmente, la comparación entre el método empírico actual y un enfoque basado en aprendizaje automático puede mostrar en qué condiciones la analítica realmente aporta valor y en cuáles un modelo simple o una línea base estadística sigue siendo suficiente (Makridakis et al., 2020; Bergmeir et al., 2018).

1.4 Hipótesis

1.5. Hipótesis de investigación (H1)

Al menos un modelo de aprendizaje automático reducirá en 20 % o más el RMSE de la predicción del importe diario de compras frente a la línea base empírica, y mostrará un desempeño no inferior al de los modelos estadísticos de referencia. La evaluación se complementará con MAE; MAPE se interpretará de manera cautelosa por la presencia de valores cero.

2 MARCO TEÓRICO

El presente marco teórico establece los fundamentos conceptuales y empíricos que sustentan la investigación. Se analiza la transición del paradigma intuitivo en la microempresa hacia la toma de decisiones basada en datos (Data-Driven Decision Making). Asimismo, se examina el estado de la analítica predictiva, contrastando enfoques estadísticos clásicos con modelos de aprendizaje automático (Machine Learning), para finalmente abordar las métricas de evaluación, el tratamiento de datos en escenarios limitados y las barreras de adopción de Inteligencia Artificial (IA) en economías emergentes.

2.1 Microempresa, intuición y el conocimiento tácito

2.1.1 Caracterización Estructural y Ontología de la Microempresa en Economías Emergentes

Para comprender la dinámica de la toma de decisiones dentro del objeto de estudio, es imperativo realizar una deconstrucción ontológica y estructural de lo que representa la microempresa, particularmente dentro del contexto socioeconómico de las economías emergentes como México. Las microempresas no constituyen simplemente versiones reducidas a escala de las grandes corporaciones; poseen una naturaleza orgánica, operativa y relacional cualitativamente diferenciada.

De acuerdo con el Instituto Nacional de Estadística y Geografía (**INEGI, 2023**), las microempresas representan más del 95% del tejido empresarial en México y son responsables de generar aproximadamente el 41.8% del empleo nacional. Esta relevancia macroeconómica contrasta severamente con sus niveles de productividad relativa y sus alarmantes índices de mortalidad prematura.

La literatura económica formal (**CEPAL, 2020; OCDE, 2021**) identifica que la microempresa se caracteriza por una severa restricción de recursos financieros, tecnológicos y logísticos, así como por una estructura organizacional plana donde la figura del propietario centraliza la totalidad de las funciones estratégicas, operativas y administrativas.

Esta centralización absoluta genera una vulnerabilidad intrínseca. Mientras que las grandes organizaciones operan bajo sistemas de gobernanza basados en la departamentalización, la estandarización de procesos y la planeación estratégica a largo plazo mediante comités de riesgos y herramientas analíticas avanzadas, la microempresa subsiste en un régimen de inmediatez operativa.

Kantis, Federico y García (2020) señalan que en las etapas tempranas y de consolidación orgánica de estos negocios, la gestión no responde a planes formales de contingencia o presupuestación matricial, sino a la resolución de problemas inmediatos del día a día. Esta inmediatez absorbe la capacidad cognitiva y el tiempo del administrador, postergando de manera indefinida la inversión en infraestructura del conocimiento y la digitalización de procesos.

En consecuencia, el crecimiento de unidades como Cup&Cake suele ser de carácter orgánico y reactivo: surge como respuesta a la aceptación empírica del producto en el mercado local, pero carece de un andamiaje analítico que permita absorber choques macroeconómicos o planificar expansiones de capital sin comprometer la liquidez inmediata del negocio. La ontología de la microempresa está, por tanto, ligada a la gestión de la escasez y a la adaptación en entornos de alta incertidumbre.

2.1.2 El Conocimiento Tácito y la Experiencia Empírica como Activos Operativos

En ausencia de sistemas formales de registro de información y manuales de procedimientos estandarizados, el activo estratégico más valioso de la microempresa reside en el capital intelectual de su fundador, quien se manifiesta predominantemente bajo la forma de conocimiento tácito. La conceptualización clásica del conocimiento tácito, acuñada originalmente por **Polanyi M. (1966)** y posteriormente integrada a la teoría de la firma y la gestión del conocimiento por **Nonaka y Takeuchi (1995)**, postula que "sabemos más de lo que podemos expresar". Es un conocimiento altamente personalizado, enraizado en la acción, los esquemas mentales, los valores, la experiencia acumulada y el involucramiento directo en un contexto específico.

García-Pérez, Ghio, Occhipinti y Verona (2020) explican que, en las organizaciones intensivas en conocimiento empírico, la transferencia de habilidades y la toma de decisiones

ocurren de manera informal a través de procesos de socialización y externalización imperfecta. En el caso de una microempresa del sector de la repostería creativa, este conocimiento tácito abarca desde el dominio técnico artesanal (el "saber hacer" culinario, la modulación manual de insumos perecederos y la estética del diseño) hasta la comprensión intuitiva de la dinámica comercial del entorno local.

El emprendedor acumula experiencia a través de un proceso dinámico de aprendizaje continuo derivado de la interacción directa con su mercado (**Minniti & Bygrave, 2018**). Con los años, este aprendizaje empírico permite al propietario identificar ciertos patrones regulares, tales como el incremento de la demanda en fechas conmemorativas de alta relevancia social (el Día de San Valentín, el Día de la Madre o el Día del Niño).

El conocimiento tácito del propietario es útil para interpretar el contexto del negocio, pero suele estar poco formalizado y es difícil de evaluar con métricas reproducibles. La investigación no asume que el empirismo sea inválido; lo convierte en una referencia contrastable frente a modelos predictivos para anticipar el presupuesto de abastecimiento.

2.1.3 El Paradigma de la Intuición y el "Pensamiento de Sistema 1" en la Toma de Decisiones

Cuando el conocimiento tácito se activa ante una contingencia operativa o una decisión financiera sin el respaldo de un análisis estadístico formal, la mente humana recurre de manera automática al paradigma de la intuición. Para desentrañar los mecanismos cognitivos que subyacen a este fenómeno, es indispensable recurrir a la Teoría de los Procesos Duales de la cognición humana, desarrollada con rigurosidad científica por el Premio Nobel **Kahneman D. (2011)**. Esta teoría postula la existencia de dos modos diferenciados de procesamiento del pensamiento: el Sistema 1 y el Sistema 2.

El Sistema 1 (Pensamiento Intuitivo) opera de manera automática, sumamente rápida, con poco o ningún esfuerzo cognitivo y sin una sensación de control voluntario. Se basa en el reconocimiento inmediato de patrones almacenados en la memoria asociativa a largo plazo, permitiendo al individuo reaccionar de forma ágil ante estímulos del entorno.

Por el contrario, el Sistema 2 (Pensamiento Analítico) se caracteriza por ser lento, deliberado, secuencial, computacionalmente costoso y requiere un esfuerzo consciente enfocado en el cálculo matemático, la inferencia lógica y la evaluación de evidencias empíricas contrastables.

En la gestión de la microempresa, la resolución de problemas financieros y de abastecimiento se ejecuta predominantemente bajo el dominio del Sistema 1. El microempresario, absorbido por las demandas de la producción física y la atención al cliente, no dispone del tiempo ni de las capacidades analíticas internas para activar el Sistema 2 en cada transacción operativa (**Simon, 1997**). Herbert Simon, en su teoría de la racionalidad limitada (*bounded rationality*), demostró de manera concluyente que los agentes económicos no toman decisiones de optimización global, sino de satisfacción local, debido a las limitaciones intrínsecas en la capacidad de procesamiento de información del cerebro humano y a la restricción del tiempo disponible.

La intuición experta, por lo tanto, es el resultado del Sistema 1 ejecutando heurísticas basadas en la experiencia. Si bien este enfoque es adaptativo y permite la supervivencia en condiciones donde los datos son inexistentes o inaccesibles, su debilidad estructural radica en que carece de mecanismos de verificación interna. El Sistema 1 es propenso a generar conclusiones categóricas con base en información fragmentada o anecdótica, lo que introduce un conjunto de distorsiones sistemáticas conocidas como sesgos cognitivos, los cuales pueden comprometer severamente la viabilidad económica de la firma.

2.1.4 Sesgos Cognitivos y Heurísticas en la Gestión del Abastecimiento y la Planeación Financiera

La dependencia del Sistema 1 expone la planeación financiera y operativa de la microempresa a fallas estructurales derivadas de la aplicación de atajos mentales o heurísticas. **Amos Tversky y Daniel Kahneman (1974, 1979)** catalogaron y demostraron matemáticamente estas anomalías en el juicio bajo incertidumbre. En el contexto específico de una microempresa repostera con alta variabilidad de demanda como Cup&Cake, los sesgos cognitivos más dañinos y recurrentes se articulan en cuatro dimensiones analíticas:

1. Sesgo de Sobreconfianza (Overconfidence Bias): El propietario tiende a sobreestimar de manera sistemática la precisión de sus propias predicciones intuitivas respecto al

mercado. Al haber logrado la subsistencia del negocio durante una década mediante estimaciones empíricas, se genera la falsa ilusión de que el control sobre el entorno es mayor del que realmente se posee. En la planeación financiera, este sesgo se traduce en proyecciones excesivamente optimistas de ingresos orgánicos y flujos de caja, lo que induce a tomar decisiones de inversión en activos fijos (como la apertura de nuevos puntos de venta) sin contar con el colchón de liquidez necesario para mitigar periodos de contracción de la demanda.

2. **Heurística de Disponibilidad (*Availability Heuristic*):** Consiste en evaluar la probabilidad o frecuencia de un evento futuro con base en la facilidad con la que ejemplos o experiencias recientes acuden a la mente. Si la microempresa experimentó un pico de ventas extraordinario en el Día de la Madre del año inmediato anterior debido a un evento fortuito no registrado (como una festividad comunitaria local), el administrador asumirá intuitivamente que dicha anomalía representa la norma para el ciclo actual. Esto provoca un sobreabastecimiento severo de materias primas perecederas, derivando en altos niveles de merma, desperdicio y la consecuente inmovilización destructiva de capital de trabajo.
3. **Anclaje y Ajuste (*Anchoring and Adjustment*):** Ocurre cuando los individuos formulan proyecciones a partir de un valor inicial arbitrario (el "ancla") y realizan ajustes numéricos insuficientes para llegar a la estimación final. Por ejemplo, si el presupuesto histórico asignado a la compra de harina y lácteos para el mes de febrero ha sido tradicionalmente de una cantidad fija, el emprendedor ajustará intuitivamente ese valor con base en la inflación percibida del entorno inmediato, omitiendo por completo variables predictivas de carácter no lineal como cambios estacionales sutiles, el comportamiento de competidores emergentes o patrones calendáricos móviles (como la cercanía de fines de semana al Día de San Valentín).
4. **Teoría de los Prospectos (*Prospect Theory*) y Aversión a la Pérdida:** **Kahneman y Tversky (1979)** demostraron que los agentes económicos experimentan el dolor de una pérdida financiera con una intensidad matemática que duplica el placer obtenido por una ganancia equivalente. En la cadena de suministro de productos perecederos, la aversión al desabasto (perder una venta y la fidelidad del cliente debido a la falta de inventario) empuja al microempresario a sobreproducir de manera sistemática. El costo

psicológico de decir "no tengo el producto disponible" supera al costo financiero real, pero oculto en la contabilidad empírica, de la merma diaria por productos caducados.

2.1.5 Limitaciones Epistemológicas de la Intuición frente a la Variabilidad Compleja del Mercado

La persistencia del enfoque intuitivo encuentra un límite epistemológico absoluto cuando la organización transiciona de una etapa de autoempleo hacia un escenario de crecimiento y expansión comercial. **Eric Ries (2017)**, en sus aportaciones sobre el desarrollo de modelos de negocio bajo metodologías lean, sostiene que la gestión empírica pura opera bajo supuestos no validados que funcionan exclusivamente dentro de un nicho de mercado hiperlocal y de baja complejidad. Cuando el volumen de ventas orgánicas se incrementa de manera sostenida, la cantidad de variables interrelacionadas que determinan la salud del negocio supera la capacidad de procesamiento del cerebro humano.

La demanda en el sector económico de la repostería creativa contemporánea no responde a comportamientos lineales simples que puedan promediarse de forma mental (**Borsato, 2023**). Está sujeta a una compleja interacción de dinámicas estacionales cruzadas (estacionalidad anual macro, variaciones mensuales ligadas a los ciclos de pago quincenales de los consumidores, y micro-estacionalidades semanales asociadas a eventos sociales de fin de semana). A esto se suman variables exógenas altamente dinámicas como las condiciones climáticas del día (las cuales alteran la vida útil del producto perecedero expuesto y la afluencia de clientes), las tendencias estéticas en redes sociales que disparan la demanda de diseños específicos (**Ab Karim et al., 2020**), y las fluctuaciones imprevistas en los precios de los insumos clave por parte de proveedores locales.

Intentar predecir el comportamiento financiero y de abastecimiento en este ecosistema de alta variabilidad mediante la intuición genera un desfase crítico. El administrador se ve atrapado en una gestión puramente reactiva: compra insumos basándose en lo que vendió la semana anterior y proyecta inversiones basándose en la liquidez visible en la caja registradora en el momento presente.

Como señalan **Hyndman y Athanasopoulos (2021)**, los errores sistemáticos derivados de la falta de modelos predictivos formales producen oscilaciones severas en los inventarios (el

efecto látigo o *bullwhip effect* a microescala), mermas financieras recurrentes y una crónica escasez de capital de trabajo que frena cualquier intento de escalabilidad.

La intuición, por tanto, satura su utilidad operativa cuando el negocio requiere precisión matemática para subsistir en un entorno competitivo maduro. Nace de ahí la necesidad de transicionar hacia esquemas analíticos estructurados que sustituyan el instinto por la toma de decisiones basada en datos (DDDM).

El análisis detallado del binomio microempresa-intuición demuestra que, si bien el conocimiento tácito y el pensamiento intuitivo de Sistema 1 constituyen el motor inicial que permite la génesis y la flexibilidad adaptativa de emprendimientos como Cup&Cake, su mantenimiento exclusivo como eje de la gobernanza corporativa actúa como un techo de cristal que limita la supervivencia a largo plazo y la expansión financiera.

Las limitaciones cognitivas intrínsecas de la mente humana, manifestadas a través de sesgos como la sobreconfianza, el anclaje y la heurística de disponibilidad, distorsionan sistemáticamente las proyecciones de inventarios y flujo de efectivo. Ante la creciente complejidad y variabilidad de un mercado que comercializa bienes altamente perecederos, la intuición empírica colapsa, abriendo la puerta a ineficiencias contables y mermas operativas severas.

Por consiguiente, la transformación predictiva propuesta en esta investigación no pretende anular el valioso conocimiento heurístico del microempresario, sino complementarlo mediante la introducción de un andamiaje tecnológico formal. Este andamiaje, basado en la Inteligencia de Negocios y el Aprendizaje Automático, está diseñado para absorber el ruido estadístico, mitigar los sesgos cognitivos y dotar a la administración de una capacidad de previsión proactiva sustentada en la evidencia empírica de los datos.

2.2 Inteligencia de Negocios y Analítica Predictiva en la Planeación Financiera

Frente a las limitaciones cognitivas del razonamiento empírico, emerge el paradigma de la toma de decisiones basada en datos (DDDM, por sus siglas en inglés). **Provost y Fawcett (2013)** sostienen que los datos constituyen un activo estratégico que reduce la incertidumbre.

En este contexto, la Inteligencia de Negocios (BI) actúa como el marco tecnológico que transforma datos brutos en conocimiento procesable.

Dentro del espectro de BI, la analítica predictiva trasciende el análisis descriptivo al utilizar algoritmos para estimar comportamientos futuros (**Shmueli & Koppius, 2011**). Aplicada a la planeación financiera, permite a la organización proyectar ingresos, anticipar flujos de efectivo y alinear las decisiones de abastecimiento con las fluctuaciones previstas de la demanda, mitigando simultáneamente los costos por desabasto y por mantenimiento excesivo de inventario.

2.2.1 Evolución Epistemológica de la Inteligencia de Negocios y los Sistemas de Soporte a la Decisión (DSS)

La evolución del pensamiento administrativo y tecnológico ha consolidado a la Inteligencia de Negocios (*Business Intelligence*, BI) no como una mera herramienta de visualización de datos, sino como un marco arquitectónico, metodológico y conceptual de transformación corporativa. Para rastrear los fundamentos de BI, es indispensable acudir a la evolución de los Sistemas de Soporte a la Decisión (DSS, por sus siglas en inglés), cuya conceptualización formal fue estructurada por **Daniel Power (2002)**. Históricamente, las organizaciones dependían de informes estáticos, retrospectivos e inconexos que describían de forma rudimentaria eventos contables pasados. Estos reportes impresos o tabulaciones manuales limitaban la capacidad de los administradores a una gestión puramente retrospectiva, donde el análisis de los desvíos financieros se realizaba semanas o meses después de haber ocurrido el impacto operativo.

Power (2002) describe la transición evolutiva de estos sistemas desde los primeros sistemas de procesamiento de datos transaccionales en la década de 1970 hacia los sistemas interactivos basados en datos, modelos y conocimientos. La Inteligencia de Negocios contemporánea surge de la convergencia de estas tecnologías, configurándose como el conjunto de arquitecturas, aplicaciones, bases de datos y metodologías que permiten a una organización recopilar, integrar, purificar, almacenar y analizar flujos de datos operativos para convertirlos en conocimiento estratégico e histórico útil para la toma de decisiones.

En la microempresa tradicional, el acceso a este ecosistema tecnológico estuvo vedado durante décadas debido a la complejidad de las arquitecturas de almacenamiento de datos

(*Data Warehouses*) y los altos costos asociados al licenciamiento de plataformas analíticas de grado empresarial. No obstante, el advenimiento de soluciones modulares, accesibles y de código abierto ha democratizado el acceso a BI.

En el caso específico de unidades económicas en etapas de expansión como *Cup&Cake*, la Inteligencia de Negocios provee el andamiaje técnico inicial para consolidar una única fuente de verdad. Ello implica transicionar desde la fragmentación informática (donde los registros de ventas orgánicas, las compras de insumos locales y las mermas se gestionan en cuadernos o archivos aislados) hacia una infraestructura integrada de soporte a la decisión. Esta infraestructura permite limpiar el ruido transaccional y estructurar las series temporales de ingresos de la firma, sentando las bases analíticas obligatorias para la posterior inyección de modelos matemáticos avanzados.

2.2.2 El Paradigma del Data-Driven Decision Making (DDDM) como Activo Estratégico

La adopción de la Inteligencia de Negocios es el vehículo técnico que viabiliza el paradigma de la Toma de Decisiones Basada en Datos (*Data-Driven Decision Making*, DDDM). **Provost F. y Fawcett T. (2013)**, en sus aportaciones fundamentales a la ciencia de datos aplicada a los negocios, definen el DDDM como la práctica de basar las decisiones organizacionales en el análisis sistemático de evidencias empíricas derivadas de los datos, en lugar de fundamentarlas de forma exclusiva en el instinto, la intuición pura o la experiencia anecdótica del tomador de decisiones. Bajo este paradigma, los datos no se conciben como un subproducto pasivo de la operación contable, sino como un activo estratégico de alto rendimiento, un recurso intangible capaz de generar ventajas competitivas sostenibles mediante la reducción drástica de la incertidumbre.

La validez empírica del DDDM y su correlación directa con el desempeño financiero de las firmas ha sido ampliamente documentada por la literatura econométrica. **Brynjolfsson E., Hitt L. y Kim H. (2011)**, mediante el análisis de grandes paneles de empresas, demostraron cuantitativamente que las organizaciones que adoptan formalmente una cultura analítica y estructuran sus procesos estratégicos bajo los principios del DDDM logran incrementos significativos en su productividad, así como una mayor rentabilidad financiera y valor de mercado en comparación con sus competidores rezagados digitalmente.

Posteriormente, **Brynjolfsson y McElheran (2016)** identificaron que la difusión y velocidad de adopción de la toma de decisiones basada en datos no se limita a grandes corporaciones tecnológicas, sino que está reconfigurando la frontera operativa de los sectores tradicionales, incluyendo la industria manufacturera y el comercio minorista a pequeña escala.

Para una microempresa como *Cup&Cake*, el DDDM representa una ruptura epistemológica con la gestión empírica que la caracterizó durante sus primeros diez años de operación. Pasar de la intuición a la evidencia analítica transforma la cultura organizacional del negocio. El microempresario deja de preguntarse de manera ambigua "cuánto se espera vender en el siguiente periodo" con base en su estado de ánimo o en la memoria de eventos recientes (heurística de disponibilidad), y comienza a formular preguntas gobernadas por el pensamiento analítico: **cuáles son las variables exógenas con mayor peso estadístico sobre la varianza de los ingresos quincenales, o cuál es el nivel mínimo óptimo de inventario de materias primas que maximiza la tasa de servicio sin comprometer la liquidez**. Los datos, al actuar como un activo estratégico purificado de sesgos cognitivos individuales, blindan la planeación de la firma frente a choques operativos del entorno local.

2.2.3 Taxonomía Analítica: Del Análisis Descriptivo a la Frontera de la Analítica Predictiva

Para comprender el alcance de la Inteligencia de Negocios en la planeación financiera, es fundamental estructurar la taxonomía de las capacidades analíticas organizacionales. **Davenport T. y Harris J. (2007)**, en su obra de referencia sobre la competencia analítica en las organizaciones, clasifican el análisis de datos en niveles progresivos de madurez analítica, divididos esencialmente entre la analítica retrospectiva (descriptiva y diagnóstica) y la analítica prospectiva (predictiva y prescriptiva).

La **analítica descriptiva** responde de manera estricta a la interrogante: *¿Qué pasó en el negocio?* Se enfoca en la agregación, tabulación y visualización de datos históricos acumulados para generar métricas agregadas como ventas totales mensuales, márgenes de ganancia brutos o costos acumulados de insumos. Aunque valiosa para fines de cumplimiento fiscal y control contable elemental, la analítica descriptiva posee un valor predictivo nulo.

Muestra los síntomas de la salud financiera de la empresa cuando los eventos ya son inmodificables.

Por su parte, la **analítica diagnóstica** aborda la pregunta: *¿Por qué pasó?* Utiliza técnicas estadísticas correlacionales y de perforación de datos (*drill-down*) para identificar las causas subyacentes de un resultado contable, vinculando, por ejemplo, una caída en la utilidad neta con el incremento súbito en el precio de la mantequilla o la harina durante un trimestre específico.

La frontera de la ventaja competitiva se cruza con la transición hacia la **analítica predictiva**. **Shmueli G. y Koppius O. (2011)**, en su célebre tratado sobre la distinción epistemológica entre modelado explicativo y predictivo, establecen que la analítica predictiva se orienta de forma exclusiva hacia el futuro, respondiendo a la pregunta medular: *¿Qué es probable que suceda bajo determinadas condiciones temporales y de mercado?* Mientras que el modelado explicativo tradicional (descriptivo/diagnóstico) busca probar teorías causales e interpretar la significancia estadística interna de los coeficientes de un modelo, el modelado predictivo evalúa su éxito a partir de una métrica estrictamente empírica: su capacidad para generar pronósticos precisos sobre nuevos datos del futuro no observados por el algoritmo durante su fase de diseño (**Shmueli, 2010**).

En la planeación financiera de la repostería creativa, esta diferenciación es de carácter crítico. Para la supervivencia operativa de Cup&Cake, no basta con poseer un reporte estático en un tablero web de inteligencia de negocios que indique de manera visual que los ingresos por ventas se duplicaron durante el 14 de febrero pasado (analítica descriptiva), ni un modelo explicativo que confirme que el incremento se debió a la festividad de San Valentín (analítica diagnóstica).

2.2.4 La Intersección Estratégica entre Analítica Predictiva, Planeación Financiera y Gestión del Flujo de Efectivo

La intersección donde la analítica predictiva genera el mayor impacto económico dentro de la microempresa se localiza en la planeación financiera y, específicamente, en la gobernanza y optimización del flujo de efectivo. **Bertsimas D. y Kallus N. (2020)**, al analizar la transición desde la analítica predictiva hacia la prescriptiva aplicada al *management*, postulan que el

valor de un pronóstico no reside en su belleza matemática interna, sino en cómo se vincula formalmente con los Sistemas de Soporte a la Decisión Financiera (DSS). En las microempresas, la liquidez es el indicador vital de supervivencia más crítico. A diferencia de las corporaciones maduras que cuentan con líneas de crédito revolventes, fondos de contingencia o acceso a mercados de capital para financiar déficits temporales de capital de trabajo, la microempresa opera al límite de su capacidad de flujo de efectivo diario.

Góngora Chonillo (2023) expone que la evaluación del riesgo financiero en el estrato microempresarial está intrínsecamente ligada a la precisión de los pronósticos de ventas a corto plazo. Cuando una microempresa carece de modelos predictivos formales, la estimación del flujo de caja se realiza mediante extrapolaciones lineales simples o promedios móviles intuitivos que omiten patrones complejos de estacionalidad no lineal y el comportamiento errático de variables exógenas.

Esta deficiencia metodológica induce a dos fallos financieros críticos: la crisis de liquidez por subestimación de egresos y el costo de oportunidad por inmovilización destructiva de capital de trabajo.

La implementación de modelos avanzados de Machine Learning e Inteligencia de Negocios rompe este círculo vicioso. Al proyectar con un alto grado de precisión matemática y estabilidad predictiva los ingresos por ventas orgánicas y de fechas conmemorativas clave, la analítica predictiva permite al administrador realizar simulaciones dinámicas de su flujo de efectivo futuro. Ello se traduce en la capacidad estratégica de:

- Optimizar los ciclos de caja.
- Sincronizar las cuentas por pagar a proveedores locales con los picos reales de monetización del negocio.
- Prever con antelación matemática los periodos de contracción de la demanda estacional (los "valles" de venta), permitiendo construir reservas de liquidez precautorias.

En esta investigación, los pronósticos se emplean para anticipar el presupuesto de abastecimiento de corto plazo. La evaluación de inversiones, expansión comercial o flujos de

efectivo requiere datos y modelos adicionales, por lo que se reconoce como una línea de trabajo futura.

2.2.5 Sincronización Operativa: S&OP, Gestión de Inventarios y Mitigación de Costos en Productos Perecederos

El puente analítico que conecta las proyecciones financieras derivadas de la analítica predictiva con la ejecución diaria de la microempresa es el proceso de **Planeación de Ventas y Operaciones (S&OP, por sus siglas en inglés, *Sales and Operations Planning*)**. En organizaciones de pequeña escala, este proceso suele estar desarticulado. La gestión financiera opera por un carril contable abstracto, mientras que la gestión operativa de compras y producción se ejecuta de forma aislada en el piso del negocio, guiada por el empirismo diario.

Como explican **Hübner A., Kuhn H. y Sternbeck M. (2024)**, en sectores que comercializan bienes con alta obsolescencia o ciclos de vida extremadamente cortos —como la industria alimentaria y de panificación especializada—, la desarticulación entre finanzas y operaciones penaliza severamente el estado de resultados de la firma.

Hübner N. et al. (2024), a través de un riguroso estudio de caso enfocado en la implementación de modelos de Machine Learning en la nube para el pronóstico de demanda diaria en panaderías, demostraron de manera concluyente que la precisión analítica del pronóstico tiene un impacto tridimensional inmediato: financiero, operativo y ambiental. En este sector, los errores sistemáticos de planificación de la demanda generan ineficiencias críticas en la cadena de suministro. Una subestimación de la demanda provoca desabasto (*stockouts*), lo que no solo implica una pérdida económica directa de ingresos marginales, sino la erosión de la fidelidad del cliente y la degradación del valor de marca, factores sumamente sensibles en mercados locales competitivos.

Por otro lado, la sobreestimación de la demanda es aún más lesiva para el flujo de caja de la microempresa repostería. Debido a la naturaleza altamente perecedera de los insumos lácteos, frutas frescas, harinas estabilizadas y decoraciones artísticas especializadas utilizadas en la repostería creativa, el inventario sobreestimado que no se transforma y vende en ciclos cortos se convierte de forma automática en merma destructiva y desperdicio alimentario. Esto representa costos hundidos directos absorbidos por el estado de pérdidas y ganancias de la

firma. Los hallazgos empíricos de **Hübner et al. (2024)** evidenciaron que la introducción de pronósticos basados en aprendizaje automático es capaz de reducir el desperdicio de alimentos y las tasas de merma en porcentajes de doble dígito, optimizando la eficiencia de la cadena de suministro y liberando capital de trabajo atrapado en inventario obsoleto.

La transformación predictiva de la planeación financiera en *Cup&Cake* instrumentaliza este principio de sincronización operativa. El pronóstico de la demanda no se limita a estimar una cifra macroeconómica de ventas, sino que se traduce, mediante ingeniería de características e Inteligencia de Negocios, en desgloses operativos de requerimientos de abastecimiento. El sistema predictivo actúa como un optimizador analítico de recursos: al alinear con precisión el volumen de insumos adquiridos con las fluctuaciones probabilísticas reales del mercado minorista local en Tizayuca, Hidalgo, se minimizan los tiempos muertos de la capacidad instalada, se reduce la tasa de desperdicio de materias primas perecederas y se maximiza el rendimiento marginal de los factores de producción. La microempresa transiciona así de una gestión puramente reactiva a un modelo de gobernanza proactivo sustentado en el rigor científico de los datos.

La revisión exhaustiva de la literatura especializada demuestra que la Inteligencia de Negocios y la Analítica Predictiva constituyen un binomio transformacional indiscutible para la planeación financiera de la microempresa contemporánea. Al romper con el paradigma de los reportes retrospectivos estáticos y sustituirlos por sistemas dinámicos de soporte a la decisión fundamentados en el *Data-Driven Decision Making* (DDDM), la firma adquiere la capacidad analítica de anticipar escenarios futuros con un alto grado de certidumbre científica.

En entornos altamente vulnerables y con restricciones severas de capital de trabajo, la intersección estratégica entre los pronósticos algorítmicos y la gestión del flujo de efectivo actúa como un escudo financiero que preserva la liquidez, mitiga los riesgos asociados a la expansión de capital y optimiza de forma transversal la cadena de suministro de bienes perecederos.

La analítica predictiva, por tanto, unifica los objetivos contables con la ejecución operativa diaria, permitiendo a organizaciones como *Cup&Cake* blindar su rentabilidad frente a las

oscilaciones de la demanda y cimentar sus estrategias de crecimiento sobre la base empírica y contrastable de la ciencia de datos.

2.3 Modelos de pronóstico: Enfoques estadísticos y Aprendizaje Automático

El modelado de series temporales ha estado dominado por métodos estadísticos clásicos, como ARIMA y el suavizamiento exponencial, los cuales asumen relaciones lineales y requieren supuestos estadísticos estrictos (**Box et al., 2015**). Sin embargo, en entornos volátiles y con alta dimensionalidad, el Aprendizaje Automático (*Machine Learning*) ha demostrado superioridad al capturar patrones no lineales complejos sin depender de distribuciones predefinidas (**Hastie, Tibshirani, & Friedman, 2009**).

Investigaciones derivadas de las competencias de pronóstico M4 y M5 han evidenciado que algoritmos como *Random Forest*, *Gradient Boosting* y Redes Neuronales Recurrentes (*RNN/LSTM*) mejoran sustancialmente la precisión predictiva cuando se integran variables exógenas o estacionales (**Makridakis, Spiliotis, & Assimakopoulos, 2020**).

2.3.1 Fundamentos Epistemológicos y Matemáticos de los Enfoques Estadísticos Clásicos

El modelado predictivo de series temporales ha constituido históricamente el pilar fundamental de la econometría corporativa y la planificación operativa. Desde una perspectiva epistemológica, los enfoques estadísticos clásicos operan bajo el supuesto de que el comportamiento futuro de una variable económica es una función lineal de sus observaciones pasadas y de los errores aleatorios acumulados. La representación teórica más rigurosa de este paradigma se consolidó a través de la metodología estructurada por **Box G., Jenkins G., Reinsel G. y Ljung G. (2015)**, conocida formalmente como el marco de modelos Autorregresivos Integrados de Medias Móviles (*ARIMA*).

Un modelo $ARIMA(p, d, q)$ descompone la dinámica de una serie temporal en tres componentes matemáticos esenciales:

1. **El componente Autorregresivo (AR, parametrizado por p):** Establece una relación de regresión lineal donde la variable en el momento actual (Y_t) se explica a partir de sus propios valores rezagados en periodos anteriores ($Y_{t-1}, Y_{t-2}, \dots, Y_{t-p}$). Representa la memoria o persistencia interna del fenómeno económico.
2. **El componente Integrado (I, parametrizado por d):** Define el orden de diferenciación matemática necesario para transformar una serie temporal no estacionaria (aquella cuya media, varianza o estructura de autocorrelación cambian a lo largo del tiempo) en una serie estacionaria. Esto es indispensable para estabilizar la varianza global antes del ajuste algorítmico.
3. **El componente de Medias Móviles (MA, parametrizado por q):** Modela el impacto residual de los choques aleatorios o perturbaciones del entorno mediante una combinación lineal de los errores de pronóstico pasados ($\varepsilon_{t-1}, \varepsilon_{t-2}, \dots, \varepsilon_{t-q}$).

Cuando las organizaciones enfrentan patrones de demanda condicionados por ciclos estacionales rígidos, el modelo se expande hacia su arquitectura estacional, denominada **SARIMA** (p, d, q)(P, D, Q) $_s$. En esta formulación, los operadores estacionales de orden superior (P, D, Q) capturan las autocorrelaciones repetitivas asociadas a un periodo regular (s), como los ciclos anuales o mensuales. De forma paralela, la escuela estadística clásica fundamenta sus proyecciones en los modelos de Suavizamiento Exponencial (**ETS: Error, Trend, Seasonal**), entre los que destaca el algoritmo de **Holt-Winters (Hyndman & Athanasopoulos, 2021)**. El suavizamiento exponencial calcula medias ponderadas de observaciones pasadas donde los pesos asignados a los datos decrecen de manera geométrica o exponencial a medida que los registros son más antiguos.

A pesar de su robustez teórica y de haber gobernado la práctica del *forecasting* comercial durante más de medio siglo, los enfoques estadísticos clásicos presentan severas limitaciones epistemológicas cuando se confrontan con la realidad de los mercados contemporáneos. Estos modelos exigen el cumplimiento estricto de supuestos matemáticos de caja blanca, tales como la linealidad de las relaciones entre variables, la homocedasticidad de la varianza residual y la ausencia de autocorrelación en los errores (independencia estocástica de los residuos).

En el ecosistema operativo de una microempresa como Cup&Cake, dichos supuestos suelen violarse de manera sistemática. La volatilidad implícita en la venta minorista local, la presencia de rupturas estructurales en las series históricas debido a factores competitivos o macroeconómicos y, fundamentalmente, la naturaleza marcadamente no lineal de la demanda estacional cruzada, invalidan la rigidez de los modelos lineales de *Box-Jenkins*. Los modelos tradicionales tienden a suavizar los picos y valles extremos, lo que reduce su utilidad práctica para anticipar fluctuaciones complejas en el abastecimiento operativo.

2.3.2 El Paradigma del Aprendizaje Automático (Machine Learning) en el Pronóstico de Demanda

Frente a las restricciones paramétricas de la estadística clásica, el surgimiento del Aprendizaje Automático (*Machine Learning*, ML) ha reconfigurado los fundamentos de la analítica predictiva. Trevor Hastie, Robert Tibshirani y Jerome Friedman (2009) postulan que el ML se basa en un enfoque no paramétrico y guiado por datos (*data-driven*). A diferencia de los modelos econométricos tradicionales que imponen una estructura matemática a priori al fenómeno estudiado, los algoritmos de aprendizaje automático poseen la capacidad intrínseca de descubrir de forma autónoma las interacciones complejas, las dependencias temporales y las relaciones no lineales ocultas directamente a partir de los datos estructurados de entrenamiento.

Dentro de la taxonomía del aprendizaje supervisado aplicado a la regresión de series temporales, los métodos de ensamble basados en árboles de decisión han adquirido una relevancia crítica debido a su alto rendimiento computacional y estabilidad analítica (James et al., 2021). Dos son las arquitecturas dominantes validadas por la práctica científica:

- **Random Forest (Bosques Aleatorios):** Basado en el principio de agregación por arranque (*bagging*), este algoritmo construye de forma paralela una multiplicidad de árboles de decisión independientes, introduciendo aleatoriedad tanto en la selección de las muestras de entrenamiento como en el subconjunto de características analizadas en cada división nodal. El pronóstico final se obtiene mediante el promedio matemático de las predicciones individuales de toda la floresta. Esta estructura reduce de forma drástica la varianza global del modelo y mitiga el riesgo de sobreajuste.

- **Gradient Boosting Machines (GBM, XGBoost, LightGBM):** Operan bajo el paradigma del aprendizaje secuencial e incremental (*boosting*). A diferencia de *Random Forest*, los árboles de decisión en un modelo de *Gradient Boosting* se construyen uno tras otro de forma encadenada. Cada árbol emergente se diseña específicamente para predecir y corregir los errores residuales (la pérdida de gradiente) cometidos por los árboles que le antecedieron en la secuencia algorítmica.

Max Kuhn y Kjell Johnson (2013) destacan que los métodos basados en árboles presentan ventajas metodológicas insustituibles en problemas de pronóstico comercial minorista. En primer lugar, poseen una inmunidad casi total ante la presencia de valores atípicos (*outliers*) y datos faltantes aislados, anomalías recurrentes en los registros operativos de las microempresas. En segundo lugar, y de manera medular para la planeación financiera de *Cup&Cake*, los algoritmos de ensamble permiten incorporar de forma directa variables categóricas complejas e indicadores exógenos de carácter multidimensional (como banderas de días festivos móviles, variables climáticas continuas, periodos de pago quincenal o estrategias de promoción de competidores) sin requerir transformaciones estadísticas restrictivas.

Al mapear estas características en un espacio multidimensional no lineal, el Machine Learning supera la frontera del análisis univariado clásico, capturando cómo la interacción simultánea de variables temporales y comerciales determina la fluctuación real de los ingresos y los requerimientos físicos de abastecimiento.

2.3.3 Arquitecturas de Aprendizaje Profundo (Deep Learning) y Redes Neuronales Recurrentes

La evolución de la Inteligencia Artificial ha llevado la frontera predictiva hacia el dominio del Aprendizaje Profundo (*Deep Learning*). En el modelado de secuencias temporales complejas donde la memoria de largo plazo y el orden cronológico de los eventos son determinantes, las redes neuronales densas tradicionales colapsan debido a su incapacidad para retener información secuencial. Para resolver esta limitación estructural, se desarrollaron las Redes Neuronales Recurrentes (RNN, por sus siglas en inglés), las cuales introducen bucles de

retroalimentación en su arquitectura arquitectónica, permitiendo que la información persista a través de los diferentes pasos temporales del procesamiento.

No obstante, las RNN clásicas se enfrentan a un obstáculo matemático severo durante su fase de entrenamiento mediante el algoritmo de retropropagación a través del tiempo (*Backpropagation Through Time*, BPTT): el fenómeno del desvanecimiento o explosión del gradiente (*vanishing and exploding gradient problem*). Cuando una secuencia temporal se extiende a lo largo de múltiples pasos (como meses o semanas acumuladas), la multiplicación sucesiva de derivadas parciales provoca que el gradiente de error disminuya exponencialmente hacia cero, inhabilitando a la red neuronal para aprender dependencias de largo plazo y dejándola condicionada exclusivamente por los eventos más inmediatos.

Para erradicar esta patología matemática, Sepp Hochreiter y Jürgen Schmidhuber diseñaron la arquitectura de Redes de Memoria a Largo Corto Plazo (LSTM, *Long Short-Term Memory*), una variante sofisticada de RNN que sustituye los nodos neuronales ordinarios por bloques de memoria complejos dotados de una estructura de compuertas reguladoras. La columna vertebral de una celda LSTM es el estado de la celda (c_t), una línea de transmisión horizontal que atraviesa toda la cadena secuencial con alteraciones lineales mínimas, actuando como una memoria de banda ancha. El flujo de información dentro del estado de la celda se gobierna mediante tres compuertas matemáticas basadas en funciones de activación sigmoideas y tangenciales:

1. **Compuerta de Olvido (f_t):** Evalúa la información entrante y decide cuantitativamente qué porcentaje de la memoria histórica almacenada en el estado de la celda debe ser descartado por haber perdido relevancia económica para el pronóstico actual.
2. **Compuerta de Entrada (i_t):** Determina qué nuevos flujos de información procedentes del vector de entrada del paso actual (x_t) y del estado oculto previo ($h_{(t-1)}$) son significativos para ser incorporados al estado de la celda.
3. **Compuerta de Salida (o_t):** Filtra y modula el estado de la celda consolidado para generar el nuevo estado oculto (h_t), que representa la predicción o salida de la red para ese paso temporal específico.

La literatura científica más reciente en la gestión de cadenas de suministro globales valida el uso de estos enfoques híbridos de alta densidad. Muhammad Abrar, Abu Shahriar y Al Amin (2024) propusieron el modelo de Red de Fusión de Datos Multicanal (MCDFN, *Multi-Channel Data Fusion Network*), una arquitectura de frontera que integra de forma simultánea Redes Neuronales Convolucionales (CNN) para la extracción automatizada de patrones espaciales y características locales en los datos, acopladas con capas densas de redes LSTM para capturar las dinámicas de dependencia temporal a largo plazo.

Asimismo, el modelo incorpora mecanismos avanzados de Inteligencia Artificial Explicable (XAI), lo que permite abrir la "caja negra" del Deep Learning e interpretar matemáticamente el peso específico y la contribución real de cada canal de datos en el pronóstico final de la demanda. Estas arquitecturas avanzadas demuestran que la IA contemporánea posee la capacidad técnica de asimilar flujos heterogéneos de información para estabilizar las proyecciones financieras en entornos organizacionales dinámicos.

2.3.4 Confrontación Empírica: Métodos Estadísticos Avanzados vs. Algoritmos de Machine Learning

La coexistencia de los enfoques estadísticos clásicos y los algoritmos de Machine Learning ha desatado uno de los debates metodológicos más profundos e intensos dentro de la ciencia de datos aplicada a la administración de empresas. Durante años, la comunidad científica asumió de forma acrítica que la mayor complejidad computacional y flexibilidad matemática de los modelos de Machine Learning se traducían automáticamente en una superioridad predictiva en el ámbito corporativo. Sin embargo, los hallazgos empíricos derivados de las famosas Competencias M (organizadas por Spyros Makridakis) obligaron a una revisión epistemológica de estos supuestos.

Spyros Makridakis, Evangelos Spiliotis y Vassilios Assimakopoulos (2018), al publicar los resultados consolidados de la Competencia M4 —la cual evaluó el desempeño de más de 100,000 series de tiempo procedentes de diversas industrias y horizontes de planeación—, arrojaron conclusiones determinantes que impactaron a la comunidad analítica. Los datos empíricos demostraron de manera concluyente que los métodos estadísticos tradicionales basados en el principio de parsimonia e igualaron o incluso superaron consistentemente en

precisión predictiva a los modelos puros e independientes de Machine Learning. Los autores identificaron que la flexibilidad extrema de los algoritmos avanzados de ML se convierte en una debilidad crítica cuando se enfrentan a series temporales caracterizadas por un alto nivel de ruido inherente, muestras de entrenamiento de tamaño muestral limitado y horizontes de corto plazo. En estas condiciones, los modelos complejos tienden a incurrir en sobreajuste (*overfitting*), memorizando las anomalías del pasado en lugar de aprender la señal estructural del mercado.

No obstante, la frontera de este debate experimentó un cambio de paradigma con la ejecución de la Competencia de Precisión M5 (Makridakis, Spiliotis, & Assimakopoulos, 2021, 2022). A diferencia de sus predecesoras, la M5 se estructuró a partir de datos transaccionales desagregados a nivel de unidad de mantenimiento de existencias (SKU) de la corporación minorista Walmart, incorporando un volumen masivo de información cruzada, jerarquías de productos y variables calendáricas exógenas detalladas. En este escenario de alta dimensionalidad y complejidad transversal, los algoritmos de Machine Learning —y de manera unánime los métodos basados en potenciación de gradiente como LightGBM— dominaron de forma absoluta las primeras posiciones de rendimiento predictivo.

La evidencia comparativa disponible en la literatura sugiere que los modelos de aprendizaje automático pueden aportar valor cuando existen relaciones no lineales y variables exógenas relevantes. Sin embargo, su superioridad no debe asumirse: depende de la calidad de los datos, del objetivo y de una validación temporal rigurosa.

Evangelos Spiliotis, Spyros Makridakis y Vassilios Assimakopoulos (2025) sostienen que las organizaciones contemporáneas deben transicionar hacia sistemas de pronóstico continuo (*Continuous Business Forecasting*). Bajo este enfoque, las empresas ya no formulan planes predictivos estáticos aislados, sino que implementan arquitecturas adaptativas basadas en IA que recalculan probabilísticamente las proyecciones financieras y operativas a medida que se capturan nuevos flujos transaccionales en tiempo real.

Para una microempresa operando bajo un régimen de información limitada o *Small Data*, este debate define la estrategia metodológica a seguir. Como sugieren los hallazgos de las competencias M, la implementación de Machine Learning en entornos de recursos acotados

requiere un diseño experimental riguroso. No se trata de aplicar algoritmos complejos de manera indiscriminada, sino de robustecer el proceso analítico mediante:

1. Protocolos estrictos de validación temporal (como la metodología de ventanas deslizantes o *Rolling-Origin*).
2. Técnicas matemáticas de regularización para controlar la varianza del modelo.
3. Una meticulosa ingeniería de características que optimice la relación señal-ruido en los conjuntos de datos de entrenamiento.

2.3.5 Aplicación Crítica al Sector de Productos Perecederos y Repostería Creativa

La validación empírica y la selección entre enfoques estadísticos clásicos y algoritmos de Machine Learning adquieren una dimensión de criticidad absoluta cuando se transfieren al contexto operativo del sector económico de la repostería creativa y la panificación artesanal especializada. P. PraveenaSri, V. Padma, R. Muruguesan y S. Usha (2023) demuestran que la industria de la panificación minorista presenta desafíos analíticos singulares que la diferencian de otros sectores comerciales. A diferencia del comercio de bienes duraderos, la repostería creativa opera bajo un modelo de negocio híbrido que combina la manufactura artesanal bajo pedido con la venta orgánica directa de mostrador, gestionando insumos caracterizados por una vida útil extremadamente corta y una alta vulnerabilidad a la degradación física (Borsato, 2023).

En este escenario específico, los errores sistemáticos derivados de una planeación financiera y operativa defectuosa penalizan de forma inmediata el estado de resultados de la microempresa. Nils Hübner, Jan Caspers, Vlad Coroamă y Matthias Finkbeiner (2024), mediante la modelación de impactos ambientales y financieros a través de ciclos de vida en la industria panadera, evidenciaron que la subestimación de la demanda activa costos de oportunidad directos y erosiona el valor de marca local por desabasto.

Sin embargo, el escenario más perjudicial para el flujo de caja operativo es la sobreestimación de la demanda. Debido a que los productos reposteros artísticos incorporan materias primas premium perecederas (lácteos estabilizados, frutas frescas, agentes leudantes específicos), el

inventario excesivo que no se transforma y comercializa en ventanas temporales de pocas horas se convierte de forma irreversible en merma destructiva y pérdida neta de capital de trabajo hundiéndose en la contabilidad del negocio.

La transformación predictiva implementada en el caso de estudio de la empresa *Cup&Cake*, ubicada en Tizayuca, Hidalgo, instrumentaliza este marco teórico para resolver las deficiencias del método empírico intuitivo utilizado históricamente. Mientras que el propietario actual se limita a identificar de manera cualitativa los picos de venta asociados a macro-estacionalidades anuales rígidas (como el 14 de febrero o el 10 de mayo), los modelos estadísticos parsimoniosos (como SARIMA o ETS) introducen la capacidad matemática de formalizar dichos ciclos, proveyendo intervalos de confianza precisos para la presupuestación base.

No obstante, para capturar la verdadera complejidad del negocio, se requiere la inyección de modelos de Machine Learning (como *Random Forest* y XGBoost) y arquitecturas de Deep Learning (como LSTM). Estos algoritmos avanzados permiten fusionar las series univariadas de ingresos históricos con la matriz de variables exógenas no lineales desarrolladas en la ingeniería de características. El sistema predictivo basado en IA asimila cómo la cercanía de un día de pago quincenal potencia el volumen de venta orgánica de fin de semana, o cómo una fluctuación climática local altera la demanda de productos especializados.

Al optimizar las métricas críticas de error (MAE, RMSE, MAPE) a través de un tablero de Inteligencia de Negocios, *Cup&Cake* adquiere la capacidad analítica de ejecutar un proceso de S&OP científico. El pronóstico de la demanda deja de ser una estimación abstracta y se traduce de forma automatizada en órdenes de compra exactas y simulaciones dinámicas de flujo de efectivo, blindando la liquidez corporativa y maximizando el rendimiento marginal de la microempresa frente a la incertidumbre del mercado.

La revisión profunda y sistemática de la literatura especializada en ciencias de la decisión y modelos predictivos confirma que la convergencia entre los enfoques estadísticos clásicos y los paradigmas emergentes del Machine Learning y Deep Learning dota a la investigación de un arsenal metodológico de alta precisión. Mientras que la estadística paramétrica tradicional aporta parsimonia, interpretabilidad estructural y una base sólida para el análisis de series de tiempo estacionarias, los algoritmos de aprendizaje automático y las arquitecturas recurrentes

de memoria como las redes LSTM expanden de forma exponencial la capacidad analítica para capturar interacciones complejas, no linealidades extremas y flujos de datos exógenos heterogéneos.

En el ámbito crítico de las microempresas que comercializan bienes altamente perecederos bajo restricciones severas de capital de trabajo, la superación del debate clásico mediante la selección empírica de modelos optimizados bajo metodologías de ventanas deslizantes actúa como el catalizador científico de la eficiencia organizacional.

La correcta implementación de este andamiaje predictivo permite a firmas como *Cup&Cake* sustituir la inestabilidad de la intuición por un modelo de gobernanza proactivo basado en datos, logrando la sincronización matemática entre sus capacidades operativas de abastecimiento y sus objetivos estratégicos de planeación financiera.

2.4 Pronóstico en productos perecederos

La precisión del modelo adquiere criticidad en industrias alimentarias. Hübner et al. (2024) demuestran que una sobreestimación de la demanda en repostería genera costos irre recuperables por caducidad (merma), mientras que la subestimación resulta en un costo de oportunidad directo. Los modelos predictivos en este nicho deben capturar micro-estacionalidades (días de la semana, festividades) para optimizar el reabastecimiento en ciclos cortos.

2.4.1 Ontología del Producto Perecedero en la Cadena de Suministro y su Complejidad Analítica

Para abordar el pronóstico de la demanda dentro de la industria alimentaria y, específicamente, en la repostería creativa, es imperativo establecer la ontología del producto perecedero desde la perspectiva de la gestión de la cadena de suministro y la investigación de operaciones. A diferencia de los bienes duraderos o de consumo empaquetado (FMCG, por sus siglas en inglés) que pueden ser almacenados indefinidamente sin perder sus propiedades intrínsecas, un producto perecedero se define por poseer un ciclo de vida útil (*shelf-life*) drásticamente acotado, el cual está determinado por procesos inexorables de degradación biológica, química o física.

P. PraveenaSri, V. Padma, R. Muruguesan y S. Usha (2023) identifican que en la industria de la panificación y la repostería, la ventana de comercialización óptima suele medirse en horas o, en el mejor de los casos, en un par de días. Una vez superado este umbral temporal, el valor de recuperación del inventario (*salvage value*) no solo decae a cero, sino que frecuentemente adquiere un valor residual negativo, toda vez que la organización debe incurrir en costos logísticos y operativos adicionales para la disposición final y destrucción sanitaria de los residuos orgánicos.

En el caso específico de la empresa *Cup&Cake*, la perecibilidad no se limita exclusivamente al producto terminado (el pastel o postre exhibido en vitrina), sino que permea hacia atrás a lo largo de toda la estructura de la lista de materiales (BOM, *Bill of Materials*). Los insumos primarios requeridos para la repostería creativa —tales como lácteos no pasteurizados, cremas estabilizadas, frutas frescas, levaduras biológicas y coberturas fotosensibles— presentan tasas de degradación asimétricas. Esta característica fragmenta la planeación de compras: no es posible abastecer de forma agregada para un trimestre, sino que se requiere una sincronización quirúrgica entre las órdenes de compra a proveedores locales y el programa maestro de producción diario. En consecuencia, el pronóstico en este sector no admite el lujo del almacenamiento como amortiguador (*buffer*) ante la incertidumbre; el inventario, que tradicionalmente actúa como un mecanismo de defensa en otras industrias, se convierte aquí en un pasivo de alto riesgo financiero.

2.4.2 El Problema del Vendedor de Periódicos (*Newsvendor Problem*) y la Asimetría del Costo de Error

El desafío analítico de estimar el volumen exacto de producción para bienes perecederos se fundamenta matemáticamente en la investigación de operaciones a través del clásico modelo estocástico conocido como el Problema del Vendedor de Periódicos (*Newsvendor Problem*).

El Problema del Vendedor de Periódicos constituye el fundamento teórico para la toma de decisiones de producción bajo incertidumbre en productos perecederos. Su objetivo es determinar la cantidad óptima a producir que maximice la utilidad esperada, equilibrando los costos asociados al exceso de inventario y a la escasez de producto, razón por la cual ha sido

ampliamente utilizado en estudios de pronóstico de demanda y optimización de inventarios en la industria alimentaria.

Este modelo encapsula el dilema fundamental de la toma de decisiones bajo incertidumbre cuando la demanda es una variable aleatoria y el inventario no puede ser trasladado al siguiente periodo.

La función objetivo de la microempresa consiste en determinar la cantidad óptima de insumos a adquirir y productos a elaborar (Q) que minimice el costo total esperado por errores de pronóstico frente a una demanda real desconocida (D). Esta penalización económica se divide en dos componentes diametralmente opuestos pero interdependientes:

1. **Costo de Subestimación o Desabasto (c_u):** Ocurre cuando la demanda supera la cantidad producida ($D > Q$). El costo asociado no es únicamente el margen de contribución perdido por la venta no concretada (lucro cesante), sino que, en mercados locales altamente competitivos, incorpora penalizaciones intangibles y a largo plazo. Un cliente que acude a *Cup&Cake* buscando un pastel para una celebración y encuentra desabasto, probablemente trasladará su demanda a un competidor, erosionando el capital de marca (N. Hübner et al., 2024).
2. **Costo de Sobreestimación o Excedente (c_o):** Se materializa cuando la cantidad producida excede la demanda real ($Q > D$). Dado que el producto perecedero no puede almacenarse para su venta íntegra al día siguiente, el costo de sobreestimación es igual al costo variable unitario de producción menos el valor de recuperación, el cual en la repostería suele ser cero. Este exceso se traduce en merma directa, destruyendo de forma inmediata la liquidez invertida en la compra de la materia prima y en la mano de obra utilizada.

Matemáticamente, la función de pérdida asimétrica se expresa mediante el costo esperado del modelo Newsvendor. La relación se formaliza en la ecuación (1).

$$E[Cost] = c_u E[\max(D - Q, 0)] + c_o E[\max(Q - D, 0)] \quad (1)$$

En la gestión empírica e intuitiva (como la que predominó en los primeros diez años de *Cup&Cake*), el administrador es incapaz de calcular la distribución probabilística de la demanda $E[D]$. Dominado por el sesgo cognitivo de la aversión a la pérdida y el temor psicológico al cliente insatisfecho, el propietario tiende a sobredimensionar el costo de subestimación (c_u) y a ignorar el impacto acumulado de la sobreproducción (c_o). El resultado sistemático es un exceso crónico de inventario, lo que desencadena una ineficiencia silenciosa pero letal para el flujo de caja: la utilidad bruta generada por los pasteles vendidos es devorada por el costo hundido de los pasteles y materias primas desechados al final del ciclo operativo.

2.4.3 Variabilidad de la Demanda y Micro-estacionalidad en la Repostería Creativa

Para que un modelo de Inteligencia de Negocios optimice la ecuación de costos descrita, debe ser capaz de modelar las fluctuaciones atípicas de la repostería creativa. A diferencia de la venta de bienes de consumo básico (como el pan de molde industrial), cuya demanda es elástica y presenta una varianza reducida, la repostería creativa clasificada como *cake design* y pastelería artística obedece a patrones de consumo condicionados fuertemente por variables socioculturales, hedónicas y de calendario (**Ab Karim et al., 2020**).

M. Borsato (2023) argumenta que la repostería contemporánea ha difuminado las fronteras entre la gastronomía alimentaria y la expresión estética experiencial. El consumidor no adquiere calorías, sino elementos simbólicos para celebraciones. Esta naturaleza hedonista provoca que la demanda exhiba una alta volatilidad explicada por múltiples niveles de estacionalidad superpuestos, conocidos en la literatura estadística como ciclos de estacionalidad múltiple (*multiple seasonality*):

- **Macro-estacionalidad anual (Eventos ancla):** Fluctuaciones extremas de la demanda impulsadas por festividades de alcance nacional o cultural (San Valentín, Día de la Madre, Día del Niño, época decembrina). Durante estas ventanas temporales, la demanda puede triplicar la línea base operativa.

- **Micro-estacionalidad semanal:** Los picos de consumo se concentran abrumadoramente en los fines de semana (viernes a domingo), días en los que se agendan los eventos sociales, bautizos, bodas y fiestas infantiles.
- **Ciclos socioeconómicos:** El comportamiento del mercado minorista en México está fuertemente correlacionado con los ciclos de liquidez de los hogares, generando incrementos en la demanda coincidentes con los días de pago de nómina (quincenas, días 15 y 30/31 del mes).

A la complejidad de estos ciclos deterministas se suma la influencia de perturbaciones exógenas aleatorias. Por ejemplo, las condiciones climáticas severas (como frentes fríos o tormentas atípicas) reducen drásticamente el tráfico peatonal hacia los puntos de venta físicos de la microempresa y alteran el comportamiento de compra impulsiva.

Intentar proyectar esta intrincada red de estacionalidades múltiples y variables climáticas mediante un enfoque empírico o estadístico univariado simple es operativamente inviable. Es aquí donde la literatura señala a los algoritmos de Aprendizaje Automático como la única alternativa metodológica capaz de aislar y cuantificar el efecto marginal de cada evento calendárico sobre el volumen final de ventas.

2.4.4 Impacto Financiero y Medioambiental de la Integración de Modelos Predictivos

La literatura científica más reciente ha trasladado el análisis del pronóstico en bienes perecederos desde un enfoque puramente estadístico hacia la cuantificación de su impacto corporativo integral. Alexander Hübner, Jan Caspers, Vlad Coroamă y Matthias Finkbeiner (2024), al igual que las investigaciones previas de **Martins-Turner K. et al. (2023)**, demostraron empíricamente que la implementación de sistemas de pronóstico basados en Machine Learning en panaderías minoristas genera beneficios económicos y medioambientales simultáneos y de gran escala.

Desde la perspectiva financiera —la cual es el núcleo rector de la presente tesis aplicada a Cup&Cake—, la transición de la intuición a la Inteligencia Artificial transforma la estructura de costos de la microempresa. Los modelos algorítmicos (como *Random Forest* o Redes LSTM) logran capturar las dinámicas de las variables exógenas con tal nivel de granularidad, que

reducen significativamente el Error Absoluto Medio (*MAE*). Al disminuir el margen de error entre lo que se produce y lo que realmente se demanda, se mitiga el problema del Vendedor de Periódicos:

1. **Protección de la Liquidez:** Al anticipar con exactitud que un fin de semana específico cruzado con un día de quincena y un clima favorable incrementará la demanda en un 18%, el departamento de compras adquiere exclusivamente el volumen de fruta, crema y harina necesario. El capital de trabajo no se inmoviliza en excesos "por si acaso" dictados por el miedo empírico.
2. **Mitigación de Mermas:** Estudios de caso documentados por Hübner et al. (2024) evidencian que el desperdicio alimentario en panaderías convencionales que operan bajo regímenes empíricos oscila peligrosamente entre el 10% y el 15% de su volumen total de producción. Al integrar redes neuronales o algoritmos de ensamble, estas tasas de merma caen sustancialmente. Para una microempresa, reducir la merma de materia prima premium no impacta en los ingresos marginales, sino que incrementa de forma directa y pura la utilidad neta (*bottom line*) del estado de resultados.

Adicionalmente, desde la perspectiva de la sustentabilidad, la erradicación de la sobreproducción disminuye la huella de carbono organizacional, posicionando al uso de la Inteligencia Artificial como un habilitador tecnológico para el cumplimiento de objetivos de desarrollo sostenible a nivel local.

2.4.5 Desafíos de Integración: Del Algoritmo Matemático a la Ejecución Operativa

El desarrollo de un modelo predictivo con bajo error (*RMSE*, *MAPE*) en una computadora es una condición necesaria, pero insuficiente, para asegurar el éxito organizacional. El último gran desafío en el ecosistema de los productos perecederos es traducir el resultado abstracto de la caja negra algorítmica en instrucciones operativas legibles, confiables y ejecutables para el personal de la microempresa.

Si el sistema predictivo dictamina que el próximo miércoles se venderán 42.5 unidades de pastel de chocolate, este dato crudo es poco útil para la logística de aprovisionamiento si no se articula con las listas de materiales y los tiempos de maduración de los insumos.

En este sentido, la Inteligencia de Negocios (BI) actúa como la capa de interfaz crítica. Hyndman y Athanasopoulos (2021) enfatizan que los resultados predictivos deben ser acoplados a sistemas de soporte a la decisión (DSS) que los tomadores de decisiones puedan interpretar sin fricción cognitiva. A través de la construcción de tableros de control en herramientas como Un tablero web de inteligencia de negocios, las estimaciones de ML de *Cup&Cake* se desagregan automáticamente. El pronóstico de ventas se invierte analéticamente para generar una "explosión de materiales": el sistema no solo predice la demanda del producto final, sino que indica a la administración la cantidad exacta en kilogramos de harina, azúcar, huevos y empaques que deben ser solicitados al proveedor local el día lunes, respetando los plazos de entrega (*lead times*) y las capacidades máximas de almacenamiento refrigerado disponibles en las instalaciones físicas de Tizayuca, Hidalgo.

La integración de pronósticos en un tablero puede hacer explícitos los supuestos y apoyar una revisión sistemática del presupuesto de abastecimiento. No elimina el juicio humano ni garantiza, por sí sola, resultados financieros u operativos; su utilidad depende de la calidad de los datos y de la decisión que adopte el responsable del negocio.

La revisión de la literatura expone que la gestión de productos perecederos en la microempresa representa uno de los entornos analíticos más hostiles e implacables de la investigación de operaciones. La restricción absoluta del tiempo como destructor del valor del inventario invalida los esquemas de aprovisionamiento tradicionales y amplifica de manera crítica los costos financieros derivados de la sobreproducción y el desabasto.

El modelo empírico de gestión, condicionado por los sesgos cognitivos humanos frente a la aversión a la pérdida, se demuestra estructuralmente incapaz de decodificar la alta volatilidad y la estacionalidad múltiple que caracterizan la demanda en el sector de la repostería creativa. Ante esta asimetría, la introducción de modelos algorítmicos de Aprendizaje Automático emerge como el único vehículo tecnológico capaz de proyectar escenarios de consumo con la precisión que exige la preservación de la liquidez.

Al sincronizar estos pronósticos avanzados con herramientas de Inteligencia de Negocios, la organización no solo transforma su política de inventarios reduciendo drásticamente las mermas económicas y el desperdicio alimentario, sino que eleva la planeación financiera a un

nivel estratégico, garantizando la viabilidad económica requerida para soportar el crecimiento sostenido del negocio.

2.5 Fundamentos técnicos del modelado predictivo en entornos de *Small Data*

La implementación de IA en microempresas suele enfrentarse al reto del *Small Data* (escasez de registros históricos). En este escenario, la construcción del modelo debe ser rigurosa para evitar problemas estructurales.

- **Sobreajuste (Overfitting) y Capacidad de Generalización:** El sobreajuste ocurre cuando un modelo memoriza el ruido estadístico de los datos de entrenamiento, perdiendo su capacidad para predecir datos futuros no observados (James et al., 2021). Para mitigarlo, se prioriza el principio de parsimonia (modelos más simples) y se aplican técnicas de regularización matemática.
- **Ingeniería de Características (Feature Engineering):** Constituye el proceso de transformar datos crudos en variables predictivas significativas (Kuhn & Johnson, 2013). En la microempresa, la inclusión del conocimiento heurístico del dueño es vital para crear variables derivadas eficaces (ej. rezagos, promedios móviles, indicadores de días festivos) que maximicen la señal sobre el ruido.

2.5.1 La Paradoja de la Dimensionalidad y el Fenómeno del *Small Data* en la Microempresa

La transición hacia la Toma de Decisiones Basada en Datos (DDDM) exige que la infraestructura analítica se adapte a las condiciones materiales de la organización. La narrativa dominante en la ciencia de datos contemporánea ha sido monopolizada por el paradigma del *Big Data*, el cual presupone la existencia de flujos masivos, continuos y automatizados de información (Volumen, Velocidad, Variedad). Sin embargo, la ontología digital de la microempresa opera en las antípodas de este concepto. **Alekseeva, Ginevičius y Stankevičienė (2021)** definen este entorno operativo como el dominio del *Small Data* (datos pequeños), caracterizado por registros históricos fragmentados, ventanas temporales

acotadas, asimetría en la captura de información y una alta proporción de ruido estadístico frente a la señal real del mercado.

Aplicar algoritmos de Aprendizaje Automático directamente sobre un entorno de *Small Data* sin adaptaciones matemáticas rigurosas desencadena un fenómeno conocido en la matemática aplicada como la "maldición de la dimensionalidad" (*curse of dimensionality*), acuñado originalmente por Richard Bellman. Este principio establece que a medida que se incrementa el número de variables explicativas (características) en un modelo, el volumen del espacio matemático crece de forma exponencial, provocando que los datos disponibles se vuelvan dispersos (Hastie, Tibshirani, & Friedman, 2009).

En el contexto de la planeación financiera de la microempresa Cup&Cake, si se intenta construir un modelo predictivo incorporando decenas de variables (clima, precios de competidores múltiples, interacciones en redes sociales diarias, indicadores macroeconómicos) contando con un historial de ventas limitado a unos pocos años de operación, el algoritmo será matemáticamente incapaz de encontrar patrones estadísticamente significativos. La densidad de la muestra es insuficiente para sustentar la complejidad del modelo, lo que colapsa la capacidad predictiva del sistema y anula cualquier beneficio para el pronóstico de la demanda de bienes perecederos.

2.5.2 El Equilibrio Sesgo-Varianza (*Bias-Variance Tradeoff*) y el Riesgo de Sobreajuste (*Overfitting*)

La restricción fundamental del modelado en entornos de datos limitados se explica a través de uno de los teoremas más críticos del aprendizaje estadístico: el equilibrio entre el sesgo y la varianza (*Bias-Variance Tradeoff*). Gareth James, Daniela Witten, Trevor Hastie y Robert Tibshirani (2021) postulan que el error de predicción esperado (EPE) de cualquier modelo de aprendizaje supervisado aplicado a un conjunto de datos no observados se descompone aditivamente en tres elementos inseparables: La relación se formaliza en la ecuación (2).

$$Err(x) = Sesgo^2(\hat{f}(x)) + Varianza(\hat{f}(x)) + \sigma^2 \quad (2)$$

Donde:

- **Sesgo (*Bias*):** Representa el error introducido al aproximar un problema de la vida real, que es inherentemente complejo y no lineal, mediante un modelo matemático demasiado simplista (por ejemplo, intentar predecir las ventas estacionales cruzadas de la repostería utilizando una regresión lineal estricta). Los modelos con alto sesgo sufren de subajuste (*underfitting*), fracasando en capturar la señal principal de los datos.
- **Varianza (*Variance*):** Cuantifica cuánto cambiaría la función predictiva estimada $\hat{f}(x)$ si se entrenara el modelo utilizando un conjunto de datos histórico ligeramente distinto.
- **Error Irreducible (σ^2):** Es la varianza inherente al propio ruido blanco del mercado, fluctuaciones aleatorias imposibles de predecir por cualquier modelo sin importar su sofisticación.

En el escenario de la microempresa, el riesgo catastrófico reside en la varianza. Cuando se utilizan algoritmos de alta capacidad (como redes neuronales profundas o árboles de decisión no podados) sobre conjuntos de datos pequeños, el modelo tiende a reducir su sesgo a cero "memorizando" cada detalle de los datos de entrenamiento. Este fenómeno es el **Sobreajuste (*Overfitting*)**. El algoritmo aprende no solo la tendencia genuina del mercado, sino que asimila el ruido estadístico, las anomalías temporales y las variaciones fortuitas del pasado como si fueran leyes universales del negocio.

Si Cup&Cake experimentó un desabasto inusual de un proveedor hace dos años que deprimió las ventas temporalmente, un modelo sobreajustado inferirá erróneamente que esa caída se repetirá exactamente bajo las mismas condiciones. Al desplegar este modelo en la planeación financiera del mes siguiente, sus predicciones sobre datos nuevos y reales fallarán de forma estrepitosa, induciendo compras de inventario defectuosas y mermas económicas críticas.

2.5.3 Estrategias de Regularización y Contracción Matemática para la Parsimonia

Para viabilizar la aplicación de Inteligencia Artificial frente a la amenaza del sobreajuste en *Small Data*, la literatura exige la **imposición metodológica del principio de parsimonia**. A nivel algorítmico, esto se logra mediante la inyección de técnicas de regularización (métodos de contracción). La regularización altera la función de pérdida matemática del modelo, añadiendo

una penalización directa basada en la complejidad (magnitud y cantidad de coeficientes) del propio algoritmo.

Entre las metodologías más robustas para datos comerciales limitados destacan las penalizaciones L_1 y L_2 :

1. **Regresión Ridge (Regularización L_2):** Añade una penalización equivalente al cuadrado de la magnitud de los coeficientes. Reduce el impacto de variables poco informativas acercando sus pesos a cero, mitigando el problema de la multicolinealidad (cuando variables explicativas, como el número de seguidores en redes y las ventas semanales, están altamente correlacionadas entre sí).
2. **Regresión Lasso (Regularización L_1):** Su función de pérdida incorpora la penalización absoluta de los coeficientes, representada matemáticamente mediante regularización L_1 . La relación se formaliza en la ecuación (3).

$$Loss = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p |\beta_j| \quad (3)$$

El parámetro de ajuste estocástico λ controla la severidad de la penalización. La propiedad matemática excepcional de la regularización Lasso para microempresas es que actúa como un selector de características automatizado: fuerza a que los coeficientes de las variables irrelevantes se conviertan exactamente en cero, eliminándolas de la ecuación.

Al emplear regularización u optimización de hiperparámetros (como limitar la profundidad máxima de un *Random Forest* a unos pocos nodos), el sistema sacrifica intencionalmente un pequeño porcentaje de exactitud en los datos históricos pasados (aumenta ligeramente el sesgo) a cambio de una reducción dramática en la varianza. El resultado es un modelo mucho más estable, generalizable e inmune al ruido, capaz de generar un pronóstico de compras coherente y seguro para el flujo de efectivo a futuro.

2.5.4 Ingeniería de Características (*Feature Engineering*): La Incorporación Heurística del Conocimiento Tácito

Si la regularización es la barrera de contención contra el ruido, la Ingeniería de Características (*Feature Engineering*) es el motor de extracción de señales predictivas. **Kuhn M. y Johnson K. (2013)** establecen que los algoritmos de Machine Learning no operan en un vacío cognitivo; su precisión está estrictamente determinada por la calidad, forma y representación matemática de las variables de entrada.

En un contexto de microempresa, la Ingeniería de Características es el puente epistemológico exacto donde el conocimiento tácito y la intuición del microempresario (discutidos en la Sección 2.1) se traducen, codifican e inyectan formalmente en la arquitectura del modelo estadístico. El empirismo humano deja de ser un factor de toma de decisión de Sistema 1, para convertirse en una variable explicativa (*feature*) computable. Para el pronóstico de ventas en repostería creativa, esta ingeniería se estructura en tres dimensiones metodológicas:

A. Variables de Rezagos Temporales (*Lag Features* y Ventanas Móviles)

Dado que las series temporales presentan autocorrelación, es imperativo informar al modelo sobre el pasado reciente. Se construyen variables que representan el valor de la demanda desplazada en el tiempo (por ejemplo, y_{t-1} para la demanda de ayer, y_{t-7} para la demanda del mismo día de la semana anterior). Asimismo, para suavizar anomalías, se calculan medias móviles de distintos periodos (promedio de los últimos 3, 7 o 15 días), lo que proporciona al algoritmo la inercia a corto plazo de la tendencia de ingresos.

B. Transformaciones Cíclicas de Variables Temporales

La demanda de Cup&Cake presenta fuerte dependencia del día de la semana y el mes del año. No obstante, introducir estas variables como etiquetas numéricas ordinales simples (ej. Lunes = 1, Domingo = 7) es un error matemático grave, pues el algoritmo no entenderá que el Domingo (7) y el Lunes (1) son días temporalmente adyacentes. La Ingeniería de Características soluciona esto mediante codificación trigonométrica, proyectando la variable temporal en un círculo de dos dimensiones mediante una proyección seno-coseno. La relación se formaliza en la ecuación (4).

$$x_{sin} = \sin\left(\frac{2\pi t}{T}\right), \quad x_{cos} = \cos\left(\frac{2\pi t}{T}\right) \quad (4)$$

Donde T es el periodo del ciclo (ej. 7 para días de la semana). Esta transformación permite que los algoritmos capten la continuidad cíclica de la micro-estacionalidad minorista.

C. Variables Exógenas Booleanas (Días Festivos y Dinámica Quincenal)

La inclusión del conocimiento empírico del dueño es crítica para identificar la macro-estacionalidad. Se generan variables *dummy* o indicadoras (0 o 1) para señalar fechas que distorsionan el mercado: Día de las Madres, San Valentín o días de quincena laboral. Los algoritmos basados en árboles (como *XGBoost*) son extraordinariamente eficientes particionando los datos con base en estas características exógenas, separando la línea base de ventas orgánicas de los picos anómalos, lo que evita desbordamientos en la planeación de la compra de materia prima perecedera.

2.5.5 Validación Temporal Estricta: Metodología de Ventanas Deslizantes (*Rolling-Origin*)

Una vez que los modelos han sido diseñados y regularizados, el paso final en la cimentación de su arquitectura técnica es la evaluación rigurosa de su rendimiento antes de desplegarlos en el entorno productivo real. En conjuntos de datos independientes tradicionales, el estándar estadístico es la validación cruzada *k-fold*. Sin embargo, **Bergmeir C. y Benítez J. M. (2012)** demostraron de forma taxativa que aplicar el muestreo aleatorio de validación cruzada en datos secuenciales constituye un error analítico insalvable. Mezclar aleatoriamente las ventas de enero y diciembre para predecir marzo destruye la dependencia de las series de tiempo y genera un fenómeno denominado "fuga de datos" (*data leakage*), donde el modelo utiliza encubiertamente información del futuro para predecir el pasado. Esto arroja métricas de precisión falsamente altas (*RMSE* bajo en laboratorio) que invariablemente fracasarán al implementarse en el negocio.

Para garantizar la estabilidad predictiva en la planeación financiera, la literatura especializada (**Hyndman & Athanasopoulos, 2021**) establece como estándar de oro metodológico la

Validación Cruzada para Series Temporales, formalmente conocida como **Validación de Origen Deslizante (*Rolling-Origin Evaluation*)**.

Esta técnica simula cronológicamente el escenario empírico exacto que enfrentará el administrador en el piso de la microempresa, respetando de manera dogmática la asimetría inquebrantable del tiempo. Su mecanismo operativo consta de los siguientes pasos iterativos:

1. **Definición de la Ventana Inicial:** Se designa un subconjunto de datos históricos continuos más antiguo para el entrenamiento fundacional del modelo.
2. **Proyección *h-Step Ahead*:** El algoritmo estima los ingresos o demanda para el horizonte temporal contiguo (ej. la proyección de abastecimiento para los próximos 7 días). Se calcula el error de esta predicción comparándola contra los datos reales.
3. **Deslizamiento Temporal:** El origen del tiempo avanza un periodo hacia el futuro. Los datos reales que acaban de ser pronosticados se integran oficialmente a la base de conocimiento de entrenamiento.
4. **Re-calibración Secuencial:** El modelo se entrena nuevamente (ajustando sus parámetros) con este conocimiento expandido y vuelve a pronosticar el siguiente bloque temporal. El proceso se repite cíclicamente hasta alcanzar el final del historial disponible.

Leonard Tashman (2000) subraya que en entornos de pequeñas organizaciones, se puede optar por una **Ventana de Entrenamiento Expansiva (*Expanding Window*)**, donde el bloque de datos históricos acumula registros de forma aditiva para dotar al algoritmo de la mayor cantidad de varianza histórica posible frente al fenómeno del *Small Data*.

La aplicación de esta metodología es el pilar de validez científica de la presente investigación. Al calcular el Error Absoluto Medio (*MAE*) y el Error Porcentual Absoluto Medio (*MAPE*) sobre las iteraciones de validación deslizante, se asegura empíricamente que el modelo de Aprendizaje Automático propuesto tiene la robustez necesaria para anticipar las contingencias del mercado de Tizayuca, Hidalgo. Esto transforma a los modelos predictivos de meras curiosidades estadísticas en herramientas corporativas fidedignas, habilitando la toma de

decisiones basada en datos para orquestar la compra de insumos perecederos y dictaminar la viabilidad de la expansión de puntos de venta de Cup&Cake.

La implementación de Inteligencia de Negocios impulsada por Aprendizaje Automático en la microempresa no está exenta de riesgos estructurales. Como la teoría estadística de los ecosistemas de *Small Data* advierte, someter muestras limitadas e infectadas de ruido a modelos algorítmicos complejos sin restricciones desemboca irremediablemente en el sobreajuste matemático. Un modelo que sufre la maldición de la dimensionalidad pierde por completo su capacidad predictiva en escenarios futuros, socavando la viabilidad de la planeación financiera.

Para contrarrestar estos obstáculos, el diseño predictivo debe regirse por los principios ineludibles de la parsimonia y la validación estricta. La aplicación de estrategias de regularización matemática de contracción actúa como el primer cerco de defensa, limitando la varianza del algoritmo y garantizando su capacidad de generalización. Simultáneamente, la ejecución de una profunda Ingeniería de Características permite convertir el conocimiento empírico e intuitivo acumulado por el propietario en señales cuantitativas explícitas asimilables por el software. Finalmente, la exposición del modelo a la simulación implacable de la validación por Ventanas Deslizantes (*Rolling-Origin*) asegura que las predicciones financieras posean la fiabilidad ejecutiva necesaria.

Este andamiaje técnico metodológico conforma el puente definitivo para transicionar con éxito del riesgo de la intuición humana a la certidumbre táctica de la Inteligencia Artificial.

2.6 Métricas de evaluación de modelos predictivos

Para determinar la superioridad de un modelo algorítmico sobre el método intuitivo (línea base), es imperativo emplear métricas de error estandarizadas que cuantifiquen la desviación entre los valores reales (y_i) y los pronosticados ($\hat{y}_i$) sobre n observaciones (**Hyndman & Athanasopoulos, 2021**). Las métricas seleccionadas para esta investigación son:

- **Error Absoluto Medio (MAE - Mean Absolute Error):** Mide la magnitud promedio de los errores en las mismas unidades de los datos, sin considerar su dirección. Es

altamente interpretable en el contexto comercial (ej. "el modelo se equivoca por 5 pasteles en promedio"). Se expresa matemáticamente como la (15)

- **Raíz del Error Cuadrático Medio (*RMSE - Root Mean Squared Error*):** Al elevar los errores al cuadrado antes de promediarlos, esta métrica penaliza desproporcionadamente las desviaciones grandes o valores atípicos. Es crucial en planeación financiera para evitar fallos catastróficos de predicción. Se expresa matemáticamente como la (14)
- **Error Porcentual Absoluto Medio (*MAPE - Mean Absolute Percentage Error*):** Expresa el error como un porcentaje, facilitando la comparación del rendimiento del modelo entre diferentes escalas de productos. Se expresa matemáticamente como la (13)

2.6.1 Fundamentos Epistemológicos de la Medición del Error Predictivo

En la construcción de modelos estadísticos y de Aprendizaje Automático, la cuantificación de la exactitud algorítmica no es un mero formalismo matemático, sino el núcleo epistemológico que determina la validez científica y la utilidad operativa del sistema. El célebre aforismo del estadístico **Box G. (1976)**, "*Todos los modelos son incorrectos, pero algunos son útiles*", establece la premisa fundamental del *forecasting*: la incertidumbre absoluta es inerradicable, y el pronóstico perfecto no existe. Por consiguiente, el objetivo de la analítica predictiva no es alcanzar el error cero, sino minimizar la varianza del error y comprender su distribución matemática para mitigar el riesgo financiero.

Hyndman R. J. y Athanasopoulos G. (2021) establecen una distinción crítica entre la bondad de ajuste (*goodness-of-fit*) y la precisión predictiva (*predictive accuracy*). Históricamente, la estadística clásica evaluaba los modelos econométricos utilizando métricas intra-muestrales (*in-sample*), como el Coeficiente de Determinación (R^2) o el Criterio de Información de *Akaike* (*AIC*). Sin embargo, estas métricas premian la complejidad del modelo y no garantizan su desempeño en el mundo real.

En la ciencia de datos contemporánea, y de manera obligatoria en entornos de evaluación por Ventanas Deslizantes (*Rolling-Origin*), la precisión se evalúa de manera estricta fuera de la

muestra (*out-of-sample*). Es decir, el modelo se juzga exclusivamente por su capacidad para estimar observaciones futuras que no formaron parte de su proceso de entrenamiento.

Para la investigación de la microempresa Cup&Cake, la evaluación del desempeño adquiere un peso crítico. La hipótesis de investigación (H_1) postula que la implementación de Inteligencia Artificial reducirá el error del pronóstico en un 20% frente al método empírico actual. Para someter esta hipótesis a un escrutinio científico riguroso y falsable, se requiere definir y aplicar funciones de pérdida o métricas de error estandarizadas. Cada métrica posee características matemáticas particulares que penalizan de forma distinta las desviaciones entre el valor real observado (y_i) y el valor pronosticado por el algoritmo ($\hat{y}_i$). Las métricas seleccionadas metodológicamente para esta tesis son el *MAE*, el *RMSE* y el *MAPE*.

2.6.2 Error Absoluto Medio (*MAE*) y la Magnitud Lineal del Riesgo Operativo

El Error Absoluto Medio (*MAE*, por sus siglas en inglés, *Mean Absolute Error*) es una de las métricas de evaluación más transparentes, interpretables y robustas dentro de la analítica predictiva. Matemáticamente, se define como el promedio aritmético de los valores absolutos de los errores individuales sobre una muestra de N observaciones. Se expresa mediante la siguiente ecuación formal ((15)):

La aplicación del valor absoluto asegura que los errores de sobreestimación (pronosticar por encima de la demanda real) y los errores de subestimación (pronosticar por debajo) no se cancelen algebraicamente entre sí, lo cual ocurriría si simplemente se sumaran los residuos crudos. El *MAE* opera bajo la norma vectorial L_1 , lo que significa que su tasa de penalización es estrictamente lineal: un error de 10 unidades es penalizado exactamente el doble que un error de 5 unidades.

Implicaciones prácticas para la microempresa:

La superioridad del *MAE* radica en su interpretabilidad de negocio (*scale-dependent metric*). El resultado se expresa en las mismas unidades físicas de la variable objetivo. En el contexto operativo de Cup&Cake, si el modelo de ensamble arroja un *MAE* de 4.5, el administrador comprende inmediatamente que el algoritmo se equivoca, en promedio, por 4.5 pasteles o 4.5 kilogramos de insumo por cada ciclo de planeación.

Esta característica es invaluable para el proceso de Planeación de Ventas y Operaciones (S&OP). Al conocer la desviación promedio esperada en unidades físicas, el departamento de compras puede establecer un inventario de seguridad (*safety stock*) analítico y fundamentado, diseñado específicamente para absorber ese margen de error lineal. Asimismo, el *MAE* es una métrica matemáticamente robusta frente a la presencia de valores atípicos aislados (*outliers*), lo que proporciona una evaluación equilibrada del desempeño del modelo en días regulares de venta orgánica, sin que el promedio se distorsione drásticamente por una anomalía extrema del mercado.

2.6.3 Raíz del Error Cuadrático Medio (*RMSE*) y la Penalización de Errores Catastróficos

Mientras que el *MAE* evalúa el desempeño operativo cotidiano, la Raíz del Error Cuadrático Medio (*RMSE*, *Root Mean Squared Error*) actúa como el guardián de la estabilidad macrofinanciera y el liquidador del riesgo extremo. Matemáticamente, el *RMSE* calcula el promedio de los errores elevados al cuadrado y, posteriormente, extrae la raíz cuadrada de este resultado para devolver la métrica a las unidades originales del problema ((14)):

Basado en la norma vectorial L_2 , el *RMSE* no trata a los errores de forma lineal. Al elevar el término residual ($y_i - \hat{y}_i$) al cuadrado, la métrica penaliza de manera exponencial y desproporcionada a las desviaciones de gran magnitud. Un error de pronóstico de 20 unidades no es castigado el doble que un error de 10 unidades, sino cuatro veces más.

Implicaciones prácticas para la microempresa:

La justificación de la inclusión del *RMSE* en el diseño experimental de esta tesis es fundamental para la supervivencia corporativa. En la gestión de productos perecederos (como se abordó en la Sección 2.4), los errores no tienen el mismo impacto económico dependiendo de su volumen. Equivocarse por dos pasteles en un martes ordinario genera una merma absorbible por el margen de contribución semanal. Sin embargo, fallar catastróficamente en la estimación del Día de San Valentín —por ejemplo, pronosticando 150 unidades por encima de la demanda real— representa un choque de liquidez que puede inmovilizar el flujo de caja operativo de la microempresa durante todo el trimestre posterior.

El RMSE es altamente sensible a estos fallos atípicos. Cuando se comparan modelos algorítmicos, si el Modelo A y el Modelo B tienen un MAE idéntico, pero el Modelo B presenta un RMSE significativamente mayor, significa que la varianza del error del Modelo B es peligrosa: acierta muy bien la mayoría de los días, pero cuando falla, falla de manera destructiva. Para Cup&Cake, optimizar el modelo de Aprendizaje Automático minimizando el RMSE equivale a contratar un seguro matemático contra la quiebra técnica por sobreabastecimiento en fechas críticas, blindando la planeación financiera ante escenarios de estrés.

2.6.4 Error Porcentual Absoluto Medio (MAPE) y la Relatividad Comercial

Una de las limitaciones intrínsecas tanto del MAE como del RMSE es su dependencia de la escala (*scale-dependency*). No permiten comparar la exactitud de un pronóstico entre diferentes líneas de productos que poseen volúmenes de venta dispares. Si el modelo se equivoca por 10 unidades, este error es insignificante para una línea de "galletas individuales" que vende 1,000 unidades diarias, pero es un fallo crítico para la línea de "pasteles de boda personalizados" que vende 12 unidades semanales.

Para subsanar esta asimetría, la industria ha adoptado de forma unánime el Error Porcentual Absoluto Medio (MAPE, *Mean Absolute Percentage Error*). Esta métrica divide el error absoluto entre el valor real observado, expresando el resultado final como un porcentaje ((13)):

Ventajas y patologías matemáticas del MAPE:

Makridakis S., Spiliotis E. y Assimakopoulos V. (2018), en sus análisis metodológicos derivados de las Competencias M, subrayan que el *MAPE* es la métrica preferida por la alta dirección y los tomadores de decisiones no técnicos, debido a su universalidad comunicativa. Decir que el "método empírico actual tiene un margen de error del 35%, y el modelo de Inteligencia Artificial lo redujo a un 12%" es una narrativa corporativa irrefutable y fácilmente asimilable en un tablero de Inteligencia de Negocios.

No obstante, el investigador debe ser epistemológicamente consciente de las debilidades matemáticas del *MAPE*. Su vulnerabilidad más grave es el "problema de la división por cero". En la microempresa minorista, es común que existan días donde la demanda real de un

producto específico sea exactamente cero ($y_i = 0$). En estos casos, el cálculo del *MAPE* se vuelve matemáticamente indefinido (tiende al infinito). Además, el *MAPE* es inherentemente asimétrico: penaliza mucho más las proyecciones que exceden el valor real (sobreestimaciones) que aquellas que se quedan cortas (subestimaciones), dado que el error positivo puede crecer de forma ilimitada, mientras que el error negativo está acotado al 100%.

A pesar de estas limitaciones, la aplicación del *MAPE* (o en su defecto, variantes ajustadas como el *sMAPE* - *symmetric MAPE*) sigue siendo indispensable para medir la rentabilidad relativa de la transformación digital de Cup&Cake. Permite ponderar de forma equitativa el desempeño del algoritmo a través de todo el catálogo de repostería creativa, facilitando la creación de presupuestos financieros indexados porcentualmente.

2.6.5 Validación de Modelos en Series Temporales: Metodología de Ventanas Deslizantes (*Rolling-Origin Cross-Validation*)

En la construcción de modelos de aprendizaje automático predictivos, la evaluación rigurosa del rendimiento es un paso crítico para garantizar la capacidad de generalización del algoritmo. En conjuntos de datos transversales (donde las observaciones son independientes), el estándar de la industria es la validación cruzada *k-fold*. Sin embargo, aplicar este método tradicional a datos secuenciales (como el registro histórico de ventas semanales de una microempresa) constituye un error metodológico grave.

De acuerdo con **Bergmeir y Benítez (2012)**, la validación cruzada aleatoria en series de tiempo destruye la dependencia temporal inherente a los datos y provoca "fuga de datos" (*data leakage*), un fenómeno donde el modelo utiliza información del futuro para predecir el pasado, generando métricas de precisión artificialmente altas que colapsan en el entorno operativo real.

Para mitigar este problema, la literatura especializada establece el uso de la validación cruzada para series temporales, también conocida como pronóstico con origen deslizante o *Rolling-Origin Evaluation* (**Hyndman & Athanasopoulos, 2021**). Esta metodología respeta estrictamente la asimetría del tiempo y simula el escenario exacto en el que operará la empresa.

El mecanismo de ventanas deslizantes opera bajo los siguientes principios iterativos:

1. **Definición de la ventana de entrenamiento inicial:** Se establece un subconjunto inicial de datos históricos continuos para entrenar el modelo (por ejemplo, los primeros 12 meses de ventas).
2. **Pronóstico sobre el horizonte de prueba:** El modelo entrenado emite una predicción para el siguiente periodo temporal o bloque de periodos (*h-step ahead*), equivalente al horizonte de planeación de abastecimiento.
3. **Deslizamiento del origen temporal:** El "origen" del pronóstico avanza un paso en el tiempo. La observación real que acaba de ser pronosticada se incorpora al conjunto de entrenamiento.
4. **Reentrenamiento y repetición:** El modelo se actualiza con esta nueva información y pronostica el siguiente paso temporal. Este ciclo se repite hasta agotar los datos disponibles.

Dentro de esta metodología, **Tashman (2000)** identifica dos arquitecturas de entrenamiento predominantes, cuya selección depende de la naturaleza del negocio:

- **Ventana expansiva (*Expanding Window*):** El límite inferior del conjunto de entrenamiento permanece fijo, por lo que el volumen de datos de entrenamiento crece en cada iteración. Es ideal para microempresas que requieren acumular toda la varianza histórica posible debido a la escasez inicial de datos (*Small Data*).
- **Ventana deslizante de tamaño fijo (*Rolling Window*):** Al incorporar un nuevo dato reciente al conjunto de entrenamiento, se descarta el dato más antiguo, manteniendo un tamaño de muestra constante. Este enfoque es superior en entornos con alta volatilidad o cuando el comportamiento del consumidor ha cambiado estructuralmente, permitiendo que el modelo se adapte rápidamente a la realidad comercial reciente sin ser "anclado" por patrones obsoletos.

En el contexto de la planeación financiera e inventarios en productos perecederos, la técnica de ventanas deslizantes permite calcular el error promedio empírico (*MAE*, *RMSE*, *MAPE*) a lo largo de múltiples periodos de prueba simulados. Esto garantiza que las estimaciones de error

reflejen con alta fidelidad la incertidumbre real que enfrentará el microempresario al proyectar sus ingresos y requerimientos de materia prima semana a semana.

2.6.6 Fusión Multicriterio y Evaluación Contra la Línea Base Empírica

El desarrollo de un marco analítico corporativo maduro exige que la evaluación del desempeño predictivo no descansa sobre una única métrica, sino sobre una estrategia analítica multicriterio. El *MAE* se consolida como la brújula táctica para la calibración del *safety stock* físico; el *RMSE* actúa como el indicador avanzado de riesgo extremo para prevenir quiebras técnicas por mermas acumuladas; y el *MAPE* opera como el *KPI* de traducción financiera universal para la alta dirección.

El componente culminante de este marco de evaluación es la confrontación matemática contra la **Línea Base (*Baseline*)**. En la ciencia empírica, demostrar que un algoritmo de red neuronal o *Random Forest* genera un pronóstico con un *MAPE* del 15% carece de valor científico intrínseco si no se compara contra el rendimiento del sistema que busca reemplazar.

En la investigación realizada con los datos de Cup&Cake, la referencia comparativa es una línea base empírica reproducible, integrada por la persistencia del último valor y el promedio móvil de siete días. No constituye un grupo de control experimental ni permite atribuir las compras históricas exclusivamente a la intuición del propietario.

La magnitud de la innovación tecnológica y el retorno de inversión (ROI) del sistema de Inteligencia de Negocios se calculan cuantificando el delta o diferencial de las métricas de error, tal como se muestra en la (11):

Si la introducción de algoritmos avanzados de IA logra una contracción estadísticamente significativa en estas métricas de error —tal y como postula la Hipótesis General (H1) de esta tesis—, el impacto trasciende el ámbito matemático y se internaliza directamente en el Estado de Resultados y el Flujo de Efectivo de la organización. Una reducción del 20% en el *MAPE* no solo disminuye el costo de oportunidad y la merma de productos perecederos, sino que dota a la microempresa de un nivel de certidumbre operativa previamente inalcanzable. Este blindaje analítico es la condición *sine qua non* que permite al fundador de Cup&Cake planificar simulaciones de inversión y expansión de nuevos puntos de venta en Tizayuca, Hidalgo, con

la seguridad de que su capital de trabajo central se encuentra custodiado por el rigor irrefutable de los datos.

Demostrar la reducción matemática del error mediante este riguroso marco experimental provee la justificación científica para transicionar hacia la toma de decisiones basada en datos (DDDM). Al someter las proyecciones a simulaciones crónicamente honestas mediante *Rolling-Origin*, se garantiza que las métricas obtenidas reflejen una ventaja analítica real, transformando el pronóstico univariado en un motor estratégico de optimización de recursos y preservación del flujo de efectivo.

La evaluación científica de los modelos de pronóstico constituye el eslabón metodológico definitivo que unifica los desarrollos algorítmicos del Aprendizaje Automático con la viabilidad financiera en el piso operativo de la microempresa. Como se demuestra a lo largo de esta sección, el uso de métricas de error univariadas tradicionales es insuficiente si no se inscribe dentro de un protocolo de validación que respete la asimetría temporal implícita en la gestión comercial.

La integración de la metodología de Ventanas Deslizantes (*Rolling-Origin Cross-Validation*) erradica por completo la patología analítica de la fuga de datos (*data leakage*), forzando a los modelos computacionales a demostrar su verdadera capacidad de generalización en condiciones que simulan fielmente la incertidumbre semanal del mercado minorista.

Bajo este marco temporal estricto, MAE y RMSE permiten comparar la magnitud media y la penalización de errores grandes en cada modelo. MAPE se utiliza sólo como diagnóstico complementario, pues las series con numerosos valores cero pueden producir porcentajes inestables. Las métricas sirven para seleccionar el modelo que mejor anticipa el presupuesto de abastecimiento, no para calcular directamente inventario o liquidez.

Optimizar y estabilizar estas métricas mediante Inteligencia de Negocios no representa únicamente un logro de precisión matemática; constituye el blindaje analítico del flujo de efectivo y la validación empírica necesaria para fundamentar proyectos de expansión de capital con el menor grado de riesgo posible.

2.7 Limitaciones en la adopción de Inteligencia Artificial en microempresas

A pesar de las ventajas expuestas, la penetración de la analítica avanzada en MIPYMES de economías emergentes es precaria. **Alekseeva et al. (2021)** categorizan estas barreras en tres ejes:

1. **Tecnológicas:** Ausencia de registros históricos digitalizados en bases de datos relacionales y silos de información.
2. **Financieras:** Presupuestos restrictivos que impiden la adquisición de infraestructuras analíticas de grado corporativo o licenciamientos en la nube.
3. **Capital humano:** Carencia de alfabetización en datos (*data literacy*) y talento especializado para la interpretación estadística.

Frente a este paradigma, la literatura reciente propone un enfoque ágil y parsimonioso, donde la combinación de modelos de aprendizaje automático accesibles y tableros de BI actúan como un puente cognitivo que democratiza la IA.

2.7.1 Asimetrías Tecnológicas y de Conocimiento en el Estrato Microempresarial

La justificación teórica y el éxito de los modelos algorítmicos en entornos de laboratorio matemático chocan de manera invariable con las barreras de carácter estructural que condicionan la realidad operativa de las unidades económicas de menor escala. A pesar de que la literatura científica de frontera ensalza las virtudes de la Inteligencia Artificial (IA) y el *Machine Learning* como catalizadores de la productividad, su difusión e implantación no se distribuyen de manera homogénea en el aparato productivo. La Organización para la Cooperación y el Desarrollo Económicos (**OCDE, 2022**) advierte que existe una brecha digital profunda y multifactorial que separa a las grandes corporaciones de las micro, pequeñas y medianas empresas (MIPYMES) en los países en vías de desarrollo, donde menos del 25% de las microempresas utilizan algún tipo de herramienta analítica elemental.

Desde una perspectiva sociotécnica, esta problemática se define como una asimetría estructural de capacidades de absorción tecnológica (*absorptive capacity*). De acuerdo con la teorización clásica de Cohen y Levinthal, la capacidad de una firma para reconocer el valor de

nueva información externa, asimilarla y aplicarla con fines comerciales está estrictamente determinada por el nivel de su conocimiento previo acumulado y su infraestructura existente.

L. Alekseeva, R. Ginevičius y J. Stankevičienė (2021) demuestran que las microempresas operan bajo un ecosistema de restricciones interconectadas que bloquean la asimilación de la IA. Estas limitaciones no constituyen fallas aisladas de gestión, sino patologías estructurales arraigadas en tres dimensiones fundamentales: la escasez crítica de infraestructura analítica, las severas restricciones presupuestarias y la brecha cognitiva de capital humano especializado.

2.7.2 Barreras de Infraestructura y el Fenómeno de los Silos Informáticos Analógicos

El primer gran obstáculo que imposibilita la adopción orgánica de modelos predictivos avanzados en microempresas es la ausencia absoluta de una infraestructura mínima de datos. Mientras que las organizaciones maduras gestionan sus flujos de información a través de sistemas de Planificación de Recursos Empresariales (*ERP*) integrados, Sistemas de Gestión de Relaciones con Clientes (*CRM*) y almacenes de datos (*Data Warehouses*) que automatizan el proceso de Extracción, Transformación y Carga (*ETL*), la microempresa subsiste en la fragmentación analógica o en la ofimática aislada.

Alekseeva, Gorbunova y Parshina (2021) describen que en el sector comercial minorista tradicional, la información transaccional suele estar confinada en lo que se denomina "silos informáticos analógicos". En el caso específico de Cup&Cake antes de la intervención tecnológica, este fenómeno se manifestaba en la coexistencia de registros de ventas y listado de compras en bases de datos aisladas sin vinculación relacional.

Esta desconexión estructural anula la integridad y trazabilidad de los datos a largo plazo. Para que un modelo predictivo univariado o multivariado identifique patrones no lineales de estacionalidad múltiple, requiere series cronológicas cruzadas donde la variable dependiente (ventas) converse matemáticamente con las variables independientes (compras, insumos, fechas). La existencia de bases de datos aisladas introduce una barrera técnica que imposibilita la alimentación directa de los algoritmos de entrenamiento. La microempresa, por tanto, enfrenta la paradoja de requerir soluciones de Inteligencia Artificial para optimizar su flujo de efectivo, pero necesitando resolver primero el desafío de consolidar y relacionar sus

bases de datos bajo estándares de gobernanza mínima mediante herramientas de programación con el apoyo de herramientas de Inteligencia de Negocios.

2.7.3 Restricciones Presupuestarias y el Costo Total de Propiedad (TCO) de la Analítica Avanzada

El segundo factor de exclusión tecnológica es de naturaleza estrictamente financiera. La planeación macro-financiera en la microempresa se rige por la preservación inmediata de la liquidez diaria (como se detalló en la Sección 2.2). Cada egreso de capital debe justificar un retorno de inversión (*ROI*) tangible a corto plazo para evitar tensiones operativas en el flujo de caja. En este escenario, el Costo Total de Propiedad (*Total Cost of Ownership, TCO*) asociado al despliegue de soluciones tradicionales de Inteligencia Artificial resulta prohibitivo e inviable para el presupuesto de la firma.

El *TCO* de un proyecto analítico convencional de grado corporativo incorpora múltiples componentes de costo hundido:

1. **Costos de Licenciamiento:** Las plataformas líderes de software estadístico, entornos integrados de ciencia de datos y arquitecturas de computación en la nube (*Cloud Computing*) operan bajo esquemas de suscripción mensual por usuario o volumen de procesamiento de datos que impactan de forma directa el balance de egresos corrientes.
2. **Infraestructura de Hardware:** La ejecución local de arquitecturas neuronales complejas (como las celdas *LSTM* discutidas en la Sección 2.3) demanda capacidades de procesamiento intensivo (unidades de procesamiento gráfico, *GPU*) que superan por amplio margen el hardware comercial disponible en las oficinas o mostradores de la microempresa.
3. **Costos de Integración y Middleware:** La consolidación de una arquitectura unificada que conecte el software del punto de venta con el modelo predictivo exige la contratación de servicios de consultoría externa especializados en ingeniería de datos, cuyos honorarios de mercado resultan financieramente inaccesibles para una

organización que se encuentra evaluando la apertura de nuevas sucursales bajo una estricta optimización de recursos.

2.7.4 Analfabetismo de Datos (*Data Literacy*) y la Brecha Organizacional de Capital Humano

Más allá de las restricciones de infraestructura física y financiera, el cuello de botella más complejo de resolver radica en el factor humano y la cultura organizacional de la empresa. La ciencia de datos y el modelado predictivo exigen un perfil multidisciplinario que conjugue conocimientos avanzados en estadística matemática, programación e inferencia algorítmica, acoplados con un profundo dominio del negocio.

Mikalef P., Boura M., Lekakos G. y Krogstie J. (2019), en sus investigaciones empíricas sobre las capacidades analíticas de Big Data (*Big Data Analytics Capabilities, BDAC*), postulan que el rendimiento tecnológico está mediado por las capacidades dinámicas organizacionales y el factor humano. La mera adquisición de una tecnología avanzada no genera valor si el personal interno carece de la habilidad cognitiva para interpretar sus resultados y traducirlos en acciones tácticas.

En el estrato de las microempresas, se manifiesta de forma aguda el fenómeno del analfabetismo de datos (*Data Literacy Gap*). El propietario y los colaboradores operativos poseen competencias digitales básicas enfocadas en el soporte de la transacción del negocio (uso de terminales de cobro, redes sociales para marketing digital elemental u ofimática general), pero carecen de formación en interpretación de métricas estocásticas de error o intervalos de confianza probabilísticos.

Exponer a un tomador de decisiones habituado al "Pensamiento de Sistema 1" (intuición pura) a un vector crudo de predicciones matemáticas emanado de una "caja negra" algorítmica genera desconfianza cultural y resistencia al cambio. Si el administrador no comprende conceptualmente por qué el modelo penaliza el *RMSE* o cómo la Ingeniería de Características extrae las señales del entorno, tenderá a ignorar las recomendaciones del sistema ante la primera discrepancia con su instinto empírico, provocando el abandono de la herramienta analítica y el retorno a las prácticas heurísticas tradicionales.

2.7.5 La Democratización de la Ciencia de Datos y el Enfoque *Lean Data Science* como Vía de Solución

Para romper el ciclo de exclusión digital antes expuesto y viabilizar la transformación predictiva propuesta en esta tesis para el caso de Cup&Cake, la literatura científica contemporánea ha formulado un cambio de paradigma metodológico: la democratización de la ciencia de datos y el enfoque de analítica parsimoniosa ágil (*Lean Data Science*). **Dubey R. et al. (2021)** demuestran que la Inteligencia Artificial puede impulsar el desempeño operativo de organizaciones con recursos limitados si el despliegue tecnológico se ejecuta mediante metodologías que prioricen la simplicidad, la accesibilidad financiera y la interpretabilidad directa.

Este enfoque de democratización se fundamenta en la hibridación de tres habilitadores tecnológicos de código abierto y bajo costo:

- **Sistemas de *Machine Learning* Automatizado (*AutoML*):** Tecnologías que automatizan las fases computacionalmente complejas del ciclo analítico, tales como la imputación de valores faltantes, la normalización matemática de las series y la selección adaptativa del algoritmo óptimo para series de tiempo (**Bontempi, Ben Taieb, & Le Borgne, 2013**). Esto mitiga de forma directa la escasez de científicos de datos en la nómina corporativa.
- **Modelos Parsimoniosos Locales:** Privilegiar el uso de algoritmos de ensamble eficientes (como *Random Forest* de baja profundidad o modelos híbridos estadísticos) que pueden ser ejecutados de forma local en computadoras comerciales convencionales en fracciones de segundo, anulando la dependencia de costosos servidores en la nube.
- **La Inteligencia de Negocios (*BI*) como Puente Cognitivo:** Herramientas como *Un tablero web de inteligencia de negocios* actúan como el traductor visual definitivo. En lugar de presentar al microempresario ecuaciones abstractas, el tablero de *BI* absorbe el output del modelo de *Machine Learning* y lo despliega bajo una interfaz gráfica interactiva intuitiva (gráficos de tendencias, semáforos de riesgo de flujo de caja, alertas de compra automatizadas).

Al acoplar el rigor matemático del *Machine Learning* con la accesibilidad de una interfaz de BI de bajo costo, se reduce la fricción cognitiva del analfabetismo de datos. El microempresario de Tizayuca, Hidalgo, no requiere convertirse en programador; utiliza el tablero de control como un radar estratégico que complementa su conocimiento experto del entorno local. La analítica avanzada deja de ser una tecnología exclusiva de los grandes corporativos globales y se transforma en una herramienta de gestión democrática, viable y metodológicamente rigurosa que blindada la planeación financiera y dinamiza la cadena de suministro perecedera de la microempresa frente a los desafíos del mercado contemporáneo.

2.8 Conclusión del Marco Teórico

El desarrollo exhaustivo y sistemático del presente Marco Teórico establece la fundamentación científica, epistemológica y operativa que valida la transformación predictiva de la planeación financiera en el estrato microempresarial. A través de la deconstrucción analítica de la toma de decisiones, se demuestra de forma taxativa que el paradigma intuitivo tradicional, condicionado por las limitaciones cognitivas del "Pensamiento de Sistema 1" y los sesgos sistemáticos de sobreconfianza, anclaje y heurística de disponibilidad, resulta estructuralmente insuficiente para absorber la variabilidad no lineal de un mercado minorista dinámico que comercializa bienes altamente perecederos. Dependencia exclusivamente del empirismo histórico condena a la firma a una gestión reactiva, caracterizada por ineficiencias logísticas crónicas, mermas destructivas de capital de trabajo y una vulnerabilidad aguda ante crisis de liquidez.

Ante este colapso metodológico de la intuición pura, la convergencia entre el paradigma del *Data-Driven Decision Making* (DDDM), la arquitectura de la Inteligencia de Negocios y el arsenal algorítmico del Aprendizaje Automático (*Machine Learning* y *Deep Learning*) emerge no como un lujo tecnológico prescindible, sino como un imperativo estratégico de supervivencia corporativa. Como se dedujo a partir de los hallazgos de las competencias de pronóstico M4 y M5, la superioridad analítica del aprendizaje estadístico radica en su capacidad para purificar los datos del ruido blanco del mercado e incorporar variables exógenas complejas mediante una meticulosa Ingeniería de Características, superando la rigidez paramétrica de los modelos lineales univariados clásicos.

No obstante, el aporte medular de este marco conceptual es el establecimiento de un diseño de implementación riguroso adaptado a los escenarios hostiles de *Small Data*. Para mitigar la paradoja de la dimensionalidad y el riesgo de sobreajuste (*overfitting*) inherentes a las microempresas, la arquitectura analítica propuesta se blindo mediante la imposición matemática del principio de parsimonia a través de técnicas de regularización, acopladas de manera dogmática con el estándar de oro de la Validación por Ventanas Deslizantes (*Rolling-Origin Cross-Validation*).

Este protocolo de evaluación temporal estricto, evaluado bajo el prisma tridimensional del *MAE*, el *RMSE* y el *MAPE*, garantiza que las proyecciones de ingresos y requerimientos de abastecimiento posean la máxima estabilidad y fidelidad científica fuera de la muestra, proveyendo al microempresario de una métrica de riesgo fidedigna.

Finalmente, el análisis crítico de las barreras estructurales de adopción tecnológica permite justificar el diseño del Sistema de Soporte a la Decisión (DSS) implementado en el caso de la empresa Cup&Cake en Tizayuca, Hidalgo. Al instrumentalizar herramientas de Inteligencia de Negocios de bajo costo como un puente cognitivo que traduce la complejidad algorítmica en instrucciones visuales ejecutables, se derriban los muros del analfabetismo de datos y las restricciones presupuestarias.

La Inteligencia Artificial se democratiza, permitiendo sincronizar con precisión matemática las capacidades logísticas de abastecimiento con los flujos contables proyectados de efectivo. Este andamiaje conceptual y empírico dota a la presente investigación de la solidez metodológica requerida para someter a prueba la hipótesis general de esta tesis, demostrando que es científicamente viable transicionar del instinto de la intuición a la certidumbre estratégica de los datos para sustentar el crecimiento y la expansión de capital en las pequeñas unidades económicas de nuestro país.

3 METODOLOGÍA

Investigar significa llevar a cabo diferentes acciones o estrategias con el fin de descubrir algo. Así, dichos actos se dirigen a obtener y aplicar nuevos conocimientos, explicar una realidad determinada o a obtener maneras de resolver cuestiones y situaciones de interés. La investigación es la base del conocimiento científico, si bien no toda investigación es científica de por sí.

Para que un conocimiento sea científico es necesario que la investigación realizada se haga de forma sistemática, con unos objetivos claros y que parte de aspectos que puedan ser comprobados y replicados. Los resultados obtenidos deben ser analizados de forma objetiva y teniendo en cuenta las diversas variables que pueden estar afectando al fenómeno estudiado.

Como se ha dicho, se puede investigar desde muy diferentes perspectivas, con diferentes objetivos o teniendo en cuenta diferentes tipos de datos, procedimientos o métodos para obtenerlos.

Tipo de tesis: estudio aplicado, cuantitativo, no experimental y evaluativo, basado en un caso de estudio longitudinal-retrospectivo.

3.1 Tipo de investigación según el objetivo de ésta

Investigación aplicada

Se trata de una investigación centrada en evaluar un mecanismo concreto: el uso de modelos de aprendizaje automático para predecir el importe diario de compras de una microempresa de repostería creativa. El ámbito es específico y delimitado; no busca explicar una amplia variedad de situaciones ni atribuir causalidad sobre ingresos, sino contrastar precisión predictiva en un caso de estudio.

En este sentido, la investigación persigue un fin utilitario y estratégico: evaluar en qué medida la integración de modelos de Aprendizaje Automático (*Machine Learning*) y plataformas de Inteligencia de Negocios (*BI*) optimiza el desempeño de una organización real.

Específicamente, el conocimiento tecnológico generado se aplica de manera directa en la microempresa Cup&Cake en Tizayuca, Hidalgo, utilizándose como el mecanismo principal para sustituir el método empírico del propietario por proyecciones basadas en datos. Con ello, el estudio no busca explicar fenómenos de mercado generalizados, sino abordar y resolver la problemática particular de la organización, aplicando la Inteligencia Artificial para predecir el abastecimiento de materia prima, reducir la incertidumbre operativa y, consecuentemente, fortalecer su planeación financiera y potenciar el incremento de sus ingresos.

3.2 Según el alcance evaluativo del estudio

La investigación se puede llevar a cabo de diferentes formas y profundizando más o menos en cómo son o el porqué de las cosas.

La investigación profundiza en como actualmente **el propietario predice de manera empírica la compra de materia prima que necesita para cubrir las necesidades de un negocio de repostería creativa, mostrando dificultades para hacerlo adecuadamente**, a su vez el método empleado provoca un escenario poco confiable y con ello dificulta realizar planes de inversión a largo plazo.

Evaluativa y comparativa

Se trata de uno de los tipos de investigación más frecuentes y en los que la ciencia se centra. Es el tipo de investigación que se utiliza con el fin de intentar determinar las causas y consecuencias de un fenómeno concreto. Se busca no solo el qué sino el porqué de las cosas, y cómo han llegado al estado en cuestión.

En un estudio evaluativo se comparan alternativas de pronóstico bajo las mismas condiciones temporales. El objetivo es estimar cuál generaliza mejor fuera de muestra, no establecer relaciones de causa-efecto.

La presente investigación tiene un alcance evaluativo y comparativo. Describe el comportamiento histórico de ventas y compras y compara, bajo las mismas ventanas temporales, la precisión de reglas empíricas, modelos estadísticos y modelos de aprendizaje

automático. El diseño no permite atribuir causalidad sobre la rentabilidad, los ingresos o la eficiencia real de inventarios; su inferencia se limita al desempeño predictivo fuera de muestra.

En consecuencia, el diseño evaluativo busca determinar si la tecnología algorítmica aporta una mejora verificable de precisión respecto de las referencias comparadas. La inteligencia artificial se evalúa como una alternativa de apoyo para anticipar el presupuesto de abastecimiento, sin suponer que sustituye el juicio del responsable ni que genera automáticamente mejoras financieras u operativas.

3.3 Según el tipo de datos empleados

Otra manera de clasificar los diferentes tipos de investigación es según el tipo de datos que recojan. En este sentido nos podemos encontrar con los siguientes tipos.

Cuantitativa

La investigación cuantitativa se basa en el estudio y análisis de la realidad a través de diferentes procedimientos basados en la medición. Permite un mayor nivel de control e inferencia que otros tipos de investigación, siendo posible realizar experimentos y obtener explicaciones contrastadas a partir de hipótesis. Los resultados de estas investigaciones se basan en la estadística y son generalizables.

Atendiendo a la naturaleza de los datos recolectados y procesados, la presente investigación se fundamenta estrictamente bajo un enfoque **cuantitativo**. Este paradigma metodológico resulta de carácter obligatorio para el proyecto, debido a que el desarrollo de sistemas de Inteligencia de Negocios y el entrenamiento de algoritmos de aprendizaje automático exigen la manipulación matemática, estructuración analítica y el tratamiento estadístico de variables numéricas para identificar patrones de comportamiento robustos en el tiempo.

En el escenario operativo de Cup&Cake, este enfoque se operacionaliza mediante la recopilación e integración de conjuntos de datos brutos provenientes de los registros históricos de la microempresa, abarcando variables críticas como los ingresos, los volúmenes de ventas y las bitácoras de adquisición de materias primas. Asimismo, la naturaleza **cuantitativa** del estudio permite la codificación numérica de variables temporales y exógenas fundamentales

para el sector de la repostería creativa, tales como la estacionalidad cronológica (días de la semana y meses) y los picos atípicos de demanda correspondientes a fechas comerciales clave (como el 14 de febrero, 30 de abril y 10 de mayo).

La transformación de estos registros en matrices numéricas estructuradas permite alimentar y contrastar los modelos predictivos (tanto las líneas base estadísticas como los algoritmos supervisados de *Machine Learning*). De este modo, el nivel de control e inferencia del estudio no depende de apreciaciones cualitativas, sino de la validación matemática de la hipótesis mediante métricas de precisión estandarizadas: el Error Absoluto Medio (*MAE*), la Raíz del Error Cuadrático Medio (*RMSE*) y el Error Porcentual Absoluto Medio (*MAPE*). Este rigor analítico dota a los hallazgos de un carácter completamente verificable, reproducible y auditable, garantizando que el pronóstico resultante sea metodológicamente generalizable para la planeación financiera y estratégica del negocio.

3.4 Según el grado de manipulación de las variables

Podemos encontrar diferentes tipos de investigaciones según si los datos obtenidos parten de un nivel mayor o menor de manipulación de variables.

No experimental, evaluativa y retrospectiva

En un diseño no experimental se analizan datos observados sin manipular deliberadamente las condiciones de la empresa. La comparación temporal permite estimar desempeño predictivo, pero no inferir causalidad experimental.

Por las condiciones inherentes al caso de estudio, la investigación adopta un diseño no experimental, evaluativo y retrospectivo. No se introdujo una intervención deliberada en la operación de la empresa ni se asignaron grupos; se analizaron registros históricos en su secuencia temporal.

En el contexto de esta investigación, el objeto evaluado es la precisión predictiva del importe y la frecuencia de compras. La línea base representa reglas reproducibles basadas en el último valor disponible y el promedio móvil de siete días; los modelos estadísticos y de aprendizaje automático se comparan con ella en las mismas ventanas futuras.

Por consiguiente, el rigor del estudio proviene de la separación temporal estricta, la validación Rolling-Origin y la comparación homogénea contra referencias reproducibles. Estos elementos permiten evaluar generalización predictiva en condiciones históricas reales, sin afirmar causalidad experimental.

3.5 Diseño evaluativo y comparación contra la línea base

Se adoptó un diseño cuantitativo, aplicado, no experimental y evaluativo, basado en un estudio de caso longitudinal-retrospectivo. No se manipuló deliberadamente la operación de la empresa ni se asignaron grupos aleatorios; se analizaron registros históricos ordenados cronológicamente.

La comparación se operacionalizó como el contraste entre el error de la línea base empírica —último valor disponible y promedio móvil de siete días— y el error de los modelos predictivos en las mismas ventanas futuras. No se emplearon preprueba, posprueba ni grupos de control experimentales.

La comparación utilizó tres orígenes temporales finales. En cada iteración, el entrenamiento incluyó exclusivamente observaciones anteriores al periodo de prueba, preservando la secuencia causal y evitando fuga de información.

3.6 Según el tipo de inferencia

Otro tipo de clasificación se puede extraer a partir del método empleado a la hora de inferir cómo funciona la realidad.

De método deductivo

Este tipo de investigación se basa en el estudio de la realidad y la búsqueda de verificación o falsación de unas premisas básicas a comprobar. A partir de la ley general se considera que ocurrirá en una situación particular.

Atendiendo al proceso lógico empleado para inferir y estructurar el conocimiento sobre la realidad, la presente investigación se rige estrictamente por el **método deductivo**. Este enfoque inferencial se caracteriza por guiar el pensamiento de manera sistemática desde premisas, leyes y teorías universales consolidadas hacia la verificación, contrastación o falsación de una proposición particular aplicable a un escenario específico.

En el marco de este estudio, el proceso deductivo parte de los principios generales y abstractos de la Ciencia de Datos, las teorías del Aprendizaje Automático Supervisado y los fundamentos de la Inteligencia de Negocios (*Business Intelligence*). La literatura científica contemporánea postula, de forma generalizada, que la modelación matemática de patrones no lineales mediante algoritmos predictivos supera consistentemente a la heurística humana y a los métodos tradicionales en entornos caracterizados por la volatilidad y la alta incertidumbre.

Para someter a prueba esta ley general en el plano de la realidad empírica, la deducción se operacionaliza mediante la formulación de una hipótesis de investigación (*H1*). Esta premisa teórica postula que la implementación de modelos supervisados reducirá de forma significativa el error de pronóstico frente al método empírico actual del negocio. La hipótesis se somete a verificación mediante el análisis y procesamiento de los datos transaccionales y exógenos concretos de la microempresa Cup&Cake en Tizayuca, Hidalgo. De este modo, el flujo metodológico va de lo general a lo particular, buscando confirmar si las regularidades predictivas de la Inteligencia Artificial son capaces de solucionar de manera efectiva la problemática específica de planeación financiera y predicción de compra de materia prima en este caso de estudio

3.7 Temporalidad de la investigación

La investigación fue longitudinal y retrospectiva, porque examinó la evolución diaria de ventas y compras entre 2022 y 2026 mediante observaciones repetidas del mismo negocio. Esta temporalidad permitió estudiar estacionalidad, cambios de nivel, periodos sin actividad y estabilidad del error predictivo.

3.8 Procedimiento Metodológico

Para dar cumplimiento a los objetivos de la investigación y estructurar el diseño evaluativo, el desarrollo operativo se divide en fases secuenciales: recolección, integración, modelado, validación temporal y comunicación de resultados para el presupuesto de abastecimiento.

3.8.1 Recolección y estructuración de los conjuntos de datos (*Datasets*)

El primer paso metodológico consiste en la extracción y depuración de la información histórica de la microempresa Cup&Cake. Dado que las microempresas operan en entornos de *Small*

Data, el proceso requiere la consolidación de registros fragmentados para construir un conjunto de datos (dataset) estructurado y relacional. Se integrarán dos conjuntos de datos con información principalmente:

1. Histórico de ventas con ingresos diarios.
2. Bitácoras de compra de materia prima.

Esta estructuración permitirá transformar el empirismo del propietario en matrices cuantitativas, sentando la base matemática indispensable para el entrenamiento de los algoritmos predictivos.

3.8.2 Ingeniería de características y variables exógenas

En el sector de la repostería creativa, la demanda no presenta un comportamiento lineal, sino que está fuertemente condicionada por factores estacionales y comerciales. Por ello, se aplicarán técnicas de ingeniería de características (*feature engineering*) para enriquecer el conjunto de datos.

Se diseñarán variables temporales y exógenas que capturen los patrones cíclicos del negocio, tales como los días de la semana, fines de semana de quincena y, de manera crítica, fechas festivas o eventos especiales de alta demanda previamente identificados por el empresario (e.g., 14 de febrero, 30 de abril, 10 de mayo). La literatura advierte que la integración de estos componentes calendáricos mejora significativamente el rendimiento de los modelos algorítmicos frente a líneas base tradicionales.

3.8.3 Selección y configuración de modelos predictivos

Para garantizar la parsimonia y mitigar el riesgo de sobreajuste (*overfitting*) asociado a muestras de datos limitadas, se evaluará un abanico progresivo de algoritmos, partiendo de enfoques estadísticos clásicos hasta llegar a arquitecturas complejas de Aprendizaje Automático:

- **Modelos Estadísticos de Línea Base:** Se implementarán modelos Autorregresivos Integrados de Media Móvil (*ARIMA*) y su variante estacional (*SARIMA*), los cuales

permitirán capturar la estructura de autocorrelación interna de la serie temporal y servirán como punto de comparación fundamental.

- **Modelos Supervisados de Aprendizaje Automático:** Para capturar relaciones no lineales complejas, se integrarán algoritmos de regresión lineal multivariable y ensambles basados en árboles de decisión (*Random Forest*, *Gradient Boosting*).
- **Redes Neuronales:** Finalmente, se explorará la implementación de Redes Neuronales Recurrentes (*RNN*) y arquitecturas de Memoria a Corto y Largo Plazo (*LSTM*), las cuales poseen una capacidad superior para retener dependencias temporales prolongadas en las series de demanda.

3.8.4 Estrategias de partición temporal y validación

Al tratarse de series de tiempo financieras, la partición aleatoria clásica de datos (como el *train-test split* estándar) invalidaría el orden cronológico. Por lo tanto, se aplicará una técnica de validación cruzada de origen rodante (*Rolling-Origin Validation* o *Time Series Cross-Validation*).

Este método consiste en fijar un punto temporal de origen, entrenar el modelo con los datos pasados y predecir el horizonte futuro inmediato, desplazando gradualmente el punto de origen hacia adelante. En conjunto con técnicas de ajuste de hiperparámetros y regularización estadística, este enfoque garantiza la estabilidad predictiva, asegurando que el modelo tenga capacidad de generalización ante datos comerciales inéditos y evite memorizar anomalías históricas (ruido).

3.8.5 Métricas de evaluación del desempeño

La evaluación comparativa de los modelos algorítmicos y la línea base empírica se realizó calculando la discrepancia entre el valor real observado y la predicción. Se utilizaron las siguientes métricas estadísticas:

- **MAE (Error Absoluto Medio):** Mide la magnitud promedio de los errores en las predicciones de compra de materia prima, sin considerar su dirección.

- **RMSE (Raíz del Error Cuadrático Medio):** Penalizará de manera más severa las desviaciones grandes (errores catastróficos de predicción), lo cual es crítico en productos perecederos donde un sobreabastecimiento masivo genera mermas costosas.
- **MAPE (Error Porcentual Absoluto Medio):** Expresará el error del pronóstico en términos porcentuales, facilitando la interpretación gerencial del nivel de certidumbre para el microempresario.

3.8.6 Integración en Inteligencia de Negocios y comunicación del presupuesto de abastecimiento

La fase final del diseño metodológico consiste en traducir el rigor matemático en valor de negocio directo. Los resultados del modelo algorítmico de mayor precisión serán integrados y desplegados mediante un tablero interactivo de Inteligencia de Negocios.

Esta plataforma funcionará como el Sistema de Soporte a la Decisión (*DSS*) de Cup&Cake. A través de él, se estimará el impacto de los pronósticos en escenarios concretos de planeación financiera. El tablero permitirá realizar simulaciones dinámicas de escenarios comerciales (*What-If Analysis*), anticipando los flujos de abastecimiento y evaluando cuantitativamente el riesgo de expansión hacia nuevos puntos de venta operativos, sustituyendo así de manera definitiva la intuición por evidencia algorítmica y reduciendo el costo de oportunidad del negocio.

4 DESARROLLO

4.1 El repositorio

Se construyó un repositorio en GITHUB en el cual se podrá consultar todos los archivos creados para realizar la investigación. La fuente visual correspondiente se identifica en la Imagen 1.




Imagen 1 - Repositorio github

4.2 El contexto del negocio

4.2.1 El registro de ventas y compra de insumos

En 2022 Cup&Cake inició el registro de las ventas en un archivo de Excel, posteriormente adquirió una herramienta de uso comercial denominada KYTE lo cual le permitió generar un catálogo de productos y facilitó la exhibición de su catálogo de productos a través de una plataforma web de acceso libre a su vez le permitía la gestión de ventas dado que, para generar confianza en el cliente final, al realizar un pedido se le entrega un recibo digital. Para contar con la información unificada, se migró la información del archivo de Excel a la base de datos

de la plataforma KYTE. Dicha plataforma permite generar un reporte de ventas diarias el cual se emplea como primer fuente de datos.

Por otro lado, se tuvo la necesidad de conocer cuál es el comportamiento de compras de insumos y materia prima para la elaboración de cada pedido, se diseñó un sistema de apoyo para el registro de las compras realizadas, este sistema se creó en Microsoft Access, con ello, la información se ha ido acumulando al pasar los años. El acceso a la información es directa pues fue un diseño propio.

Los conjuntos de datos existentes

Tabla 2 - Conjuntos de datos de Ventas y Compras

Dimensión Analítica	Nombre de la Variable	Conjunto de Datos	Tipo de Dato
Identificadores y Estado	Number / NumPedido / Id	Ambos	Alfanumérico
	Status	Ambos	Categorico
	Pedido	Ventas	Alfanumérico
Variables Temporales	Fecha/Hora	Ambos	Timestamp
	Fecha, Año, Mes, Día	Ventas	Fecha / Numérico
Variables Financieras	Cantidad / Total de ítems	Ambos	Numérico (Entero)
	Subtotal	Venta	Numérico (Monetario)
	Descuento	Ventas	Numérico (Monetario)
	Tasa	Ventas	Numérico (Monetario)
	Envío	Ventas	Numérico (Monetario)
	Importe / Monto	Ambos	Numérico (Monetario)
	Ganancia	Ventas	Numérico (Monetario)
Descriptivas y Logística	Descri. Items	Ambos	Texto libre
	Nombre	Ambos	Texto
	Vendedor	Ventas	Categorico
	Observación	Ventas	Texto libre
Segmentación de Productos	Pastel,Galletas, Cupcakes, Otros	Ventas	Binario (0/1)

Como se observa en la Tabla 2, la arquitectura de ambos conjuntos de datos comparte dimensiones fundamentales (Temporales, Financieras y Logísticas). Esta homologación estructural es crucial para la investigación, ya que permite la vinculación directa entre el costo de abastecimiento (Compras) y la captación de ingresos (Ventas), facilitando la

implementación de métricas financieras de inteligencia de negocios y la evaluación precisa de la rentabilidad del proyecto. Los datos correspondientes se sintetizan en la Tabla 2.

4.2.1.1 Descripción General del Conjunto de Datos de Ventas

El conjunto de datos analizado corresponde a un registro histórico de transacciones comerciales de un negocio perteneciente al sector de la repostería y pastelería (enfocado en la venta de pasteles, cupcakes, galletas; de línea y personalizados). El dataset está estructurado en formato tabular (.csv) y cada fila representa un pedido o venta individual, capturando detalles operativos, financieros, temporales y logísticos.

Este dataset es fundamental para el estudio, ya que permite comprender la dinámica comercial, la rentabilidad y el comportamiento de consumo de los clientes a lo largo del tiempo.

Estructura y Clasificación de las Variables

El dataset cuenta con un amplio conjunto de características (columnas) que se pueden agrupar en cinco dimensiones principales para su análisis:

1. Identificadores y Estado Operativo:

- **Number / NumPedido:** Identificador único alfanumérico para cada transacción o pedido.
- **Status:** Estado del pedido en el flujo de venta (e.g., Venta, Pagado, Confirmado), lo que ayuda a auditar la conversión de los servicios.
- **Pedido:** Variable adicional de seguimiento interno del pedido.

2. Variables Temporales:

- **Fecha/Hora:** Marca de tiempo exacta (timestamp) en la que se generó la venta.
- **Fecha, Año, Mes, Día:** Variables extraídas y desglosadas cronológicamente para facilitar el modelado de series de tiempo, evaluar estacionalidad e identificar patrones de demanda en fechas festivas específicas.

3. Variables Financieras y Transaccionales:

- **Cantidad / Total de ítems:** Volumen o número de productos adquiridos en una sola transacción.
- **Subtotal:** Monto de la compra antes de ajustes.
- **Descuento:** Montos deducidos como parte de promociones o ajustes comerciales.
- **Tasa:** Cargos por impuestos o tasas adicionales.
- **Envío:** Costo asociado a la logística de entrega o envío a domicilio.
- **Importe:** Monto total final pagado por el cliente.
- **Ganancia:** Beneficio neto (utilidad) obtenido por cada pedido, siendo una variable clave para el análisis de rentabilidad del negocio.

4. Variables Descriptivas y de Entidades:

- **Descri. Items:** Descripción detallada (texto libre) de los artículos vendidos, incluyendo cantidades por tipo, combinaciones de sabores y características del postre (e.g., Red Velvet, Vainilla / Queso con Zarzamora).
- **Nombre:** Nombre o identificador del cliente que realizó la compra.
- **Vendedor:** Persona, sucursal o canal responsable de concretar la venta (e.g., Nancy Lopez, cup&cake Tizayuca).
- **Observación:** Notas en texto libre que incluyen instrucciones de personalización, dedicatorias, fechas y horas programadas para entregas futuras y condiciones logísticas.

5. Variables de Segmentación de Productos (Dummies / Contadores):

- **Pastel, Galletas, Cupcakes, Otros:** Variables indicadoras numéricas o binarias (0 y 1) que señalan de forma estructurada si el pedido incluyó esa categoría de producto específico. Esto facilita el análisis estadístico rápido sin necesidad de procesar los textos de las descripciones.

Potencial Analítico

La riqueza de este dataset permite realizar diversos análisis cuantitativos y cualitativos, tales como:

- **Análisis de Rentabilidad:** Evaluación de los márgenes de ganancia por línea de producto o por canal de venta.
- **Comportamiento del Consumidor:** Minería de texto en las descripciones (Descri. Items y Observación) para identificar tendencias en sabores preferidos o temáticas más solicitadas.
- **Pronóstico de Demanda:** Uso de las variables temporales para modelos predictivos (Machine Learning/Series de tiempo) orientados a estimar ventas futuras o preparar inventarios.

4.2.1.2 Descripción General del Conjunto de Datos de Compras (Egresos)

El presente conjunto de datos corresponde al registro histórico de abastecimiento, adquisiciones y egresos operativos del negocio. Estructurado en formato tabular (.csv), cada fila documenta una transacción de compra individual, capturando la trazabilidad logística y financiera de las materias primas y materiales de empaque necesarios para la operación.

Este dataset es un pilar fundamental para la investigación, ya que permite modelar el flujo de salida de capital y la recurrencia de adquisición de insumos, elementos críticos para estructurar modelos orientados a la optimización de la cadena de suministro en el rubro de la repostería creativa.

Estructura y Clasificación de las Variables

Las variables que conforman este conjunto de datos se agrupan en cuatro dimensiones analíticas principales:

1. Identificadores y Estado de la Transacción:

- **Number / Id:** Identificadores únicos (alfanuméricos) que aseguran la integridad referencial de cada transacción de compra y evitan la duplicidad de registros en la base de datos.
- **Status:** Clasificador del estado operativo de la transacción (e.g., Compra), que permite filtrar los registros efectivamente consolidados en el inventario.

2. Variables Temporales:

- **Fecha/Hora:** Marca de tiempo exacta (timestamp) en la que se efectuó o registró la adquisición.
- **Fecha, Año, Mes, Día:** Variables temporales extraídas y desglosadas. Esta separación es crucial para la integración en algoritmos de aprendizaje automático (Machine Learning) y modelos de series de tiempo, permitiendo detectar ciclos de reabastecimiento y la estacionalidad en la compra de insumos.

3. Variables Financieras y de Clasificación de Costos:

- **Cantidad / Total de ítems:** Volumen físico o cantidad de lotes de los productos adquiridos.
- **Subtotal, Tasa, Envío, Descuento:** Desglose financiero de la compra, separando el costo base de los impuestos, los costos logísticos de transporte y los beneficios por negociaciones con proveedores.
- **Importe:** Flujo de salida total (egreso real) de la transacción.
- **Costo fijo:** Variable binaria o categórica (e.g., 0, 1) de alto valor analítico, que permite discriminar entre los gastos variables directos de la cadena de suministro (materia prima) y los gastos operativos constantes del negocio.

4. Variables Descriptivas y Logísticas:

- **Descri. Items:** Descripción detallada del insumo o material adquirido (e.g., Cajas decoradas, Base cupcake, Domo cupcake). Esta columna de texto libre es esencial para la categorización del inventario mediante técnicas de procesamiento de lenguaje natural (NLP) o minería de texto.
- **Nombre:** Identificador del usuario, responsable o proveedor asociado a la transacción (e.g., Nancy Lopez).
- **Observación:** Campo de texto libre destinado a documentar incidencias de entrega, condiciones especiales de la compra o información logística complementaria.

Potencial Analítico y Justificación Metodológica

La integración armónica de este dataset de compras con el de ventas permite una visión holística del ciclo de vida del producto. Desde una perspectiva analítica y de optimización, el dataset facilita:

- **Gestión Inteligente de Inventarios:** El análisis de las frecuencias de compra (variables temporales) cruzado con el volumen de adquisición (Cantidad) ayuda a prevenir cuellos de botella y escenarios de desabastecimiento o sobrestock.
- **Análisis de Eficiencia en Costos:** La separación explícita a través de la variable Costo fijo permite aislar los costos variables (insumos y empaques) para calcular el margen de contribución unitario y evaluar el impacto real de la inflación o el costo logístico (Envío) en la rentabilidad.

4.2.2 Conjuntos de datos de variables exógenas temporales y comerciales

4.2.2.1 Descripción General del Conjunto de Datos de Variables Exógenas Calendáricas (Contexto Tizayuca)

El conjunto de datos Tabla 3 integra una serie histórica (ene 2022- may 2026) de variables exógenas correspondientes al municipio de Tizayuca. Estructurado en formato tabular (.csv), este documento recopila factores ambientales, de calendario económico y sociodemográficos que ocurren de forma paralela a las operaciones del negocio.

Tabla 3 - Conjunto de datos de variables exógenas (Contexto Tizayuca, Hgo.)

Dimensión Analítica	Nombre de la Variable	Tipo de Dato
Integración Temporal	Fecha	Fecha (Date)
Calendario / Económica	EsFestivoMexicano	Binario (0/1)
	EsFechaPago	Binario (0/1)
Meteorológica	TemperaturaMax	Númérico (Entero)
	TemperaturaMin	Númérico (Entero)
	Clima	Categórico
Sociodemográfica	NacimientosIndice	Númérico (Entero)

A diferencia de los registros transaccionales internos, este dataset captura el entorno en el que opera la sucursal. Su función en la investigación es actuar como un bloque de variables independientes (características o *features*) para entrenar algoritmos de Inteligencia Artificial, permitiendo que el modelo comprenda el contexto externo que motiva o inhibe el

comportamiento de compra del consumidor en la repostería creativa. Los datos correspondientes se sintetizan en la Tabla 3.

Estructura y Clasificación de las Variables

Las variables que conforman este dataset se pueden agrupar en cuatro dimensiones contextuales:

1. Llave Temporal de Integración:

- **Fecha:** Marca cronológica diaria (YYYY-MM-DD). Esta es la variable fundamental (llave primaria) que permite fusionar este dataset con los registros transaccionales de Ventas y Compras para crear un modelo de datos unificado.

2. Variables de Calendario Económico y Cultural:

- **EsFestivoMexicano:** Variable dicotómica que identifica los días feriados oficiales o de alta relevancia cultural en el país. Resulta vital para modelar picos atípicos de demanda en festividades.
- **EsFechaPago:** Variable dicotómica que señala los días de quincena o pago de nómina. Es un excelente indicador proxy de la liquidez disponible del consumidor en la región.

3. Variables Meteorológicas:

- **TemperaturaMax y TemperaturaMin:** Registros numéricos de las condiciones térmicas diarias.
- **Clima:** Variable categórica (e.g., *Soleado*) que describe la condición atmosférica general. El clima tiene una correlación directa comprobada con el tráfico de clientes en puntos de venta físicos y la predisposición al consumo de postres específicos.

4. Variables Sociodemográficas (Proxys de Demanda):

- **NacimientosIndice:** Índice numérico que funciona como una variable proxy excepcional. Dado que el rubro principal del caso de estudio incluye pasteles de celebración, la fluctuación en las tasas de natalidad históricas (y sus aniversarios)

representa un indicador adelantado para predecir la demanda de productos de cumpleaños en la región.

Potencial Analítico y Justificación Metodológica

La incorporación de este dataset al ecosistema de datos del proyecto es el diferenciador metodológico para la optimización de la cadena de suministro mediante Inteligencia Artificial:

- **Entrenamiento de Modelos Predictivos Avanzados:** Algoritmos como *ARIMAX*, *Prophet* o *XGBoost* requieren de este tipo de regresores externos para no solo "adivinar" el futuro basado en el pasado, sino "entender" que un pico de ventas se debió a una combinación de factores (ej. *fue quincena, clima soleado y festivo*).
- **Gestión Proactiva de la Cadena de Suministro:** Al predecir la demanda con mayor exactitud utilizando el clima y las fechas de pago, el negocio puede programar sus órdenes de compra de materia prima perecedera (lácteos, harinas, mermeladas) con precisión, minimizando la merma y asegurando la disponibilidad de inventario para productos estrella.

4.2.2.2 Descripción General del Conjunto de Datos de Variables Exógenas Inflación INPC

$$\text{Importe real}_t = \text{Importe nominal}_t \times (\text{INPC_base} / \text{INPC}_t) \quad (5)$$

Ecuación - Deflactación de importes monetarios.

Este nuevo conjunto de datos (Tabla 4) recopila la serie histórica y proyectada (2022-2026) del Índice Nacional de Precios al Consumidor (INPC), el cual actúa como el indicador macroeconómico oficial para medir la inflación en el contexto mexicano. Estructurado en formato tabular (.csv) con una periodicidad mensual, este registro captura las fluctuaciones porcentuales en el nivel general de precios de la economía. La relación se formaliza en la ecuación (5).

Tabla 4 - Inflación histórica en México (INPC)

Dimensión Analítica	Nombre de la Variable	Tipo de Dato
Integración Temporal	Fecha	Timestamp / Fecha
Indicador Macroeconómico	Valor	Numérico (Continuo)

La incorporación de esta métrica exógena en la investigación metodológica tiene como objetivo dotar a los algoritmos de aprendizaje automático de una dimensión económica global. Esto permite al sistema correlacionar las tendencias inflacionarias con el incremento en los costos operativos de abastecimiento y la posible contracción o elasticidad en la demanda de productos de repostería creativa. Los datos correspondientes se sintetizan en la Tabla 4.

Estructura y Clasificación de las Variables

El esquema de datos se caracteriza por su alta especificidad y baja dimensionalidad, centrándose en dos variables fundamentales:

- **Fecha:** Marca temporal cronológica con granularidad mensual. Funciona como la llave primaria de agregación macroeconómica. Para su correcta integración con los *datasets* operativos internos (Ventas y Compras), requiere un proceso de transformación (*ETL*) que homologue su periodicidad a nivel diario o semanal mediante técnicas de interpolación o propagación de valores.
- **Valor:** Variable cuantitativa continua de tipo numérico (flotante). Representa la tasa de inflación anualizada o el factor de variación del índice para el periodo correspondiente. Esta métrica sirve como un regresor exógeno continuo para el modelado predictivo.

Potencial Analítico y Justificación Metodológica

Desde la perspectiva de la Inteligencia Artificial y la ciencia de datos aplicada a la cadena de suministro, este dataset proporciona ventajas metodológicas clave:

- **Modelado de Tendencias de Costos a Largo Plazo:** Al cruzar la variable *Valor* (INPC) con el dataset de Compras, los modelos predictivos (como redes neuronales *LSTM* o algoritmos de gradiente impulsado como *XGBoost*) pueden aislar el efecto inflacionario del incremento de precios de proveedores. Esto facilita la proyección de presupuestos de compra y la detección de anomalías en los precios de insumos críticos (lácteos, harinas, empaques personalizados).

- **Ajuste Dinámico de Márgenes de Ganancia:** La inflación altera directamente la relación entre los costos y los precios de venta. Integrar el INPC permite evaluar el comportamiento histórico de la variable *Ganancia* en el dataset de Ventas frente a los periodos de mayor presión inflacionaria, fundamentando la toma de decisiones prescriptivas para el ajuste estratégico de precios sin afectar severamente la demanda en la región de Tizayuca.

Dado que el dataset de INPC (Tabla 4) posee una granularidad mensual (registrando el primer día de cada mes) y los registros transaccionales de Ventas y Compras operan a nivel de marca de tiempo diaria, se estableció en la arquitectura del pipeline de datos una estrategia de **imputación por propagación hacia adelante (Forward Fill)**. De esta manera, el valor de la inflación correspondiente a un mes específico se asocia uniformemente a cada uno de los días de dicho periodo, permitiendo que el algoritmo de Machine Learning evalúe el entorno macroeconómico diario de manera homogénea y sin pérdida de registros en el proceso de combinación (*Join*)

4.2.2.3 Descripción General del Conjunto de Datos de Variables Exógenas Temperatura (Contexto Tizayuca)

Este conjunto de datos complementa el análisis de variables exógenas incorporando un **factor ambiental crítico: la temperatura histórica regional**. Aunque el archivo lleva por nombre *Temperatura_Tizayuca.csv*, al inspeccionar su estructura se observa que contiene un registro de cobertura nacional desglosado por entidades federativas de México (incluyendo el estado de **Hidalgo**, donde se localiza el municipio de Tizayuca).

En industrias como la repostería y la pastelería fina, las condiciones climáticas medias tienen un impacto directo comprobado tanto en la conservación física de las materias primas (como coberturas de chocolate, cremas y fondant) como en los hábitos estacionales de consumo de los clientes.

Descripción General del Conjunto de Datos de Temperatura Regional

El presente conjunto de datos recopila la serie histórica y proyectada (2022-2026) de las temperaturas medias mensuales a nivel estatal en la República Mexicana, sirviendo como proxy climático para el área de influencia comercial del proyecto. Estructurado en formato tabular (.csv), el registro consolida información meteorológica oficial extraída de reportes anuales consolidados de la Comisión Nacional del Agua (CONAGUA¹) en formato PDF por año. La fuente visual correspondiente se identifica en la Imagen 2.



**Temperatura Media por Entidad Federativa y Nacional
2026**

Estado	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic	Anual
Aguascalientes	14.1	17.2	18.1	21.3	22.7								
Baja California	15.3	16.5	20.3	18.8	20.3								
Baja California Sur	20.0	20.8	23.2	24.3	25.1								
Campeche	23.4	23.4	26.8	28.9	31.0								
Coahuila	14.0	19.1	22.2	24.4	26.4								
Colima	26.0	25.8	26.1	27.4	28.6								
Chiapas	22.9	22.2	25.6	27.2	28.5								
Chihuahua	10.5	14.7	18.6	20.2	22.8								
Ciudad de México	15.4	17.5	17.1	19.9	20.6								
Durango	13.0	16.4	18.7	21.3	23.0								
Guanajuato	15.1	16.9	18.1	21.5	23.1								
Guerrero	24.6	24.7	25.7	27.5	28.5								
Hidalgo	14.9	16.5	17.9	21.1	22.3								
Jalisco	18.3	20.0	21.4	23.6	25.3								
Estado de México	12.3	14.7	14.2	16.7	17.6								
Michoacán	17.5	19.5	20.3	22.3	23.7								
Morelos	20.0	21.3	23.0	25.3	26.4								
Nayarit	23.2	23.7	25.0	26.3	28.6								
Nuevo León	15.4	20.2	22.5	23.5	25.4								
Oaxaca	20.9	21.3	23.7	25.1	27.0								
Puebla	15.1	16.9	17.5	19.6	21.4								
Querétaro	15.9	18.1	19.0	22.6	23.7								
Quintana Roo	23.7	23.5	26.1	27.3	29.6								
San Luis Potosí	17.4	19.7	22.6	26.0	26.6								
Sinaloa	22.1	22.1	25.2	27.4	29.0								
Sonora	16.8	19.2	22.8	23.5	25.1								
Tabasco	23.2	23.7	26.7	28.7	30.8								
Tamaulipas	18.0	21.2	24.6	26.3	28.0								
Tlaxcala	12.2	16.1	14.4	17.0	18.3								
Veracruz	18.7	19.8	22.0	24.4	26.5								
Yucatán	22.7	23.1	26.3	27.8	30.5								
Zacatecas	13.2	16.4	17.5	20.6	22.2								
Nacional	17.0	19.3	21.9	23.7	25.4								

Imagen 2 - Temperatura Media por Entidad Federativa y Nacional, contenido en PDF

Para los fines de la investigación, este dataset (Tabla 5) proporciona la variabilidad térmica ambiental del estado de Hidalgo. Su propósito metodológico es servir como un regresor exógeno continuo de mediano plazo para que los modelos de Inteligencia Artificial identifiquen correlaciones macro climáticas con la demanda de productos de repostería.

¹ <https://smn.conagua.gob.mx/es/climatologia/temperaturas-y-lluvias/resumenes-mensuales-de-temperaturas-y-lluvias>

Tabla 5 - Temperatura mensual (Tizayuca, Hgo.)

Dimensión Analítica	Nombre de la Variable	Tipo de Dato
Segmentación Geográfica	Estado	Categorico
Dimensión Temporal	Mes	Categorico
	fecha	Fecha (Date)
Métrica Ambiental	Valor	Numérico (Continuo)
Trazabilidad de Datos	archivo	Texto

Estructura y Clasificación de las Variables

El *dataset* cuenta con una estructura limpia y estandarizada compuesta por las siguientes variables:

- **Estado:** Variable categórica que identifica la entidad federativa de la transacción (e.g., *Hidalgo*). Funciona como la variable de filtrado geográfico para aislar el contexto de la sucursal objeto de estudio.
- **Mes:** Variable cualitativa nominal que abrevia el periodo mensual evaluado (e.g., *Ene*, *Feb*, *Mar*).
- **Valor:** Variable cuantitativa continua de tipo numérico (flotante). Representa la temperatura media mensual registrada en grados Celsius (°C) para ese estado en específico.
- **fecha:** Marca temporal cronológica estandarizada (DD/MM/AAAA) fijada al primer día de cada mes. Actúa como la llave de indexación temporal para el cruce de datos.
- **archivo:** Variable de metadatos en texto libre que documenta el archivo fuente (e.g., *2022.pdf*) del cual se digitalizó u obtuvo la información, aportando trazabilidad y auditoría a la base de datos.

Potencial Analítico y Justificación Metodológica

La inclusión de la temperatura mensual dentro de la arquitectura de datos aporta un valor significativo a la cadena de suministro y la planeación comercial:

- **Elasticidad de la Demanda según el Clima:** El modelo predictivo puede aprender patrones estacionales complejos. Por ejemplo, temperaturas medias elevadas en los meses de primavera/verano suelen correlacionarse con variaciones en el tipo de postres

solicitados (preferencia por productos más frescos o caídas en la demanda de repostería densa), permitiendo programar la producción de manera eficiente.

- **Estabilidad y Logística de Insumos:** Conocer las proyecciones o tendencias de temperatura permite correlacionar el *dataset* de Compras para identificar si en los meses con picos de calor se incrementan los costos logísticos (envíos refrigerados o mermas en almacén de materias primas sensibles como lácteos y chocolates).

Debido a que el archivo `Temperatura_Tizayuca.csv` posee una cobertura político-administrativa a nivel nacional, la primera etapa del pipeline de preprocesamiento de datos consistió en un filtrado por máscara booleana sobre la columna Estado, aislando exclusivamente las observaciones correspondientes a 'Hidalgo'. Adicionalmente, dado que la temperatura se presenta con una granularidad mensual y los modelos predictivos operan a nivel diario, se implementó una técnica de interpolación lineal temporal sobre la variable Valor. Esto permitió suavizar la transición térmica entre meses y asignar a cada día del año un valor estimado de temperatura, evitando cambios abruptos artificiales en los límites mensuales del entrenamiento del algoritmo de *Machine Learning*. La representación visual correspondiente se presenta en la Figura 27.

4.3 El proceso de construcción del dataset maestro




Figura 27 - Trazabilidad del pipeline analítico de la investigación.

4.3.1 Análisis Exploratorio de Datos (EDA)

El propósito de este trabajo fue construir una base de datos unificada, diaria y lista para modelado, que permita:

1. Predecir la demanda o ventas diarias.
2. Utilizar esa predicción como base para estimar compras futuras.
3. Integrar variables exógenas que ayuden al modelo a capturar estacionalidad, efectos de calendario y condiciones externas.

La salida final se preparó como un dataset maestro con una fila por día, desde 2022-01-01 hasta 2026-05-31.

Fuentes utilizadas

Se trabajó con cinco archivos de entrada:

1. Compras.xlsx
2. Ventas.xlsx
3. Dataset_Tizayuca_2022_2026.xlsx
4. INPC_2022_2026.csv
5. Temperatura_Tizayuca.csv

Criterio general de integración

Se definió como unidad de análisis un registro por día.

Esto implicó:

1. Limpiar cada fuente por separado.
2. Estandarizar nombres, fechas y tipos de datos.
3. Generar tablas diarias agregadas para compras y ventas.
4. Crear un calendario completo para todo el periodo.
5. Unir todas las variables sobre la misma llave temporal: fecha.

Reglas de limpieza aplicadas

Estandarización de fechas

Se convirtieron las fechas al formato de fecha diaria (YYYY-MM-DD) para evitar inconsistencias en:

- Fechas con hora.

- Formatos mezclados.
- Fechas mensuales frente a diarias.

Normalización de texto

Se aplicó limpieza de texto para:

- Eliminar espacios duplicados.
- Quitar acentos.
- Homogeneizar mayúsculas y minúsculas.
- Estandarizar etiquetas categóricas.

Tratamiento de duplicados

Se identificaron y removieron duplicados exactos en las fuentes donde era necesario, especialmente en compras.

Valores faltantes

Se manejaron de forma distinta según el archivo:

- En variables numéricas agregadas se imputó 0 cuando el día no tenía registros.
- En el detalle de compras y ventas se conservaron los campos útiles y se eliminaron filas incompletas solo cuando afectaban la calidad del análisis.

Ajuste por inflación

Se utilizó el INPC para deflactar montos nominales a pesos de mayo de 2026.

Esto permitió construir variables comparables en el tiempo:

- Compras reales ajustadas.
- Ventas reales ajustadas.
- Ganancia, subtotal, envío y descuentos reales ajustados.

$$Importe_t^{real} = Importe_t^{nominal} \left(\frac{INPC_{mayo2026}}{INPC_t} \right)$$

Los importes nominales se ajustaron mediante el cociente entre el INPC del periodo de referencia y el INPC correspondiente a la fecha de cada observación .

Limpieza por archivo

Con el propósito de documentar el proceso de preparación de la información utilizada en el estudio, la Tabla 6 - Síntesis de fuentes de datos y transformaciones aplicadas presenta las principales características de cada archivo, su función dentro del análisis, las variables conservadas o generadas y los procedimientos de limpieza, homologación, agregación e integración realizados. Esta síntesis permite identificar de manera estructurada cómo se construyó la base analítica final y cómo se garantizó la consistencia temporal, climática y monetaria de los datos.

Tabla 6 - Síntesis de fuentes de datos y transformaciones aplicadas

Fuente de datos	Propósito dentro del estudio	Variables conservadas o generadas	Transformaciones aplicadas	Resultado y observaciones
Dataset_Tizayuca_2022_2026.xlsx	Base para incorporar variables temporales, climáticas y exógenas al modelo.	EsFestivoMexico no EsFechaPago TemperaturaMax TemperaturaMin Clima NacimientosIndice	• Renombrado de columnas con un formato homogéneo. • Conversión de la variable Clima a texto estandarizado. • Ordenamiento cronológico de los registros.	El archivo ya se encontraba estructurado con una observación por día y cubría el periodo comprendido entre el 1 de octubre de 2022 y el 31 de mayo de 2026.
INPC_2022_2026.csv	Índice mensual utilizado para convertir los valores monetarios nominales en valores reales comparables.	Fecha INPC_mes INPC_base FactorAjuste	• Conversión de la fecha al primer día de cada mes. • Filtrado al periodo de análisis. • Selección de mayo de 2026 como periodo base. • Cálculo del factor de ajuste mediante la fórmula: Factor de ajuste = INPC base / INPC del mes.	La fecha base seleccionada fue el 1 de mayo de 2026. El factor calculado se utilizó para deflactar los importes de compras y ventas.
Temperatura_Tizayuca.csv	Complementar la información climática con una serie histórica mensual de temperatura.	Estado Fecha Temperatura Promedio	• Filtrado de los registros correspondientes a Hidalgo. • Conversión de las fechas a periodicidad mensual. • Construcción de una serie mensual de temperatura promedio. • Expansión posterior de la información mensual a nivel diario.	Aunque el archivo incluía información de varios estados, únicamente se conservaron los datos de Hidalgo. La serie mensual se integró al calendario maestro diario.
Compras.xlsx — detalle limpio	Conservar información granular de las adquisiciones	Proveedor Fecha Número Cantidad	• Selección de registros y variables relevantes. • Homologación de nombres y formatos. • Ajuste de montos y	Se obtuvo una tabla detallada y depurada de compras, con importes expresados tanto en valores

	realizadas durante el periodo de análisis.	UnidadMedida Descripción MontoNominal MontoRealAjustado PrecioUnitarioNominal PrecioUnitarioRealAjustado Clasificación Subclasificación	precios unitarios mediante el INPC. • Organización de los productos mediante clasificación y subclasificación.	nominales como en valores reales de mayo de 2026.
Compras.xlsx — tabla diaria agregada	Representar el comportamiento diario de las compras y facilitar su integración con el calendario maestro.	Columnas pivotadas por Clasificación. NumeroRegistrosCompra TotalNominal TotalRealAjustado CantidadTotalCompra Fecha de venta, importe, cliente, vendedor, observaciones, estado y demás variables transaccionales válidas, excluyendo columnas redundantes o derivadas.	• Agrupación de registros por fecha. • Creación de columnas pivotadas por clasificación. • Cálculo de métricas totales diarias. • Integración con un calendario completo del periodo. • Imputación de ceros en días sin compras. • Priorización de la columna Fecha y uso de Fecha/Hora cuando fue necesario. • Conservación de registros con importe válido. • Normalización de nombres, vendedores, observaciones y estados. • Eliminación de registros duplicados. • Eliminación de columnas derivadas o redundantes. • Conservación de ventas incompletas cuando contenían información válida.	Se generó una tabla con una fila por día. Todos los días del periodo fueron incluidos y aquellos sin compras se representaron con valores iguales a cero.
Ventas.xlsx — detalle limpio	Obtener una base confiable y granular de las operaciones de venta.		• Agrupación de registros por fecha. • Creación de columnas pivotadas por clasificación. • Cálculo de métricas totales diarias. • Integración con un calendario completo del periodo. • Imputación de ceros en días sin compras. • Priorización de la columna Fecha y uso de Fecha/Hora cuando fue necesario. • Conservación de registros con importe válido. • Normalización de nombres, vendedores, observaciones y estados. • Eliminación de registros duplicados. • Eliminación de columnas derivadas o redundantes. • Conservación de ventas incompletas cuando contenían información válida.	Fue el archivo que requirió la depuración más cuidadosa debido a registros sin estado, duplicados, fechas con hora, columnas derivadas y operaciones parcialmente incompletas.
Ventas.xlsx — tabla diaria agregada	Construir los indicadores diarios de actividad comercial utilizados en el análisis y modelado.	NumeroRegistros PedidosUnicos ImporteNominal ImporteRealAjustado SubtotalNominal y SubtotalReal GananciaNominal y GananciaReal EnvioNominal EnvioReal DescuentoNominal y DescuentoReal CantidadTotal TotalItems ClientesUnicos	• Agrupación de operaciones por día. • Conteo de pedidos, clientes y vendedores únicos. • Suma de cantidades, artículos e importes. • Ajuste monetario de las métricas mediante el INPC. • Integración con el calendario completo. • Asignación de ceros a los días sin ventas.	Se obtuvo una tabla con una observación por día, incluyendo métricas nominales y reales. Los días sin actividad comercial se conservaron con valores iguales a cero para mantener la continuidad temporal.

Fuente: Elaboración propia a partir del proceso de integración, limpieza y transformación de las bases de datos del proyecto.

Construcción del dataset maestro

Se generó un archivo final llamado dataset_maestro_diario.xlsx con una única hoja:

- maestro

Variables incluidas

El dataset final contiene variables agrupadas en cuatro bloques:

Tipo	Variable
Calendario y exógenas	fecha
	es_festivo_mexicano
	es_fecha_pago
	nacimientos_indice
	temperatura_promedio_mensual_hidalgo
Ventas	inpc_valor_mensual
	ventas_registros
	ventas_pedidos_unicos
	ventas_importe_real_2026_05
	ventas_ganancia_real_2026_05
	ventas_envio_real_2026_05
	ventas_descuento_real_2026_05
	ventas_cantidad_total
	ventas_total_items
	ventas_pastel
	ventas_galletas
	ventas_otros
	ventas_cupcakes
	ventas_clientes_unicos
	ventas_vendedor_unico
Compras	compras_registros
	compras_total_real_2026_05
	compras_cantidad_total
	Columnas pivotadas por clasificación, por ejemplo:
	compras_harina_real_2026_05
	compras_chocolate_real_2026_05
	compras_empaque_real_2026_05
Clima codificado	compras_fondant_real_2026_05
	clima_DÉSPEJADO
	clima_LLUVIOSO
	clima_SIN_DATO
	clima_SOLEADO

Resultados de calidad del dataset final

Como resultado del proceso de depuración, homologación e integración, el dataset maestro final quedó conformado por 1,612 observaciones diarias y 65 variables. Cada fila representa

un día del periodo comprendido entre el 1 de enero de 2022 y el 31 de mayo de 2026, por lo que se obtuvo una serie temporal continua de 1,612 días y una base homogénea para los análisis posteriores.

Las verificaciones de calidad confirmaron que no existen fechas omitidas dentro del intervalo analizado ni valores nulos en las columnas del archivo maestro. Esta completitud temporal y estructural reduce el riesgo de sesgos asociados con interrupciones en la serie y evita la necesidad de aplicar imputaciones adicionales antes de la ingeniería de características y del entrenamiento de los modelos. Los valores iguales a cero se conservaron cuando representan días sin actividad operativa y, por tanto, no deben interpretarse como datos ausentes.

Archivos generados

Como evidencia del proceso de preparación y para asegurar la trazabilidad de las transformaciones, los productos finales se almacenaron en la carpeta outputs/. Cada archivo corresponde a una etapa específica de limpieza, corrección, integración o documentación del análisis:

- dataset_maestro_diario.xlsx: base consolidada con granularidad diaria y todas las variables integradas.
- ventas_limpias.xlsx: registros de ventas depurados y estandarizados.
- compras_limpias.xlsx: versión inicial de los registros de compras después del proceso de limpieza.
- compras_limpias_corregidas.xlsx: versión corregida y validada de los registros de compras.
- dataset_tizayuca_limpio.xlsx: variables contextuales del municipio, preparadas para su integración.
- inpc_limpio.xlsx: serie del INPC homologada para el ajuste de los importes monetarios.
- temperatura_hidalgo_limpia.xlsx: serie climática filtrada y preparada para el estado de Hidalgo.
- eda_resumen.md: síntesis de los principales hallazgos del análisis exploratorio de datos.

En conjunto, estos archivos constituyen la evidencia intermedia y final del flujo de procesamiento. Su conservación permite reproducir la construcción del dataset maestro, auditar las decisiones de limpieza y utilizar versiones consistentes de los datos en las etapas posteriores de modelado y evaluación.

4.3.2 Ingeniería de Características (Feature Engineering)

Resultado de la transformación

La aplicación del proceso de ingeniería de características generó el archivo `dataset_modelado_diario.xlsx`, integrado por 1,584 observaciones diarias y 276 columnas. Su cobertura temporal comprende del 29 de enero de 2022 al 31 de mayo de 2026. En comparación con el dataset maestro, esta estructura conserva la granularidad diaria, pero amplía el espacio de variables mediante predictores derivados que representan el calendario, la estacionalidad, el contexto externo y el comportamiento histórico del negocio.

Variables objetivo

Para el análisis se definieron como variables objetivo principales `target_ventas_importe_real_2026_05` y `target_compras_total_real_2026_05`. La primera representa el importe diario de las ventas, mientras que la segunda corresponde al valor diario de las compras. Ambas se expresan en pesos reales de mayo de 2026, lo que permite realizar comparaciones temporales sin que la variación general de los precios distorsione el aprendizaje de los modelos.

La consideración conjunta de ambos objetivos permite estudiar dos componentes relacionados de la operación: el comportamiento de la demanda y los requerimientos de abastecimiento. No obstante, cada variable se modela por separado para conservar una interpretación clara de sus determinantes y de sus respectivos errores de pronóstico.

Estrategia de generación de características

La estrategia de modelado combina variables de calendario y estacionalidad con representaciones cíclicas del mes, el día de la semana y el día del año. Estas últimas se construyeron mediante funciones seno y coseno para conservar la continuidad natural de los ciclos temporales y evitar saltos artificiales entre periodos consecutivos, como diciembre y enero o domingo y lunes.

También se incorporaron indicadores de proximidad a días festivos y fechas de pago, debido a que estos eventos pueden modificar el momento y la intensidad de la demanda. Para representar la memoria temporal de las series se generaron rezagos de 1, 2, 3, 7, 14 y 28 días, además de estadísticos calculados en ventanas móviles de 7, 14 y 28 días. Esta combinación permite capturar efectos inmediatos, semanales y de mediano plazo.

La representación se complementó con rezagos desagregados por categorías de ventas y compras, así como con variables de estabilidad, recencia y tendencia. De esta manera, el modelo puede distinguir entre patrones generales de la operación y comportamientos particulares de los distintos productos o insumos, sin limitarse al valor agregado diario.

Tratamiento de la ventana inicial

Debido a que el rezago máximo y la ventana móvil más extensa abarcan 28 días, se eliminaron las primeras 28 observaciones del dataset maestro. Esta decisión explica que el periodo efectivo de modelado comience el 29 de enero de 2022 y que el número de registros se reduzca de 1,612 a 1,584. La pérdida de observaciones es controlada y se concentra exclusivamente al inicio de la serie; no corresponde a fechas faltantes, sino a la necesidad de asegurar que todas las filas utilizadas por los modelos dispongan de un historial completo y comparable.

Desarrollo del proceso

El procedimiento se implementó mediante el script `feature_engineering_profesional.py`, que transforma el dataset maestro diario en un panel temporal preparado para aprendizaje

supervisado. El proceso no se limita a reorganizar la información: genera variables de calendario, integra factores exógenos e indicadores del contexto económico y operativo, y construye características históricas asociadas con las ventas y las compras.

Para preservar la validez temporal del experimento, cada predictor se calculó únicamente con información disponible antes de la fecha que se desea pronosticar. Este desplazamiento evita la fuga de información y permite que el desempeño obtenido represente de forma más realista las condiciones de uso del modelo. Las transformaciones específicas aplicadas al dataset original se describen a continuación.

Transformaciones aplicadas al dataset original

La transformación del dataset maestro se realizó de forma secuencial para conservar la relación temporal entre las observaciones y convertir los registros operativos en predictores adecuados para el aprendizaje supervisado. Las etapas aplicadas se describen a continuación.

Preparación temporal y variables de calendario

En primer lugar, el dataset maestro diario se ordenó cronológicamente. La columna fecha se convirtió al tipo datetime y se utilizó como referencia temporal para todas las transformaciones posteriores. Esta operación asegura que los rezagos, las ventanas móviles y las divisiones temporales respeten la secuencia real de los acontecimientos.

A partir de la fecha se obtuvieron variables de año, trimestre, mes, semana del año, día del mes, día de la semana y día del año. Asimismo, se crearon indicadores binarios para identificar fines de semana, inicios y cierres de mes, además de variables auxiliares como el número de días del mes, los días transcurridos desde su inicio y los días restantes hasta su conclusión. Estas características permiten representar regularidades calendarias que podrían influir en la demanda y en la programación de las compras. La relación se formaliza en la ecuación (6).

Codificación cíclica de las variables temporales

$$x_{\text{sen}} = \sin(2\pi x/P); \quad x_{\text{cos}} = \cos(2\pi x/P) \quad (6)$$

Ecuación - Codificación cíclica de una variable temporal.

El mes, el día de la semana y el día del año poseen una estructura periódica que no queda representada adecuadamente mediante números enteros. Por esta razón, dichas variables se transformaron en pares de componentes seno y coseno. Para una posición temporal x dentro de un ciclo de longitud P , la representación se obtiene mediante $\sin(2\pi x/P)$ y $\cos(2\pi x/P)$. Con ello se preserva la cercanía entre el final y el inicio de cada ciclo, como ocurre entre diciembre y enero o entre domingo y lunes, y se evitan discontinuidades artificiales que podrían dificultar el aprendizaje de los modelos.

Variables exógenas y proximidad a eventos

El panel se enriqueció con información externa y contextual: días festivos mexicanos, fechas de pago, índice de nacimientos, temperatura promedio mensual, inflación mensual y variables indicadoras de las categorías climáticas. La inclusión de estos factores permite evaluar si parte de la variación de las ventas o de las compras se relaciona con condiciones económicas, ambientales o de calendario que no dependen directamente de la operación interna de Cup&Cake.

Para los festivos y las fechas de pago se calcularon tanto los días transcurridos desde el evento anterior como los días faltantes para el siguiente. También se generaron conteos acumulados en ventanas de 7 y 30 días, utilizando únicamente eventos anteriores para representar su intensidad reciente. Las variables que anticipan el siguiente evento no producen fuga de información, puesto que las fechas del calendario oficial y de pago se conocen antes del momento de elaborar el pronóstico.

Características históricas y composición por categoría

$$\text{lag}_k(y_t) = y_{t-k}; \quad MA_w(y_t) = (1/w) \sum_{i=1}^w y_{t-i} \quad (7)$$

Ecuación - Rezagos y media móvil sin información futura.

Para las series principales de ventas y compras se construyeron rezagos de 1, 2, 3, 7, 14 y 28 días. Además, se calcularon la media, la desviación estándar y la suma en ventanas móviles de 7, 14 y 28 días. Antes de calcular cada estadístico móvil, la serie se desplazó un día; por consiguiente, el valor asignado a una fecha determinada resume exclusivamente observaciones anteriores. Los distintos horizontes permiten capturar persistencia inmediata, patrones semanales, variaciones recientes y tendencias de mediano plazo. La relación se formaliza en la ecuación (7).

La misma lógica se aplicó de forma desagregada a las categorías de venta de pasteles, galletas, cupcakes y otros productos, así como a los componentes monetarios de las compras. Para estas variables se generaron rezagos de 1 y 7 días y medias móviles de 7 días. Esta desagregación permite que el modelo reconozca comportamientos específicos de los productos e insumos que podrían quedar ocultos en los totales diarios.

Estabilidad y relación entre ventas y compras

Con el propósito de representar el equilibrio operativo reciente, se calculó la razón entre las medias móviles de ventas y compras de siete días, junto con la diferencia monetaria entre ambas. También se incorporaron variables de recencia que cuantifican los días transcurridos desde la última venta y la última compra con valor distinto de cero. Estos indicadores aportan información sobre la continuidad de la actividad, los periodos de inactividad y la relación dinámica entre entradas y requerimientos de abastecimiento.

Objetivos predictivos y control de fuga de información

El procedimiento generó cuatro variables objetivo asociadas con el comportamiento diario de la operación: los importes reales de ventas y compras, y el número de registros de ventas y compras. Para la comparación principal de los modelos se priorizaron los objetivos monetarios, mientras que los conteos se conservaron como salidas auxiliares que permiten analizar la frecuencia de las transacciones.

El control de fuga de información se estableció mediante el desplazamiento temporal de los predictores históricos. Ningún rezago o estadístico móvil utiliza valores del día que se intenta estimar ni de fechas posteriores. Adicionalmente, se eliminaron las primeras 28 observaciones, ya que no disponían del historial completo requerido por la ventana máxima. De esta forma, cada fila del conjunto de modelado reproduce la información que habría estado disponible en una situación real de pronóstico.

Limpieza y exportación del resultado

Las divisiones entre cero producidas al calcular algunos cocientes se identificaron como valores infinitos y se convirtieron inicialmente en valores ausentes. Después, tanto estos casos como los valores no definidos derivados de las transformaciones se sustituyeron por cero, de acuerdo con la regla implementada en el pipeline, para obtener una matriz numérica completa y estable antes del entrenamiento.

Finalmente, el resultado se exportó al archivo `dataset_modelado_diario.xlsx`. Este libro contiene las hojas modelo, diccionario y resumen: la primera almacena el panel preparado para el aprendizaje supervisado; la segunda documenta el nombre, la función y la clasificación de las variables; y la tercera registra las principales características de la ejecución. De manera complementaria, se generó un resumen en formato Markdown para conservar una evidencia legible del proceso y facilitar su incorporación a la documentación de la tesis.

Valor metodológico del proceso

En términos metodológicos, la ingeniería de características convierte un conjunto de registros transaccionales en una representación analítica capaz de expresar relaciones que no aparecen de forma directa en las variables originales. Los rezagos, las ventanas móviles, la codificación cíclica y los indicadores de contexto hacen observables la dependencia temporal, la estacionalidad, la recencia de la actividad y la posible influencia de factores económicos, climáticos y comerciales. De esta manera, los modelos no se limitan a asociar valores contemporáneos, sino que disponen de información estructurada sobre el comportamiento previo del negocio.

Este enriquecimiento también introduce un reto metodológico: el número de predictores aumenta sin que crezca el número de observaciones. El dataset modelado contiene 1,584 registros y 276 columnas, lo que equivale aproximadamente a 5.7 observaciones por variable antes de separar los periodos de ajuste, validación y prueba. En un contexto de Small Data, esta relación incrementa el riesgo de redundancia, multicolinealidad y sobreajuste; por ello, la ampliación de variables debe complementarse con diagnóstico dimensional, selección de características y comparación con representaciones de menor dimensión.

El valor del procedimiento no depende únicamente de ampliar la capacidad predictiva. La construcción determinista de las variables, el orden cronológico de las observaciones y el desplazamiento de los predictores históricos fortalecen la reproducibilidad y la validez temporal del experimento. Estas condiciones permiten atribuir las diferencias de desempeño a los modelos y a las representaciones evaluadas, y no a la incorporación accidental de información futura.

Metodología propuesta para el análisis dimensional y el modelado

Contexto y criterios de reducción dimensional

El archivo dataset_modelado_diario.xlsx integra variables calendáricas y exógenas, rezagos, estadísticas móviles, composición de ventas y compras, indicadores de estabilidad y cuatro variables objetivo. Esta diversidad permite representar el problema desde perspectivas temporales, operativas, financieras y contextuales; sin embargo, no implica que todas las columnas aporten información independiente o útil para cada objetivo de pronóstico.

En consecuencia, la reducción dimensional no se planteó como una eliminación indiscriminada de variables, sino como una comparación controlada entre información disponible, relevancia predictiva e interpretabilidad. La decisión se fundamentó en tres criterios complementarios.

Capacidad predictiva. La representación reducida debe conservar las señales necesarias para pronosticar la demanda, los ingresos y las compras. Una disminución del número de variables

solo es favorable si el desempeño fuera de muestra se mantiene o mejora frente al dataset completo.

Interpretabilidad financiera y operativa. Las variables seleccionadas deben permitir relacionar los resultados con decisiones comprensibles para Cup&Cake, como la programación de compras, la evolución de los ingresos, la actividad por categoría y la respuesta ante eventos del calendario. Esta condición evita privilegiar una reducción numérica que elimine el significado empresarial del modelo.

Validez temporal. Toda comparación debe respetar el orden de la serie y mantener separados los periodos de entrenamiento, validación y prueba. Tanto la selección de características como el ajuste de hiperparámetros deben realizarse con información anterior al periodo evaluado para impedir la fuga de información y obtener una estimación realista de la capacidad de generalización.

Secuencia reproducible de ejecución

El análisis dimensional y el modelado se organizaron como una cadena de etapas dependientes. Cada script recibe las salidas de la fase anterior y genera archivos de evidencia que permiten auditar las decisiones tomadas. La numeración que se presenta corresponde a los nombres vigentes dentro del pipeline maestro.

Etapas 0. Configuración metodológica

El archivo `config_metodologia.py` centraliza las rutas de entrada y salida, las variables objetivo, las particiones temporales y las reglas utilizadas para clasificar las columnas. Su función es mantener una configuración común entre los análisis y reducir inconsistencias derivadas de parámetros definidos de forma independiente en cada script.

Etapas 1. Perfil del dataset y sus dimensiones

El script `03_perfil_dataset_y_dimensiones.py` describe cada variable, agrupa las columnas por dimensión metodológica y cuantifica propiedades como la presencia de valores nulos,

variables constantes y concentración de ceros. Este perfil constituye el inventario inicial del dataset y permite distinguir entre ausencia de información, intermitencia operativa y falta de variabilidad.

Etapas 2. Diagnóstico de multicolinealidad

$$VIF_j = 1 / (1 - R_j^2) \quad (8)$$

Ecuación - Factor de inflación de la varianza.

Mediante 04_diagnostico_multicolinealidad.py se identifican predictores altamente correlacionados y se proponen variables que pueden conservarse o eliminarse para reducir redundancia. El diagnóstico se complementa con el factor de inflación de la varianza (VIF) cuando statsmodels está disponible. La correlación examina relaciones por pares, mientras que el VIF permite detectar dependencias de una variable respecto del conjunto de predictores. La relación se formaliza en la ecuación (8).

Etapas 3. Selección de características

El archivo 05_seleccion_caracteristicas_dataset_reducido.py genera un ranking específico para cada variable objetivo y construye una versión reducida del dataset. La selección considera la asociación con el objetivo y, cuando las dependencias necesarias están disponibles, incorpora métodos de aprendizaje automático y regularización. La ruta basada en correlación se conserva como mecanismo de contingencia, pero la evaluación temporal posterior determina si la reducción realmente aporta capacidad predictiva.

Etapas 4. Reducción mediante componentes principales

$$Z = XW ; Varianza\ acumulada(m) = \sum_{j=1}^m \lambda_j / \sum_{j=1}^p \lambda_j \quad (9)$$

Ecuación - Transformación PCA y varianza explicada acumulada.

El script 06_pca_reduccion_componentes.py produce una representación alternativa mediante análisis de componentes principales (PCA). Esta técnica concentra la varianza de los

predictores en componentes ortogonales y reduce los efectos de la multicolinealidad. Su principal ventaja es la compactación del espacio de entrada; su principal limitación es la pérdida de interpretabilidad directa, debido a que cada componente combina múltiples variables originales. La relación se formaliza en la ecuación (9).

Etapas 5. Modelos estadísticos y de aprendizaje automático

Con `07_modelos_estadisticos_ml_rolling_origin.py` se comparan el método empírico, ARIMA y SARIMA, regresión lineal, árboles de decisión y bosque aleatorio. La evaluación utiliza validación Rolling-Origin para simular pronósticos sucesivos a lo largo del tiempo y reporta MAE, RMSE y MAPE. El ajuste de hiperparámetros se realiza con orígenes anteriores a los reservados para evaluación, de modo que las configuraciones finales se prueben en periodos no utilizados durante su selección.

Etapas 6. Redes neuronales recurrentes

Finalmente, `08_rnn_lstm_dataset_reducido.py` entrena arquitecturas RNN y LSTM mediante ventanas temporales. Estas redes se aplican a las versiones reducida y PCA, ya que el número limitado de observaciones hace poco conveniente alimentar las arquitecturas con todas las columnas originales. Las configuraciones se validan en un bloque temporal anterior a la prueba y las alternativas ganadoras se reentrenan con el historial de desarrollo disponible.

En conjunto, esta secuencia genera tres representaciones comparables —dataset completo, dataset reducido y dataset PCA— y somete sus resultados a un mismo esquema temporal de evaluación. Así, la selección final puede sustentarse simultáneamente en precisión, estabilidad, parsimonia e interpretabilidad, en lugar de depender únicamente del mejor ajuste observado durante el entrenamiento.

4.4 Diagnóstico de la línea base empírica y evaluación comparativa

Tabla 7 - Operacionalización de la línea base y los modelos predictivos

Componente	Definición operacional	Indicador
------------	------------------------	-----------

Preprueba	Método empírico: último valor o promedio de 7 días	RMSE y MAE de referencia
Posprueba	Mejor modelo evaluado en los mismos orígenes	RMSE y MAE del modelo
Contraste	Reducción relativa del RMSE	Umbral de H1: 20 %

La línea base representó una referencia empírica reproducible con la que se contrastaron los modelos. Para cada objetivo se evaluaron la persistencia del último valor y el promedio móvil de siete días; se conservó como referencia el método con menor RMSE en cada ventana temporal. Este planteamiento permitió cuantificar la ganancia predictiva sin equiparar la línea base con un grupo control ni atribuir causalidad experimental. Los datos correspondientes se sintetizan en la Tabla 7.

4.5 Auditoría, Depuración e Integración del Conjunto de Datos (Dataset)

Tabla 8 - Trazabilidad de los conjuntos analíticos

Conjunto	Observaciones	Variables	Cobertura o criterio
Dataset maestro	1,612	65	2022-01-01 a 2026-05-31; sin fechas faltantes
Dataset modelado	1,584	276	2022-01-29 a 2026-05-31
Dataset reducido	1,584	85	80 predictores, fecha y cuatro objetivos
Dataset PCA	1,584	135	130 componentes, fecha y cuatro objetivos

La auditoría examinó cobertura temporal, duplicados, valores nulos, consistencia de tipos, concentración de ceros y continuidad diaria. Después de homologar fechas, categorías y unidades monetarias reales, las fuentes se integraron por fecha en un dataset maestro trazable. El pipeline completo finalizó sin errores y produjo artefactos de control para cada etapa. La representación visual correspondiente se presenta en la Figura 24. Los datos correspondientes se sintetizan en la Tabla 8.

4.6 Ingeniería de Características (Feature Engineering) y Variables Exógenas




Figura 24 - Expansión dimensional producida por la ingeniería de características.

Tabla 9 - Dimensiones principales de las variables modeladas

Dimensión	Número de variables	Finalidad analítica
Rezagos	126	Memoria temporal de corto y mediano plazo
Ventanas móviles	105	Nivel, dispersión y acumulación reciente
Calendario y estacionalidad	19	Ciclos semanales, mensuales y anuales
Otras variables	21	Exógenas, relaciones, estabilidad y objetivos

La ingeniería de características transformó las series originales en una representación supervisada de 271 predictores. Se incorporaron calendario, codificación cíclica, eventos

exógenos, rezagos, ventanas móviles, composición por categorías, estabilidad y recencia. Todas las características históricas se desplazaron temporalmente y se eliminaron los primeros 28 días para asegurar ventanas completas. La representación visual correspondiente se presenta en la Figura 25. Los datos correspondientes se sintetizan en la Tabla 9.

4.7 Desarrollo, Configuración y Entrenamiento de los Modelos Predictivos




Figura 25 - Arquitecturas recurrentes consideradas para el modelado temporal.

Tabla 10 - Familias de modelos y configuración evaluada

Familia	Configuración general	Representaciones
Empírica	Persistencia y promedio móvil de 7 días	Serie original
ARIMA/SARIMA	Órdenes seleccionados por objetivo	Completa y univariada
Regresión y árboles	Lineal, árbol de decisión y Random Forest	Completa, reducida y PCA
Redes recurrentes	RNN simple y LSTM con ventanas temporales	Reducida y PCA

Se compararon enfoques empíricos, ARIMA/SARIMA, regresión lineal, árboles, Random Forest, RNN y LSTM. Cada familia se entrenó sobre representaciones completa, reducida y

PCA cuando resultó procedente. Los hiperparámetros se seleccionaron dentro del conjunto de entrenamiento de cada origen temporal; la comparación final privilegió RMSE, MAE, estabilidad entre ventanas e interpretabilidad. La representación visual correspondiente se presenta en la Figura 26. Los datos correspondientes se sintetizan en la Tabla 10.

4.8 Evaluación comparativa del rendimiento predictivo frente a la línea base




Figura 26 - Esquema de validación temporal Rolling-Origin.

$$\begin{aligned} RMSE &= (1/K) \sum_k RMSE_k; \text{Entrenamiento}_k = \{t \leq \tau_k\}, \\ Prueba_k &= \{\tau_k < t \leq \tau_k + h\} \end{aligned} \quad (10)$$

Ecuación - Formalización de la validación Rolling-Origin.

La evaluación se ejecutó mediante Rolling-Origin. Los conjuntos de entrenamiento crecieron de forma acumulativa y cada prueba se situó después del último dato empleado para ajustar el modelo. La selección global se basó en el promedio del error y su variabilidad en los tres orígenes finales. La representación visual correspondiente se presenta en la Figura 28. La relación se formaliza en la ecuación (10).

4.9 Arquitectura e Integración del Tablero de Inteligencia de Negocios (DSS)




Figura 28 - Arquitectura funcional del sistema de soporte a la decisión.

El tablero desarrollado para Cup&Cake funciona como un sistema de soporte a la decisión (Decision Support System, DSS) que integra los resultados del pipeline predictivo y los transforma en información comprensible para la planeación financiera y de abastecimiento. Su propósito no es sustituir el criterio de la persona responsable del negocio, sino reducir la complejidad de los resultados estadísticos, hacer explícitas sus limitaciones y facilitar decisiones sustentadas en evidencia.

Arquitectura tecnológica

La implementación se encuentra en la carpeta dashboard del proyecto. La versión operativa de la interfaz está contenida en `public/index.html` y utiliza HTML, hojas de estilo y JavaScript ejecutado en el navegador. El archivo `app/page.tsx` actúa como punto de entrada del proyecto y remite a la versión estática publicada. Esta decisión reduce dependencias durante la consulta, facilita la portabilidad y permite reproducir la misma vista de resultados en diferentes equipos.

Para su distribución, `scripts/build-static.mjs` empaqueta el documento HTML y genera un servicio compatible con Cloudflare Workers. El servicio entrega la aplicación con encabezados

de seguridad, control de caché y una ruta de verificación de disponibilidad. La interfaz es adaptable a distintos tamaños de pantalla y contempla etiquetas semánticas, descripciones para la gráfica y contraste para temas claro y oscuro. Estas características favorecen el acceso al DSS desde computadoras o dispositivos móviles sin requerir software analítico especializado.

Integración de los resultados predictivos

Los resultados consolidados se incorporan al tablero como una estructura de datos en JavaScript. Para cada objetivo se almacenan el modelo ganador, la versión del dataset utilizada, los valores promedio de RMSE, MAE y MAPE, la cobertura temporal efectiva, las observaciones excluidas y los errores obtenidos en tres ventanas de evaluación Rolling-Origin. Esta organización conserva la relación entre la configuración seleccionada y la evidencia con la que fue evaluada.

El flujo de integración puede resumirse de la siguiente manera: las salidas del pipeline de modelado se consolidan por variable objetivo; posteriormente se seleccionan el modelo y el dataset con menor RMSE promedio; los resultados se incorporan a la estructura interna del tablero; y, finalmente, la interfaz calcula la mejora frente a la línea base elegida y actualiza los indicadores, la gráfica y la interpretación para la decisión. De esta forma, el tablero constituye la capa de presentación del proceso analítico y mantiene trazabilidad con la validación temporal.

Filtros e indicadores para la decisión

La interfaz permite seleccionar cuatro objetivos: importe real de ventas, número de registros de venta, importe real de compras y número de registros de compra. También permite alternar entre dos referencias empíricas: el promedio móvil de siete días y el último valor observado. Esta combinación posibilita examinar el desempeño desde una perspectiva monetaria o de frecuencia operativa y comprobar si la conclusión se mantiene al cambiar el criterio de comparación.

Como indicadores principales, el tablero muestra el modelo ganador, el dataset asociado, el RMSE promedio, el MAE promedio y el porcentaje de reducción de RMSE respecto de la línea base. La mejora se calcula como la diferencia entre el RMSE de referencia y el RMSE del modelo, dividida entre el RMSE de referencia y expresada en porcentaje. Una barra de progreso y un estado cualitativo indican si se alcanza la reducción mínima de 20% establecida en la hipótesis H1.

La visualización central compara el RMSE del modelo y el método empírico en tres ventanas temporales. Esta desagregación evita que un promedio global oculte periodos con errores elevados y permite valorar la estabilidad del pronóstico. El panel lateral complementa la gráfica con una lectura ejecutiva, una advertencia metodológica, el MAPE, la cobertura efectiva y el número de días excluidos. Finalmente, una franja de calidad resume las dimensiones de los datasets, el periodo analizado y la ausencia de valores nulos en el maestro.

Resultados incorporados al DSS

Para los objetivos de ventas, el tablero identifica modelos ARIMA sobre el dataset completo. El importe de ventas utiliza una configuración ARIMA (1,1,2), con RMSE promedio de 161.1493, mientras que el número de registros de venta utiliza ARIMA (1,1,1), con RMSE de 0.5251. Frente al promedio móvil de siete días, las reducciones aproximadas son 3.2% y 5.1%, respectivamente; por lo tanto, las mejoras no alcanzan el umbral de 20% establecido en H1.

En compras, los resultados favorecen a Random Forest entrenado con el dataset reducido. Para el importe real de compras se obtuvo un RMSE promedio de 213.0144 frente a 297.2899 de la línea base de siete días, equivalente a una reducción aproximada de 28.3%. Para el número de registros de compra, el RMSE disminuyó de 3.3579 a 2.5932, lo que representa una mejora aproximada de 22.8%. Ambos objetivos superan la meta de H1 cuando se utiliza esta línea base.

La conclusión global presentada por el DSS es, por consiguiente, parcial: la evidencia apoya la hipótesis para las variables de compras, pero no para las de ventas. El tablero evita una

aceptación general de H1 y muestra que la utilidad del aprendizaje automático depende del objetivo específico, del comportamiento de la serie y de la referencia empírica utilizada.

Interpretación operativa y salvaguardas

El DSS traduce cada resultado en una recomendación operativa. Para las compras, la reducción de errores extremos respalda el uso de Random Forest como insumo para la presupuestación y la programación del abastecimiento. Para las ventas, la mejora moderada de ARIMA sugiere conservar políticas de seguridad y evitar asumir que una mayor complejidad garantiza un pronóstico superior. Asimismo, el tablero advierte que el MAPE puede resultar inestable en días con valores reales cercanos a cero, por lo que la interpretación principal se apoya en RMSE y MAE.

La cobertura temporal se presenta como una condición de uso y no como un dato secundario. Las variables de ventas abarcan hasta el 31 de mayo de 2026, mientras que la información de compras termina el 30 de julio de 2025 y deja 305 días sin cobertura. Esta advertencia impide interpretar las mejoras de compras como una autorización automática para desplegar el modelo con información desactualizada; antes de su utilización operativa es necesario actualizar la fuente y volver a ejecutar el proceso de validación. La representación visual correspondiente se presenta en la Figura 29.

Alcance actual de la integración




Figura 29 - Interfaz funcional del tablero DSS implementado para Cup&Cake.

En su estado actual, el tablero funciona como una instantánea reproducible de los resultados finales. El esquema de base de datos del proyecto permanece vacío y los indicadores están integrados directamente en el código de la interfaz; por ello, la aplicación no actualiza automáticamente sus valores cuando se incorporan nuevas ventas, compras o ejecuciones del pipeline. Esta arquitectura es adecuada para comunicar y auditar los resultados de la tesis, pero debe distinguirse de un sistema transaccional conectado en tiempo real.

Para una implementación continua en Cup&Cake, la siguiente evolución consistiría en automatizar la exportación de los resultados ganadores hacia una fuente de datos consumida por el tablero, incorporar controles de actualización y registrar la fecha de la última ejecución. Aun con esta limitación, el prototipo cumple la función central de un DSS: integrar evidencia predictiva, compararla con la práctica empírica, comunicar incertidumbre y facilitar que la decisión final permanezca bajo responsabilidad del usuario del negocio. La representación visual correspondiente se presenta en la Figura 30.

4.10 Alcance del apoyo al presupuesto de abastecimiento




Figura 30 - Flujo de decisión operativa asistido por el DSS.

El DSS permite explorar el comportamiento de los objetivos, comparar el desempeño contra la línea base y revisar estabilidad por ventana. Su alcance es anticipar el importe y la frecuencia de compras como apoyo para reservar presupuesto de abastecimiento. No genera órdenes automáticas ni cantidades físicas por insumo, porque los registros no contienen de manera consistente recetas, inventario inicial/final, merma, tiempos de entrega ni unidades de medida homologadas. Por rigor científico, los resultados se interpretan como apoyo diagnóstico y de planeación presupuestal.

5 RESULTADOS

Calidad, cobertura e integración de datos

El pipeline se completó sin errores. El dataset maestro reunió 1,612 días consecutivos entre el 1 de enero de 2022 y el 31 de mayo de 2026, con 65 columnas, sin fechas faltantes ni valores nulos. Después de exigir 28 días de historia para rezagos y ventanas, el dataset de modelado conservó 1,584 observaciones. La cobertura de ventas llegó a mayo de 2026; la de compras terminó el 30 de julio de 2025, por lo que 305 días posteriores se excluyeron de la evaluación de esos objetivos.

Reducción dimensional

El perfil inicial identificó 271 predictores. La selección supervisada conservó 80 variables y produjo un dataset reducido de 85 columnas al añadir fecha y cuatro objetivos. Como representación alternativa, PCA necesitó 130 componentes para explicar al menos 95 % de la varianza, lo que confirma que la estructura informativa se encontraba distribuida en numerosas dimensiones. La mejora frente a la línea base y la selección de modelos se muestran, respectivamente, en las Figuras 31 y 32.

Rendimiento comparativo de los modelos




Figura 31 - Mejora relativa del RMSE frente a la línea base empírica.




Figura 32 - Mejor modelo por objetivo y representación de datos.

Resultados de redes neuronales recurrentes

Las arquitecturas RNN y LSTM no superaron a los modelos ganadores. El mejor RMSE recurrente fue 163.777 para importe de ventas, 0.545 para registros de ventas, 239.714 para importe de compras y 2.748 para registros de compras. El resultado respalda el uso de modelos más parsimoniosos ante el tamaño muestral disponible y la demanda intermitente.

Contraste de hipótesis

La hipótesis H1 estableció una reducción mínima de 20 % en el RMSE del importe diario de compras frente a la línea base. El umbral se alcanzó en importe y registros de compras mediante Random Forest. En consecuencia, H1 se respaldó para el presupuesto de

abastecimiento. Los resultados de ventas se reportan como análisis complementario y muestran que ARIMA fue más competitivo en ese dominio.

Resultados del tablero DSS

El tablero integró los modelos ganadores, métricas globales, desempeño por ventana, cobertura y contraste de hipótesis. Los filtros permiten seleccionar objetivo y representación; las salvaguardas advierten cuando la cobertura está desactualizada o la mejora no alcanza el umbral. La interfaz funciona como capa de comunicación analítica y mantiene la decisión final bajo responsabilidad del usuario. Las métricas y el criterio comparativo se formalizan en las ecuaciones (11), (12), (13), (14) y (15).

$$\text{Mejora_RMSE} = 100 \times (\text{RMSE_base} - \text{RMSE_modelo}) / \text{RMSE_base} \quad (11)$$

Ecuación - Reducción relativa del RMSE frente a la línea base.

$$\text{WAPE} = 100 \times \Sigma_i |y_i - \hat{y}_i| / \Sigma_i |y_i| \quad (12)$$

Ecuación - Error porcentual absoluto ponderado como diagnóstico complementario.

$$\text{MAPE} = (100/|I|) \Sigma_i \in I |(y_i - \hat{y}_i)/y_i|, \quad I = \{i: y_i \neq 0\} \quad (13)$$

Ecuación - Error porcentual absoluto medio sobre observaciones no nulas.

$$\text{RMSE} = \sqrt{[(1/n) \Sigma_{i=1}^n (y_i - \hat{y}_i)^2]} \quad (14)$$

Ecuación - Raíz del error cuadrático medio.

$$\text{MAE} = (1/n) \Sigma_{i=1}^n |y_i - \hat{y}_i| \quad (15)$$

Ecuación - Error absoluto medio.

ARIMA fue la familia ganadora para ambos objetivos de ventas, mientras que Random Forest sobre el dataset reducido obtuvo el mejor desempeño en compras. Los resultados se resumen en la Tabla 11; la MAPE se reporta únicamente como referencia debido a la elevada frecuencia de valores cero.

Tabla 11 - Modelos ganadores y desempeño temporal

Objetivo	Modelo y representación	MAE	RMSE	Mejora RMSE
Importe de ventas	ARIMA(1,1,2)	101.951	161.149	3.2 %
Registros de ventas	ARIMA(1,1,1)	0.362	0.525	5.1 %
Importe de compras	Random Forest, reducido	116.961	213.014	28.3 %
Registros de compras	Random Forest, reducido	1.727	2.593	22.8 %

6 DISCUSION

Interpretación de los hallazgos

La superioridad de ARIMA en ventas indica que la dinámica agregada se explica mejor mediante dependencia temporal y diferenciación que mediante una estructura de alta complejidad. En compras, Random Forest capturó relaciones no lineales entre rezagos, ventanas y composición categórica, con mejoras superiores al umbral de la hipótesis.

El resultado de RNN y LSTM muestra que una arquitectura más compleja no implica automáticamente una mejor predicción. Con 1,584 observaciones, alta dimensionalidad y numerosos días con valor cero, el incremento de parámetros eleva el riesgo de varianza y limita la generalización.

Demanda intermitente y selección de métricas

La proporción de días con valor cero fue aproximadamente 75.9 % en ventas y 82.0 % en compras. Esta condición vuelve inestable la MAPE y explica sus valores elevados; por ello, las conclusiones se fundamentaron principalmente en RMSE y MAE. WAPE se incorporó como métrica complementaria propuesta para futuras corridas, sin atribuirle resultados que no fueron persistidos por el pipeline.

Implicaciones operativas y financieras

La evidencia permite priorizar el uso predictivo en compras, donde la mejora fue material y consistente con la necesidad de anticipar el presupuesto de abastecimiento. No es posible inferir reducción efectiva de faltantes o sobreabastecimiento, porque no se cuenta con inventarios, recetas, mermas ni tiempos de entrega. Para ventas, el DSS debe emplearse como referencia de tendencia y alerta, acompañado del juicio del responsable del negocio, ya que ARIMA fue más competitivo que los modelos de aprendizaje automático.

Validez y limitaciones

La validez interna se fortaleció mediante separación temporal, desplazamiento de características y comparación sobre ventanas equivalentes. La validez externa es limitada porque se estudió una sola microempresa. Además, la menor cobertura de compras, la concentración de ceros y la ausencia de inventarios, mermas, tiempos de entrega y costos de faltante restringen la simulación prescriptiva.

7 CONCLUSIONES

Se construyó una solución analítica reproducible que integra datos transaccionales y exógenos, transforma las series mediante ingeniería de características, compara modelos con validación temporal y comunica los resultados en un DSS. El proceso convirtió registros dispersos en evidencia verificable para anticipar el presupuesto de abastecimiento.

La hipótesis se respaldó para el presupuesto de abastecimiento. Random Forest redujo el RMSE de compras en 28.3 % para importes y 22.8 % para registros frente a la línea base. ARIMA fue más competitivo para ventas; por ello, la evidencia no respalda una superioridad general de los modelos de aprendizaje automático para todos los objetivos, sino su utilidad específica para anticipar compras.

El estudio también demuestra que, en un contexto de Small Data y demanda intermitente, la parsimonia, la calidad de las variables y la validación temporal pueden ser más relevantes que la complejidad algorítmica.

Recomendaciones

Se recomienda actualizar mensualmente las fuentes, vigilar la cobertura de compras, conservar la línea base como referencia permanente y reentrenar cuando el RMSE por ventana muestre deterioro sostenido. El pronóstico debe utilizarse para reservar y revisar el presupuesto de abastecimiento; las decisiones de compra deben incorporar revisión humana y límites financieros.

Trabajo futuro

Como trabajo futuro, conviene registrar inventario inicial y final, recetas, merma, costo de faltante, tiempo de entrega y promociones; homologar las unidades de medida por insumo; evaluar modelos específicos para demanda intermitente; y efectuar una validación prospectiva antes de automatizar recomendaciones de compra por volumen.

GLOSARIO

Inteligencia Artificial (IA): Rama de la informática que diseña sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, como el aprendizaje, la planificación y la predicción.

Cadena de suministro: Conjunto de procesos involucrados en la producción, distribución y entrega de un producto desde su origen hasta el cliente final.

PYMES: Pequeñas y Medianas Empresas, generalmente caracterizadas por tener un número limitado de empleados y recursos, pero con alto potencial de innovación.

Agentes Inteligentes: Programas o sistemas que ejecutan acciones de manera autónoma para alcanzar objetivos específicos, basados en reglas o **aprendizaje automático**.

Pronóstico de demanda: Proceso de estimar la demanda futura de productos o servicios a través de datos históricos y modelos estadísticos o de **aprendizaje automático**.

REFERENCIAS

- Ab Karim, M. S., Ab Rahman, S., Chua, B. L., et al. (2020). The creative minds of extraordinary pastry chefs: an integrated theory of aesthetic expressions – a portraiture study. *International Journal of Contemporary Hospitality Management*, 32(9), 3015–3034. <https://doi.org/10.1108/IJCHM-04-2020-0329>
- Abrar, M., et al. (2024). An Explainable Multi-Channel Data Fusion Network for Demand Forecasting in Supply Chains. *Expert Systems with Applications*.
- Abrar, M., Shahriar, M. A., & Amin, A. (2024). MCDFN: Supply chain demand forecasting via an explainable multi-channel data fusion network model. *arXiv preprint arXiv:2405.15598*. <https://doi.org/10.48550/arXiv.2405.15598>
- Akter, S., Wamba, S. F., Gunasekaran, A., Dubey, R., & Childe, S. J. (2019). How to improve firm performance using big data analytics capability and business strategy alignment. *Journal of Big Data*, 6(1).
- Alekseeva, L., Ginevičius, R., & Stankevičienė, J. (2021). Adoption of artificial intelligence technologies in SMEs: Evidence from Europe. *Sustainability*, 13(19), 10663. <https://doi.org/10.3390/su131910663>
- Alekseeva, L., Ginevičius, R., & Stankevičienė, J. (2021). Factors affecting artificial intelligence adoption in small and medium-sized enterprises. *Sustainability*, 13(21), 12156.
- Alekseeva, M., Gorbunova, N., y Parshina, E. (2021). *Digital transformation of small and medium-sized enterprises: Barriers and opportunities*. Springer.
- Aprodu, I., Banu, I., Vasilean, I., et al. (2025). The Digital Revolution in the Bakery Sector: A Systematic Review of Industry 4.0 Technologies. *Foods*, 14(2).
- Banco Interamericano de Desarrollo (BID). (2019). *Emprender en América Latina: aprendizajes y desafíos*. <https://www.iadb.org>

- Ben Abdallah, H., Ayadi, M., Boujelbene, Y. (2022). The main determinants and effects of product innovation: An exploratory study on the pastry companies of the region of Sfax (in Tunisia). *Technological Forecasting and Social Change*, 185, 122065. DOI: 10.1016/j.techfore.2022.122065.
- Bergmeir, C., & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191, 192-213. <https://doi.org/10.1016/j.ins.2011.12.028>
- Bertsimas, D., & Kallus, N. (2020). From predictive to prescriptive analytics. *Management Science*, 66(3), 1025–1044. <https://doi.org/10.1257/mnsc.2018.3243>
- Bertsimas, D., Dunn, J., & Pawlowski, C. (2021). Artificial intelligence for business decision support systems. *Decision Analytics Journal*, 1, 100003.
- Bontempi, G., Ben Taieb, S., & Le Borgne, Y.-A. (2013). Machine learning strategies for time series forecasting. En M. Aufaure & E. Zimányi (Eds.), *Business intelligence* (pp. 62–77). Springer. https://doi.org/10.1007/978-3-642-36318-4_3
- Borsato, M. (2023). “Edible Aesthetics”: Blurring Boundaries between Pastry and Art. *Humanities*, 12(5), 126. <https://doi.org/10.3390/h12050126>
- Box, G. E. P. (1976). Science and statistics. *Journal of the American Statistical Association*, 71(356), 791–799. <https://doi.org/10.1080/01621459.1976.10480949>
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5th ed.). Wiley.
- Brynjolfsson, E., & McElheran, K. (2016). The rapid adoption of data-driven decision-making. *American Economic Review*, 106(5), 133–139. <https://doi.org/10.1257/aer.p20161016>

Brynjolfsson, E., Hitt, L. M., & Kim, H. H. (2011). Strength in numbers: How does data-driven decision making affect firm performance? SSRN Electronic Journal. <https://doi.org/10.2139/ssrn.1819486>

Cao, G., Duan, Y., Edwards, J. S., & Dwivedi, Y. K. (2025). Future trends in predictive analytics. *Analytics*, 4(1), Article 3. <https://doi.org/10.3390/analytics4010003>

Cuevas-Vargas, H., Estrada, S., & Larios-Gómez, E. (2016). The effects of ICTs as innovation facilitators for a greater business performance. Evidence from Mexico. *Procedia Computer Science*, 91, 47–56. <https://doi.org/10.1016/j.procs.2016.07.040>

Davenport, T. H., & Harris, J. G. (2007). *Competing on analytics: The new science of winning*. Harvard Business School Press.

Dubey, R., Bryde, D., Blome, C., Roubaud, D., & Giannakis, M. (2021). Facilitating artificial intelligence powered supply chain analytics through alliance management during the pandemic crises in the B2B context. *Industrial Marketing Management*, 96, 135–146.

Dubey, R., Gunasekaran, A., Childe, S. J., Bryde, D. J., Giannakis, M., & Foropon, C. (2021). Big data analytics and artificial intelligence pathway to operational performance under the effects of entrepreneurial orientation and environmental dynamism: A study of manufacturing organisations. *International Journal of Production Economics*, 226, 107599. <https://doi.org/10.1016/j.ijpe.2019.107599>

García-Murillo, M., MacInnes, I., & Bauer, J. (2019). Techno-economic analysis of digital transformation in Latin American SMEs. *Telecommunications Policy*, 43(9). <https://doi.org/10.1016/j.telpol.2019.101820>

García-Pérez, A., Ghio, A., Occhipinti, Z., & Verona, R. (2020). Knowledge management and intellectual capital in knowledge-based organisations: A review and theoretical perspectives. *Journal of Knowledge Management*, 24(7), 1719–1751. <https://doi.org/10.1108/JKM-12-2019-0682>

- García-Sánchez, A., Fernández, M., & Ruiz, P. (2023). Machine learning techniques for financial forecasting and decision support. *Revista Iberoamericana de Inteligencia Artificial*.
- Góngora Chonillo, J. T. (2023). Evaluación del riesgo financiero en microempresas a través de inteligencia artificial. *Revista Pulso Científico*, 1(2), 34–49. <https://doi.org/10.70577/rps.v1i2.10>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer.
- Huber, J., & Stuckenschmidt, H. (2020). Daily retail demand forecasting using machine learning with emphasis on calendric special days. *International Journal of Forecasting*, 135, 113322. <https://doi.org/10.1016/j.ijforecast.2020.02.005>.
- Hübner, A., Kuhn, H., & Sternbeck, M. G. (2024). *Sales and operations planning in retail and supply chains*. Springer.
- Hübner, N., Caspers, J., Coroamă, V. C., & Finkbeiner, M. (2024). Machine-learning-based demand forecasting against food waste: Life cycle environmental impacts and benefits of a bakery case study. *Journal of Industrial Ecology*, 28, 1117–1131. <https://doi.org/10.1111/jiec.13528>
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>
- Hyndman, R. J., Athanasopoulos, G., Wang, E., & Wang, Y. (2023). Advances in business forecasting methods and applications. *Journal of Forecasting*.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2nd ed.). Springer.
- Kahneman, D. (2011). *Thinking, fast and slow*. Farrar, Straus and Giroux.
- Kahneman, D., & Tversky, A. (1974). Judgment under uncertainty: Heuristics and biases. *Science*, 185(4157), 1124–1131. <https://doi.org/10.1126/science.185.4157.1124>
- Kahneman, D., & Tversky, A. (1979). Prospect theory: An analysis of decision under risk. *Econometrica*, 47(2), 263–291. <https://doi.org/10.2307/1914185>

- Kantis, H., Federico, J., & García, S. (2020). Índice de condiciones sistémicas para el emprendimiento dinámico. Prodem.
- Kuhn, M., & Johnson, K. (2013). Applied predictive modeling. Springer.
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). Statistical and machine learning forecasting methods: Concerns and ways forward. PLOS ONE, 13(3), e0194889. <https://doi.org/10.1371/journal.pone.0194889>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). The M4 competition: Results, findings, conclusion and way forward. International Journal of Forecasting, 34(4), 802–808. <https://doi.org/10.1016/j.ijforecast.2018.06.001>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M5 accuracy competition: Results, findings and conclusions. International Journal of Forecasting, 38(4), 1346–1364.
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2021). The M5 accuracy competition: Results, findings and conclusions. International Journal of Forecasting, 38(4), 1346–1364. <https://doi.org/10.1016/j.ijforecast.2021.11.013>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. International Journal of Forecasting, 38(4), 1346–1364. <https://doi.org/10.1016/j.ijforecast.2021.11.013>
- Martins-Turner, K., von Massow, M., O'Rourke, S., & Fraser, E. D. G. (2023). Machine learning based demand forecasting against food waste: Life cycle environmental impacts and benefits of a bakery case study. Journal of Cleaner Production, 384, 135539. <https://doi.org/10.1016/j.jclepro.2022.135539>
- Mikalef, P., Boura, M., Lekakos, G., & Krogstie, J. (2019). Big data analytics capabilities and innovation: The mediating role of dynamic capabilities and moderating effect of the

environment. *British Journal of Management*, 30(2), 272–298.
<https://doi.org/10.1111/1467-8551.12343>

Mikalef, P., Krogstie, J., Pappas, I., & Pavlou, P. (2019). Investigating the effects of big data analytics capabilities on firm performance. *Information & Management*, 57(2), 103169.

Minniti, M., & Bygrave, W. (2018). A dynamic model of entrepreneurial learning. *Entrepreneurship Theory and Practice*, 25(3), 5-16.
<https://doi.org/10.1177/104225870102500301>

Nonaka, I., & Takeuchi, H. (1995). *The knowledge-creating company: How Japanese companies create the dynamics of innovation*. Oxford University Press.

OECD. (2022). *Financing growth and turning data into business: Helping SMEs scale up*. OECD Publishing. <https://doi.org/10.1787/81c738f0-en>

Organización para la Cooperación y el Desarrollo Económicos (OCDE). (2022). *Financing growth and turning data into business: Helping SMEs scale up*. OECD Publishing. <https://doi.org/10.1787/81c738f0-en>

Petropoulos, F., Makridakis, S., Assimakopoulos, V., & Nikolopoulos, K. (2020). Forecasting: Theory and practice in a changing world. *Forecasting*, 2(1), 15–28.

Polanyi, M. (1966). *The Tacit Dimension*. Doubleday & Company.

Power, D. J. (2002). *Decision support systems: Concepts and resources for managers*. Quorum Books.

PraveenaSri, P., Padma, V., Muruguesan, R., & Usha, S. (2023). Business challenges of forecasting sales in the bakery industry: Applications of machine learning algorithms. <https://www.researchgate.net/publication/370666295>

- PraveenaSri, P., Padma, V., Muruguesan, R., & Usha, S. (2023). Business challenges of forecasting sales in the bakery industry: Applications of machine learning algorithms. ResearchGate Publication. <https://www.researchgate.net/publication/370666295>
- Provost, F., & Fawcett, T. (2013). Data science for business: What you need to know about data mining and data-analytic thinking. O'Reilly Media.
- Ramírez-Montoya, M. S., et al. (2022). Data-driven decision making and business intelligence in organizations. RISTI – Revista Ibérica de Sistemas y Tecnologías de Informação.
- Ries, E. (2017). *El método Lean Startup: Cómo crear empresas de éxito utilizando la innovación continua*. Deusto.
- Romero-Hidalgo, J. A., Isiordia-Lachica, P. C., Valenzuela, A., & Rodríguez-Carvajal, R. A. (2021). Knowledge and innovation management model in the organizational environment. *Information* (Switzerland), 12(6), 225. <https://doi.org/10.3390/info12060225>
- Saavedra-García, M., & Tapia-Sánchez, B. (2020). The role of information technologies in Mexican SMEs. *Contaduría y Administración*, 65(2). <https://doi.org/10.22201/fca.24488410e.2020.2215>
- Sánchez, M., & Terrazas, R. (2020). Inteligencia de negocios como herramienta para la toma de decisiones en PYMES mexicanas. *Contaduría y Administración*, 65(3). <https://doi.org/10.22201/fca.24488410e.2020.2314>
- Scuotto, V., Del Giudice, M., Tarba, S., & Bresciani, S. (2021). Digital technologies and SMEs' performance: The role of digital transformation. *Technological Forecasting and Social Change*, 173, 121139. <https://doi.org/10.1016/j.techfore.2021.121139>
- Shmueli, G. (2010). To explain or to predict? *Statistical Science*, 25(3), 289–310. <https://doi.org/10.1214/10-STS330>

- Shmueli, G., & Koppius, O. R. (2011). Predictive analytics in information systems research. *MIS Quarterly*, 35(3), 553–572. <https://doi.org/10.2307/23042796>
- Simon, H. A. (1997). *Administrative behavior: A study of decision-making processes in administrative organizations* (4th ed.). Free Press.
- Spiliotis, E., Makridakis, S., & Assimakopoulos, V. (2025). Continuous business forecasting in modern organizations. *Forecasting*, 7(1), 12–29. <https://doi.org/10.3390/forecast7010012>
- Spiliotis, E., Makridakis, S., Semenoglou, A. A., & Assimakopoulos, V. (2020). Comparison of statistical and machine learning methods for daily SKU forecasting. *Operational Research*, 20(4), 1–31. <https://doi.org/10.1007/s12351-020-00573-0>
- Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: an analysis and review. *International Journal of Forecasting*, 16(4), 437–450. [https://doi.org/10.1016/S0169-2070\(00\)00065-0](https://doi.org/10.1016/S0169-2070(00)00065-0)
- Verhoef, P. C., Broekhuizen, T., Bart, Y., Bhattacharya, A., Dong, J. Q., Fabian, N., & Haenlein, M. (2021). Digital transformation: A multidisciplinary reflection and research agenda. *Journal of Business Research*, 122, 889–901. <https://doi.org/10.1016/j.jbusres.2019.09.022>
- Viteri, C., & Murillo, D. (2022). Inteligencia de negocios para las organizaciones. *Revista Killkana Social*, 6(12). <https://doi.org/10.35381/R.K.V6I12.1291>