



**MODELO HÍBRIDO ESTADÍSTICO Y DE APRENDIZAJE AUTOMÁTICO PARA EL
PRONÓSTICO Y LA DISTRIBUCIÓN DEL PRESUPUESTO SEMANAL DE
ABASTECIMIENTO: ESTUDIO DE CASO EN UNA MICROEMPRESA DE REPOSTERÍA
CREATIVA EN TIZAYUCA, HIDALGO**

**TESIS PARA OBTENER EL GRADO DE MAESTRO EN
INTELIGENCIA ARTIFICIAL**

PRESENTADA POR:

RODRIGO ADRIÁN MARTÍNEZ FLORES

DIRECTOR DE TESIS:

LUIS EDUARDO URBAN RIVERO

Tolcayuca, Hidalgo. 28, agosto 2025.

DEDICATORIA

A mi amada esposa, mi compañera de vida, mi mejor complemento, quien me ha impulsado para alcanzar cada nuevo reto.

A mis hijos que han sido inspiración avanzar en mi formación académica y que con su espontaneidad han llenado mi vida de entusiasmo por seguir adelante.

A mis padres que siempre me han apoyado.

AGRADECIMIENTOS

A la Universidad Politécnica Metropolitana de Hidalgo

ÍNDICE

Contenido

RESUMEN	12
ABSTRACT	1
1. INTRODUCCIÓN.....	2
1.1 Estado del Arte	4
1.1.1 Aplicaciones de la inteligencia artificial en la cadena de suministro	4
1.1.2 Modelos de aprendizaje automático para el pronóstico de demanda.....	5
1.1.3 Demanda intermitente, Small Data y comparación de modelos	5
1.1.4 La repostería creativa como sector económico especializado	7
1.1.5 Innovación y transformación digital en la industria pastelera	8
1.1.6 Adopción de inteligencia artificial en microempresas	9
1.1.7 Investigaciones en México y América Latina.....	10
1.1.8 Síntesis del estado del arte y vacío de investigación	14
1.2 El planteamiento del problema	15
1.2.1 Contexto del caso de estudio	16
1.2.2 Pregunta de Investigación	17
1.2.3 Objetivo	18
1.3 Justificación	18

1.4	Hipótesis.....	21
2	MARCO TEÓRICO	22
2.1	Microempresa y planeación del presupuesto de abastecimiento	22
2.1.1	Recursos de información y conocimiento del negocio.....	22
2.1.2	Pronóstico como información para decidir.....	23
2.2	Compras monetarias y contexto de la repostería	23
2.2.1	Delimitación de la variable objetivo	23
2.2.2	Agregación del importe y niveles de análisis.....	24
2.3	Series temporales semanales y calidad de los registros	24
2.3.1	Frecuencia y continuidad.....	24
2.3.2	Nivel tendencia y estacionalidad	25
2.3.3	Estacionariedad y dependencia temporal	25
2.3.4	Intermitencia y valores extremos.....	26
2.4	Métodos estadísticos y de aprendizaje automático	26
2.4.1	Referencias simples	26
2.4.2	Suavizamiento exponencial y ARIMA.....	27
2.4.3	Bosques aleatorios y potenciación de gradiente	28
2.4.4	Redes neuronales y alcance de los comparadores.....	28
2.5	Fundamentos de integración del modelo híbrido.....	29

2.5.1	Combinación de pronósticos	29
2.5.2	Integración mediante componentes	30
2.6	Distribución porcentual y coherencia de las asignaciones	30
2.6.1	Participaciones como datos composicionales	30
2.6.2	Desagregación del pronóstico total	31
2.6.3	Representación relativa de las participaciones	32
2.7	Datos limitados e ingeniería de características	32
2.7.1	Complejidad y capacidad de generalización	32
2.7.2	Penalizaciones y selección de variables	32
2.7.3	Predictores temporales y calendario	33
2.7.4	Disponibilidad de variables exógenas	34
2.8	Evaluación temporal y métricas de precisión	34
2.8.1	Origen del pronóstico y ventana de entrenamiento	34
2.8.2	Error monetario del importe total	35
2.8.3	Escalamiento y límites de errores porcentuales	35
2.8.4	Error de participaciones y evaluación conjunta	36
2.9	Inteligencia de negocios y comunicación del pronóstico	36
2.9.1	Presentación del presupuesto y su incertidumbre	36
2.9.2	Adopción y límites operativos	37

2.10	Síntesis de fundamentos y relación con la hipótesis	37
3	METODOLOGÍA	39
3.1	Tipo de investigación según el objetivo de ésta	39
3.2	Según el alcance evaluativo del estudio.....	40
3.3	Según el tipo de datos empleados	41
3.4	Según el grado de manipulación de las variables	42
3.5	Diseño evaluativo y comparación contra la línea base	42
3.6	Según el tipo de inferencia	43
3.7	Temporalidad de la investigación	44
3.8	Procedimiento Metodológico	45
	Business Comprehension	45
3.8.1	Data Collection y control de calidad	45
	EDA de la serie temporal semanal	46
3.8.2	Feature Engineering y disponibilidad temporal.....	47
3.8.3	Model Training y selección de componentes.....	47
3.8.4	Estrategias de partición temporal y validación	49
3.8.5	Testing and Debugging	49
3.8.6	Deployment y comunicación del presupuesto	51
	Monitoring y reentrenamiento controlado	51

4	DESARROLLO	53
4.1	Antecedentes del negocio	53
4.1.1	El registro de ventas y compras de insumos	54
4.1.2	Antecedentes de los conjuntos de datos existentes	55
4.2	Fases del pipeline híbrido con enfoque MLOps.....	57
4.2.1	Análisis Exploratorio de Datos (EDA)	60
4.2.2	Ingeniería de Características (Feature Engineering).....	67
	Antecedentes de análisis exploratorio de la serie temporal semanal	77
	Auditoría de cobertura y selección del bloque continuo.....	77
	Estructura temporal, estacionariedad y dependencia serial	78
	Intermitencia, variabilidad y valores atípicos	79
	Implicaciones para los modelos de Inteligencia Artificial	81
4.3	Antecedentes de diagnóstico de la línea base empírica y evaluación comparativa ..	81
4.4	Estado de la implementación del pipeline híbrido.....	82
4.5	Antecedentes del repositorio y de la preparación de datos	83
4.6	Antecedentes de auditoría, Depuración e Integración del Conjunto de Datos (Dataset)	84
4.7	Antecedentes de ingeniería de Características (Feature Engineering) y Variables Exógenas	85

4.8	Antecedentes de desarrollo, Configuración y Entrenamiento de los Modelos Predictivos.....	86
4.9	Antecedentes de evaluación comparativa del rendimiento predictivo frente a la línea base	87
4.10	La evaluación heredada utilizó una ventana de 52 semanas y reportó 16 orígenes para $h=1$ y $h=4$. Se conserva exclusivamente como antecedente. La configuración principal actual utiliza historia creciente y reserva 26 semanas calendario; los objetivos observados se contabilizarán por horizonte. Las cifras de 16 semanas y 13 orígenes de la rama strict no describen <code>calendar_gaps</code> , cuya corrida real todavía no ha completado entrenamiento y evaluación.	88
	Arquitectura tecnológica	89
	Integración de los resultados predictivos.....	89
	Filtros e indicadores para la decisión.....	90
	Resultados incorporados al DSS.....	90
	Interpretación operativa y salvaguardas.....	91
	Alcance actual de la integración	91
4.11	Alcance del apoyo al presupuesto de abastecimiento	92
5	RESULTADOS	94
	Calidad, cobertura e integración de datos.....	94
	Reducción dimensional	94
	Rendimiento comparativo de los modelos.....	94
	Resultados de redes neuronales recurrentes.....	96

Contraste de hipótesis.....	96
Resultados del tablero DSS	97
6 DISCUSION.....	99
Interpretación de los hallazgos.....	99
Demanda intermitente y selección de métricas	99
Implicaciones operativas y financieras	99
Validez y limitaciones	99
7 CONCLUSIONES	100
Recomendaciones.....	100
Trabajo futuro	100
GLOSARIO	102
REFERENCIAS	103
Anexo A Diccionario de datos	113

TABLAS, IMÁGENES Y ECUACIONES

Tabla 1 - Estudios citados en el estado del arte y relación con la presente investigación

[\(1\)](#) ¡Error! Marcador no definido.

[\(2\)](#) ¡Error! Marcador no definido.

[\(3\)](#) ¡Error! Marcador no definido.

[\(4\)](#) ¡Error! Marcador no definido.

[Imagen 1 - Repositorio github](#)83

[Tabla 2 - Conjuntos de datos de Ventas y Compras](#)56

[Tabla 3 - Conjunto de datos de variables exógenas \(Contexto Tizayuca, Hgo.\)](#) ¡Error!
Marcador no definido.

[Tabla 4 - Inflación histórica en México \(INPC\)](#) ¡Error! Marcador no definido.

[Imagen 2 - Temperatura Media por Entidad Federativa y Nacional, contenido en PDF](#) .. ¡Error!
Marcador no definido.

[Tabla 5 - Temperatura mensual \(Tizayuca, Hgo.\)](#) ¡Error! Marcador no definido.

[Figura 27 - Fases del pipeline híbrido semanal con enfoque MLOps](#)59

[Tabla 6 - Síntesis de fuentes de datos y transformaciones aplicadas](#)63

[Tabla 7 - Operacionalización de la línea base y la posprueba](#)81

[Tabla 8 - Trazabilidad de los conjuntos analíticos](#)84

[Figura 24 - Expansión dimensional producida por la ingeniería de características](#)85

[Tabla 9 - Dimensiones principales de las variables modeladas](#)85

<u>Figura 25 - Arquitecturas recurrentes consideradas para el modelado temporal</u>	86
<u>Tabla 10 - Familias de modelos y configuración evaluada</u>	86
<u>Figura 26 - Esquema de validación temporal Rolling-Origin</u>	87
<u>Figura 28 - Arquitectura funcional del sistema de soporte a la decisión</u>	88
<u>Figura 29 - Interfaz funcional del tablero DSS implementado para Cup&Cake</u>	92
<u>Figura 30 - Flujo de decisión operativa asistido por el DSS</u>	92
<u>Figura 31 - Mejora relativa del RMSE frente a la línea base empírica</u>	95
<u>Figura 32 - Mejor modelo por objetivo y representación de datos</u>	96
<u>Tabla 11 - Modelos ganadores y desempeño temporal</u>	97

RESUMEN

La investigación evalúa modelos estadísticos y de aprendizaje automático para pronosticar semanalmente el presupuesto de abastecimiento de Cup&Cake, microempresa de repostería ubicada en Tizayuca, Hidalgo. A partir de registros diarios de ventas y compras se construyó una serie semanal integrada con variables calendáricas, económicas y climáticas disponibles antes del periodo pronosticado. Antes del modelado se realizó un análisis explícito de cobertura, tendencia, estacionariedad, autocorrelación, intermitencia y valores atípicos, utilizando únicamente el bloque temporal continuo y reservando las últimas 16 semanas para evaluación.

El análisis identificó una serie errática, con ADI de 1.16, CV^2 de 1.03 y 13.5% de semanas con importe cero dentro del bloque de desarrollo. La evaluación mediante ventana deslizante mostró que, para $h=1$, el ingenuo estacional de 52 semanas obtuvo el menor RMSE descriptivo (695.19), seguido por Random Forest con transformación $\log_{1p}$ (699.28); para $h=4$, la mejor configuración descriptiva fue HistGradientBoosting tipo hurdle con variables exógenas (RMSE 399.56). Ningún modelo superó significativamente la línea base primaria después del ajuste Holm. Los resultados se comunican mediante un sistema de soporte a la decisión que conserva la interpretación humana y evita presentar la inteligencia artificial como sustituto automático del criterio empresarial.

Palabras clave: presupuesto de abastecimiento, microempresa, series temporales, aprendizaje automático, Rolling-Window, inteligencia de negocios.

ABSTRACT

This research evaluates statistical and machine-learning models for weekly procurement-budget forecasting at Cup&Cake, a small bakery in Tizayuca, Hidalgo. Daily sales and purchasing records were aggregated into a weekly series and complemented with calendar, economic, and weather variables available before each forecast. Prior to modeling, the study explicitly assessed coverage, trend, stationarity, autocorrelation, intermittency, and robust outliers using only the main continuous block while reserving the final 16 weeks for evaluation. The series was classified as erratic. At $h=1$, the 52-week seasonal naive benchmark achieved the lowest descriptive RMSE (695.19), closely followed by log-transformed Random Forest (699.28); at $h=4$, the best descriptive result was obtained by an exogenous hurdle HistGradientBoosting configuration (RMSE 399.56). No model significantly outperformed the primary baseline after Holm adjustment. Results support human review through a business-intelligence decision-support dashboard.

Keywords: procurement budget, microenterprise, time series, machine learning, Rolling-Window, business intelligence.

1.INTRODUCCIÓN

Un emprendimiento surge a partir de una idea que resuelve alguna necesidad básica o simplemente permite hacer más sencilla la vida de otras personas ofreciendo productos y/o servicios útiles para alguna comunidad. Suele ser una alternativa para situaciones complejas como la pérdida de empleo o con la intención de generar una utilidad que sirva para mejorar la calidad de vida familiar. El Global Entrepreneurship Monitor (**GEM, 2023**) indica que los emprendimientos contribuyen al bienestar económico y social, generando ingresos y mejorando la calidad de vida tanto de los emprendedores como de sus comunidades.

Los emprendimientos o microempresas enfrentan importantes desafíos dado que en la mayoría de los casos surgen sin una adecuada planeación. Minniti y Bygrave (2018) explican que el proceso emprendedor es dinámico y se basa en el aprendizaje continuo derivado de la interacción con el entorno y la toma de decisiones bajo incertidumbre. Asimismo, Ries (2017), desde la perspectiva del *lean startup*, sostiene que muchos emprendimientos comienzan con supuestos no validados y van ajustando su modelo de negocio mediante prueba y error. El emprendedor va generando experiencia sobre el negocio a partir del conocimiento de su entorno y del mercado.

La Organización para la Cooperación y el Desarrollo Económicos (**OCDE, 2021**) señala que las pequeñas empresas enfrentan restricciones de información y capacidades, lo que dificulta prever la demanda y optimizar la gestión de inventarios. La compra de materia prima se realiza con cautela sin tener certeza de si se logrará vender los productos que se elaboran, en muchos casos el mismo crecimiento orgánico provoca un caos y desperdicio de materia prima y recursos que limitan el crecimiento, todo este aprendizaje se obtiene generalmente de manera empírica conforme va evolucionando el negocio y aumentando las ventas. Kantis, Federico y García (2020) indican que la falta de capacidades de gestión en etapas tempranas puede provocar problemas en la organización interna, uso ineficiente de recursos y limitaciones para escalar el negocio.

Cuando se observa que el producto o servicio ofrecido recibe una aceptación del mercado se presentan nuevos retos, principalmente la alta variabilidad de la demanda, el reto de predecir la compra de materia prima o la creación de planes de crecimiento del negocio que lo lleven hacia un nuevo nivel y participación del mercado, lo anterior genera incertidumbre y poca claridad para el emprendedor. El **Banco Interamericano de Desarrollo (BID, 2019)** destaca que los emprendedores en contextos latinoamericanos suelen aprender haciendo, lo que implica un proceso de mejora progresiva, aunque con costos asociados como errores, desperdicio y baja productividad inicial.

Las microempresas representan el núcleo del aparato productivo en México y América Latina. De acuerdo con el Instituto Nacional de Estadística y Geografía (INEGI), en México existen más de 4.9 millones de micro, pequeñas y medianas empresas, de las cuales el 95% corresponde a microempresas, generando aproximadamente el 41.8% del empleo nacional (INEGI, 2023). A pesar de su relevancia económica y social, estas organizaciones enfrentan serias limitaciones estructurales, particularmente en materia de planeación financiera, gestión de inventarios y administración de la cadena de suministro.

Uno de los principales retos que enfrentan las microempresas es la escasa adopción de tecnologías avanzadas para la toma de decisiones. Según la OCDE (OCDE, 2022), menos del 25% de las microempresas en países en desarrollo utilizan herramientas analíticas avanzadas, lo que implica que la mayoría de ellas basa sus decisiones estratégicas en la experiencia empírica del propietario, en promedios históricos simples o en la intuición. Este enfoque incrementa la incertidumbre financiera, dificulta la previsión de ingresos y eleva el riesgo de sobre inventarios o desabasto, especialmente en sectores con alta variabilidad de la demanda. En el sector alimentario y de productos perecederos, como la repostería, estos desafíos se intensifican.

Una planificación inadecuada de la demanda en el sector de panadería puede generar niveles significativos de merma, con tasas de devolución que oscilan entre el 1.5% y el 19%, lo cual tiene implicaciones económicas y operativas relevantes para las empresas del sector (Hübner et al., 2024). Asimismo, la falta de pronósticos confiables limita la capacidad de las

microempresas para diseñar estrategias de crecimiento, expandirse a nuevos mercados o realizar inversiones con menor riesgo financiero. (Makridakis et al., 2018; Spiliotis et al., 2025)(Cao et al., 2025)

La literatura reciente muestra que los modelos de aprendizaje automático pueden capturar relaciones no lineales, estacionalidad y variables externas; sin embargo, su desempeño frente a los métodos estadísticos depende de las características de la serie, la disponibilidad de datos, el horizonte de pronóstico y el protocolo de evaluación (Makridakis et al., 2018; Spiliotis et al., 2022).

Frente a este escenario, el aprendizaje automático (ML por sus siglas en inglés, Machine Learning) como rama de la Inteligencia Artificial ha emergido como herramienta clave para transformar la planeación financiera y la gestión de la cadena de suministro.

1.1 Estado del Arte

1.1.1 Aplicaciones de la inteligencia artificial en la cadena de suministro

El uso de la inteligencia artificial (IA) en la cadena de suministro ha demostrado ser una herramienta eficaz para mejorar la eficiencia operativa y la toma de decisiones, especialmente en industrias con productos perecederos. Distintos estudios han explorado su aplicación desde enfoques variados, ofreciendo evidencia empírica, conceptual y técnica que fundamenta su utilidad en contextos empresariales.

Uno de los estudios más relevantes es el de Hübner et al. (2024), quienes analizaron la implementación de un sistema de aprendizaje automático en la nube denominado *Foodforecast* en panaderías de Berlín, Alemania. El objetivo del estudio fue evaluar el impacto del uso de modelos predictivos en la reducción del desperdicio de alimentos. La investigación adoptó un enfoque cuantitativo basado en datos históricos de ventas y producción, utilizando modelos de aprendizaje automático para pronosticar la demanda diaria de productos. Los resultados mostraron una reducción significativa del desperdicio alimentario y una mejora en la precisión de los pronósticos de demanda. El principal aporte radica en demostrar que los

sistemas de predicción basados en inteligencia artificial pueden contribuir a mejorar la eficiencia operativa y la sostenibilidad en industrias con productos perecederos.

Sin embargo, el modelo *Foodforecast* presenta como limitación el hecho de que fue desarrollado en organizaciones con infraestructura tecnológica avanzada, lo cual dificulta la extrapolación de sus resultados a microempresas con recursos limitados.

1.1.2 Modelos de aprendizaje automático para el pronóstico de demanda

Huber y Stuckenschmidt (2020) desarrollaron un estudio orientado al pronóstico diario de ventas en el sector minorista, utilizando algoritmos de aprendizaje automático capaces de incorporar variables calendáricas y eventos especiales. La metodología consistió en comparar distintos modelos predictivos utilizando datos históricos de ventas de una cadena comercial. Los resultados evidenciaron que los modelos de aprendizaje automático lograron mejorar la precisión de los pronósticos, especialmente en periodos asociados a eventos especiales o festividades.

En la literatura reciente también se observa un creciente interés por el desarrollo de modelos híbridos y técnicas avanzadas de predicción. Un ejemplo de ello es el estudio de Abrar et al. (2024) quienes propusieron un modelo híbrido denominado *Multi-Channel Data Fusion Network (MCDFN)* para el pronóstico de la demanda en cadenas de suministro. Este modelo integra redes neuronales convolucionales, redes LSTM y mecanismos de interpretabilidad basados en inteligencia artificial explicable (XAI). Los resultados del estudio evidencian una mejora significativa en la precisión de los pronósticos.

1.1.3 Demanda intermitente, Small Data y comparación de modelos

Los registros diarios de ventas y compras en negocios de pequeña escala pueden contener numerosos periodos sin movimiento y picos asociados a pedidos extraordinarios o fechas comerciales. Al agregarlos semanalmente, la serie puede reducir su intermitencia y ofrecer una unidad más congruente con la planeación de corto plazo; sin embargo, disminuye el número de observaciones disponibles. Por ello, los modelos de aprendizaje automático deben

compararse con métodos estadísticos establecidos y no asumirse superiores por su mayor complejidad (Spiliotis et al., 2022).

La evidencia de las competencias M respalda este criterio de comparación. En M4, las combinaciones de métodos estadísticos y los enfoques híbridos obtuvieron resultados competitivos, mientras que los modelos puramente basados en aprendizaje automático no dominaron de forma generalizada (Makridakis et al., 2018). De manera consistente, Hewamalage et al. (2021) advierten que las redes neuronales recurrentes son alternativas competitivas, pero no soluciones universales, especialmente cuando las series individuales son cortas o heterogéneas.

La revisión de Giannopoulos et al. (2025) confirma que la demanda intermitente requiere atención explícita al diseño de características, la partición temporal, el ajuste de hiperparámetros y las métricas de evaluación. Esta literatura sustenta que, en un contexto de Small Data, una validación Rolling-Window y la comparación con líneas base reproducibles son más pertinentes que inferir superioridad a partir de un único modelo o una única partición.

Agregación temporal y horizonte de planeación

La elección del horizonte debe responder a la frecuencia efectiva de decisión. En esta investigación, los registros diarios se agregan por semana calendario para apoyar la planeación del presupuesto de abastecimiento de corto plazo. La agregación semanal puede reducir ruido e intermitencia, aunque también disminuye el número de observaciones; por ello, la evaluación debe privilegiar modelos parsimoniosos y validación temporal estricta. El consolidado mensual se obtendrá a partir de los pronósticos semanales, sin asumir que existe un modelo mensual independiente con evidencia suficiente.

Análisis de series temporales para demanda errática y Small Data

El pronóstico constituye una fase posterior a la caracterización de la serie. Antes de comparar algoritmos es necesario examinar la continuidad de la cobertura, la frecuencia de observación, la proporción de ceros, la tendencia, la autocorrelación y la estabilidad de los patrones

estacionales. En Small Data, estos diagnósticos permiten limitar la complejidad del modelo y evitar que una arquitectura de inteligencia artificial aprenda discontinuidades producidas por ausencia de registro como si fueran comportamiento económico real (Hyndman & Athanasopoulos, 2021).

En series con semanas sin movimiento, el intervalo promedio entre ocurrencias (ADI) y el cuadrado del coeficiente de variación de los importes positivos (CV^2) permiten distinguir comportamientos suaves, intermitentes, erráticos e irregulares. Esta clasificación no determina por sí sola el modelo ganador, pero fundamenta la inclusión de métodos especializados como Croston-SBA y TSB, así como transformaciones logarítmicas y modelos de dos etapas (Syntetos & Boylan, 2005).

El análisis temporal también debe separar la descripción retrospectiva de la selección predictiva. Las gráficas pueden mostrar toda la cobertura para fines de auditoría; sin embargo, las pruebas de estacionariedad, autocorrelación y selección de características que influyen en la configuración del modelo deben calcularse sin observar el bloque final de evaluación. Esta separación preserva el carácter fuera de muestra de la comparación entre métodos estadísticos y aprendizaje.

1.1.4 La repostería creativa como sector económico especializado

La industria de la repostería ha experimentado una evolución significativa durante las últimas décadas, pasando de modelos tradicionales de producción a esquemas altamente personalizados orientados a nichos específicos de mercado. Dentro de esta evolución destaca la denominada repostería creativa o *cake design*, caracterizada por la elaboración de productos personalizados para celebraciones, eventos sociales y ocasiones especiales. Esta transformación ha permitido que los productos de repostería trasciendan su función alimentaria para incorporar componentes estéticos, simbólicos y experienciales que agregan valor a la oferta comercial (Borsato, 2023).

La repostería contemporánea combina elementos gastronómicos, artísticos y comerciales, donde la diferenciación mediante el diseño, la personalización y la experiencia del cliente

constituyen factores clave para la competitividad empresarial. En este contexto, la creatividad se ha convertido en un recurso estratégico para los profesionales de la pastelería, integrando conocimientos técnicos, innovación estética y comprensión de las preferencias del consumidor (Ab Karim et al., 2020). Asimismo, la innovación en productos representa uno de los principales factores que contribuyen al desempeño y posicionamiento competitivo de las empresas del sector pastelero (Ben Abdallah et al., 2022).

A diferencia de la panadería tradicional, en la repostería creativa la demanda en este tipo de negocios suele presentar una mayor variabilidad debido a factores estacionales, eventos sociales y preferencias particulares de los consumidores. Esta dinámica genera desafíos importantes para la planeación de la producción, la gestión de inventarios y la estimación de ingresos, especialmente en microempresas que operan con recursos limitados y productos altamente perecederos. En consecuencia, la capacidad para anticipar cambios en la demanda y optimizar la toma de decisiones se ha convertido en un factor crítico para la sostenibilidad y competitividad de este tipo de organizaciones.

1.1.5 Innovación y transformación digital en la industria pastelera

La innovación tecnológica ha adquirido un papel relevante dentro de la industria alimentaria y, particularmente, en los sectores de panadería y repostería. La incorporación de herramientas digitales para la gestión de pedidos, control de inventarios, planificación de la producción y análisis de datos ha permitido mejorar la eficiencia operativa y la capacidad de respuesta ante cambios en la demanda. Mikalef et al. (2019) y Dubey et al. (2021) señalan en sus artículos que la digitalización de procesos facilita la optimización de recursos, incrementa la productividad y fortalece la capacidad de adaptación de las organizaciones ante entornos cada vez más dinámicos.

Hübner et al. (2024) demostraron que la implementación de modelos de aprendizaje automático para el pronóstico de la demanda en panaderías permitió disminuir significativamente el desperdicio alimentario y mejorar la planificación de la producción. De manera complementaria, estudios recientes sobre la digitalización del sector panadero

destacan que las tecnologías asociadas a la Industria 4.0 facilitan la integración de datos operativos, la automatización de procesos y la mejora continua en la gestión de la cadena de suministro (Aprodu et al., 2025).

No obstante, gran parte de estas innovaciones han sido implementadas en organizaciones medianas y grandes que cuentan con infraestructura tecnológica avanzada y capacidades analíticas consolidadas. En contraste, existe una limitada evidencia sobre la aplicación de estas herramientas en microempresas dedicadas a la repostería creativa, donde las restricciones financieras, tecnológicas y de personal especializado continúan representando barreras importantes para la adopción de tecnologías basadas en datos (Alekseeva et al., 2021).

1.1.6 Adopción de inteligencia artificial en microempresas

Diversos estudios han analizado los factores que influyen en la adopción de tecnologías basadas en inteligencia artificial dentro de pequeñas y medianas empresas.

Alekseeva, Ginevičius y Stankevičienė (2021) identifican que las principales barreras para la adopción de inteligencia artificial en PYMES están relacionadas con la falta de recursos financieros, infraestructura tecnológica limitada y escasez de capital humano especializado.

De manera similar, Mikalef et al. (2019) señalan que la capacidad de las organizaciones para aprovechar el potencial del análisis de datos depende en gran medida de sus capacidades analíticas y de su orientación hacia la innovación tecnológica.

Por otra parte, Dubey et al. (2021) destacan que la integración de analítica avanzada y herramientas de inteligencia artificial contribuye significativamente al desempeño operativo de las organizaciones cuando se combina con capacidades dinámicas y estrategias de innovación.

1.1.7 Investigaciones en México y América Latina

En el contexto mexicano, diversos estudios han analizado el impacto de la adopción tecnológica y la digitalización en el desempeño de las pequeñas y medianas empresas.

Por ejemplo, **Maldonado-Guzmán, Pinzón-Castro y García-Pérez-de-Lema (2018)** analizaron la relación entre innovación tecnológica y desempeño empresarial en PYMES mexicanas, encontrando que **las empresas que adoptan tecnologías digitales presentan mayores niveles de competitividad y eficiencia organizacional.**

De manera similar, **Cuevas-Vargas, Estrada y Larios-Gómez (2016)** examinaron el efecto de la adopción de tecnologías de información y comunicación en pequeñas y medianas empresas mexicanas. Sus resultados indican que **la digitalización de procesos y el uso de herramientas analíticas contribuyen significativamente a mejorar el desempeño organizacional.**

En la misma línea, **Maldonado-Guzmán y Garza-Reyes (2020)** analizaron los procesos de transformación digital en PYMES mexicanas, concluyendo que **la incorporación de tecnologías basadas en datos permite fortalecer los procesos de toma de decisiones y mejorar la capacidad de adaptación al entorno competitivo.**

Asimismo, **Saavedra-García y Tapia-Sánchez (2020)** señalan que las tecnologías de información desempeñan un papel clave en la competitividad de las PYMES mexicanas; sin embargo, **su adopción se ve limitada por restricciones financieras y por la falta de personal especializado.**

Finalmente, **Romero-Hidalgo et al. (2021)** destacan que la gestión del conocimiento y el uso de datos en las organizaciones favorecen los procesos de innovación empresarial, lo que **resulta particularmente relevante en el contexto de pequeñas empresas que buscan mejorar su desempeño mediante el uso de tecnologías digitales.**

Como complemento regional, **Poveda-Valverde y Fierro Barragán (2026)**, en una revisión sistemática de estudios sobre IA en PYMES latinoamericanas, **identifican restricciones de infraestructura, presupuesto y talento especializado, y observan que las aplicaciones se**

concentran principalmente en logística, manufactura y telecomunicaciones. Este hallazgo refuerza la necesidad de estudios aplicados y reproducibles en microempresas de servicios alimentarios, donde la disponibilidad de datos es más limitada.

Con el propósito de sintetizar las principales contribuciones de la literatura revisada, en la Tabla 1 se presentan los estudios más relevantes relacionados con la aplicación de inteligencia artificial, analítica de datos y adopción tecnológica en la gestión empresarial y el pronóstico de demanda.

Tabla 1 - Investigaciones relevantes sobre inteligencia artificial, analítica de datos y adopción tecnológica en la gestión empresarial

Autor(es) y año	País de origen	Palabras clave	Contexto y datos	Metodología	Hallazgo relevante	Limitación o brecha	Relación con la investigación
Hübner et al. (2024)	Alemania	panadería; ML; pronóstico; desperdicio	Panaderías; ventas, producción y desperdicio	Caso cuantitativo con ML	El pronóstico de demanda puede apoyar la reducción de desperdicio.	Caso con infraestructura superior a la microempresa.	Aporta el antecedente sectorial; justifica evaluar una solución acotada a registros internos.
Huber y Stuckenschmidt (2020)	Alemania	retail; ML; calendario; demanda diaria	Retail diario; ventas y calendario	Comparación de ML con variables calendáricas	Las variables de calendario mejoran pronósticos en eventos.	Contexto minorista de mayor escala.	Sustenta incluir calendario y eventos disponibles en el dataset.
Abrar et al. (2024)	Internacional	cadena de suministro; CNN; LSTM; XAI	Cadena de suministro; demanda multifuente	Modelo híbrido CNN-LSTM con XAI	Los modelos híbridos pueden integrar señales complejas.	Alta complejidad y requisitos de datos.	Sirve como contraste: la tesis evalúa alternativas parsimoniosas en Small Data.
Spiliotis et al. (2022)	Grecia	SKU; demanda diaria; ML; métodos estadísticos	SKU diarios; series irregulares e intermitentes	Comparación de métodos estadísticos y ML	La superioridad de ML depende del objetivo y debe verificarse empíricamente.	Datos minoristas con múltiples SKU.	Fundamenta comparar Random Forest, ARIMA y línea base empírica.
Makridakis et al. (2018)	Internacional	M4; forecasting; ML; métodos híbridos	Competencia M4; múltiples series y horizontes	Benchmark de métodos estadísticos, híbridos y ML	Los modelos complejos no dominan de forma universal.	No estudia microempresas ni compras.	Sustenta una hipótesis condicional y la evaluación comparativa.
Hewamalage et al. (2021)	Australia	RNN; series temporales; ARIMA; ETS	Series temporales con RNN	Estudio empírico frente a ETS y ARIMA	Las RNN son competitivas, pero no son soluciones universales.	No se centra en presupuesto de compras de microempresas.	Justifica reportar RNN/LSTM sin asumir superioridad frente a modelos simples.
Giannopoulos et al. (2025)	Grecia	demanda intermitente; ML; evaluación; Small Data	Demanda intermitente en distintas industrias	Revisión de ML y protocolos de evaluación	La intermitencia exige atención a partición temporal, ajuste y métricas.	Predomina evidencia de SKU y refacciones.	Sustenta Rolling-Origin y el uso cauteloso de MAPE.
Borsato (2023)	Italia	repostería; estética; personalización	Repostería creativa y valor estético	Estudio sectorial cualitativo	La personalización distingue a la repostería creativa.	No evalúa pronósticos ni IA.	Delimita el contexto de negocio del caso Cup&Cake.
Ab Karim et al. (2020)	Malasia	pastelería; creatividad; experiencia	Pastelería; creatividad y experiencia	Estudio de retrato/teoría integrada	La creatividad y personalización influyen en la oferta del sector.	No modela demanda.	Apoya la explicación de la variabilidad comercial del caso.
Ben Abdallah et al. (2022)	Túnez	innovación; pastelería; competitividad	Empresas pasteleras; innovación de producto	Estudio exploratorio	La innovación favorece desempeño y posicionamiento competitivo.	No analiza pronóstico ni ML.	Complementa la caracterización del sector de repostería.
Mikalef et al. (2019)	Noruega	big data; capacidades analíticas; innovación	Organizaciones orientadas a datos	Modelo de capacidades analíticas	Las capacidades analíticas se relacionan con innovación.	No se limita a microempresas ni pronóstico.	Sustenta la adopción de datos como capacidad organizacional.
Dubey et al. (2021)	Reino Unido / India	IA; big data; desempeño operativo	Manufactura; analítica, IA y desempeño	Modelo empírico de desempeño operativo	El valor de IA depende de capacidades y contexto.	Contexto industrial.	Refuerza que el DSS es apoyo y no garantía automática de desempeño.
Aprodu et al. (2025)	Rumania	panadería; Industria 4.0; digitalización	Sector panadero e Industria 4.0	Revisión sistemática	La digitalización integra datos y automatización en panadería.	Evidencia sectorial heterogénea.	Apoya la pertinencia de digitalizar ventas y compras del caso.
Alekseeva et al. (2021)	Lituania	adopción de IA; PYMES; barreras	PYMES europeas; adopción de IA	Estudio sobre barreras de adopción	Recursos, infraestructura y talento limitan la adopción.	No mide pronóstico de compras.	Justifica una solución de bajo requerimiento basada en datos existentes.
Maldonado-Guzmán et al. (2018)	México	innovación tecnológica; PYMES; desempeño	PYMES mexicanas; innovación y desempeño	Estudio empírico cuantitativo	La adopción tecnológica se asocia con competitividad.	No evalúa IA ni pronósticos.	Aporta contexto nacional de transformación tecnológica.
Cuevas-Vargas et al. (2016)	México	TIC; PYMES; innovación	PYMES mexicanas; TIC y desempeño	Estudio cuantitativo	Las TIC favorecen la innovación y el desempeño organizacional.	No incorpora ML.	Sustenta el antecedente mexicano de digitalización.

Autor(es) y año	País de origen	Palabras clave	Contexto y datos	Metodología	Hallazgo relevante	Limitación o brecha	Relación con la investigación
Maldonado-Guzmán y Garza-Reyes (2020)	México	transformación digital; PYMES; datos	PYMES mexicanas; transformación digital	Estudio de procesos de digitalización	Las tecnologías basadas en datos fortalecen decisiones.	No compara modelos predictivos.	Contextualiza la brecha entre digitalización y analítica predictiva.
Saavedra-García y Tapia-Sánchez (2020)	México	TIC; PYMES; competitividad	PYMES mexicanas; adopción de TIC	Análisis de adopción tecnológica	Las restricciones financieras y de talento limitan la adopción.	Enfoque descriptivo.	Respalda la pertinencia de una solución reproducible y accesible.
Romero-Hidalgo et al. (2021)	México	gestión del conocimiento; innovación; datos	Pequeñas empresas; conocimiento e innovación	Modelo de gestión del conocimiento	El uso de datos favorece la innovación organizacional.	No evalúa precisión predictiva.	Complementa el valor de formalizar registros dispersos.
Poveda-Valverde y Fierro Barragán (2026)	Ecuador / América Latina	IA; PYMES; adopción; barreras	PYMES latinoamericanas; adopción de IA	Revisión sistemática	Persisten barreras de infraestructura, presupuesto y talento; logística concentra aplicaciones.	No se centra en microempresas de repostería.	Refuerza el vacío regional y la necesidad de evidencia aplicada en microempresas.
Hyndman y Athanasopoulos (2021)	Australia	series temporales; diagnóstico; pronóstico; validación.	Ejemplos de series reales de distintos sectores	Libro metodológico con aplicaciones en R	El diagnóstico precede al modelado; la evaluación requiere datos fuera de muestra.	No estudia compras de microempresas.	Sustenta el diagnóstico temporal y la evaluación fuera de muestra.
Syntetos y Boylan (2005)	Reino Unido	demanda intermitente; Croston; SBA; precisión	Industria automotriz; 3,000 series intermitentes	Comparación de cuatro métodos y simulación	La modificación de Croston mejora la precisión en las series evaluadas.	No compara ML ni estudia microempresas alimentarias.	Fundamenta incluir Croston-SBA y métricas compatibles con ceros..

Fuente: Elaboración propia con base en las referencias citadas en el Estado del Arte.

1.1.8 Síntesis del estado del arte y vacío de investigación

La literatura revisada destaca el potencial de los modelos híbridos y las combinaciones de métodos para mejorar la precisión del pronóstico. **Makridakis et al. (2018)** identificaron en la competencia M4 resultados destacados mediante la integración de componentes estadísticos y de aprendizaje automático. Por su parte, **Abrar et al. (2024)** presentaron una arquitectura híbrida de redes neuronales con mejoras en el contexto evaluado. Aunque representan formas distintas de integración, estos antecedentes fundamentan el estudio de enfoques complementarios, cuya precisión debe comprobarse según las características de los datos y el horizonte de pronóstico.

Los antecedentes incluyen estudios de demanda por producto y aplicaciones en el sector panadero. **Huber y Stuckenschmidt (2020)** abordaron el pronóstico diario por categoría y establecimiento en una cadena de panaderías, mientras que **Spiliotis et al. (2022)** compararon métodos estadísticos y de aprendizaje automático en series diarias de demanda por producto. Estos contextos difieren del pronóstico del importe semanal de compras de una microempresa. Asimismo, **Poveda-Valverde y Fierro Barragán (2026)** identificaron restricciones de infraestructura, presupuesto y talento especializado para la adopción de IA en PYMES latinoamericanas, lo que refuerza la pertinencia de soluciones adaptadas a sus recursos.

Dentro de los trabajos revisados, se identifica evidencia limitada sobre el desarrollo y la evaluación temporal de modelos híbridos estadísticos y de aprendizaje automático para el pronóstico del importe semanal de compras, junto con un procedimiento de distribución porcentual entre los principales insumos, en microempresas de repostería creativa. El vacío aplicado se sitúa en la articulación de ambos resultados como apoyo al presupuesto de abastecimiento, bajo condiciones de información histórica limitada y variabilidad en las compras.

La investigación aborda este vacío mediante la evaluación de la precisión del importe total pronosticado y de su distribución porcentual frente a modelos de referencia. La distribución se fundamentará en la composición histórica de las compras y su variación temporal, y permitirá expresar asignaciones presupuestarias por insumo. Su evaluación determinará la capacidad de anticipar el gasto registrado y su composición; establecer cantidades óptimas de compra

requeriría información adicional sobre necesidades de producción, existencias y condiciones de suministro.

La contribución consiste en desarrollar un modelo híbrido que integra métodos estadísticos y aprendizaje automático, acompañado de un procedimiento de distribución porcentual del importe semanal entre los principales insumos de Cup&Cake, microempresa de repostería creativa de Tizayuca, Hidalgo. A partir de los registros de ventas y compras, se construirán las series semanales y se evaluará temporalmente la precisión frente a modelos de referencia. Los resultados servirán como apoyo a la planeación del presupuesto de abastecimiento, con un alcance centrado en el pronóstico y la asignación presupuestaria.

1.2 El planteamiento del problema

Las microempresas operan en entornos caracterizados por alta incertidumbre financiera, variabilidad en la demanda y limitaciones en recursos tecnológicos y analíticos (Góngora Chonillo, 2023). En la mayoría de los casos, la planeación financiera y la gestión de la cadena de suministro se sustentan en la experiencia empírica del propietario, en estimaciones intuitivas o en el análisis retrospectivo de resultados históricos, sin el apoyo de modelos predictivos formales que permitan anticipar escenarios futuros con mayor precisión.

Esta situación resulta especialmente crítica en microempresas del sector alimentario, donde la demanda presenta fuertes componentes estacionales y donde una planeación inadecuada impacta directamente en el control de inventarios, la gestión de ingresos y la rentabilidad del negocio. Hyndman y Athanasopoulos (2021) explican que la calidad de los pronósticos impacta directamente en la planificación estratégica, la gestión de inventarios y la toma de decisiones financieras, señalando que errores sistemáticos generan sobrecostos y desabastecimientos.

A pesar de la creciente disponibilidad de soluciones basadas en Inteligencia Artificial (IA) y analítica avanzada, su adopción en micro y pequeñas empresas continúa siendo limitada. Estudios como el de Alekseeva et al. (2021), evidencian que estas organizaciones enfrentan barreras estructurales asociadas a restricciones financieras y limitaciones en infraestructura tecnológica, lo que dificulta la implementación de herramientas digitales avanzadas.

Asimismo, la literatura señala que la carencia de capital humano especializado y de capacidades analíticas internas reduce significativamente la posibilidad de integrar soluciones basadas en datos en los procesos estratégicos empresariales (Mikalef et al., 2019). Esta limitación se vincula directamente con la baja capacidad de absorción tecnológica característica de las empresas de menor tamaño.

En el ámbito de la gestión operativa y de la cadena de suministro, se ha identificado que la incorporación de tecnologías de analítica avanzada e IA depende del desarrollo de capacidades dinámicas y de una orientación estratégica clara hacia la innovación, condiciones que no siempre están presentes en microempresas (Dubey et al., 2021).

Asimismo, la literatura evidencia que la mayoría de las investigaciones sobre analítica avanzada e Inteligencia Artificial se han desarrollado en organizaciones medianas y grandes o en entornos industriales altamente estructurados, lo que limita la comprensión de su aplicabilidad en microempresas (Mikalef et al., 2020; Alekseeva et al., 2021). Esta concentración ha generado un vacío en el análisis empírico acerca de cómo los modelos de aprendizaje automático pueden incidir en la planeación financiera y operativa de empresas de menor escala.

Dicho vacío se profundiza cuando se examina la integración simultánea del pronóstico de ingresos y la gestión de inventarios como procesos interdependientes dentro de la cadena de suministro, dimensión que la literatura reconoce como crítica para el desempeño organizacional, pero escasamente abordada en microempresas (Dubey et al., 2021; Hyndman & Athanasopoulos, 2021).

1.2.1 Contexto del caso de estudio

En el contexto de las micro, pequeñas y medianas empresas (MIPYMES), la toma de decisiones suele caracterizarse por una fuerte dependencia del conocimiento tácito, la experiencia acumulada del propietario o directivo y prácticas organizacionales poco formalizadas. Este enfoque, predominantemente empírico, si bien aporta flexibilidad y rapidez en entornos de alta incertidumbre, limita la estructuración sistemática del conocimiento y la consolidación de procesos estratégicos basados en información analítica (García-Pérez et al., 2020).

Cup&Cake, es una empresa fundada en 2014, con más de diez años de operación el crecimiento orgánico le ha permitido subsistir gracias a las compras que actualmente se realizan se hacen con base en el empirismo del empresario ya que lo único que conoce son las fechas de eventos importantes como el Día de San Valentín (14 de febrero), el día del niño (30 de abril), el día de la madre (10 de mayo), entre otros que son los picos de venta que año con año se repiten.

Con el paso del tiempo, Cup&Cake ha incrementado sus ventas de manera orgánica, producto de un proceso mercadológico inicial, donde clientes que han depositado su confianza en la empresa recomiendan sus productos por su sabor y alta calidad en la decoración y personalización de sus productos, provocando el aumento constante en las ventas.

El reto de Cup&Cake es fortalecer la planeación semanal del presupuesto de abastecimiento. Para ello, requiere estimar al inicio de cada semana el importe probable de compra semanal así como la distribución entre los principales insumos, considerando el comportamiento histórico, las fechas comerciales y las variables exógenas disponibles.

El pronóstico tendrá como propósito reducir la incertidumbre al reservar y revisar el presupuesto de abastecimiento de corto plazo. La investigación no pretende medir directamente incrementos de utilidad, expansión comercial o reducción de costos, pues dichas conclusiones requerirían información adicional y un diseño de evaluación operativa.

1.2.2 Pregunta de Investigación

¿Qué precisión ofrece un modelo híbrido que integra métodos estadísticos y aprendizaje automático, mediante evaluación temporal de su precisión frente a modelos de referencia, para estimar el importe total semanal de compras y su distribución porcentual entre los principales insumos, como apoyo a la planeación del presupuesto de abastecimiento en una microempresa de repostería creativa de Tizayuca, Hidalgo?

1.2.3 Objetivo

Objetivo general

Desarrollar un modelo híbrido que integra métodos estadísticos y aprendizaje automático, mediante evaluación temporal de su precisión frente a modelos de referencia, para el pronóstico del importe total semanal de compras y su distribución porcentual entre los principales insumos, como apoyo a la planeación del presupuesto de abastecimiento de una microempresa de repostería creativa de Tizayuca, Hidalgo

Objetivos específicos

1. Analizar los registros históricos de ventas y compras mediante depuración, agregación semanal y caracterización temporal del importe total y de la participación de los principales insumos.
2. Desarrollar la estructura del modelo híbrido mediante la integración de componentes estadísticos y de aprendizaje automático, con variables históricas y exógenas disponibles al momento del pronóstico.
3. Determinar la distribución porcentual del importe semanal pronosticado entre los principales insumos, a partir de su composición histórica y variación temporal.
4. Contrastar la precisión del modelo híbrido y del procedimiento de distribución porcentual frente a modelos de referencia, mediante evaluación temporal y métricas de error monetario y de participación.

1.3 Justificación

1.1. Relevancia social

Esta investigación propone generar evidencia sobre el uso de herramientas de pronóstico semanal en una microempresa con recursos tecnológicos y analíticos limitados. Las restricciones financieras, tecnológicas y de personal especializado dificultan que las microempresas adopten soluciones basadas en datos. Por ello, evaluar modelos a partir de la información disponible permitirá identificar alternativas cuya pertinencia pueda valorarse en

función de sus capacidades operativas (Alekseeva et al., 2021; Poveda-Valverde & Fierro Barragán, 2026).

En Cup&Cake, el estudio buscará determinar si el modelo híbrido mejora la estimación del importe semanal de compras y su distribución porcentual entre los principales insumos frente a modelos de referencia. Los resultados podrían aportar información útil para el responsable de la planeación del presupuesto de abastecimiento. Asimismo, el procedimiento podrá servir como referencia para otras microempresas con condiciones semejantes, aunque su aplicación requerirá evaluar las características y los datos de cada negocio.

1.2. Conveniencia

El estudio atiende una necesidad operativa concreta de Cup&Cake: estimar, con horizontes de una a cuatro semanas, el importe total de las compras y su distribución porcentual entre los principales insumos. Se propone aprovechar los registros históricos de ventas y compras e incorporar variables exógenas disponibles al momento del pronóstico para desarrollar un procedimiento de apoyo a la planeación del presupuesto de abastecimiento.

Se comparará la precisión del modelo híbrido con la de modelos de referencia mediante validación temporal de ventana deslizante. Este contraste permitirá determinar si la integración de métodos estadísticos y aprendizaje automático aporta mejoras en el pronóstico frente a alternativas más sencillas, sin presuponer la superioridad de una mayor complejidad algorítmica (Makridakis et al., 2018; Spiliotis et al., 2022).

1.3. Valor teórico

El valor teórico esperado de la investigación consiste en aportar evidencia sobre el desempeño de métodos de pronóstico semanal en un contexto de datos limitados e intermitencia de las compras. La literatura señala que la precisión de los modelos depende de la cantidad y calidad de los datos, la granularidad temporal, las variables disponibles y el protocolo de evaluación; por tanto, su superioridad requiere contrastación empírica (Hewamalage et al., 2021; Giannopoulos et al., 2025).

El estudio permitirá examinar la precisión de un modelo híbrido que integre métodos estadísticos y aprendizaje automático, así como la de un procedimiento de distribución porcentual del importe semanal entre los principales insumos. También se analizará si las variables exógenas disponibles antes de cada pronóstico aportan información adicional. La contribución prevista será principalmente empírica y metodológica, circunscrita al caso de estudio, y podrá orientar investigaciones posteriores en microempresas con características semejantes.

1.4. Implicaciones prácticas

Se propone desarrollar para Cup&Cake un procedimiento reproducible para depurar e integrar los registros diarios, agregarlos semanalmente, construir variables predictivas, generar pronósticos y estimar la distribución porcentual del importe entre los principales insumos. Su precisión se evaluará fuera de muestra mediante métricas de error monetario y de participación. Se prevé presentar los resultados en un tablero de inteligencia de negocios que permita consultar el importe semanal esperado de compras, su consolidado mensual y la distribución presupuestaria entre los principales insumos.

El tablero tendrá como propósito apoyar la planeación y revisión del presupuesto de abastecimiento. No generará órdenes automáticas de compra ni calculará cantidades físicas por insumo, pues estas funciones requerirían información adicional sobre recetas, existencias, merma, costos de faltante, tiempos de entrega y unidades de medida homologadas. Los posibles beneficios operativos dependerán de los resultados obtenidos y de su posterior aplicación en la empresa.

La investigación se justifica por la necesidad de evaluar si un modelo híbrido que integre métodos estadísticos y aprendizaje automático puede mejorar el pronóstico del importe semanal de compras y su distribución porcentual entre los principales insumos de Cup&Cake. Se propone contrastar su precisión frente a modelos de referencia mediante evaluación temporal, con el propósito de aportar elementos para la planeación del presupuesto de abastecimiento. Su alcance no comprende la medición de efectos sobre inventarios, merma, rentabilidad o expansión comercial.

1.4 Hipótesis

1.5. Hipótesis de investigación (H1)

H1. El modelo híbrido que integre métodos estadísticos y aprendizaje automático, junto con el procedimiento de distribución porcentual entre los principales insumos, presentará menores errores de pronóstico fuera de muestra que los respectivos modelos de referencia para estimar el importe total semanal de compras y su composición porcentual en Cup&Cake, utilizando información disponible al momento del pronóstico y los mismos periodos y horizontes de evaluación.

2 MARCO TEÓRICO

El presente marco teórico desarrolla los fundamentos conceptuales y matemáticos que sustentan la propuesta de un modelo híbrido para pronosticar el importe total semanal de compras y su distribución porcentual entre los principales insumos de Cup&Cake. Para ello, se abordan la planeación del presupuesto de abastecimiento, las características de las series temporales semanales, los métodos estadísticos y de aprendizaje automático, y las estrategias para su integración. Posteriormente, se examinan los fundamentos de la distribución porcentual de las compras, el tratamiento de datos limitados y la evaluación del desempeño predictivo fuera de muestra mediante métricas de error monetario y de participación porcentual. Finalmente, se analiza el uso de los pronósticos como apoyo a la planeación de compras en el contexto de la microempresa (Hyndman & Athanasopoulos, 2021; Power, 2002).

2.1 Microempresa y planeación del presupuesto de abastecimiento

2.1.1 Recursos de información y conocimiento del negocio

Las empresas pequeñas presentan condiciones heterogéneas de digitalización (OECD, 2021). La disponibilidad de registros, las competencias del personal y los recursos para integrar herramientas condicionan el uso de analítica. Estas restricciones justifican procedimientos proporcionales a la información disponible, pero no permiten asumir que toda microempresa carece de registros o que una solución tecnológica tendrá beneficios automáticos. En Cup&Cake, la pertinencia del procedimiento se evaluará respecto de la necesidad de anticipar el presupuesto de compras.

La experiencia del responsable del negocio puede aportar información sobre celebraciones, cambios de proveedores o adquisiciones extraordinarias que no aparece explícitamente en una serie. Ese conocimiento permite interpretar registros y proponer variables, mientras que las reglas de pronóstico hacen reproducible la estimación. La complementariedad requiere distinguir hechos documentados de expectativas y conservar el momento en que cada dato estuvo disponible (Hyndman & Athanasopoulos, 2021).

2.1.2 Pronóstico como información para decidir

Un pronóstico puntual resume una distribución de resultados posibles. Bajo pérdida cuadrática, el valor que minimiza el error esperado es la media condicional. La ecuación (2.1) adapta esta propiedad al importe de compras: la estimación depende de la información existente en el origen del pronóstico, sin utilizar datos posteriores (Hastie et al., 2009).

$$\hat{y}_{t+h|t} = E(y_{t+h}|I_t) \quad (2.1)$$

En esta notación, y representa el importe semanal observado, t es la última semana conocida, h es el horizonte e I representa la información disponible. El sombrero distingue el pronóstico del valor observado y la barra vertical separa el periodo pronosticado del origen de información. Una estimación puntual ayuda a formular expectativas, pero no determina por sí sola la decisión presupuestaria del responsable (Hastie et al., 2009; Power, 2002).

La planeación del presupuesto utilizará esa estimación como un insumo para revisar recursos destinados al abastecimiento. Un sistema de soporte a la decisión organiza datos y modelos para facilitar la valoración de alternativas; la decisión final también puede incorporar restricciones que el modelo no observa. Por ello, el estudio evaluará precisión predictiva y no supondrá que un menor error produce necesariamente un retorno financiero positivo (Power, 2002).

2.2 Compras monetarias y contexto de la repostería

2.2.1 Delimitación de la variable objetivo

Pronosticar requiere definir con precisión qué se observa, con qué frecuencia y para qué horizonte. En esta investigación, la respuesta principal será el importe total semanal registrado de compras. Las ventas, el consumo de ingredientes y las existencias son magnitudes diferentes: pueden aportar contexto, pero no sustituyen la variable definida. La comparación entre modelos deberá mantener la misma respuesta y las mismas unidades monetarias (Hyndman & Athanasopoulos, 2021).

El importe de una adquisición puede variar por cantidad, precio y composición de insumos. Además, la fecha de compra puede diferir de la fecha de consumo o pago. Por tanto, la interpretación prevista será presupuestaria: se intentará anticipar el registro monetario de compras, sin identificarlo con una cantidad óptima de abastecimiento. Esta delimitación

mantiene separado el objetivo de predicción de las inferencias explicativas o causales (Shmueli, 2010).

2.2.2 Agregación del importe y niveles de análisis

Los pronósticos jerárquicos representan series relacionadas mediante sumas. Adaptada al caso, la identidad de agregación expresa el importe semanal total como suma de los importes de las categorías de insumos. La ecuación (2.2) es una aplicación de esa estructura aditiva, no un modelo causal de costos (Hyndman et al., 2011).

$$y_t = \sum_{j=1}^J b_{j,t} \quad (2.2)$$

Aquí, b es el importe del insumo o categoría j y J es el número de categorías mutuamente excluyentes que cubren el total. Si solo se presentan los principales insumos, será necesario conservar una categoría residual para las demás compras o declarar que se trabaja con un subtotal. La suma evita que las asignaciones se interpreten como un total cuando omiten parte de sus componentes (Hyndman et al., 2011).

La **perecibilidad** aporta contexto a la periodicidad de las compras, pero no hace equivalentes el pronóstico monetario y la planificación de inventarios. La frecuencia y el nivel de agregación deben responder a la decisión analizada. En el caso propuesto, la escala semanal facilitará la revisión del presupuesto; la traducción de importes a unidades físicas requeriría precios, recetas, existencias y condiciones de suministro que exceden ese pronóstico (Hyndman & Athanasopoulos, 2021).

2.3 Series temporales semanales y calidad de los registros

2.3.1 Frecuencia y continuidad

Una serie temporal es una secuencia ordenada de observaciones. La agregación semanal debe conservar un calendario consistente y distinguir ausencia de compra de ausencia de registro. Rellenar automáticamente huecos con ceros cambiaría el fenómeno observado. La continuidad de las fuentes y la identificación de semanas incompletas deberán examinarse antes de interpretar patrones o entrenar modelos (Hyndman & Athanasopoulos, 2021).

2.3.2 Nivel tendencia y estacionalidad

La descomposición aditiva representa una serie mediante tendencia-ciclo, estacionalidad y residuo. Es útil cuando las oscilaciones estacionales se interpretan en la escala original; si aumentan proporcionalmente al nivel, pueden considerarse transformaciones u otras representaciones. La ecuación (2.3) presenta la descomposición con notación adaptada al importe semanal (Hyndman & Athanasopoulos, 2021).

$$y_t = T_t + S_t + R_t \quad (2.3)$$

T representa el componente de tendencia-ciclo, S el patrón estacional y R la variación restante. El residuo no debe interpretarse automáticamente como error de captura: puede contener acontecimientos legítimos o estructura no representada. La descomposición sirve para explorar el comportamiento de la serie, sin demostrar que los componentes conservarán la misma forma en periodos futuros (Hyndman & Athanasopoulos, 2021).

La estacionalidad implica repetición asociada al calendario. Para compras semanales, un patrón anual debe examinarse con la cobertura disponible y con atención a festividades móviles. Contar con un ciclo no permite observar su repetición entre años. La incorporación de componentes estacionales dependerá de evidencia histórica y de su utilidad predictiva, no solo de la existencia de fechas comerciales relevantes (Hyndman & Athanasopoulos, 2021).

2.3.3 Estacionariedad y dependencia temporal

La diferenciación transforma la serie mediante cambios entre observaciones sucesivas, como muestra la ecuación (2.4). Puede ayudar a tratar variaciones persistentes de nivel; la estabilización de varianza, en cambio, puede requerir transformaciones de escala. ADF y KPSS examinan hipótesis distintas sobre estacionariedad, y su interpretación debe considerar el tamaño de muestra y los componentes incluidos en la prueba (Hyndman & Athanasopoulos, 2021).

$$\Delta y_t = y_t - y_{t-1} \quad (2.4)$$

La autocorrelación describe asociación lineal entre observaciones separadas por un rezago. En la ecuación (2.5), k identifica la separación temporal, N el número de semanas y la barra el promedio de la serie. La función ayuda a explorar memoria temporal, sin constituir por sí sola una regla de selección del modelo (Hyndman & Athanasopoulos, 2021).

$$r_k = \frac{\sum_{t=k+1}^N (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^N (y_t - \bar{y})^2} \quad (2.5)$$

La autocorrelación parcial y las pruebas de dependencia conjunta pueden complementar el diagnóstico. Las decisiones sobre rezagos deben respetar el origen temporal: analizar toda la serie para escoger características y luego evaluar sobre una parte de ella puede incorporar información de los periodos reservados. En la evaluación propuesta, los diagnósticos que determinen ajustes se restringirán al historial disponible (Hyndman & Athanasopoulos, 2021).

2.3.4 Intermitencia y valores extremos

Cuando existen periodos con valor cero, resulta útil distinguir tamaño de los eventos positivos y tiempo entre eventos. El método de Croston mantiene estimaciones suavizadas de ambas cantidades y obtiene una tasa por periodo mediante su cociente, representado en la ecuación (2.6). Su traslado de demanda a compras monetarias deberá justificarse por el patrón observado (Hyndman & Athanasopoulos, 2021).

$$\hat{y}_{t+h|t} = \frac{\hat{z}_t}{\hat{a}_t} \quad (2.6)$$

La estimación z corresponde al tamaño de los eventos positivos y a al intervalo entre ellos. El procedimiento es una alternativa de referencia para intermitencia, no una garantía de superioridad. Los picos también deberán distinguirse entre errores de registro y compras extraordinarias; eliminarlos por su magnitud podría retirar información legítima del proceso que se desea pronosticar (Hyndman & Athanasopoulos, 2021; Kuhn & Johnson, 2013).

2.4 Métodos estadísticos y de aprendizaje automático

2.4.1 Referencias simples

Una referencia establece qué precisión puede obtenerse con una regla reproducible. El método ingenuo conserva el último valor conocido para los horizontes futuros, como muestra la ecuación (2.7). Una referencia estacional utiliza el periodo comparable de un ciclo anterior cuando existe historial suficiente. Ninguna de estas reglas representa por sí misma el juicio del propietario (Hyndman & Athanasopoulos, 2021).

$$\hat{y}_{t+h|t} = y_t \quad (2.7)$$

La utilidad de estas referencias es contextualizar el error: una arquitectura compleja puede reducir el error de entrenamiento sin mejorar el de semanas futuras. El estudio deberá comparar al híbrido con referencias previamente definidas para el importe y para la composición, de modo que la mejora se mida respecto de alternativas pertinentes (Hyndman & Athanasopoulos, 2021).

2.4.2 Suavizamiento exponencial y ARIMA

El suavizamiento exponencial simple actualiza una estimación del nivel mediante una combinación de la observación reciente y el nivel previo. En la ecuación (2.8), α controla el peso de la información reciente y toma valores entre cero y uno. Su pronóstico no incorpora por sí mismo tendencia o estacionalidad, por lo que funciona como una representación básica (Hyndman & Athanasopoulos, 2021).

$$\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}, \quad \hat{y}_{t+h|t} = \ell_t \quad (2.8)$$

Los modelos de suavizamiento con tendencia y estacionalidad amplían esta representación. Su pertinencia dependerá de la estructura temporal y de la cantidad de observaciones. No será suficiente seleccionar una variante más compleja: deberá verificarse si sus componentes ayudan a estimar las semanas reservadas para evaluación (Hyndman & Athanasopoulos, 2021).

Un ARIMA combina términos autorregresivos, diferenciación y medias móviles de innovaciones. La ecuación (2.9) usa el operador de rezago B , de modo que B aplicado a y en t devuelve el valor anterior. Los polinomios ϕ y θ representan los órdenes autorregresivo y de medias móviles; d es el orden de diferenciación y ε_t la innovación (Hyndman & Athanasopoulos, 2021).

$$\phi(B)(1 - B)^d y_t = c + \theta(B)\varepsilon_t \quad (2.9)$$

El componente de medias móviles de ARIMA opera sobre innovaciones y no equivale a promediar compras de semanas anteriores. Las variantes estacionales añaden operadores a una periodicidad definida. La selección debe considerar longitud del historial y diagnóstico de residuos; los modelos estadísticos no son inadecuados por definición ante una microempresa (Hyndman & Athanasopoulos, 2021).

2.4.3 Bosques aleatorios y potenciación de gradiente

Random Forest combina árboles contruidos con aleatoriedad en muestras y predictores. En regresión, la salida es el promedio de las predicciones, representado en la ecuación (2.10). B es el número de árboles, T identifica cada árbol y x reúne los predictores disponibles. La agregación busca reducir variabilidad respecto de un árbol individual (Breiman, 2001).

$$\hat{f}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x) \quad (2.10)$$

Los árboles permiten representar interacciones y relaciones no lineales. Para series semanales necesitan entradas temporales adecuadas, como rezagos y calendario; no deducen automáticamente qué información estará disponible en el futuro. Su comportamiento depende de profundidad, tamaño de nodos y diversidad de árboles, y no puede describirse como inmunidad a errores de captura o datos faltantes (Breiman, 2001).

La potenciación de gradiente construye una función de manera aditiva. La ecuación (2.11) expresa una actualización con un aprendiz base g, un coeficiente rho y una tasa de aprendizaje nu. La dirección de actualización depende del gradiente negativo de la pérdida; con pérdida cuadrática se relaciona con los residuales (Friedman, 2001).

$$F_m(x) = F_{m-1}(x) + \nu \rho_m g_m(x) \quad (2.11)$$

La tasa de aprendizaje y el número de etapas controlan la magnitud de la adaptación. Estas técnicas pueden aprovechar interacciones entre calendario e historial, pero requieren ajuste temporal. Evaluar más etapas sobre los mismos datos finales usados para reportar precisión introduciría optimismo en la comparación (Friedman, 2001).

2.4.4 Redes neuronales y alcance de los comparadores

Una red autorregresiva aproxima una relación entre rezagos mediante una función no lineal. Las arquitecturas recurrentes añaden estados internos y mecanismos de memoria, pero también parámetros y decisiones de ajuste. En escenarios con pocas observaciones, su inclusión debe justificarse por información suficiente y comparación con métodos más sencillos; no define por sí misma el carácter híbrido del estudio (Hyndman & Athanasopoulos, 2021).

La selección de familias tendrá sentido si permite examinar representaciones distintas del mismo objetivo. Un comparador adicional deberá aportar una pregunta pertinente, como la utilidad de no linealidad o memoria, y no solo ampliar una lista de algoritmos. La configuración final pertenecerá a metodología y se fijará mediante información anterior a las semanas de evaluación (Kuhn & Johnson, 2013).

2.5 Fundamentos de integración del modelo híbrido

2.5.1 Combinación de pronósticos

La combinación de pronósticos parte de que métodos distintos pueden contener información complementaria. Para dos modelos, la ecuación (2.12) pondera un pronóstico estadístico y uno de aprendizaje automático. La notación adapta el principio de combinación al caso; el peso w determina la contribución del primero. Restringirlo entre cero y uno produce una combinación convexa (Bates & Granger, 1969).

$$\hat{y}_{t+h|t}^H = w\hat{y}_{t+h|t}^E + (1-w)\hat{y}_{t+h|t}^A \quad (2.12)$$

Los superíndices H, E y A identifican híbrido, estadístico y aprendizaje automático. Bajo errores insesgados con varianzas finitas, la varianza del error combinado depende de las varianzas individuales y de su covarianza. La ecuación (2.13) explica por qué el grado de dependencia entre errores importa para la combinación (Bates & Granger, 1969).

$$\sigma_H^2 = w^2\sigma_E^2 + (1-w)^2\sigma_A^2 + 2w(1-w)\sigma_{EA} \quad (2.13)$$

Cuando los errores se parecen mucho, combinar puede aportar poco. Si el denominador es positivo, el peso que minimiza esa varianza sin imponer la restricción convexa se expresa en la ecuación (2.14). Su uso exige estimar varianzas y covarianza sin información futura; la estimación puede ser inestable con pocos errores disponibles (Bates & Granger, 1969).

$$w^* = \frac{\sigma_A^2 - \sigma_{EA}}{\sigma_E^2 + \sigma_A^2 - 2\sigma_{EA}} \quad (2.14)$$

La combinación simple también debe considerarse como referencia, pues estimar pesos no garantiza mejorar un promedio. En el estudio propuesto, el interés será contrastar si integrar representaciones distintas produce menores errores. La evaluación deberá distinguir esa combinación de la mera selección del algoritmo ganador (Hyndman & Athanasopoulos, 2021).

2.5.2 Integración mediante componentes

Otra estrategia híbrida representa la serie como suma de componentes lineal y no lineal. Un antecedente integra ARIMA y una red neuronal para modelar estructura complementaria. La ecuación (2.15) resume esa formulación; sus componentes no son observables independientes, sino representaciones estimadas mediante un procedimiento de modelado (Zhang, 2003).

$$y_t = L_t + N_t, \quad \hat{y}_{t+h|t} = \hat{L}_{t+h|t} + \hat{N}_{t+h|t} \quad (2.15)$$

Si el segundo componente se entrena con errores del primero, debe cuidarse cómo se generan esos errores. Los residuales de entrenamiento pueden presentar un comportamiento distinto del error predictivo. Por ello, cualquier adaptación a Cup&Cake deberá construir y ajustar sus componentes respetando el orden temporal y evaluar la suma sobre semanas no utilizadas para configurar el procedimiento (Hyndman & Athanasopoulos, 2021; Zhang, 2003).

Estas alternativas ofrecen mecanismos plausibles para H1, sin anticipar cuál resultará más preciso. Una combinación puede fallar si los componentes comparten errores, si los pesos se estiman con poca información o si la estructura cambia. La selección de una arquitectura concreta requerirá especificar qué componentes se integran y cómo se contrastará el conjunto (Hyndman & Athanasopoulos, 2021).

2.6 Distribución porcentual y coherencia de las asignaciones

2.6.1 Participaciones como datos composicionales

Las participaciones describen partes de un total y están sujetas a una restricción de suma. Por ello, no se interpretan como variables completamente independientes: aumentar una participación requiere disminuir alguna otra. La ecuación (2.16) adapta la representación composicional a importes no negativos de compras, incluyendo la condición de total positivo (Aitchison, 1982).

$$p_{j,t} = \frac{b_{j,t}}{y_t}, \quad p_{j,t} \geq 0, \quad \sum_{j=1}^J p_{j,t} = 1, \quad y_t > 0 \quad (2.16)$$

Las proporciones se expresan entre cero y uno; su multiplicación por cien produce porcentajes. Si el total observado es cero, las participaciones no quedan definidas por el cociente. Una regla

de tratamiento deberá distinguir ese caso de una participación cero dentro de una semana con compras. Las transformaciones logarítmicas requieren además componentes estrictamente positivos (Aitchison, 1982).

2.6.2 Desagregación del pronóstico total

El enfoque descendente pronostica un agregado y lo distribuye mediante proporciones. La ecuación (2.17) adapta esa relación a importes por insumo: cada asignación es el producto del total pronosticado y la participación estimada para el mismo horizonte. Las proporciones deben cumplir las restricciones de suma y no negatividad (Hyndman & Athanasopoulos, 2021).

$$\hat{b}_{j,t+h|t} = \hat{p}_{j,t+h|t} \hat{y}_{t+h|t} \quad (2.17)$$

El procedimiento preserva la suma cuando todas las categorías están representadas. Esa coherencia es aritmética y no demuestra precisión: un total correcto puede repartirse incorrectamente. Por esa razón, la evaluación deberá revisar tanto el importe agregado como las participaciones y, cuando resulte pertinente, las asignaciones monetarias resultantes (Hyndman et al., 2011).

Como referencia, el promedio de proporciones históricas asigna a cada categoría su participación media en las semanas de entrenamiento con total positivo. La ecuación (2.18) adapta el promedio histórico de proporciones a ese conjunto válido V , cuyo tamaño es n . No es equivalente al cociente de sumas, que otorga más peso a las semanas de mayor importe (Hyndman & Athanasopoulos, 2021).

$$\bar{p}_j = \frac{1}{n} \sum_{t \in V} \frac{b_{j,t}}{y_t} \quad (2.18)$$

Una distribución histórica fija puede ser insuficiente si la mezcla cambia. Las proporciones pronosticadas ofrecen una alternativa, aunque requieren información y evaluación propias. Debe mantenerse el mismo conjunto de categorías a lo largo del contraste o documentar sus cambios. Este principio permite diferenciar la mejora de la composición de la mejora del total (Hyndman & Athanasopoulos, 2021).

2.6.3 Representación relativa de las participaciones

El análisis composicional utiliza cocientes para representar información relativa. La transformación logarítmica de una participación respecto de una categoría de referencia aparece en la ecuación (2.19). Su utilidad es mostrar que la información relevante puede expresarse como relación entre partes, en lugar de tratar porcentajes como respuestas independientes sin restricciones (Aitchison, 1982).

$$z_{j,t} = \log\left(\frac{p_{j,t}}{p_{J,t}}\right), \quad j = 1, \dots, J - 1 \quad (2.19)$$

Esta transformación es una alternativa teórica y no obliga a seleccionarla para el estudio. Los ceros requieren un tratamiento explícito que no distorsione la composición; no deberán sustituirse de manera arbitraria solo para permitir un logaritmo. Una estrategia más simple también podrá ser pertinente si conserva coherencia y obtiene precisión comparable fuera de muestra (Aitchison, 1982).

2.7 Datos limitados e ingeniería de características

2.7.1 Complejidad y capacidad de generalización

La cantidad de observaciones debe valorarse en relación con la complejidad del modelo y la dependencia de los datos. Para pérdida cuadrática, la descomposición sesgo–varianza expresa el error esperado como suma de sesgo al cuadrado, varianza del estimador y ruido irreducible. La ecuación (2.20) resume esa relación para una entrada x (Hastie et al., 2009).

$$E[(Y - \hat{f}(x))^2] = \text{Sesgo}^2[\hat{f}(x)] + \text{Var}[\hat{f}(x)] + \sigma^2 \quad (2.20)$$

Un ajuste flexible puede reducir error de entrenamiento y ser sensible a cambios de muestra. Regularizar busca controlar esa sensibilidad, aunque no elimina toda incertidumbre. La estabilidad deberá examinarse con datos posteriores, especialmente cuando la agregación semanal reduzca el número de observaciones disponibles para estimar parámetros (Hastie et al., 2009).

2.7.2 Penalizaciones y selección de variables

Ridge añade una penalización cuadrática sobre coeficientes y Lasso una penalización absoluta. Las ecuaciones (2.21) y (2.22) presentan sus objetivos en notación común: SSE es

la suma de errores cuadrados y beta reúne los coeficientes, excluyendo el intercepto de la penalización. Lambda controla la intensidad de contracción (Hastie et al., 2009; Tibshirani, 1996).

$$\hat{\beta}^R = \operatorname{argmin}_{\beta} (\text{SSE}(\beta) + \lambda \sum_{j=1}^K \beta_j^2) \quad (2.21)$$

$$\hat{\beta}^L = \operatorname{argmin}_{\beta} (\text{SSE}(\beta) + \lambda \sum_{j=1}^K |\beta_j|) \quad (2.22)$$

Lasso puede llevar coeficientes a cero y producir una representación más reducida. Eso no demuestra que una variable carezca de importancia económica; su selección depende de los datos, la penalización y los demás predictores. La comparación deberá ajustar lambda dentro de entrenamiento y considerar el escalado, pues las unidades de las variables influyen en la penalización (Tibshirani, 1996).

2.7.3 Predictores temporales y calendario

Los rezagos y resúmenes móviles expresan información histórica en una forma utilizable por algoritmos de regresión. Deben construirse únicamente con observaciones conocidas en cada origen. Imputación, escalado y selección de variables forman parte del procedimiento de entrenamiento y no deben estimarse con las semanas finales de evaluación (Kuhn & Johnson, 2013).

Las bases armónicas representan ciclos mediante funciones seno y coseno. La ecuación (2.23) presenta un par de términos con periodicidad m y armónico k . La codificación permite representar continuidad entre el final y el inicio de un ciclo, sin asignar una distancia artificialmente grande a posiciones próximas (Hyndman & Athanasopoulos, 2021).

$$s_{k,t} = \sin\left(\frac{2\pi kt}{m}\right), \quad c_{k,t} = \cos\left(\frac{2\pi kt}{m}\right) \quad (2.23)$$

La periodicidad debe corresponder al índice temporal. En semanas completas, el número de lunes o domingos no varía entre observaciones; un calendario diario tendrá que convertirse en información semanal pertinente, como presencia o proximidad de festividades. El número de armónicos y las interacciones deberá ser compatible con el tamaño del historial (Hyndman & Athanasopoulos, 2021).

2.7.4 Disponibilidad de variables exógenas

Las variables de calendario pueden conocerse anticipadamente, mientras que clima observado, ventas futuras o indicadores publicados con retraso pueden ser desconocidos al pronosticar. Un modelo con regresores necesita sus valores futuros o un procedimiento explícito para estimarlos. Utilizar realizaciones futuras como si estuvieran disponibles produciría una evaluación que no representa el uso previsto (Hyndman & Athanasopoulos, 2021).

En horizontes de varias semanas, tampoco puede incorporarse como rezago una compra futura todavía no observada. La metodología deberá indicar si se generan pronósticos directos por horizonte o se utilizan predicciones recursivas. El análisis de variables exógenas podrá complementar el contraste principal, sin constituir una segunda hipótesis independiente (Hyndman & Athanasopoulos, 2021).

2.8 Evaluación temporal y métricas de precisión

2.8.1 Origen del pronóstico y ventana de entrenamiento

La evaluación fuera de muestra compara pronósticos con observaciones que no participaron en su ajuste. Una ventana deslizante mantiene un historial de tamaño fijo y actualiza su posición; una ventana expansiva conserva el historial previo y añade observaciones. La elección afecta recencia, tamaño de muestra y cantidad de evaluaciones posibles (Tashman, 2000).

La comparación requiere suficientes orígenes y resultados por horizonte, evitando que un único periodo determine la conclusión. Los modelos deberán enfrentar las mismas semanas y condiciones de información. El error de la ecuación (2.24) distingue el valor observado en $t+h$ del pronóstico emitido en t (Hyndman & Athanasopoulos, 2021; Tashman, 2000).

$$e_{t,h} = y_{t+h} - \hat{y}_{t+h|t} \quad (2.24)$$

El ajuste de configuraciones deberá separarse de su evaluación final. Si los pesos híbridos, las variables o el modelo se eligen observando los resultados finales, esos resultados dejan de ser una estimación independiente de la selección. El protocolo temporal permitirá comparar

alternativas sin dar por comprobada la hipótesis antes de obtener evidencia (Hyndman & Athanasopoulos, 2021).

2.8.2 Error monetario del importe total

MAE y RMSE resumen el error en las unidades de la respuesta. MAE promedia magnitudes absolutas; RMSE extrae la raíz del promedio de cuadrados y es más sensible a errores grandes. Las ecuaciones (2.25) y (2.26) se expresan para un horizonte h y un conjunto O de n orígenes evaluados (Hyndman & Athanasopoulos, 2021).

$$MAE_h = \frac{1}{n} \sum_{t \in O} |e_{t,h}| \quad (2.25)$$

$$RMSE_h = \sqrt{\frac{1}{n} \sum_{t \in O} e_{t,h}^2} \quad (2.26)$$

Las medidas se interpretarán en moneda y deberán reportarse por horizonte. Menor RMSE significa menor media de errores cuadrados, no necesariamente menor cantidad de errores extremos. Para dar transparencia a H1, el criterio principal de comparación deberá fijarse antes del análisis final, manteniendo las demás métricas como información complementaria (Hyndman & Athanasopoulos, 2021).

2.8.3 Escalamiento y límites de errores porcentuales

MASE divide el error absoluto por una escala obtenida de diferencias históricas de entrenamiento. La ecuación (2.27) muestra su forma para una partición con N observaciones de entrenamiento, n de prueba y rezago de referencia m . Permite comparar escalas sin dividir cada error por la compra observada de su semana (Hyndman & Koehler, 2006).

$$MASE = \frac{\frac{1}{n} \sum_{i=1}^n |e_i|}{\frac{1}{N-m} \sum_{t=m+1}^N |y_t - y_{t-m}|} \quad (2.27)$$

El denominador debe ser positivo y calcularse sin datos de prueba. Al desplazar la ventana, la regla de escalamiento deberá mantenerse explícita; un historial constante puede hacer indefinida la medida. MASE complementa el contraste directo con referencias y no reemplaza la interpretación de pesos monetarios (Hyndman & Koehler, 2006).

MAPE divide cada error por el valor observado. Aunque produce porcentajes, resulta indefinido con ceros e inestable con importes pequeños. Por ello, no se utilizará como criterio central de contraste de una serie con esas condiciones. Su eventual reporte deberá identificar los casos válidos sin ocultar las semanas excluidas (Hyndman & Koehler, 2006).

2.8.4 Error de participaciones y evaluación conjunta

La precisión de la composición debe medirse separadamente. La ecuación (2.28) adapta MAE a participaciones entre cero y uno y multiplica por cien para expresar el error en puntos porcentuales. O con subíndice positivo representa los orígenes cuyo total observado en el horizonte es positivo y n con el mismo subíndice es su cantidad. Esta adaptación no se presenta como una métrica composicional nueva atribuida a los autores (Aitchison, 1982; Hyndman & Koehler, 2006).

$$\text{MAE}_{p,h} = \frac{100}{n_{+J}} \sum_{t \in O_{+}} \sum_{j=1}^J |p_{j,t+h} - \hat{p}_{j,t+h|t}| \quad (2.28)$$

La ponderación uniforme ofrece igual importancia a las categorías. Si se adoptan otros pesos, deberán justificarse y fijarse antes de evaluar. Además de la medida agregada, revisar errores por insumo permite identificar si una mejora promedio oculta deterioro en categorías concretas. Se informarán por separado las semanas cuyo total cero impida definir una composición observada (Hyndman & Athanasopoulos, 2021).

El contraste de H1 tendrá dos componentes: precisión del importe total y de su distribución. Mejorar solo uno constituirá evidencia parcial respecto de su formulación conjunta. La comparación no se resolverá escogiendo retrospectivamente el horizonte favorable ni interpretando una diferencia de error como efecto financiero. La metodología deberá precisar el criterio de decisión y el tratamiento de incertidumbre de las diferencias observadas (Shmueli, 2010; Tashman, 2000).

2.9 Inteligencia de negocios y comunicación del pronóstico

2.9.1 Presentación del presupuesto y su incertidumbre

Un tablero puede reunir el total esperado, las participaciones y las asignaciones monetarias para que el responsable revise el presupuesto. La presentación deberá identificar origen,

horizonte, unidades y referencia comparativa. Esta función corresponde al soporte de decisiones; no transforma automáticamente una asignación monetaria en una orden de compra (Power, 2002).

Los intervalos de predicción comunican incertidumbre adicional al valor puntual. Bajo una aproximación normal de los errores, la ecuación (2.29) utiliza un cuantil z y una estimación de la desviación del error correspondiente al horizonte. Esa aproximación depende de supuestos que deberán verificarse antes de su uso (Hyndman & Athanasopoulos, 2021).

$$\hat{y}_{t+h|t} \pm z_{1-\alpha/2} \hat{\sigma}_h \quad (2.29)$$

Alfa expresa la probabilidad nominal fuera del intervalo y sigma la escala de incertidumbre predictiva. No debe confundirse este intervalo con uno de confianza para una media estimada ni calcularse su amplitud sumando errores sin considerar el horizonte. En series asimétricas o con ceros, otras aproximaciones podrían resultar más pertinentes (Hyndman & Athanasopoulos, 2021).

2.9.2 Adopción y límites operativos

La viabilidad de una herramienta depende también de integración, mantenimiento, competencias y recursos. La digitalización de empresas pequeñas enfrenta barreras diversas, por lo que una solución debe adecuarse a sus capacidades y no justificarse únicamente por sofisticación. El tablero propuesto buscará facilitar interpretación y trazabilidad; no se asumirá que su disponibilidad demuestra adopción efectiva (OECD, 2021).

La evaluación de costos de implementación y beneficios organizacionales es distinta de medir precisión. En consecuencia, la reducción de MAE o RMSE no se denominará retorno de inversión. La comunicación de resultados deberá mantener visible esa diferencia para que el responsable pueda utilizar el pronóstico junto con la información operativa que posea (Power, 2002).

2.10 Síntesis de fundamentos y relación con la hipótesis

Los fundamentos revisados permiten plantear una integración de métodos que representen señales diferentes y una desagregación que conserve la relación entre total e insumos. La combinación ofrece una razón teórica para esperar mejoras, mientras que la estimación de

pesos y la dependencia entre errores explican por qué esa mejora no está asegurada (Hyndman & Athanasopoulos, 2021).

La composición añade un problema propio: conservar proporciones válidas y anticipar su variación. Por tanto, el procedimiento deberá evaluar el importe y las participaciones frente a sus respectivas referencias. La coherencia de suma es una condición de la representación, mientras que la precisión requiere evidencia de semanas posteriores no utilizadas en el ajuste (Hyndman & Athanasopoulos, 2021; Hyndman et al., 2011).

La investigación se desarrollará como una evaluación predictiva del presupuesto semanal de abastecimiento. El capítulo sustenta la elección de variables, métodos y criterios de contraste, sin anticipar resultados de Cup&Cake. El respaldo de H1 requerirá evidencia favorable en el importe total y en las participaciones; una mejora aislada se describirá como un resultado de ese componente y no como confirmación de la hipótesis conjunta (Shmueli, 2010).

3 METODOLOGÍA

Investigar significa llevar a cabo diferentes acciones o estrategias con el fin de descubrir algo. Así, dichos actos se dirigen a obtener y aplicar nuevos conocimientos, explicar una realidad determinada o a obtener maneras de resolver cuestiones y situaciones de interés. La investigación es la base del conocimiento científico, si bien no toda investigación es científica de por sí.

Para que un conocimiento sea científico es necesario que la investigación realizada se haga de forma sistemática, con unos objetivos claros y que a partir de aspectos que puedan ser comprobados y replicados. Los resultados obtenidos deben ser analizados de forma objetiva y teniendo en cuenta las diversas variables que pueden estar afectando al fenómeno estudiado.

Como se ha dicho, se puede investigar desde muy diferentes perspectivas, con diferentes objetivos o teniendo en cuenta diferentes tipos de datos, procedimientos o métodos para obtenerlos.

Tipo de tesis: estudio aplicado, cuantitativo, no experimental y evaluativo, basado en un caso de estudio longitudinal-retrospectivo.

3.1 Tipo de investigación según el objetivo de ésta

Investigación aplicada

En Cup&Cake, la investigación tiene como propósito desarrollar y evaluar un modelo híbrido que integre métodos estadísticos y aprendizaje automático para pronosticar el importe total semanal de compras, junto con un procedimiento para estimar su distribución porcentual entre los principales insumos. Se dispone de una implementación computacional inicial; su precisión con datos reales todavía deberá contrastarse frente a modelos de referencia como apoyo a la planeación del presupuesto de abastecimiento.

La aplicación se delimitará al caso de Cup&Cake. Se prevé comunicar los pronósticos mediante un tablero de inteligencia de negocios, sin sustituir el juicio del responsable ni

presuponer mejoras en rentabilidad, inventarios o merma. Los resultados no se generalizarán automáticamente a otras microempresas.

3.2 Según el alcance evaluativo del estudio

La investigación se puede llevar a cabo de diferentes formas y profundizando más o menos en cómo son o el porqué de las cosas.

Se documentará el contexto de planeación de compras de Cup&Cake para interpretar las necesidades de información del responsable. La evaluación cuantitativa se realizará frente a referencias reproducibles. Solo se incluirán estimaciones del propietario como comparador si existen registros fechados antes de conocer los importes observados y compatibles con los mismos horizontes de pronóstico.

Evaluativa y comparativa

Se trata de uno de los tipos de investigación más frecuentes y en los que la ciencia se centra. Es el tipo de investigación que se utiliza con el fin de intentar determinar las causas y consecuencias de un fenómeno concreto. Se busca no solo el qué sino el porqué de las cosas, y cómo han llegado al estado en cuestión.

Para el caso de Cup&Cake no se adoptará el alcance causal descrito en la definición precedente. La aplicación tendrá carácter evaluativo y comparativo: se contrastarán alternativas de pronóstico bajo las mismas condiciones temporales para examinar su precisión fuera de muestra, sin atribuir relaciones de causa y efecto sobre la operación del negocio.

La investigación describirá el comportamiento histórico de ventas y compras y comparará la precisión del modelo híbrido y del procedimiento de distribución porcentual con sus respectivas referencias. La evaluación considerará por separado el importe total semanal y la participación de los principales insumos. Su inferencia se limitará al desempeño predictivo del caso de estudio.

En consecuencia, el diseño evaluativo busca determinar si la tecnología algorítmica aporta una mejora verificable de precisión respecto de las referencias comparadas. La inteligencia artificial se evalúa como una alternativa de apoyo para anticipar el presupuesto de abastecimiento, sin

suponer que sustituye el juicio del responsable ni que genera automáticamente mejoras financieras u operativas.

3.3 Según el tipo de datos empleados

Otra manera de clasificar los diferentes tipos de investigación es según el tipo de datos que recojan. En este sentido nos podemos encontrar con los siguientes tipos.

Cuantitativa

La investigación cuantitativa se basa en el estudio y análisis de la realidad a través de diferentes procedimientos basados en la medición. Permite un mayor nivel de control e inferencia que otros tipos de investigación, siendo posible realizar experimentos y obtener explicaciones contrastadas a partir de hipótesis. Los resultados de estas investigaciones se basan en la estadística y son generalizables.

La semana calendario constituirá la unidad temporal de análisis. Se calcularán el importe total de compras, el importe correspondiente a cada insumo seleccionado y su participación porcentual. Los registros históricos de ventas podrán utilizarse como predictores únicamente cuando su información esté disponible antes de cada origen de pronóstico.

Se integrarán los registros históricos de ventas y compras de Cup&Cake y se agregarán por semana calendario. Las variables exógenas se incorporarán según su pertinencia y disponibilidad documentada. Los eventos de calendario conocidos podrán utilizarse para la semana objetivo; los indicadores económicos y meteorológicos deberán representar la información efectivamente disponible antes del pronóstico.

Las matrices semanales permitirán ajustar y comparar los componentes estadístico y de aprendizaje automático, su integración híbrida y el procedimiento de distribución porcentual. Se evaluará el error monetario del total y el error de participación por insumo. El carácter cuantitativo no implicará generalización estadística a otras empresas: las conclusiones se circunscribirán a los registros y condiciones del caso estudiado.

3.4 Según el grado de manipulación de las variables

Podemos encontrar diferentes tipos de investigaciones según si los datos obtenidos parten de un nivel mayor o menor de manipulación de variables.

No experimental, evaluativa y retrospectiva

En un diseño no experimental se analizan datos observados sin manipular deliberadamente las condiciones de la empresa. La comparación temporal permite estimar desempeño predictivo, pero no inferir causalidad experimental.

Se adoptará un diseño no experimental basado en el análisis retrospectivo de registros históricos de Cup&Cake. No se introducirán intervenciones deliberadas en la operación ni se asignarán grupos experimentales. La evaluación reproducirá situaciones de pronóstico mediante cortes cronológicos y utilizará exclusivamente información disponible hasta cada origen.

Se evaluarán la precisión del importe total semanal y la de su distribución porcentual. Para el importe total, la referencia primaria será el último valor semanal observado; se conservarán como comparadores el promedio móvil de cuatro semanas y, cuando exista cobertura suficiente, el ingenuo estacional de 52 semanas. Para la distribución se utilizará una referencia de participaciones históricas. Todos los métodos se evaluarán sobre fechas objetivo comunes; los ceros observados se distinguirán de la ausencia de registros.

El rigor del estudio se sustentará en la separación cronológica, la validación con orígenes sucesivos y una ventana de historia creciente, conservando todas las semanas del calendario. La comparación se realizará sobre objetivos observados comunes a los métodos de cada contraste. La evaluación será retrospectiva y exploratoria; no permitirá inferir causalidad ni generalizar a otras microempresas.

3.5 Diseño evaluativo y comparación contra la línea base

El diseño cuantitativo, aplicado, no experimental y evaluativo se concretará mediante un estudio de caso longitudinal-retrospectivo. Los registros se organizarán cronológicamente y las decisiones de modelado se documentarán antes de examinar la evaluación final.

La comparación contrastará el modelo híbrido con las referencias monetarias y con sus componentes individuales; el procedimiento de distribución porcentual se contrastará con su propia referencia histórica. Se utilizarán las mismas fechas objetivo y horizontes para cada comparación. No se emplearán preprueba, posprueba ni grupos de control experimentales.

El protocolo `calendar_gaps` utiliza historia creciente desde el inicio del periodo hasta cada origen de pronóstico. La configuración vigente propone del 3 de mayo de 2021 al 24 de junio de 2024, con 165 semanas calendario y 26 semanas finales reservadas. El número de objetivos evaluables dependerá de la cobertura aprobada y del horizonte; 26 semanas reservadas no equivalen a 26 observaciones válidas. Se emitirán pronósticos para $h=1$ a $h=4$, con $h=1$ como horizonte principal. El consolidado de cuatro semanas no se denominará mes calendario. Estos parámetros deben justificarse antes de la ejecución real.

3.6 Según el tipo de inferencia

Otro tipo de clasificación se puede extraer a partir del método empleado a la hora de inferir cómo funciona la realidad.

De método deductivo

Este tipo de investigación **se basa en el estudio de la realidad y la búsqueda de verificación o falsación de unas premisas básicas a comprobar. A partir de la ley general se considera que ocurrirá en una situación particular.**

Atendiendo al proceso lógico empleado para inferir y estructurar el conocimiento sobre la realidad, **la presente investigación se rige estrictamente por el método deductivo.** Este enfoque inferencial se caracteriza por guiar el pensamiento de manera sistemática desde premisas, leyes y teorías universales consolidadas hacia la verificación, contrastación o falsación de una proposición particular aplicable a un escenario específico.

En el marco de este estudio, el proceso deductivo parte de los fundamentos de los modelos de pronóstico y de la evidencia empírica sobre Small Data. La literatura científica indica que el desempeño de los modelos depende de la estructura de la serie, las variables disponibles, el tamaño de la muestra y el protocolo de evaluación. Por ello, no se presupone superioridad de los algoritmos de aprendizaje automático sobre los métodos estadísticos o las reglas empíricas.

Para contrastar H1, se comparará el modelo híbrido y el procedimiento de distribución porcentual con sus respectivos modelos de referencia, utilizando las mismas semanas y horizontes de evaluación y únicamente información disponible antes de cada pronóstico. Se evaluarán por separado el error del importe total semanal y el error de participación de los principales insumos. Los análisis con y sin variables exógenas tendrán carácter complementario y no constituirán una segunda hipótesis. La evidencia favorable deberá abarcar ambos componentes de H1; una mejora aislada en el importe total no será suficiente para respaldarla. El protocolo de contraste, las métricas principales y el tratamiento de comparaciones múltiples se especificarán antes de examinar el conjunto de evaluación final.

3.7 Temporalidad de la investigación

El estudio será longitudinal y retrospectivo porque analizará registros históricos en su secuencia temporal. Se revisarán las fuentes disponibles del periodo 2022–2026 y se documentarán las fechas efectivas de inicio y corte para ventas y compras, sin asumir cobertura completa. El modelado se limitará a los periodos cuya disponibilidad y continuidad puedan verificarse.

La incorporación de variables exógenas se controlará mediante un registro explícito de fuente, disponibilidad y rezago. El pipeline sólo admitirá predictores incluidos en dicho registro; cualquier variable exógena no documentada se bloqueará antes del modelado. El sistema de soporte a la decisión comunicará este inventario como condición para generar pronósticos futuros, evitando utilizar información que no esté disponible ex ante.

Para asegurar la reproducibilidad, las rutas de datos y resultados se resolverán desde la ubicación del proyecto, sin depender de una carpeta fija del equipo. Cada ejecución exportará un manifiesto con las huellas de las fuentes y del código, versiones de las bibliotecas, semilla aleatoria, parámetros de ventana y diccionario de variables. Este diccionario documentará la fuente, el rezago y la disponibilidad temporal de cada predictor; los indicadores publicados u observados se desplazarán para representar únicamente la información disponible antes del pronóstico.

Cuando se identifique una cola de semanas sin cobertura de compras, dichas semanas se tratarán como ausencia de observación y no como importes cero. Cualquier extensión sintética se almacenará en un archivo independiente, con una etiqueta de procedencia, semilla y

método de generación. Sus valores podrán utilizarse únicamente en análisis de sensibilidad o pruebas técnicas del sistema de soporte a la decisión; se excluirán del ajuste, la selección de modelos, la evaluación fuera de muestra y el contraste de H1.

3.8 Procedimiento Metodológico

El procedimiento se organizará en ocho fases: Business Comprehension, Data Collection, EDA, Feature Engineering, Model Training, Testing and Debugging, Deployment y Monitoring. Se adopta como marco la metodología de cinco etapas de Ordonez Bolanos et al. (2023, fig. 1, pp. 92–99) y se integra la secuencia de experimentación, selección, puesta en producción, monitorización y reentrenamiento de García Velasco (2023, cap. 5, pp. 39–45). La Figura 27 presenta una adaptación propia para el pronóstico semanal de Cup&Cake, no una reproducción literal de los esquemas de los autores. La disponibilidad del software y las pruebas técnicas se distinguirán de la evaluación con datos reales y de la operación productiva.

Business Comprehension

Se delimitará la necesidad de información del responsable de Cup&Cake, el alcance de las adquisiciones incluidas y los criterios técnicos de aceptación. La variable objetivo será el importe nominal registrado utilizable de compras por semana, con una distribución monetaria por insumo. No se equiparará este registro con la demanda, el consumo físico ni el gasto completo del negocio. La comprensión del problema deberá precisar fuentes disponibles, factibilidad, destinatario, forma de uso y responsable del mantenimiento (Ordonez Bolanos et al., 2023, pp. 92–93; García Velasco, 2023, pp. 39–40).

3.8.1 Data Collection y control de calidad

Se recopilarán y estructurarán los registros históricos disponibles de Cup&Cake. Se verificará su integridad antes de asumir su utilidad para el modelado. La consolidación contemplará principalmente las siguientes fuentes:

1. Histórico de ventas con ingresos diarios.
2. Bitácoras de compra de materia prima.

Se conservarán las fuentes originales y se registrarán su huella SHA-256, hoja, fecha de extracción y decisiones de revisión. Se homologarán fechas, insumos e importes, documentando duplicados y registros incompletos sin eliminarlos automáticamente. El catálogo delimitará ingredientes, empaques y decoración recurrente y excluirá combustible, muebles y herramientas. El panel mantendrá todas las semanas del periodo; los estados incierta, desconocida e incompleta se representarán como NaN, mientras que los ceros requerirán confirmación. La calidad y el versionado de los datos constituyen condiciones de entrada al modelado (Ordonez Bolanos et al., 2023, pp. 93–94; García Velasco, 2023, pp. 40–41).

EDA de la serie temporal semanal

Antes del modelado se auditará la cobertura mediante el calendario semanal y la revisión de las fuentes. Las rachas de compras iguales a cero, su coincidencia con ventas positivas o su ubicación al final del registro motivarán una verificación, pero no bastarán para clasificarlas automáticamente como ausencia de observación. Se distinguirán semanas sin compras confirmadas, semanas con registros y semanas de cobertura incierta. La decisión y su evidencia se documentarán; no se imputarán ceros a periodos sin cobertura comprobada.

El calendario se dividirá cronológicamente en desarrollo y evaluación final. La configuración `calendar_gaps` reserva 26 semanas calendario y propone ocho orígenes internos de ajuste; el número de etiquetas observadas se informará por horizonte. El EDA describirá cobertura, distribución de importes, frecuencia de ceros confirmados y evolución temporal utilizando desarrollo para las decisiones de modelado. ACF, PACF y STL se omitirán cuando existan huecos en desarrollo, sin rellenar respuestas ni comprimir fechas para producir esas figuras. Los diagnósticos adicionales deberán justificarse según su pertinencia. Esta separación adapta el análisis de datos de los autores al carácter temporal e incompleto del caso (García Velasco, 2023, p. 40; Ordonez Bolanos et al., 2023, pp. 94–96).

Los diagnósticos no se utilizarán para contrastar H1. Su función será fundamentar la selección de rezagos, transformaciones y familias de modelos. Cualquier configuración derivada de estos resultados se ajustará exclusivamente con información anterior a cada origen de pronóstico, preservando la separación temporal y evitando fuga de información.

El pipeline exporta tablas de respaldo, figuras y un manifiesto por ejecución. Los diagnósticos disponibles se identifican por su conjunto temporal y las omisiones incluyen un motivo. El libro de diagnósticos de la implementación anterior se conserva como antecedente y no se considera un producto verificado del pipeline híbrido actual.

3.8.2 Feature Engineering y disponibilidad temporal

Se examinará si los registros de compras de Cup&Cake presentan patrones temporales o asociaciones con eventos comerciales que puedan aportar información predictiva. Estas relaciones no se asumirán de antemano ni se equiparará el importe de compras con la demanda de productos. Las características candidatas se evaluarán dentro del conjunto de desarrollo.

La rama `calendar_gaps` construye el último importe observado y su antigüedad, el número de observaciones históricas, medias y conteos disponibles en ventanas calendario de 4, 8 y 12 semanas, y componentes calendáricos. Las ventanas sin datos conservan sus valores ausentes. Las respuestas de entrenamiento no se imputan y cada ejemplo utiliza únicamente predictores disponibles en su origen. Las ventas y exógenas son opcionales, con fuente y disponibilidad documentadas; la configuración principal no las incorpora actualmente. La selección y transformación de variables descrita por Ordonez Bolanos et al. (2023, p. 94) se adapta a este control temporal y no autoriza rellenar compras desconocidas.

3.8.3 Model Training y selección de componentes

Para garantizar parsimonia y mitigar el sobreajuste asociado a una muestra semanal limitada, se evaluará un conjunto compacto de alternativas estadísticas y de aprendizaje automático:

- Modelos estadísticos: la rama `calendar_gaps` implementa $AR(1)$ en espacio de estados mediante SARIMAX y permite $ARIMA(1,1,1)$ como candidato adicional. Ambos conservan el calendario y admiten respuestas faltantes en el ajuste estadístico; sus estimaciones internas no se incorporan como compras observadas. ETS corresponde a la rama `historica_strict` y no al protocolo vigente con faltantes.

- Modelos de aprendizaje automático: la rama `calendar_gaps` implementa HistGradientBoosting y permite Random Forest con soporte nativo de predictores faltantes. Los modelos directos por horizonte se entrenan únicamente con objetivos observados. La configuración propone al menos 24 etiquetas utilizables por horizonte como umbral operativo; su cumplimiento no demuestra suficiencia estadística. Ridge pertenece a la rama `strict`. Cada experimento conservará parámetros, métricas y artefactos conforme al principio de trazabilidad de García Velasco (2023, pp. 41–43).
- **RNN y LSTM no forman parte de la implementación actual. Su eventual evaluación será una ampliación secundaria, condicionada a la disponibilidad de observaciones suficientes y sin modificar retrospectivamente el protocolo del experimento principal.**

La integración implementada combina un componente estadístico y uno de aprendizaje automático mediante un promedio ponderado. La pareja de componentes y el peso se seleccionan por horizonte en validación temporal interna, con pesos candidatos de 0.25, 0.50 y 0.75 para el componente estadístico y el peso complementario para el componente de aprendizaje automático. Los pronósticos se restringen a valores no negativos. Los fallos se registran y no se sustituyen silenciosamente por otro método bajo el mismo nombre.

La configuración inicial propone seleccionar los principales insumos hasta alcanzar el 80 % de participación monetaria acumulada en desarrollo y reunir el resto en una categoría residual. El umbral deberá aprobarse antes del experimento. Durante la validación interna, la selección utiliza únicamente el entrenamiento de cada partición; las categorías quedan congeladas antes de la evaluación final.

En semanas con importe total positivo, la participación de cada insumo se obtiene dividiendo su importe entre el total semanal. El procedimiento implementado estima participaciones mediante un promedio exponencial, con parámetro seleccionado internamente entre 0.1, 0.3 y 0.6 en el horizonte principal. Esta primera versión mantiene la misma composición pronosticada para los cuatro horizontes. Las participaciones son no negativas y suman uno; las asignaciones se calculan a partir del total híbrido y se reconcilian a centavos mediante la regla de mayores restos.

La referencia de distribución será el promedio de participaciones históricas de semanas observadas con importe total positivo. El candidato exponencial tendrá en cuenta la edad calendario, incluidos los huecos. Ambos usarán solo la historia previa al origen. Si no existen semanas válidas, el procedimiento informará insuficiencia y no generará una composición arbitraria.

3.8.4 Estrategias de partición temporal y validación

En `calendar_gaps` se utiliza una ventana creciente; `window=52` no limita esta rama. Ocho orígenes internos, sujetos a suficiencia por horizonte, seleccionarán componentes y pesos. Todas sus fechas objetivo deberán preceder al comienzo de la evaluación final. La configuración `independent_holdout=false` identifica una evaluación retrospectiva exploratoria; no se presentará como una prueba confirmatoria independiente. Las decisiones se registrarán antes de ejecutar la comparación real y no se modificarán para favorecer H1.

En cada origen se ajustarán los modelos con la historia previa disponible. La rama ML emitirá pronósticos directos por horizonte y la rama estadística pronósticos de varios pasos; ninguna utilizará las respuestas futuras. La combinación se seleccionará en validación interna y permanecerá fijada durante la evaluación. Las nuevas observaciones ya transcurridas podrán incorporarse mediante la regla de historia creciente, sin usar los errores finales para rediseñar el método. Se conservarán todos los orígenes y se evaluarán únicamente objetivos observados comunes a cada contraste.

3.8.5 Testing and Debugging

Esta fase distinguirá dos verificaciones. Las pruebas de software comprobarán contratos de entrada, fechas, tratamiento de NaN, ausencia de fuga temporal, convergencia, reconciliación monetaria y reproducción al recargar el artefacto. La evaluación predictiva comparará el híbrido, sus componentes y el último valor disponible sobre objetivos observados comunes por horizonte. Los referentes suplementarios podrán disponer de menos casos y deberán informar su propia muestra. Un fallo técnico exigirá corrección documentada y repetición de las etapas afectadas; los errores de la evaluación final no se usarán para reajustar la selección. La separación entre entrenamiento, validación y prueba, y las comprobaciones previas al

despliegue, se apoyan en Ordonez Bolanos et al. (2023, pp. 96–97); esta adaptación hace explícita la depuración del software.

La evaluación comparativa calculará la discrepancia entre valores observados y pronosticados del importe total semanal y de las participaciones. H1 se contrastará frente a las respectivas referencias. La comparación equivalente con y sin variables exógenas permanece como análisis complementario pendiente; admitir estas variables como entrada no equivale a haber ejecutado dicha comparación.

- ***MAE (Error Absoluto Medio): medirá la magnitud promedio de los errores en el importe semanal de compras, sin considerar su dirección.***
- ***RMSE (Raíz del Error Cuadrático Medio): se utilizará como criterio principal para el importe total semanal; MAE será una medida complementaria. La evaluación de participaciones utilizará un criterio propio y no se combinarán directamente errores monetarios con errores porcentuales.***
- MASE complementará las métricas monetarias cuando exista una escala válida. En `calendar_gaps` su denominador se obtendrá de diferencias absolutas entre pares de semanas calendario consecutivas observadas del entrenamiento. No se unirán artificialmente semanas separadas por huecos. Si la escala es cero o no puede calcularse, se informará como no definida. MAPE no será un criterio de selección.

La precisión de la distribución se evaluará mediante el error absoluto medio de las participaciones, expresado en puntos porcentuales. Se calculará por insumo y se presentará un promedio no ponderado entre las categorías previamente definidas. Las semanas con importe total observado igual a cero no tendrán una composición porcentual definida y se excluirán únicamente de esta métrica, informando su número; permanecerán en la evaluación monetaria cuando correspondan a ceros confirmados.

El análisis de H1 examinará por separado las diferencias de pérdida del importe total y de las participaciones en $h=1$. El código dispone de remuestreo circular pareado por bloques de cuatro semanas, con 2000 réplicas y ajuste de Bonferroni para dos componentes, conservando las posiciones temporales de los faltantes. Su interpretación será exploratoria y dependerá de

la cantidad y distribución de objetivos observados. La configuración actual no habilita una confirmación independiente de H1; mejorar métricas descriptivas o aprobar pruebas de software no equivale a confirmarla.

3.8.6 Deployment y comunicación del presupuesto

La implementación exporta modelos, pronósticos y una salida local DSS con importes por horizonte, participaciones, asignaciones, métricas y advertencias. La exportación local constituye el prototipo disponible. El uso productivo requerirá una ejecución real validada, versión identificada, prueba de aceptación con el responsable y mecanismo de recuperación de la versión anterior. Se propone una entrega semanal por lotes, coherente con el horizonte del estudio. El despliegue debe elegirse según el destinatario y la forma de consumo de las predicciones (Ordóñez Bolanos et al., 2023, pp. 97–98; García Velasco, 2023, p. 43).

Esta plataforma funcionará como sistema de soporte a la decisión para revisar y reservar el presupuesto de abastecimiento. No generará órdenes automáticas, cantidades físicas por insumo ni simulaciones de expansión comercial, pues esas funciones requieren inventario, recetas, costos y tiempos de entrega que no forman parte del presente estudio.

Monitoring y reentrenamiento controlado

Se propone revisar semanalmente la cobertura de los registros, la antigüedad del último dato y el cumplimiento de los contratos. Cuando estén disponibles los importes observados se calcularán errores por horizonte frente a las referencias y se registrará la cantidad de objetivos evaluables. La falta de una respuesta se informará como evaluación pendiente. El responsable revisará alertas y cambios relevantes en los datos antes de iniciar una nueva versión del experimento. La monitorización, el versionado y el retorno al reentrenamiento se fundamentan en García Velasco (2023, pp. 44–45) y Ordóñez Bolanos et al. (2023, pp. 98–99).

Esta fase permanece como ampliación propuesta. Deberán definirse responsable, frecuencia, umbrales de alerta, tamaño mínimo de muestra, registro de incidencias y criterios de promoción o reversión antes del uso operativo. Una alerta no cambiará automáticamente el modelo: abrirá una revisión que podrá retornar a Data Collection, Feature Engineering o Business Comprehension, según el problema. El reentrenamiento conservará la versión anterior y exigirá

repetir las verificaciones. No se atribuyen al prototipo actual monitoreo continuo, despliegue automático ni un nivel completo de madurez MLOps.

4 DESARROLLO

4.1 Antecedentes del negocio

Cup&Cake inició operaciones en 2012 como un negocio dedicado a la elaboración y comercialización de productos de repostería y pastelería, entre ellos pasteles, cupcakes y galletas, tanto de línea como personalizados. Su actividad requiere la adquisición de materias primas y materiales de empaque, cuyos registros constituyen una fuente de información para estudiar el importe destinado al abastecimiento y su distribución entre los principales insumos.

En noviembre de 2020, Cup&Cake inició el registro de sus ventas mediante un archivo de Microsoft Excel. Posteriormente, Cup&Cake incorporó la plataforma KYTE para registrar sus ventas. Los reportes generados por esta aplicación se descargaron e integraron al archivo de Microsoft Excel utilizado previamente, cuya estructura se ajustó para incorporar la información proveniente de KYTE. De esta manera, Excel se mantuvo como el archivo de consolidación del historial de ventas.

En diciembre de 2016, para registrar las compras de insumos y materias primas, se desarrolló un sistema propio en Microsoft Access. Este sistema permitió acumular información sobre las adquisiciones realizadas por el negocio y conservarla para su consulta. Los registros de compras constituyen la fuente principal para construir la serie del importe total semanal y calcular las participaciones monetarias de los insumos considerados en el estudio.

La existencia de ambos registros permite plantear una investigación orientada a apoyar la planeación del presupuesto semanal de abastecimiento. Las compras definirán las variables que se busca pronosticar, mientras que las ventas podrán incorporarse como información predictiva complementaria cuando estén disponibles antes de cada pronóstico. Previamente, será necesario verificar la integridad de las fuentes, homologar las descripciones de los insumos y documentar la cobertura temporal, sin interpretar la ausencia de registros como compras iguales a cero.

4.1.1 El registro de ventas y compras de insumos

Aunque Cup&Cake inició operaciones en 2012, el registro de ventas en Microsoft Excel comenzó hasta noviembre de 2020. Este archivo permitió organizar la información de las transacciones y constituyó la base inicial para integrar el historial de ventas del negocio.

Posteriormente, Cup&Cake incorporó la plataforma KYTE para gestionar sus ventas, disponer de un catálogo digital de productos y emitir recibos para sus clientes. La aplicación permite generar reportes de las ventas realizadas, los cuales se descargaron e integraron al archivo de Excel existente. Para recibir esta información, se ajustó la estructura del archivo, conservando Excel como medio de consolidación de los registros históricos y de los provenientes de KYTE.

En diciembre de 2016, Cup&Cake comenzó a registrar las compras de insumos y materias primas mediante un sistema propio desarrollado en Microsoft Access. Esta herramienta permite conservar, consultar y extraer la información de las adquisiciones para su revisión y análisis.

Tabla 2 - Hitos de cup&cake

Fecha	Hito	Registro o herramienta
2012	Inicio de operaciones de Cup&Cake.	Sistema de registro de esta etapa no especificado.
Diciembre de 2016	Inicio del registro de compras de insumos y materias primas.	Sistema propio desarrollado en Microsoft Access.
Noviembre de 2020	Inicio del registro de ventas.	Archivo de Microsoft Excel.
Posteriormente, sin fecha precisada	Incorporación de KYTE para gestionar las ventas.	Sus reportes se descargan e integran al archivo de Excel, ajustado para recibir esta información.

Nota. Elaboración propia con base en la información proporcionada sobre Cup&Cake. El inicio de los registros no garantiza cobertura continua. Los valores iguales a cero no necesariamente indican ausencia de ventas o compras; también podrían corresponder a omisiones o información incompleta. Su significado se verificará antes del análisis.

En la investigación, los registros de compras constituirán la fuente principal para calcular el importe total semanal de abastecimiento y su distribución porcentual entre los principales insumos. Los registros de ventas podrán utilizarse como predictores complementarios, siempre que la información correspondiente esté disponible antes de cada origen de pronóstico.

Antes de integrar ambas fuentes al análisis, se verificarán las fechas, los importes, las descripciones de los insumos y la posible existencia de registros duplicados o incompletos. También se documentará la cobertura semanal, distinguiendo los periodos sin compras confirmadas de aquellos en los que no exista información suficiente. La disponibilidad de

archivos históricos no se interpretará, por sí sola, como evidencia de un registro completo y continuo.

4.1.2 Antecedentes de los conjuntos de datos existentes

Cup&Cake dispone de registros históricos de ventas y compras generados mediante herramientas utilizadas en su operación. Aunque el negocio inició actividades en 2012, el registro de compras comenzó en diciembre de 2016 y el de ventas en noviembre de 2020. Estas fechas corresponden al inicio de la captura documentada y no implican que exista información completa y continua desde entonces.

El conjunto de ventas tiene su origen en un archivo de Microsoft Excel. Posteriormente, se incorporaron los reportes descargados de KYTE, para lo cual se ajustó la estructura del archivo existente. Excel se mantuvo como medio de consolidación de ambas procedencias. Antes del análisis, se revisará la correspondencia de los campos y se comprobará que la integración no haya generado duplicidades o inconsistencias.

El conjunto de compras procede de un sistema propio desarrollado en Microsoft Access para registrar las adquisiciones de insumos y materias primas. Esta información constituirá la fuente principal para construir el importe total semanal de compras y calcular su distribución porcentual entre los principales insumos. Su preparación requerirá revisar fechas e importes, homologar las descripciones y establecer un catálogo que permita agrupar las adquisiciones de manera consistente.

Ambos conjuntos contienen información temporal y monetaria, pero cumplen funciones distintas en la investigación. Las compras permitirán definir las variables que se busca pronosticar; las ventas podrán incorporarse como predictores complementarios, siempre que estén disponibles antes de cada pronóstico. La integración se realizará por semana calendario, sin asumir una correspondencia directa entre cada venta y una compra específica.

Los registros presentan valores iguales a cero que no necesariamente representan ausencia de ventas o compras, pues también podrían corresponder a omisiones o información incompleta. Por ello, se verificará su significado y se documentará la cobertura de cada fuente antes de delimitar el periodo de análisis. Los casos cuya condición no pueda determinarse se

conservarán como información incierta y no se tratarán automáticamente como ceros observados.

La Tabla 3 resume la procedencia y la función de ambos conjuntos. El Anexo A presenta el diccionario de campos de origen y variables analíticas. El periodo utilizable se establecerá después de verificar la cobertura, sin equiparar las fechas de inicio del registro con una muestra completa.

Tabla 3 - Conjuntos de datos de Ventas y Compras

Aspecto	Ventas	Compras
Inicio del registro	Noviembre de 2020	Diciembre de 2016
Procedencia	Excel y reportes descargados de KYTE	Sistema propio en Microsoft Access
Archivo inspeccionado	Ventas.xlsx, hoja Hoja1, 25 campos	Compras.xlsx, hoja Hoja1, 10 campos
Información principal	Identificación, fechas, importes y productos vendidos	Fechas, importes, cantidades y descripciones de insumos
Preparación requerida	Compatibilidad entre fuentes, estados, importes y duplicidades	Fechas, importes, catálogo y delimitación de las compras
Función en el estudio	Predictores complementarios disponibles antes del pronóstico	Importe total semanal y participaciones monetarias por insumo
Frecuencia analítica	Semanal	Semanal

Nota. Elaboración propia a partir de los archivos inspeccionados y la información histórica de Cup&Cake. Los ceros requieren verificación; no equivalen automáticamente a ausencia de operaciones. El diccionario detallado se presenta en el Anexo A.

Las compras definen las variables objetivo y las ventas constituyen una fuente predictiva complementaria. La agregación semanal no supone una correspondencia directa entre cada venta y cada adquisición ni permite, por sí sola, evaluar rentabilidad o existencias de inventario. Tabla 3 - Conjuntos de datos de Ventas y Compras

4.1.2.1 Descripción General del Conjunto de Datos de Ventas

El conjunto de ventas de Cup&Cake comenzó a registrarse en noviembre de 2020 mediante Microsoft Excel. Posteriormente, se incorporaron los reportes descargados de KYTE al archivo existente, cuya estructura se adaptó para consolidar la información. Las ventas podrán utilizarse como predictores complementarios, siempre que estén disponibles antes de cada pronóstico.

El archivo Ventas.xlsx contiene 25 campos. Su definición, tipo esperado y reglas de revisión se presentan en el Anexo A. Antes de agregar por semana se verificarán los importes, las fechas, los estados y la identificación de las transacciones para evitar duplicidades.

4.1.2.2 Descripción General del Conjunto de Datos de Compras (Egresos)

El conjunto de compras procede de un sistema propio desarrollado en Microsoft Access, utilizado desde diciembre de 2016 para registrar adquisiciones de insumos y materias primas. Constituirá la fuente principal para calcular el importe total semanal de compras y su distribución porcentual entre los principales insumos.

El archivo Compras.xlsx contiene 10 campos. El Anexo A documenta sus nombres reales y su correspondencia con las variables del pipeline. Se revisarán los importes y las fechas, se homologarán las descripciones y se delimitarán las adquisiciones incluidas. La existencia de registros no garantiza cobertura continua ni permite interpretar automáticamente los valores cero como ausencia de compras.

4.2 Fases del pipeline híbrido con enfoque MLOps

El pipeline se estructuró para transformar los registros de Cup&Cake en pronósticos del importe total semanal de compras y su distribución porcentual entre los principales insumos. El proceso comienza con la depuración de compras y ventas, la homologación de insumos y la verificación de la cobertura temporal, distinguiendo las semanas sin compras confirmadas de aquellas con información incompleta. Posteriormente, los registros se agregan por semana para obtener los importes totales, los importes por insumo y sus participaciones.


La información se divide cronológicamente en desarrollo y evaluación final. A partir de los datos disponibles en cada origen de pronóstico, se generan rezagos, resúmenes móviles y variables calendáricas. El modelo híbrido combina un componente estadístico y uno de aprendizaje automático, seleccionados y ponderados mediante validación temporal interna, para estimar las compras de las cuatro semanas siguientes.

La distribución porcentual se estima mediante un promedio exponencial de las participaciones históricas. Cada participación se multiplica por el total pronosticado para obtener la asignación presupuestaria correspondiente, verificando que los porcentajes sumen el 100 % y que las asignaciones coincidan con el importe total.

La evaluación comparará los errores del total y de las participaciones frente a sus respectivas referencias. Cada ejecución conservará los parámetros, las fuentes y los resultados para asegurar su trazabilidad y alimentar un tablero de consulta. La implementación inicial está disponible; su evaluación con datos reales requiere validar previamente las fuentes, la cobertura, el catálogo de insumos y el protocolo experimental.

Pipeline híbrido semanal de Cup&Cake

Ciclo propuesto de desarrollo y operación con enfoque MLOps



Retorno controlado: nuevos datos o degradación → revisión → nueva versión

Fallos técnicos: corregir y repetir las etapas afectadas, conservando el registro.

Evaluación final: no ajustar el método para mejorar retrospectivamente sus errores.

Trazabilidad transversal: fuentes · código · configuración · pruebas · modelos · métricas

Fuente: elaboración propia con base en Ordonez Bolanos et al. (2023, fig. 1, pp. 92–99)

y García Velasco (2023, cap. 5, pp. 39–45).

Figura 27 - Fases del pipeline híbrido semanal con enfoque MLOps. Fuente: elaboración propia con base en Ordonez Bolanos et al. (2023, fig. 1, pp. 92–99) y García Velasco (2023, cap. 5, pp. 39–45). Las fases operativas indicadas no acreditan un despliegue productivo completado.

4.2.1 Análisis Exploratorio de Datos (EDA)

El propósito de esta etapa fue construir una base diaria unificada y auditable como capa intermedia de integración. Esta base no constituye la unidad principal del experimento predictivo; su función es depurar las fuentes y permitir posteriormente la agregación semanal necesaria para el presupuesto de abastecimiento.

1. Conservar el historial diario de ventas como fuente para construir predictores semanales.
2. Agregar las compras observadas por semana calendario para formar la variable objetivo del presupuesto de abastecimiento.
3. Integrar variables exógenas en su fecha de disponibilidad y trasladarlas posteriormente a la frecuencia semanal sin utilizar información futura.

La salida diaria intermedia contiene una fila por fecha entre 2022-01-01 y 2026-05-31. A partir de ella se construyó `dataset_maestro_semanal.xlsx`, con semanas completas de lunes a domingo. Sólo el bloque continuo con cobertura defendible de compras se utiliza en el análisis principal.

Fuentes utilizadas

Se trabajó con cinco archivos de entrada:

1. `Compras.xlsx`
2. `Ventas.xlsx`
3. `Dataset_Tizayuca_2022_2026.xlsx`
4. `INPC_2022_2026.csv`
5. `Temperatura_Tizayuca.csv`

Criterio general de integración

Se definió como unidad de análisis un registro por día.

Esto implicó:

1. Limpiar cada fuente por separado.
2. Estandarizar nombres, fechas y tipos de datos.

3. Generar tablas diarias agregadas para compras y ventas.
4. Crear un calendario completo para todo el periodo.
5. Unir todas las variables sobre la misma llave temporal: fecha.

Reglas de limpieza aplicadas

Estandarización de fechas

Se convirtieron las fechas al formato de fecha diaria (YYYY-MM-DD) para evitar inconsistencias en:

- Fechas con hora.
- Formatos mezclados.
- Fechas mensuales frente a diarias.

Normalización de texto

Se aplicó limpieza de texto para:

- Eliminar espacios duplicados.
- Quitar acentos.
- Homogeneizar mayúsculas y minúsculas.
- Estandarizar etiquetas categóricas.

Tratamiento de duplicados

Se identificaron y removieron duplicados exactos en las fuentes donde era necesario, especialmente en compras.

Valores faltantes

Se manejaron de forma distinta según el archivo:

- En variables numéricas agregadas se imputó 0 cuando el día no tenía registros.
- En el detalle de compras y ventas se conservaron los campos útiles y se eliminaron filas incompletas solo cuando afectaban la calidad del análisis.

Ajuste por inflación

Se utilizó el INPC para deflactar montos nominales a pesos de mayo de 2026.

Esto permitió construir variables comparables en el tiempo:

- Compras reales ajustadas.
- Ventas reales ajustadas.
- Ganancia, subtotal, envío y descuentos reales ajustados.

$$Importe_t^{real} = Importe_t^{nominal} \left(\frac{INPC_{mayo2026}}{INPC_t} \right)$$

Los importes nominales se ajustaron mediante el cociente entre el INPC del periodo de referencia y el INPC correspondiente a la fecha de cada observación .

Limpieza por archivo

Con el propósito de documentar el proceso de preparación de la información utilizada en el estudio, la Tabla 4 - Síntesis de fuentes de datos y transformaciones aplicadas presenta las principales características de cada archivo, su función dentro del análisis, las variables conservadas o generadas y los procedimientos de limpieza, homologación, agregación e integración realizados. Esta síntesis permite identificar de manera estructurada cómo se construyó la base analítica final y cómo se garantizó la consistencia temporal, climática y monetaria de los datos.

Tabla 6 - Síntesis de fuentes de datos y transformaciones aplicadas [Antecedente de la versión anterior; no es evidencia del híbrido actual]4

Fuente de datos	Propósito dentro del estudio	Variables conservadas o generadas	Transformaciones aplicadas	Resultado y observaciones
Dataset_Tizayuca_2022_2026.xlsx	Base para incorporar variables temporales, climáticas y exógenas al modelo.	EsFestivoMexico EsFechaPago TemperaturaMax TemperaturaMin Clima NacimientosIndice	• Renombrado de columnas con un formato homogéneo. • Conversión de la variable Clima a texto estandarizado. • Ordenamiento cronológico de los registros.	El archivo ya se encontraba estructurado con una observación por día y cubría el periodo comprendido entre el 1 de octubre de 2022 y el 31 de mayo de 2026.
INPC_2022_2026.csv	Índice mensual utilizado para convertir los valores monetarios nominales en valores reales comparables.	Fecha INPC_mes INPC_base FactorAjuste	• Conversión de la fecha al primer día de cada mes. • Filtrado al periodo de análisis. • Selección de mayo de 2026 como periodo base. • Cálculo del factor de ajuste mediante la fórmula: Factor de ajuste = INPC base / INPC del mes.	La fecha base seleccionada fue el 1 de mayo de 2026. El factor calculado se utilizó para deflactar los importes de compras y ventas.
Temperatura_Tizayuca.csv	Complementar la información climática con una serie histórica mensual de temperatura.	Estado Fecha Temperatura Promedio	• Filtrado de los registros correspondientes a Hidalgo. • Conversión de las fechas a periodicidad mensual. • Construcción de una serie mensual de temperatura promedio. • Expansión posterior de la información mensual a nivel diario.	Aunque el archivo incluía información de varios estados, únicamente se conservaron los datos de Hidalgo. La serie mensual se integró al calendario maestro diario.
Compras.xlsx — detalle limpio	Conservar información granular de las adquisiciones	Proveedor Fecha Número	• Selección de registros y variables relevantes.	Se obtuvo una tabla detallada y depurada de compras, con importes

	realizadas durante el periodo de análisis.	Cantidad UnidadMedida Descripción MontoNominal MontoRealAjustado PrecioUnitarioNominal PrecioUnitarioRealAjustado Clasificación Subclasificación	• Homologación de nombres y formatos. • Ajuste de montos y precios unitarios mediante el INPC. • Organización de los productos mediante clasificación y subclasificación.	expresados tanto en valores nominales como en valores reales de mayo de 2026.
Compras.xlsx — tabla diaria agregada	Representar el comportamiento diario de las compras y facilitar su integración con el calendario maestro.	Columnas pivotadas por Clasificación. NumeroRegistrosCompra TotalNominal TotalRealAjustado CantidadTotalCompra Fecha de venta, importe, cliente, vendedor, observaciones, estado y demás variables transaccionales válidas, excluyendo columnas redundantes o derivadas.	• Agrupación de registros por fecha. • Creación de columnas pivotadas por clasificación. • Cálculo de métricas totales diarias. • Integración con un calendario completo del periodo. • Imputación de ceros en días sin compras. • Priorización de la columna Fecha y uso de Fecha/Hora cuando fue necesario. • Conservación de registros con importe válido. • Normalización de nombres, vendedores, observaciones y estados. • Eliminación de registros duplicados. • Eliminación de columnas derivadas o redundantes. • Conservación de ventas incompletas cuando contenían información válida.	Se generó una tabla con una fila por día. Todos los días del periodo fueron incluidos y aquellos sin compras se representaron con valores iguales a cero.
Ventas.xlsx — detalle limpio	Obtener una base confiable y granular de las operaciones de venta.		• Eliminación de registros duplicados. • Eliminación de columnas derivadas o redundantes. • Conservación de ventas incompletas cuando contenían información válida.	Fue el archivo que requirió la depuración más cuidadosa debido a registros sin estado, duplicados, fechas con hora, columnas derivadas y operaciones parcialmente incompletas.
Ventas.xlsx — tabla diaria agregada	Construir los indicadores diarios de actividad comercial utilizados en el análisis y modelado.	NumeroRegistros PedidosUnicos ImporteNominal ImporteRealAjustado SubtotalNominal y SubtotalReal GananciaNominal y GananciaReal EnvioNominal EnvioReal DescuentoNominal y DescuentoReal CantidadTotal TotalItems	• Agrupación de operaciones por día. • Conteo de pedidos, clientes y vendedores únicos. • Suma de cantidades, artículos e importes. • Ajuste monetario de las métricas mediante el INPC. • Integración con el calendario completo. • Asignación de ceros a los días sin ventas.	Se obtuvo una tabla con una observación por día, incluyendo métricas nominales y reales. Los días sin actividad comercial se conservaron con valores iguales a cero para mantener la continuidad temporal.

Fuente: Elaboración propia a partir del proceso de integración, limpieza y transformación de las bases de datos del proyecto.

Construcción del dataset maestro

Se generaron dataset_maestro_diario.xlsx como evidencia de integración y dataset_maestro_semanal.xlsx como base de la unidad analítica principal.

- maestro

Variables incluidas

El dataset final contiene variables agrupadas en cuatro bloques:

Tipo	Variable
Calendario y exógenas	fecha
	es_festivo_mexicano
	es_fecha_pago
	nacimientos_indice
	temperatura_promedio_mensual_hidalgo
Ventas	inpc_valor_mensual
	ventas_registros
	ventas_pedidos_unicos
	ventas_importe_real_2026_05
	ventas_ganancia_real_2026_05
	ventas_envio_real_2026_05
	ventas_descuento_real_2026_05
	ventas_cantidad_total
	ventas_total_items
	ventas_pastel
	ventas_galletas
	ventas_otros
	ventas_cupcakes
	ventas_clientes_unicos
	ventas_vendedor_unico
Compras	compras_registros
	compras_total_real_2026_05
	compras_cantidad_total
	Columnas pivotadas por clasificación, por ejemplo:
	compras_harina_real_2026_05
	compras_chocolate_real_2026_05
	compras_empaque_real_2026_05
Clima codificado	compras_fondant_real_2026_05
	clima_DESPEJADO
	clima_LLUVIOSO
	clima_SIN_DATO
	clima_SOLEADO

Resultados de calidad del dataset final

Como resultado de la integración, el dataset maestro diario quedó conformado por 1,612 observaciones y 65 variables. Este conteo documenta la capa de origen; después de la agregación se obtuvieron 230 semanas calendario. La auditoría temporal identificó un bloque continuo principal de 127 semanas entre 2022-01-03 y 2024-06-03, una brecha interna de 44 semanas y una cola de 43 semanas sin cobertura confiable de compras.

La continuidad del calendario diario no implica cobertura sustantiva de todas las fuentes. Aunque no existen fechas omitidas en el panel, una racha de compras igual a cero entre 2024-06-10 y 2025-04-07 coincide con ventas positivas en 77.3% de las semanas, por lo que se clasificó como brecha de registro y no como ausencia real de compras. Los ceros aislados dentro del bloque continuo se conservaron como actividad observada.

Archivos generados

Como evidencia del proceso de preparación y para asegurar la trazabilidad de las transformaciones, los productos finales se almacenaron en la carpeta outputs/. Cada archivo corresponde a una etapa específica de limpieza, corrección, integración o documentación del análisis:

- dataset_maestro_diario.xlsx: base consolidada con granularidad diaria y todas las variables integradas.
- ventas_limpias.xlsx: registros de ventas depurados y estandarizados.
- compras_limpias.xlsx: versión inicial de los registros de compras después del proceso de limpieza.
- compras_limpias_corregidas.xlsx: versión corregida y validada de los registros de compras.
- dataset_tizayuca_limpio.xlsx: variables contextuales del municipio, preparadas para su integración.
- inpc_limpio.xlsx: serie del INPC homologada para el ajuste de los importes monetarios.
- temperatura_hidalgo_limpia.xlsx: serie climática filtrada y preparada para el estado de Hidalgo.

- eda_resumen.md: síntesis de los principales hallazgos del análisis exploratorio de datos.

En conjunto, estos archivos constituyen la evidencia intermedia y final del flujo de procesamiento. Su conservación permite reproducir la construcción del dataset maestro, auditar las decisiones de limpieza y utilizar versiones consistentes de los datos en las etapas posteriores de modelado y evaluación.

4.2.2 Ingeniería de Características (Feature Engineering)

Las transformaciones diarias que se describen a continuación se conservan como antecedente de integración y trazabilidad. El experimento principal utiliza su versión semanal, con rezagos de 1, 2, 4, 8 y 52 semanas, ventanas móviles de 4, 8 y 12 semanas y variables exógenas controladas por disponibilidad.

Resultado de la transformación

La aplicación del proceso de ingeniería de características generó el archivo dataset_modelado_diario.xlsx, integrado por 1,584 observaciones diarias y 276 columnas. Su cobertura temporal comprende del 29 de enero de 2022 al 31 de mayo de 2026. En comparación con el dataset maestro, esta estructura conserva la granularidad diaria, pero amplía el espacio de variables mediante predictores derivados que representan el calendario, la estacionalidad, el contexto externo y el comportamiento histórico del negocio.

Variables objetivo

En la etapa diaria se conservaron variables monetarias de ventas y compras como insumos intermedios. Para la evaluación principal se definió una sola variable objetivo: target_compras_importe_semanal, expresada en pesos reales de mayo de 2026. Las ventas se utilizan únicamente como predictores históricos y como evidencia auxiliar para auditar la cobertura de compras.

La consideración conjunta de ambos objetivos permite estudiar dos componentes relacionados de la operación: el comportamiento de la demanda y los requerimientos de abastecimiento. No obstante, cada variable se modela por separado para conservar una interpretación clara de sus determinantes y de sus respectivos errores de pronóstico.

Estrategia de generación de características

La estrategia de modelado combina variables de calendario y estacionalidad con representaciones cíclicas del mes, el día de la semana y el día del año. Estas últimas se construyeron mediante funciones seno y coseno para conservar la continuidad natural de los ciclos temporales y evitar saltos artificiales entre periodos consecutivos, como diciembre y enero o domingo y lunes.

También se incorporaron indicadores de proximidad a días festivos y fechas de pago, debido a que estos eventos pueden modificar el momento y la intensidad de la demanda. Para representar la memoria temporal de las series se generaron rezagos de 1, 2, 3, 7, 14 y 28 días, además de estadísticos calculados en ventanas móviles de 7, 14 y 28 días. Esta combinación permite capturar efectos inmediatos, semanales y de mediano plazo.

La representación se complementó con rezagos desagregados por categorías de ventas y compras, así como con variables de estabilidad, recencia y tendencia. De esta manera, el modelo puede distinguir entre patrones generales de la operación y comportamientos particulares de los distintos productos o insumos, sin limitarse al valor agregado diario.

Tratamiento de la ventana inicial

Debido a que el rezago máximo y la ventana móvil más extensa abarcan 28 días, se eliminaron las primeras 28 observaciones del dataset maestro. Esta decisión explica que el periodo efectivo de modelado comience el 29 de enero de 2022 y que el número de registros se reduzca de 1,612 a 1,584. La pérdida de observaciones es controlada y se concentra exclusivamente al inicio de la serie; no corresponde a fechas faltantes, sino a la necesidad de

asegurar que todas las filas utilizadas por los modelos dispongan de un historial completo y comparable.

Desarrollo del proceso

El procedimiento se implementó mediante el script `feature_engineering_profesional.py`, que transforma el dataset maestro diario en un panel temporal preparado para aprendizaje supervisado. El proceso no se limita a reorganizar la información: genera variables de calendario, integra factores exógenos e indicadores del contexto económico y operativo, y construye características históricas asociadas con las ventas y las compras.

Para preservar la validez temporal del experimento, cada predictor se calculó únicamente con información disponible antes de la fecha que se desea pronosticar. Este desplazamiento evita la fuga de información y permite que el desempeño obtenido represente de forma más realista las condiciones de uso del modelo. Las transformaciones específicas aplicadas al dataset original se describen a continuación.

Transformaciones aplicadas al dataset original

La transformación del dataset maestro se realizó de forma secuencial para conservar la relación temporal entre las observaciones y convertir los registros operativos en predictores adecuados para el aprendizaje supervisado. Las etapas aplicadas se describen a continuación.

Preparación temporal y variables de calendario

En primer lugar, el dataset maestro diario se ordenó cronológicamente. La columna fecha se convirtió al tipo `datetime` y se utilizó como referencia temporal para todas las transformaciones posteriores. Esta operación asegura que los rezagos, las ventanas móviles y las divisiones temporales respeten la secuencia real de los acontecimientos.

A partir de la fecha se obtuvieron variables de año, trimestre, mes, semana del año, día del mes, día de la semana y día del año. Asimismo, se crearon indicadores binarios para identificar fines de semana, inicios y cierres de mes, además de variables auxiliares como el número de

días del mes, los días transcurridos desde su inicio y los días restantes hasta su conclusión. Estas características permiten representar regularidades calendarias que podrían influir en la demanda y en la programación de las compras. La relación se formaliza en la ecuación (1).

Codificación cíclica de las variables temporales

$$x_{\text{sen}} = \sin(2\pi x/P); \quad x_{\text{cos}} = \cos(2\pi x/P) \quad (1)$$

Ecuación - Codificación cíclica de una variable temporal.

El mes, el día de la semana y el día del año poseen una estructura periódica que no queda representada adecuadamente mediante números enteros. Por esta razón, dichas variables se transformaron en pares de componentes seno y coseno. Para una posición temporal x dentro de un ciclo de longitud P , la representación se obtiene mediante $\sin(2\pi x/P)$ y $\cos(2\pi x/P)$. Con ello se preserva la cercanía entre el final y el inicio de cada ciclo, como ocurre entre diciembre y enero o entre domingo y lunes, y se evitan discontinuidades artificiales que podrían dificultar el aprendizaje de los modelos.

Variables exógenas y proximidad a eventos

El panel se enriqueció con información externa y contextual: días festivos mexicanos, fechas de pago, índice de nacimientos, temperatura promedio mensual, inflación mensual y variables indicadoras de las categorías climáticas. La inclusión de estos factores permite evaluar si parte de la variación de las ventas o de las compras se relaciona con condiciones económicas, ambientales o de calendario que no dependen directamente de la operación interna de Cup&Cake.

Para los festivos y las fechas de pago se calcularon tanto los días transcurridos desde el evento anterior como los días faltantes para el siguiente. También se generaron conteos acumulados en ventanas de 7 y 30 días, utilizando únicamente eventos anteriores para representar su intensidad reciente. Las variables que anticipan el siguiente evento no producen fuga de información, puesto que las fechas del calendario oficial y de pago se conocen antes del momento de elaborar el pronóstico.

Características históricas y composición por categoría

$$lag_k(y_t) = y_{t-k}; \quad MA_w(y_t) = (1/w) \sum_{i=1}^w y_{t-i} \quad (2)$$

Ecuación - Rezagos y media móvil sin información futura.

Para las series principales de ventas y compras se construyeron rezagos de 1, 2, 3, 7, 14 y 28 días. Además, se calcularon la media, la desviación estándar y la suma en ventanas móviles de 7, 14 y 28 días. Antes de calcular cada estadístico móvil, la serie se desplazó un día; por consiguiente, el valor asignado a una fecha determinada resume exclusivamente observaciones anteriores. Los distintos horizontes permiten capturar persistencia inmediata, patrones semanales, variaciones recientes y tendencias de mediano plazo. La relación se formaliza en la ecuación (2).

La misma lógica se aplicó de forma desagregada a las categorías de venta de pasteles, galletas, cupcakes y otros productos, así como a los componentes monetarios de las compras. Para estas variables se generaron rezagos de 1 y 7 días y medias móviles de 7 días. Esta desagregación permite que el modelo reconozca comportamientos específicos de los productos e insumos que podrían quedar ocultos en los totales diarios.

Estabilidad y relación entre ventas y compras

Con el propósito de representar el equilibrio operativo reciente, se calculó la razón entre las medias móviles de ventas y compras de siete días, junto con la diferencia monetaria entre ambas. También se incorporaron variables de recencia que cuantifican los días transcurridos desde la última venta y la última compra con valor distinto de cero. Estos indicadores aportan información sobre la continuidad de la actividad, los periodos de inactividad y la relación dinámica entre entradas y requerimientos de abastecimiento.

Objetivos predictivos y control de fuga de información

El pipeline heredado conserva cuatro objetivos diarios para trazabilidad; no forman parte del contraste principal. La investigación evalúa el importe semanal de compras, mientras que los

registros de ventas y su importe se emplean como antecedentes históricos disponibles antes del pronóstico.

El control de fuga de información se estableció mediante el desplazamiento temporal de los predictores históricos. Ningún rezago o estadístico móvil utiliza valores del día que se intenta estimar ni de fechas posteriores. Adicionalmente, se eliminaron las primeras 28 observaciones, ya que no disponían del historial completo requerido por la ventana máxima. De esta forma, cada fila del conjunto de modelado reproduce la información que habría estado disponible en una situación real de pronóstico.

Limpieza y exportación del resultado

Las divisiones entre cero producidas al calcular algunos cocientes se identificaron como valores infinitos y se convirtieron inicialmente en valores ausentes. Después, tanto estos casos como los valores no definidos derivados de las transformaciones se sustituyeron por cero, de acuerdo con la regla implementada en el pipeline, para obtener una matriz numérica completa y estable antes del entrenamiento.

El resultado diario se conservó en `dataset_modelado_diario.xlsx` como antecedente reproducible. El pipeline vigente genera `dataset_modelado_semanal.xlsx`, cuyo diccionario documenta la fuente, el rezago y la disponibilidad de cada predictor utilizado en los modelos estadísticos y de aprendizaje automático.

Valor metodológico del proceso

En términos metodológicos, la ingeniería de características convierte un conjunto de registros transaccionales en una representación analítica capaz de expresar relaciones que no aparecen de forma directa en las variables originales. Los rezagos, las ventanas móviles, la codificación cíclica y los indicadores de contexto hacen observables la dependencia temporal, la estacionalidad, la recencia de la actividad y la posible influencia de factores económicos, climáticos y comerciales. De esta manera, los modelos no se limitan a asociar valores

contemporáneos, sino que disponen de información estructurada sobre el comportamiento previo del negocio.

Este enriquecimiento también introduce un reto metodológico: el número de predictores aumenta sin que crezca el número de observaciones. El dataset modelado contiene 1,584 registros y 276 columnas, lo que equivale aproximadamente a 5.7 observaciones por variable antes de separar los periodos de ajuste, validación y prueba. En un contexto de Small Data, esta relación incrementa el riesgo de redundancia, multicolinealidad y sobreajuste; por ello, la ampliación de variables debe complementarse con diagnóstico dimensional, selección de características y comparación con representaciones de menor dimensión.

El valor del procedimiento no depende únicamente de ampliar la capacidad predictiva. La construcción determinista de las variables, el orden cronológico de las observaciones y el desplazamiento de los predictores históricos fortalecen la reproducibilidad y la validez temporal del experimento. Estas condiciones permiten atribuir las diferencias de desempeño a los modelos y a las representaciones evaluadas, y no a la incorporación accidental de información futura.

Metodología propuesta para el análisis dimensional y el modelado

Contexto y criterios de reducción dimensional

El archivo dataset_modelado_diario.xlsx documenta la expansión dimensional heredada. Para responder la pregunta de investigación se utiliza dataset_modelado_semanal.xlsx, que integra variables calendáricas y exógenas, rezagos semanales, estadísticas móviles e indicadores de eventos. La selección se ejecuta dentro de cada ventana de entrenamiento y no sobre todo el historial.

En consecuencia, la reducción dimensional no se planteó como una eliminación indiscriminada de variables, sino como una comparación controlada entre información disponible, relevancia predictiva e interpretabilidad. La decisión se fundamentó en tres criterios complementarios.

Capacidad predictiva. La representación reducida debe conservar las señales necesarias para pronosticar la demanda, los ingresos y las compras. Una disminución del número de variables solo es favorable si el desempeño fuera de muestra se mantiene o mejora frente al dataset completo.

Interpretabilidad financiera y operativa. Las variables seleccionadas deben permitir relacionar los resultados con decisiones comprensibles para Cup&Cake, como la programación de compras, la evolución de los ingresos, la actividad por categoría y la respuesta ante eventos del calendario. Esta condición evita privilegiar una reducción numérica que elimine el significado empresarial del modelo.

Validez temporal. Toda comparación debe respetar el orden de la serie y mantener separados los periodos de entrenamiento, validación y prueba. Tanto la selección de características como el ajuste de hiperparámetros deben realizarse con información anterior al periodo evaluado para impedir la fuga de información y obtener una estimación realista de la capacidad de generalización.

Secuencia reproducible de ejecución

El análisis dimensional y el modelado se organizaron como una cadena de etapas dependientes. Cada script recibe las salidas de la fase anterior y genera archivos de evidencia que permiten auditar las decisiones tomadas. La numeración que se presenta corresponde a los nombres vigentes dentro del pipeline maestro.

Etapas 0. Configuración metodológica

El archivo `config_metodologia.py` centraliza las rutas de entrada y salida, las variables objetivo, las particiones temporales y las reglas utilizadas para clasificar las columnas. Su función es mantener una configuración común entre los análisis y reducir inconsistencias derivadas de parámetros definidos de forma independiente en cada script.

Etapas 1. Perfil del dataset y sus dimensiones

El script 03_perfil_dataset_y_dimensiones.py describe cada variable, agrupa las columnas por dimensión metodológica y cuantifica propiedades como la presencia de valores nulos, variables constantes y concentración de ceros. Este perfil constituye el inventario inicial del dataset y permite distinguir entre ausencia de información, intermitencia operativa y falta de variabilidad.

Etapas 2. Diagnóstico de multicolinealidad

$$VIF_j = 1 / (1 - R_j^2) \quad (3)$$

Ecuación - Factor de inflación de la varianza.

Mediante 04_diagnostico_multicolinealidad.py se identifican predictores altamente correlacionados y se proponen variables que pueden conservarse o eliminarse para reducir redundancia. El diagnóstico se complementa con el factor de inflación de la varianza (VIF) cuando statsmodels está disponible. La correlación examina relaciones por pares, mientras que el VIF permite detectar dependencias de una variable respecto del conjunto de predictores. La relación se formaliza en la ecuación (3).

Etapas 3. Selección de características

El archivo 05_seleccion_caracteristicas_dataset_reducido.py genera un ranking específico para cada variable objetivo y construye una versión reducida del dataset. La selección considera la asociación con el objetivo y, cuando las dependencias necesarias están disponibles, incorpora métodos de aprendizaje automático y regularización. La ruta basada en correlación se conserva como mecanismo de contingencia, pero la evaluación temporal posterior determina si la reducción realmente aporta capacidad predictiva.

Etapas 4. Reducción mediante componentes principales

$$Z = XW ; \text{Varianza acumulada}(m) = \sum_{j=1}^m \lambda_j / \sum_{j=1}^p \lambda_j \quad (4)$$

Ecuación - Transformación PCA y varianza explicada acumulada.

El script `06_pca_reduccion_componentes.py` produce una representación alternativa mediante análisis de componentes principales (PCA). Esta técnica concentra la varianza de los predictores en componentes ortogonales y reduce los efectos de la multicolinealidad. Su principal ventaja es la compactación del espacio de entrada; su principal limitación es la pérdida de interpretabilidad directa, debido a que cada componente combina múltiples variables originales. La relación se formaliza en la ecuación (4).

Etapas 5. Modelos estadísticos y de aprendizaje automático

La evaluación operativa se ejecuta con `06_modelos_rolling_window.py`. Este módulo compara referencias empíricas, ETS, ARIMA, Croston-SBA, TSB y configuraciones de Ridge, Random Forest e HistGradientBoosting. La ventana deslizante conserva 52 semanas de entrenamiento; los hiperparámetros se ajustan en orígenes temporales previos a los 16 orígenes reservados para evaluación.

Etapas 6. Redes neuronales recurrentes

Finalmente, `08_rnn_lstm_dataset_reducido.py` entrena arquitecturas RNN y LSTM mediante ventanas temporales. Estas redes se aplican a las versiones reducida y PCA, ya que el número limitado de observaciones hace poco conveniente alimentar las arquitecturas con todas las columnas originales. Las configuraciones se validan en un bloque temporal anterior a la prueba y las alternativas ganadoras se reentrenan con el historial de desarrollo disponible.

En conjunto, el pipeline semanal genera un conjunto de modelado trazable, selecciona predictores a partir de cada ventana de entrenamiento y conserva predicciones, métricas, contrastes y un manifiesto de ejecución. El objetivo es comparar precisión fuera de muestra, no reproducir el esquema diario heredado de conjuntos completo, reducido y PCA.

Antecedentes de análisis exploratorio de la serie temporal semanal

Auditoría de cobertura y selección del bloque continuo

El calendario semanal contenía 230 periodos. La auditoría identificó dos brechas prolongadas: 44 semanas entre 2024-06-10 y 2025-04-07, coincidentes con ventas positivas en 77.3% de las semanas, y una cola de 43 semanas a partir de 2025-08-04. Además, las 16 semanas posteriores a la brecha interna no aportaban las 52 semanas continuas requeridas para el entrenamiento. Por ello, el análisis principal seleccionó el bloque 2022-01-03 a 2024-06-03, integrado por 127 semanas; 111 se destinaron al diagnóstico y desarrollo y 16 se reservaron para evaluación.

Esta decisión modifica la interpretación de los ceros. Los ceros aislados del bloque continuo representan semanas sin compras registradas y se conservan. En cambio, las rachas prolongadas con ventas activas se consideran ausencia de cobertura y se excluyen del análisis principal. Así se evita que los algoritmos de inteligencia artificial aprendan como patrón operativo una interrupción del proceso de captura.




Figura AT-1 - Serie semanal del importe de compras y bloque final reservado [Antecedente de la versión anterior; no es evidencia del híbrido actual]

Estructura temporal, estacionariedad y dependencia serial

En el bloque de desarrollo, ADF no rechazó la presencia de raíz unitaria en nivel ($p=0.200$) ni después de la transformación $\log 1p$ ($p=0.078$). KPSS rechazó la estacionariedad en ambos casos ($p=0.010$). La evidencia conjunta indica que la serie no puede tratarse como estacionaria en nivel y fundamenta comparar transformaciones, modelos con componentes dinámicos y algoritmos regularizados.

La ACF presentó dependencia positiva en el primer rezago (0.217), mientras que Ljung-Box rechazó la ausencia conjunta de autocorrelación en los rezagos 1, 4, 13, 26 y 52. No se observó una autocorrelación anual individual fuera del límite aproximado del 95% en el rezago 52. Estos resultados justifican rezagos recientes y la comparación con una referencia estacional, pero no demuestran una estacionalidad anual estable.




Figura AT-2 - Funciones ACF y PACF del bloque de desarrollo [Antecedente de la versión anterior; no es evidencia del híbrido actual]




Figura AT-3 - Perfil exploratorio del importe por semana del año [Antecedente de la versión anterior; no es evidencia del híbrido actual]

Intermitencia, variabilidad y valores atípicos

El bloque de desarrollo contiene 13.5% de semanas con importe cero. El ADI fue 1.16 y el CV^2 de los importes positivos fue 1.03; de acuerdo con los umbrales establecidos, la serie se clasifica como errática: las compras ocurren con relativa frecuencia, pero sus importes presentan alta variabilidad. Esta caracterización respalda el uso de $\log 1p$, modelos hurdle y métodos robustos, y muestra que el problema principal no es una intermitencia extrema sino la dispersión de los montos.

El criterio robusto basado en mediana y MAD identificó siete semanas atípicas dentro del bloque continuo. Estas observaciones se conservaron porque pueden corresponder a compras extraordinarias o eventos comerciales legítimos. Su presencia refuerza la conveniencia de evaluar MAE junto con RMSE y de no seleccionar modelos mediante MAPE.




Figura AT-4 - Identificación robusta de importes semanales atípicos [Antecedente de la versión anterior; no es evidencia del híbrido actual]




Figura AT-5 - Descomposición STL exploratoria con periodo de 52 semanas [Antecedente de la versión anterior; no es evidencia del híbrido actual]

Implicaciones para los modelos de Inteligencia Artificial

Los diagnósticos sustentan un diseño parsimonioso: rezagos recientes, codificación cíclica, transformación log1p, regularización y modelos de dos etapas. La descomposición STL se conserva como visualización, pero sus índices de fuerza no se interpretan porque el bloque de desarrollo contiene sólo 2.13 ciclos anuales. La inteligencia artificial se evalúa así sobre una representación temporal auditada, sin asumir que una mayor complejidad garantizará menor error.

Después de aplicar el rezago máximo de 52 semanas, quedaron 75 observaciones compatibles con el modelado. Se utilizaron 52 semanas por ventana, orígenes previos para ajuste y 16 semanas finales comunes para evaluación. Esta muestra limitada exige interpretar los resultados como evidencia del caso de estudio y no como una generalización a otras microempresas.

4.3 Antecedentes de diagnóstico de la línea base empírica y evaluación comparativa

Tabla 7 - Operacionalización de la línea base y los modelos predictivos [Antecedente de la versión anterior; no es evidencia del híbrido actual]

Componente	Definición operacional	Indicador
Preprueba	Método empírico: último valor o promedio de 7 días	RMSE y MAE de referencia
Posprueba	Mejor modelo evaluado en los mismos orígenes	RMSE y MAE del modelo
Contraste	Reducción relativa del RMSE	Umbral de H1: 20 %

La referencia primaria es la persistencia del último importe semanal observado. Como comparadores obligatorios se conservan el promedio móvil de cuatro semanas y el ingenuo estacional de 52 semanas. La comparación se realiza en las mismas semanas y contra la misma ventana de entrenamiento, sin equiparar la línea base con un grupo de control ni atribuir causalidad experimental.

4.4 Estado de la implementación del pipeline híbrido

Al 15 de septiembre de 2026 se dispone de una implementación modular con entrada `00_pipeline_hibrido.py`. La configuración principal utiliza `calendar_gaps`, actualizada el 14 de septiembre, y conserva las ramas `strict` y `demo` como antecedentes y pruebas técnicas. La corrida real del 15 de septiembre se detuvo en la validación de fuente, antes del entrenamiento. Su auditoría identificó 1670 registros válidos para revisión y 12 pendientes; este recuento no certifica cobertura ni suficiencia del conjunto analítico.

La auditoría exige una fuente identificada mediante una huella SHA-256, un catálogo de insumos aprobado y evidencia de cobertura para cada semana. Las ausencias no se convierten automáticamente en compras cero. El importe se expresa en pesos mexicanos nominales y se reconcilia con los importes por insumo. Los registros sintéticos se reservan para pruebas técnicas independientes y se excluyen del experimento real.

La rama monetaria vigente selecciona internamente $AR(1)$ o $ARIMA(1,1,1)$ en espacio de estados y un componente `HistGradientBoosting` o `Random Forest`, según los candidatos habilitados. La historia crece conservando los huecos del calendario. La composición se estima con participaciones históricas y un promedio exponencial sensible a la edad calendario. Las categorías se fijan sin consultar los errores finales y las asignaciones conservan el total al redondear a centavos.

Los conteos de 57 pruebas de Python y tres del constructor del tablero, así como las 20 figuras de demostración, corresponden a la revisión técnica previa de la implementación inicial. No certifican por sí solos la cobertura de pruebas de la rama `calendar_gaps` ni resultados predictivos sobre `Cup&Cake`. La verificación de esta rama deberá conservar su propio reporte de ejecución, incluidos fallos, omisiones y versiones de dependencias.

Cada ejecución conserva configuración, huellas de fuentes y código, versiones, métricas y predicciones cuando procede. Las figuras se exportan con datos de respaldo y manifiesto. La descomposición temporal requiere suficiente historia; no se genera una frecuencia de

selección cuando los predictores son prefijados. La captura de la nueva interfaz está pendiente. Ninguna figura de demostración se incorpora como resultado empírico de la tesis.

Antes del experimento real deberán confirmarse la fuente definitiva, las correcciones de registros, el catálogo, la cobertura, las fechas de evaluación y la adecuación del contraste inferencial. La comparación con y sin exógenas, los diagnósticos adicionales y la actualización incremental no se presentan como funciones completadas. Los antecedentes conservados en las secciones siguientes no sustituyen estas validaciones.

4.5 Antecedentes del repositorio y de la preparación de datos

Se construyó un repositorio en GITHUB para conservar los archivos de la investigación. La Imagen 1 identifica este antecedente. Las descripciones, tablas y figuras heredadas que siguen documentan etapas previas de exploración; no acreditan cobertura, ausencia de fuga de información ni precisión del pipeline híbrido actual. Su reutilización científica requiere una nueva auditoría conforme al procedimiento vigente.¹




Imagen 1 - Repositorio github [Antecedente de la versión anterior; no es evidencia del híbrido actual]¹

4.6 Antecedentes de auditoría, Depuración e Integración del Conjunto de Datos (Dataset)

Tabla 8 - Trazabilidad de los conjuntos analíticos [Antecedente de la versión anterior; no es evidencia del híbrido actual]

Conjunto	Observaciones	Variables	Cobertura o criterio
Dataset maestro	1,612	65	2022-01-01 a 2026-05-31; sin fechas faltantes
Dataset modelado	1,584	276	2022-01-29 a 2026-05-31
Dataset reducido	1,584	85	80 predictores, fecha y cuatro objetivos
Dataset PCA	1,584	135	130 componentes, fecha y cuatro objetivos

La auditoría examinó cobertura temporal, duplicados, valores nulos, consistencia de tipos, concentración de ceros y continuidad del registro. El bloque continuo principal quedó delimitado entre 2022-01-03 y 2024-06-03. Las 44 semanas de brecha interna, la cola de 43 semanas y el bloque posterior insuficiente para una ventana de 52 semanas se excluyeron del experimento principal, conservándose como evidencia de calidad y limitación del sistema de captura.

4.7 Antecedentes de ingeniería de Características (Feature Engineering) y Variables Exógenas




Figura 24 - Expansión dimensional producida por la ingeniería de características. [Antecedente de la versión anterior; no es evidencia del híbrido actual]

Tabla 9 - Dimensiones principales de las variables modeladas [Antecedente de la versión anterior; no es evidencia del híbrido actual]

Dimensión	Número de variables	Finalidad analítica
Rezagos	126	Memoria temporal de corto y mediano plazo
Ventanas móviles	105	Nivel, dispersión y acumulación reciente
Calendario y estacionalidad	19	Ciclos semanales, mensuales y anuales
Otras variables	21	Exógenas, relaciones, estabilidad y objetivos

La ingeniería de características semanal incorpora rezagos de 1, 2, 4, 8 y 52 semanas, medias y desviaciones móviles de 4, 8 y 12 semanas, codificación cíclica y variables exógenas registradas. La selección se realiza dentro de cada ventana de entrenamiento. Para horizontes directos superiores a una semana, las características históricas se congelan en el origen y sólo se admiten exógenas disponibles para la semana objetivo.

4.8 Antecedentes de desarrollo, Configuración y Entrenamiento de los Modelos Predictivos




Figura 25 - Arquitecturas recurrentes consideradas para el modelado temporal. [Antecedente de la versión anterior; no es evidencia del híbrido actual]

Tabla 10 - Familias de modelos y configuración evaluada [Antecedente de la versión anterior; no es evidencia del híbrido actual]

Familia	Configuración general	Representaciones
Empírica	Persistencia y promedio móvil de 7 días	Serie original
ARIMA/SARIMA	Órdenes seleccionados por objetivo	Completa y univariada
Regresión y árboles	Lineal, árbol de decisión y Random Forest	Completa, reducida y PCA

Redes recurrentes	RNN simple y LSTM con ventanas temporales	Reducida y PCA
-------------------	---	----------------

Se compararon referencias empíricas, ETS, ARIMA, Croston-SBA, TSB y modelos de aprendizaje automático parsimoniosos. Las variantes log1p y hurdle respondieron a la alta variabilidad y a los ceros observados. RNN y LSTM permanecen como contraste secundario y no como evidencia principal, debido al reducido número de observaciones semanales continuas y al riesgo de sobreajuste.

4.9 Antecedentes de evaluación comparativa del rendimiento predictivo frente a la línea base




Figura 26 - Esquema de validación temporal Rolling-Origin. [Antecedente de la versión anterior; no es evidencia del híbrido actual]

$$RMSE = (1/K) \sum_k RMSE_k; \text{Entrenamiento}_k = \{t \leq \tau_k\}, \quad (5)$$

$$\text{Prueba}_k = \{\tau_k < t \leq \tau_k + h\}$$

Ecuación - Formalización de la validación Rolling-Origin.

La evaluación heredada utilizó una ventana de 52 semanas y reportó 16 orígenes para $h=1$ y $h=4$. Se conserva como antecedente, no como evaluación del híbrido. El pipeline actual distingue 16 semanas objetivo reservadas de los 13 orígenes comunes que permiten observar $h=1$ a $h=4$; sus resultados reales todavía no se han generado.

4.10 La evaluación heredada utilizó una ventana de 52 semanas y reportó 16 orígenes para $h=1$ y $h=4$. Se conserva exclusivamente como antecedente. La configuración principal actual utiliza historia creciente y reserva 26 semanas calendario; los objetivos observados se contabilizarán por horizonte. Las cifras de 16 semanas y 13 orígenes de la rama strict no describen calendar_gaps, cuya corrida real todavía no ha completado entrenamiento y evaluación.



Figura 28 - Arquitectura funcional del sistema de soporte a la decisión. [Antecedente de la versión anterior; no es evidencia del híbrido actual]

El archivo de salida para el sistema de soporte a la decisión comunica resultados semanales auditables: diagnóstico temporal, cobertura utilizable, métricas por horizonte, contraste de $H1$, predicciones históricas, consolidaciones de cuatro semanas e inventario de variables exógenas. Su propósito es facilitar la revisión humana del presupuesto y transparentar cuándo la evidencia no respalda una superioridad algorítmica.

Arquitectura tecnológica

La implementación se encuentra en la carpeta dashboard del proyecto. La versión operativa de la interfaz está contenida en public/index.html y utiliza HTML, hojas de estilo y JavaScript ejecutado en el navegador. El archivo app/page.tsx actúa como punto de entrada del proyecto y remite a la versión estática publicada. Esta decisión reduce dependencias durante la consulta, facilita la portabilidad y permite reproducir la misma vista de resultados en diferentes equipos.

Para su distribución, scripts/build-static.mjs empaqueta el documento HTML y genera un servicio compatible con Cloudflare Workers. El servicio entrega la aplicación con encabezados de seguridad, control de caché y una ruta de verificación de disponibilidad. La interfaz es adaptable a distintos tamaños de pantalla y contempla etiquetas semánticas, descripciones para la gráfica y contraste para temas claro y oscuro. Estas características favorecen el acceso al DSS desde computadoras o dispositivos móviles sin requerir software analítico especializado.

Integración de los resultados predictivos

El archivo 04_dss_semanal.json corresponde a la integración heredada y no debe utilizarse para respaldar la H1 actual. El pipeline híbrido genera dss_hibrido.json y tablero.html dentro de una carpeta identificada por ejecución, con una separación explícita entre demostración y evaluación real.

El flujo de integración parte de la ejecución semanal reproducible, exporta predicciones y métricas por horizonte, construye el consolidado $h=1+h=2+h=3+h=4$ y comunica las advertencias de cobertura y disponibilidad ex ante. La interfaz que consume esta salida debe actualizarse junto con cada nueva ejecución; de otro modo, sólo representa una instantánea histórica.

Filtros e indicadores para la decisión

Para esta investigación, la salida del DSS se limita al importe semanal de compras del bloque con cobertura defendible. Debe mostrar por separado el desempeño en $h=1$ y $h=4$, el presupuesto consolidado de cuatro semanas, el diagnóstico de cobertura y las variables exógenas registradas. No debe mezclar resultados diarios heredados ni presentar las brechas como semanas de compras iguales a cero.

En la versión actual, los indicadores monetarios son RMSE, MAE y MASE; las participaciones se evalúan mediante MAE en puntos porcentuales. El procedimiento Diebold-Mariano con ajuste Holm de la versión anterior no constituye el protocolo vigente para la H1 conjunta. La adecuación del procedimiento inferencial implementado deberá aprobarse antes de la evaluación real independiente.

La visualización central debe comparar rankings y errores de $h=1$ y $h=4$ en paneles separados. El consolidado de cuatro semanas se presenta como una suma de pronósticos directos, con sus importes observados y pronosticados, para que el usuario no lo interprete como una estimación mensual independiente.

Resultados incorporados al DSS

La evidencia semanal actual no analiza objetivos diarios de ventas. El DSS no debe conservar conclusiones de modelos de ventas generadas por el pipeline diario heredado, pues no responden a la pregunta de investigación ni al horizonte semanal definido.

Las métricas incorporadas en versiones anteriores del DSS pertenecen a experimentos heredados. No representan resultados del híbrido actual ni permiten seleccionar sus componentes. El tablero nuevo solo dispone, hasta este punto, de una ejecución demostrativa identificada como tal.

El respaldo empírico de H1 se determinará una vez desarrollado y evaluado el modelo híbrido y el procedimiento de distribución porcentual. No se anticipa su aceptación o rechazo. El

análisis complementario de variables exógenas permitirá examinar si su incorporación aporta mejoras bajo configuraciones y periodos comparables, sin formular una segunda hipótesis.

Interpretación operativa y salvaguardas

El DSS está destinado a facilitar la revisión humana del presupuesto. No se dispone todavía de evidencia real para recomendar el híbrido por encima de sus referencias. La versión inicial tampoco genera intervalos de predicción para los importes futuros; no deben interpretarse bandas o variaciones descriptivas como tales intervalos.

La cobertura se presenta como condición de uso. El bloque principal contiene 127 semanas continuas; después del rezago máximo quedaron 75 observaciones para modelado y 16 orígenes finales para evaluación. La brecha interna, la cola sin cobertura y el segmento posterior insuficiente se mantienen fuera del ajuste y de los contrastes. Antes de utilizar el sistema operativamente deben reanudarse y verificarse los registros de compras.

Alcance actual de la integración




Figura 29 - Interfaz funcional del tablero DSS implementado para Cup&Cake. [Antecedente de la versión anterior; no es evidencia del híbrido actual]

La interfaz heredada y sus capturas se conservan como antecedentes. Para el pipeline actual se añadió un constructor independiente, build-hibrido.mjs, que consume los productos de una ejecución completada y preserva las advertencias de demostración. La salida es una instantánea local; no se ha publicado ni se conecta automáticamente con los registros operativos.

La actualización incremental con configuración congelada, la captura verificada de la nueva interfaz y su uso operativo permanecen pendientes. La recarga del artefacto actual reproduce el pronóstico del corte guardado; un nuevo corte requiere incorporar fuentes y cobertura aprobadas y ejecutar nuevamente el pipeline. La configuración no debe elegirse por el mejor resultado del conjunto final.

4.11 Alcance del apoyo al presupuesto de abastecimiento




Figura 30 - Flujo de decisión operativa asistido por el DSS. [Antecedente de la versión anterior; no es evidencia del híbrido actual]

El DSS permite explorar el comportamiento de los objetivos, comparar el desempeño contra la línea base y revisar estabilidad por ventana. Su alcance es anticipar el importe y la frecuencia de compras como apoyo para reservar presupuesto de abastecimiento. No genera órdenes automáticas ni cantidades físicas por insumo, porque los registros no contienen de manera consistente recetas, inventario inicial/final, merma, tiempos de entrega ni unidades de medida

homologadas. Por rigor científico, los resultados se interpretan como apoyo diagnóstico y de planeación presupuestal.

5 RESULTADOS

Calidad, cobertura e integración de datos

La auditoría preliminar de Compras.xlsx identificó 1670 registros sin las incidencias examinadas y 13 pendientes de revisión: 12 marcados por duplicidad y uno por importe inválido. Estos conteos no establecen cobertura semanal ni constituyen una muestra final aprobada. La fuente definitiva, las correcciones, el catálogo de insumos y el periodo continuo de análisis siguen pendientes de validación.

Reducción dimensional

La versión inicial emplea características históricas y calendáricas prefijadas, con exógenas opcionales sujetas a disponibilidad documentada. No se ha ejecutado una selección dimensional del nuevo experimento con datos reales. Los análisis de reducción dimensional anteriores no se presentan como resultados del híbrido.

Rendimiento comparativo de los modelos

No se dispone todavía de métricas reales del modelo híbrido ni de su procedimiento de distribución porcentual. RMSE, MAE, MASE y MAE de participaciones se reportarán después de ejecutar el protocolo aprobado sobre fechas comparables. Los rankings y valores de versiones anteriores no permiten concluir qué modelo será más preciso en este experimento.

La ejecución demostrativa verificó que el software puede producir pronósticos para cuatro horizontes y distribuir cada total entre insumos. Sus importes y errores son datos de prueba y se excluyen de los resultados empíricos de la investigación. Las figuras heredadas siguientes se mantienen identificadas como antecedentes, pendientes de sustitución por evidencia real del procedimiento actual.




Figura 31 - Mejora relativa del RMSE frente a la línea base empírica. [Antecedente de la versión anterior; no es evidencia del híbrido actual]




Figura 32 - Mejor modelo por objetivo y representación de datos. [Antecedente de la versión anterior; no es evidencia del híbrido actual]

Resultados de redes neuronales recurrentes

RNN y LSTM no se incluyen en la implementación inicial. Por tanto, no se presentan resultados de redes recurrentes como evidencia del experimento actual.

Contraste de hipótesis

H1 permanece pendiente de contraste con datos reales. Se reportarán por separado los errores del importe total y de las participaciones frente a sus referencias, junto con la incertidumbre y las limitaciones del procedimiento. Hasta completar esa evaluación no corresponde afirmar respaldo ni rechazo de la hipótesis.

Resultados del tablero DSS

Se verificó técnicamente la generación del JSON y de la interfaz local con una ejecución demostrativa. No se ha validado su utilidad operativa con la persona responsable de Cup&Cake. Las expresiones de error conservadas a continuación son definiciones matemáticas y no constituyen resultados; los indicadores complementarios no implementados no se atribuyen a la salida actual.

$$\text{Mejora_RMSE} = 100 \times (\text{RMSE_base} - \text{RMSE_modelo}) / \text{RMSE_base} \quad (6)$$

Ecuación - Reducción relativa del RMSE frente a la línea base.

$$\text{WAPE} = 100 \times \sum_i |y_i - \hat{y}_i| / \sum_i |y_i| \quad (7)$$

Ecuación - Error porcentual absoluto ponderado como diagnóstico complementario.

$$\text{MAPE} = (100/|I|) \sum_{i \in I} |(y_i - \hat{y}_i)/y_i|, \quad I = \{i: y_i \neq 0\} \quad (8)$$

Ecuación - Error porcentual absoluto medio sobre observaciones no nulas.

$$\text{RMSE} = \sqrt{[(1/n) \sum_{i=1}^n (y_i - \hat{y}_i)^2]} \quad (9)$$

Ecuación - Raíz del error cuadrático medio.

$$\text{MAE} = (1/n) \sum_{i=1}^n |y_i - \hat{y}_i| \quad (10)$$

Ecuación - Error absoluto medio.

La tabla heredada de modelos ganadores no corresponde al experimento híbrido y no se utilizará para concluir sobre H1. La tabla de resultados vigente se elaborará únicamente después de la evaluación con datos reales y distinguirá el importe total, las participaciones y cada horizonte.

Tabla 11 - Modelos ganadores y desempeño temporal [Antecedente de la versión anterior; no es evidencia del híbrido actual]

Objetivo	Modelo y representación	MAE	RMSE	Mejora RMSE
----------	-------------------------	-----	------	-------------

Importe de ventas	ARIMA(1,1,2)	101.951	161.149	3.2 %
Registros de ventas	ARIMA(1,1,1)	0.362	0.525	5.1 %
Importe de compras	Random Forest, reducido	116.961	213.014	28.3 %
Registros de compras	Random Forest, reducido	1.727	2.593	22.8 %

6 DISCUSION

Interpretación de los hallazgos

La discusión empírica permanece pendiente de evaluar el híbrido y la distribución porcentual con datos reales. La implementación permite efectuar comparaciones separadas por horizonte, pero su funcionamiento técnico no demuestra una mejora de precisión.

El conjunto inicial acotado de componentes responde a una decisión de diseño parsimonioso. Su conveniencia deberá examinarse con el protocolo temporal definido; no se deduce superioridad de una familia de modelos a partir de su complejidad ni de los resultados demostrativos.

Demanda intermitente y selección de métricas

La evaluación monetaria conservará los ceros confirmados. Las semanas cuyo importe observado sea cero no tienen participaciones definidas y se excluirán únicamente de la métrica porcentual, informando su número. La frecuencia real de estos casos quedará establecida después de aprobar la cobertura.

Implicaciones operativas y financieras

El uso previsto es apoyar la revisión del presupuesto semanal mediante importes y participaciones pronosticados. No se han medido beneficios financieros u operativos, ni reducciones de faltantes, sobreabastecimiento o merma. La interfaz no autoriza compras automáticas y mantiene la decisión bajo responsabilidad humana.

Validez y limitaciones

Las pruebas técnicas verifican controles de separación temporal, reconciliación y trazabilidad, pero no sustituyen una evaluación independiente con datos reales. La elección de la fuente, la cobertura, el tamaño muestral y el protocolo inferencial siguen condicionando la validez del estudio. La eventual generalización se limitará al caso y a las condiciones observadas.

7 CONCLUSIONES

Se implementó una versión inicial del pipeline para combinar pronósticos estadísticos y de aprendizaje automático del importe semanal de compras, estimar participaciones y generar asignaciones monetarias reconciliadas. La verificación técnica comprende pruebas automatizadas y una ejecución demostrativa; este avance no equivale a concluir la investigación.

H1 todavía no ha sido contrastada con el modelo híbrido actual sobre datos reales aprobados. No se afirma su respaldo ni su rechazo. Las conclusiones de experimentos anteriores y los resultados sintéticos no se transfieren a la hipótesis conjunta sobre importe total y distribución porcentual.

La conclusión en esta etapa se limita a la disponibilidad de una implementación inicial verificable. Determinar su precisión y su pertinencia para Cup&Cake exige completar la auditoría de datos y la evaluación prevista, sin condicionar el cierre del estudio a obtener una hipótesis favorable.

Recomendaciones

Se recomienda resolver las incidencias de fuente, aprobar el catálogo y documentar la cobertura antes de entrenar con registros reales. Deberán fijarse y justificar el periodo y el protocolo exploratorio de `calendar_gaps`; una futura evaluación confirmatoria requerirá un diseño independiente adicional. Para alinear el ciclo con MLOps, se propone explicitar la aceptación del despliegue, el registro de versiones, la vigilancia de datos y errores y el retorno controlado al reentrenamiento (García Velasco, 2023, pp. 43–45; Ordonez Bolanos et al., 2023, pp. 97–99).

Trabajo futuro

El trabajo inmediato consiste en completar la revisión de datos y la evaluación retrospectiva, y generar las figuras empíricas correspondientes. Las ampliaciones comprenden comparación

controlada con y sin exógenas, intervalos futuros validados y un ciclo operativo de entrega semanal, monitorización y reentrenamiento versionado. Los umbrales de alerta y las reglas de sustitución del modelo deberán fijarse antes del uso productivo; no se presuponen mejoras de precisión ni beneficios financieros.

GLOSARIO

Inteligencia Artificial (IA): Rama de la informática que diseña sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, como el aprendizaje, la planificación y la predicción.

Cadena de suministro: Conjunto de procesos involucrados en la producción, distribución y entrega de un producto desde su origen hasta el cliente final.

PYMES: Pequeñas y Medianas Empresas, generalmente caracterizadas por tener un número limitado de empleados y recursos, pero con alto potencial de innovación.

Agentes Inteligentes: Programas o sistemas que ejecutan acciones de manera autónoma para alcanzar objetivos específicos, basados en reglas o **aprendizaje automático**.

Pronóstico de demanda: Proceso de estimar la demanda futura de productos o servicios a través de datos históricos y modelos estadísticos o de **aprendizaje automático**.

REFERENCIAS

- Ab Karim, M. S., Ab Rahman, S., Chua, B. L., et al. (2020). The creative minds of extraordinary pastry chefs: an integrated theory of aesthetic expressions – a portraiture study. *International Journal of Contemporary Hospitality Management*, 32(9), 3015–3034. <https://doi.org/10.1108/IJCHM-04-2020-0329>
- Abrar, M., et al. (2024). An Explainable Multi-Channel Data Fusion Network for Demand Forecasting in Supply Chains. *Expert Systems with Applications*.
- Abrar, M., Shahriar, M. A., & Amin, A. (2024). MCDFN: Supply chain demand forecasting via an explainable multi-channel data fusion network model. arXiv preprint arXiv:2405.15598. <https://doi.org/10.48550/arXiv.2405.15598>
- Aitchison, J. (1982). The statistical analysis of compositional data. *Journal of the Royal Statistical Society: Series B (Methodological)*, 44(2), 139–160. <https://doi.org/10.1111/j.2517-6161.1982.tb01195.x>
- Akter, S., Wamba, S. F., Gunasekaran, A., Dubey, R., & Childe, S. J. (2019). How to improve firm performance using big data analytics capability and business strategy alignment. *Journal of Big Data*, 6(1).
- Alekseeva, L., Ginevičius, R., & Stankevičienė, J. (2021). Adoption of artificial intelligence technologies in SMEs: Evidence from Europe. *Sustainability*, 13(19), 10663. <https://doi.org/10.3390/su131910663>
- Alekseeva, L., Ginevičius, R., & Stankevičienė, J. (2021). Factors affecting artificial intelligence adoption in small and medium-sized enterprises. *Sustainability*, 13(21), 12156.
- Alekseeva, M., Gorbunova, N., y Parshina, E. (2021). Digital transformation of small and medium-sized enterprises: Barriers and opportunities. Springer.

- Aprodu, I., Banu, I., Vasilean, I., et al. (2025). The Digital Revolution in the Bakery Sector: A Systematic Review of Industry 4.0 Technologies. *Foods*, 14(2).
- Banco Interamericano de Desarrollo (BID). (2019). *Emprender en América Latina: aprendizajes y desafíos*. <https://www.iadb.org>
- Bates, J. M., & Granger, C. W. J. (1969). The combination of forecasts. *Operational Research Quarterly*, 20(4), 451–468. <https://doi.org/10.2307/3008764>
- Ben Abdallah, H., Ayadi, M., Boujelbene, Y. (2022). The main determinants and effects of product innovation: An exploratory study on the pastry companies of the region of Sfax (in Tunisia). *Technological Forecasting and Social Change*, 185, 122065. DOI: 10.1016/j.techfore.2022.122065.
- Bergmeir, C., & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191, 192-213. <https://doi.org/10.1016/j.ins.2011.12.028>
- Bertsimas, D., & Kallus, N. (2020). From predictive to prescriptive analytics. *Management Science*, 66(3), 1025–1044. <https://doi.org/10.1257/mnsc.2018.3243>
- Bertsimas, D., Dunn, J., & Pawlowski, C. (2021). Artificial intelligence for business decision support systems. *Decision Analytics Journal*, 1, 100003.
- Bontempi, G., Ben Taieb, S., & Le Borgne, Y.-A. (2013). Machine learning strategies for time series forecasting. En M. Aufaure & E. Zimányi (Eds.), *Business intelligence* (pp. 62–77). Springer. https://doi.org/10.1007/978-3-642-36318-4_3
- Borsato, M. (2023). “Edible Aesthetics”: Blurring Boundaries between Pastry and Art. *Humanities*, 12(5), 126. <https://doi.org/10.3390/h12050126>
- Box, G. E. P. (1976). Science and statistics. *Journal of the American Statistical Association*, 71(356), 791–799. <https://doi.org/10.1080/01621459.1976.10480949>

- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). Time series analysis: Forecasting and control (5th ed.). Wiley.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
<https://doi.org/10.1023/A:1010933404324>
- Brynjolfsson, E., & McElheran, K. (2016). The rapid adoption of data-driven decision-making. *American Economic Review*, 106(5), 133–139. <https://doi.org/10.1257/aer.p20161016>
- Brynjolfsson, E., Hitt, L. M., & Kim, H. H. (2011). Strength in numbers: How does data-driven decision making affect firm performance? *SSRN Electronic Journal*.
<https://doi.org/10.2139/ssrn.1819486>
- Cao, G., Duan, Y., Edwards, J. S., & Dwivedi, Y. K. (2025). Future trends in predictive analytics. *Analytics*, 4(1), Article 3. <https://doi.org/10.3390/analytics4010003>
- Cuevas-Vargas, H., Estrada, S., & Larios-Gómez, E. (2016). The effects of ICTs as innovation facilitators for a greater business performance. Evidence from Mexico. *Procedia Computer Science*, 91, 47–56. <https://doi.org/10.1016/j.procs.2016.07.040>
- Davenport, T. H., & Harris, J. G. (2007). *Competing on analytics: The new science of winning*. Harvard Business School Press.
- Dubey, R., Bryde, D., Blome, C., Roubaud, D., & Giannakis, M. (2021). Facilitating artificial intelligence powered supply chain analytics through alliance management during the pandemic crises in the B2B context. *Industrial Marketing Management*, 96, 135–146.
- Dubey, R., Gunasekaran, A., Childe, S. J., Bryde, D. J., Giannakis, M., & Foropon, C. (2021). Big data analytics and artificial intelligence pathway to operational performance under the effects of entrepreneurial orientation and environmental dynamism: A study of manufacturing organisations. *International Journal of Production Economics*, 226, 107599. <https://doi.org/10.1016/j.ijpe.2019.107599>

- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232. <https://doi.org/10.1214/aos/1013203451>
- García-Murillo, M., MacInnes, I., & Bauer, J. (2019). Techno-economic analysis of digital transformation in Latin American SMEs. *Telecommunications Policy*, 43(9). <https://doi.org/10.1016/j.telpol.2019.101820>
- García-Pérez, A., Ghio, A., Occhipinti, Z., & Verona, R. (2020). Knowledge management and intellectual capital in knowledge-based organisations: A review and theoretical perspectives. *Journal of Knowledge Management*, 24(7), 1719–1751. <https://doi.org/10.1108/JKM-12-2019-0682>
- García-Sánchez, A., Fernández, M., & Ruiz, P. (2023). Machine learning techniques for financial forecasting and decision support. *Revista Iberoamericana de Inteligencia Artificial*.
- García Velasco, A. (2023). MLOps: Administrando el diseño y ciclo de vida de los modelos de machine learning [Trabajo de fin de grado, Universidad Politécnica de Madrid]. Archivo Digital UPM. <https://oa.upm.es/74985/>
- Giannopoulos, P. G., Dasaklis, T. K., Tsantilis, I., & Patsakis, C. (2025). Machine learning algorithms in intermittent demand forecasting: A review. *International Journal of Production Research*, 1–43. <https://doi.org/10.1080/00207543.2025.2578701>
- Góngora Chonillo, J. T. (2023). Evaluación del riesgo financiero en microempresas a través de inteligencia artificial. *Revista Pulso Científico*, 1(2), 34–49. <https://doi.org/10.70577/rps.v1i2.10>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- Hewamalage, H., Bergmeir, C., & Bandara, K. (2021). Recurrent neural networks for time series forecasting: Current status and future directions. *International Journal of Forecasting*, 37(1), 388–427. <https://doi.org/10.1016/j.ijforecast.2020.06.008>

- Huber, J., & Stuckenschmidt, H. (2020). Daily retail demand forecasting using machine learning with emphasis on calendric special days. *International Journal of Forecasting*, 135, 113322. <https://doi.org/10.1016/j.ijforecast.2020.02.005>.
- Hübner, A., Kuhn, H., & Sternbeck, M. G. (2024). *Sales and operations planning in retail and supply chains*. Springer.
- Hübner, N., Caspers, J., Coroamă, V. C., & Finkbeiner, M. (2024). Machine-learning-based demand forecasting against food waste: Life cycle environmental impacts and benefits of a bakery case study. *Journal of Industrial Ecology*, 28, 1117–1131. <https://doi.org/10.1111/jiec.13528>
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>
- Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>
- Hyndman, R. J., Ahmed, R. A., Athanasopoulos, G., & Shang, H. L. (2011). Optimal combination forecasts for hierarchical time series. *Computational Statistics & Data Analysis*, 55(9), 2579–2589. <https://doi.org/10.1016/j.csda.2011.03.006>
- Hyndman, R. J., Athanasopoulos, G., Wang, E., & Wang, Y. (2023). Advances in business forecasting methods and applications. *Journal of Forecasting*.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2nd ed.). Springer.
- Kahneman, D. (2011). *Thinking, fast and slow*. Farrar, Straus and Giroux.
- Kahneman, D., & Tversky, A. (1974). Judgment under uncertainty: Heuristics and biases. *Science*, 185(4157), 1124–1131. <https://doi.org/10.1126/science.185.4157.1124>
- Kahneman, D., & Tversky, A. (1979). Prospect theory: An analysis of decision under risk. *Econometrica*, 47(2), 263–291. <https://doi.org/10.2307/1914185>

- Kantis, H., Federico, J., & García, S. (2020). Índice de condiciones sistémicas para el emprendimiento dinámico. Prodem.
- Kuhn, M., & Johnson, K. (2013). *Applied predictive modeling*. Springer.
<https://doi.org/10.1007/978-1-4614-6849-3>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). Statistical and machine learning forecasting methods: Concerns and ways forward. PLOS ONE, 13(3), e0194889.
<https://doi.org/10.1371/journal.pone.0194889>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). The M4 competition: Results, findings, conclusion and way forward. International Journal of Forecasting, 34(4), 802–808. <https://doi.org/10.1016/j.ijforecast.2018.06.001>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. International Journal of Forecasting, 38(4), 1346–1364.
<https://doi.org/10.1016/j.ijforecast.2021.11.013>
- Martins-Turner, K., von Massow, M., O'Rourke, S., & Fraser, E. D. G. (2023). Machine learning based demand forecasting against food waste: Life cycle environmental impacts and benefits of a bakery case study. Journal of Cleaner Production, 384, 135539.
<https://doi.org/10.1016/j.jclepro.2022.135539>
- Mikalef, P., Boura, M., Lekakos, G., & Krogstie, J. (2019). Big data analytics capabilities and innovation: The mediating role of dynamic capabilities and moderating effect of the environment. British Journal of Management, 30(2), 272–298.
<https://doi.org/10.1111/1467-8551.12343>
- Mikalef, P., Krogstie, J., Pappas, I., & Pavlou, P. (2019). Investigating the effects of big data analytics capabilities on firm performance. Information & Management, 57(2), 103169.

- Minniti, M., & Bygrave, W. (2018). A dynamic model of entrepreneurial learning. *Entrepreneurship Theory and Practice*, 25(3), 5-16. <https://doi.org/10.1177/104225870102500301>
- Nonaka, I., & Takeuchi, H. (1995). *The knowledge-creating company: How Japanese companies create the dynamics of innovation*. Oxford University Press.
- OECD. (2021). *The digital transformation of SMEs*. OECD Publishing. <https://doi.org/10.1787/bdb9256a-en>
- OECD. (2022). *Financing growth and turning data into business: Helping SMEs scale up*. OECD Publishing. <https://doi.org/10.1787/81c738f0-en>
- Ordóñez Bolanos, A. A., Rojas, J. S., Gómez Gómez, J., & Ramírez-Gonzalez, G. (2023). Metodología basada en MLOps (Machine Learning Operations) para apoyo a la gestión en proyectos de ciencia de datos. *Revista Colombiana de Tecnologías de Avanzada*, 1(41), 87–103. <https://doi.org/10.24054/rcta.v1i41.2510>
- Organización para la Cooperación y el Desarrollo Económicos (OCDE). (2022). *Financing growth and turning data into business: Helping SMEs scale up*. OECD Publishing. <https://doi.org/10.1787/81c738f0-en>
- Petropoulos, F., Makridakis, S., Assimakopoulos, V., & Nikolopoulos, K. (2020). Forecasting: Theory and practice in a changing world. *Forecasting*, 2(1), 15–28.
- Polanyi, M. (1966). *The Tacit Dimension*. Doubleday & Company.
- Poveda-Valverde, F., & Fierro Barragán, S. E. (2026). AI applications that can support sustainable practices in small and medium-sized enterprises in Latin America: A systematic review. *Sustainability*, 18(7), Article 3603. <https://doi.org/10.3390/su18073603>

Power, D. J. (2002). *Decision support systems: Concepts and resources for managers*.

Quorum Books.

PraveenaSri, P., Padma, V., Muruguesan, R., & Usha, S. (2023). Business challenges of forecasting sales in the bakery industry: Applications of machine learning algorithms. <https://www.researchgate.net/publication/370666295>

PraveenaSri, P., Padma, V., Muruguesan, R., & Usha, S. (2023). Business challenges of forecasting sales in the bakery industry: Applications of machine learning algorithms. ResearchGate Publication. <https://www.researchgate.net/publication/370666295>

Provost, F., & Fawcett, T. (2013). *Data science for business: What you need to know about data mining and data-analytic thinking*. O'Reilly Media.

Ramírez-Montoya, M. S., et al. (2022). Data-driven decision making and business intelligence in organizations. *RISTI – Revista Ibérica de Sistemas y Tecnologías de Informação*.

Ries, E. (2017). *El método Lean Startup: Cómo crear empresas de éxito utilizando la innovación continua*. Deusto.

Romero-Hidalgo, J. A., Isiordia-Lachica, P. C., Valenzuela, A., & Rodríguez-Carvajal, R. A. (2021). Knowledge and innovation management model in the organizational environment. *Information* (Switzerland), 12(6), 225. <https://doi.org/10.3390/info12060225>

Saavedra-García, M., & Tapia-Sánchez, B. (2020). The role of information technologies in Mexican SMEs. *Contaduría y Administración*, 65(2). <https://doi.org/10.22201/fca.24488410e.2020.2215>

Sánchez, M., & Terrazas, R. (2020). Inteligencia de negocios como herramienta para la toma de decisiones en PYMES mexicanas. *Contaduría y Administración*, 65(3). <https://doi.org/10.22201/fca.24488410e.2020.2314>

- Scuotto, V., Del Giudice, M., Tarba, S., & Bresciani, S. (2021). Digital technologies and SMEs' performance: The role of digital transformation. *Technological Forecasting and Social Change*, 173, 121139. <https://doi.org/10.1016/j.techfore.2021.121139>
- Shmueli, G. (2010). To explain or to predict? *Statistical Science*, 25(3), 289–310.
<https://doi.org/10.1214/10-STS330>
- Shmueli, G., & Koppius, O. R. (2011). Predictive analytics in information systems research. *MIS Quarterly*, 35(3), 553–572. <https://doi.org/10.2307/23042796>
- Simon, H. A. (1997). *Administrative behavior: A study of decision-making processes in administrative organizations* (4th ed.). Free Press.
- Spiliotis, E., Makridakis, S., & Assimakopoulos, V. (2025). Continuous business forecasting in modern organizations. *Forecasting*, 7(1), 12–29.
<https://doi.org/10.3390/forecast7010012>
- Spiliotis, E., Makridakis, S., Semenoglou, A. A., & Assimakopoulos, V. (2022). Comparison of statistical and machine learning methods for daily SKU demand forecasting. *Operational Research*, 22(3), 3037–3061. <https://doi.org/10.1007/s12351-020-00605-2>
- Syntetos, A. A., & Boylan, J. E. (2005). The accuracy of intermittent demand estimates. *International Journal of Forecasting*, 21(2), 303–314.
<https://doi.org/10.1016/j.ijforecast.2004.10.001>
- Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: An analysis and review. *International Journal of Forecasting*, 16(4), 437–450. [https://doi.org/10.1016/S0169-2070\(00\)00065-0](https://doi.org/10.1016/S0169-2070(00)00065-0)

- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1), 267–288.
<https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>
- Verhoef, P. C., Broekhuizen, T., Bart, Y., Bhattacharya, A., Dong, J. Q., Fabian, N., & Haenlein, M. (2021). Digital transformation: A multidisciplinary reflection and research agenda. *Journal of Business Research*, 122, 889–901.
<https://doi.org/10.1016/j.jbusres.2019.09.022>
- Viteri, C., & Murillo, D. (2022). Inteligencia de negocios para las organizaciones. *Revista Killkana Social*, 6(12). <https://doi.org/10.35381/R.K.V6I12.1291>
- Zhang, G. P. (2003). Time series forecasting using a hybrid ARIMA and neural network model. *Neurocomputing*, 50, 159–175. [https://doi.org/10.1016/S0925-2312\(01\)00702-0](https://doi.org/10.1016/S0925-2312(01)00702-0)

Anexo A Diccionario de datos

Este diccionario describe los campos de Ventas.xlsx y Compras.xlsx, hoja Hoja1, y las variables principales de entrada y preparación del pipeline inspeccionadas el 13 de septiembre de 2026. Los encabezados se verificaron directamente. Los tipos indicados son los esperados para el análisis, no una certificación de limpieza; las definiciones no confirmadas se señalan expresamente. No se reproducen datos personales ni valores de transacciones.

7.1.1.1 Reglas comunes de interpretación

La existencia de un registro no prueba su integridad ni la cobertura de su semana. Cero, celda vacía y texto null tienen significados distintos: los valores cero se revisan con evidencia y los faltantes no se convierten automáticamente en ceros. Se observaron tipos mixtos y texto null en Ventas.xlsx. Antes de agregar se verificará si cada fila corresponde a una transacción, una línea o una repetición, y se documentará el tratamiento de devoluciones y cancelaciones.

Las fechas de inicio de captura provienen de la información histórica del negocio y no garantizan que los archivos inspeccionados contengan todo ese periodo. Los importes analíticos se expresarán en MXN nominales una vez confirmada la moneda y el alcance. Los campos administrativos y personales se excluyen del conjunto inicial de predictores. La disponibilidad temporal se comprobará antes de cada pronóstico; una fecha de operación no equivale por sí sola a fecha de disponibilidad.

7.1.1.2 Campos de origen de ventas

Campo exacto	Tipo esperado	Definición	Uso y validación
Number	Texto	Identificador registrado de la transacción.	Control; comprobar unicidad, no usar como predictor.
Status	Categoría	Estado registrado de la venta.	Validar categorías y criterio de inclusión; no asumir que todos los estados son ventas concluidas.

Campo exacto	Tipo esperado	Definición	Uso y validación
Fecha/Hora	Fecha y hora	Marca temporal del registro.	Convertir y contrastar con Fecha; no equivale necesariamente a fecha de disponibilidad.
Cantidad	Número	Cantidad consignada en la venta.	Unidad y diferencia respecto de Total de ítems pendientes de verificación.
Total de ítems	Número	Total de ítems consignado.	Verificar si cuenta unidades o líneas del pedido; no asumir equivalencia con Cantidad.
Descri. Items	Texto	Descripción de los productos de la transacción.	Descripción auxiliar; no se modela texto libre en la versión inicial.
Subtotal	Número monetario	Subtotal registrado antes de ajustes.	MXN por confirmar en origen; revisar conciliación, no sumar al Importe.
Descuento	Número	Descuento registrado.	Confirmar si expresa MXN o porcentaje antes de operar con él.
Tasa	Número	Campo de tasa del reporte.	Definición y unidad pendientes; no asumir importe de impuesto.
Envío	Número monetario	Cargo de envío registrado.	Confirmar inclusión en Importe; no duplicar cargos.
Importe	Número monetario	Importe registrado de la venta.	Candidato para agregado nominal semanal; validar concepto, moneda, ceros y estados.
Ganancia	Número	Campo de ganancia registrado.	Cálculo pendiente de verificación; no equivale a utilidad neta demostrada ni es objetivo del estudio.
Nombre	Texto	Nombre asociado al registro.	Rol pendiente de confirmar; dato potencialmente personal, excluido de predictores.
Vendedor	Texto categoría o	Responsable o canal consignado.	Dato administrativo; excluir identificadores personales del modelado.

Campo exacto	Tipo esperado	Definición	Uso y validación
Observación	Texto	Notas de la transacción.	Puede contener datos personales; no publicar valores ni usar como predictor inicial.
Fecha	Fecha	Fecha consignada sin hora.	Normalizar y contrastar con Fecha/Hora; definir fecha válida para agregación.
Año	Entero	Año consignado.	Contrastar con la fecha validada; preferir derivación consistente.
Mes	Entero	Mes consignado.	Valores esperados 1 a 12; contrastar con la fecha.
Día	Entero	Día del mes consignado.	Validar según mes y año.
Pastel	Indicador	Indicador de categoría pastel.	Se observaron 0, 1 y texto null; verificar codificación. No convertir null en 0.
Galletas	Indicador	Indicador de categoría galletas.	Se observaron 0, 1 y texto null; no prueba cantidades vendidas.
Otros	Indicador	Indicador de otros productos de venta.	No confundir con otros de la composición de compras; revisar null.
Cupcakes	Indicador	Indicador de categoría cupcakes.	Se observaron 0, 1 y texto null; verificar codificación.
Pedido	Texto	Referencia interna del pedido.	Contiene tipos mixtos; conservar como identificador y verificar relación con Number.
NumPedido	Texto	Número o referencia del pedido.	Comprobar relación con Pedido y Number; la unicidad no está garantizada.

7.1.1.3 Campos de origen de compras

Campo exacto	Tipo esperado	Definición	Uso y validación
PROVEEDOR	Texto	Proveedor consignado en la compra.	Control administrativo; no es predictor inicial.

Campo exacto	Tipo esperado	Definición	Uso y validación
FECHA	Fecha	Fecha registrada de adquisición.	Se homologa a fecha; fecha inválida genera incidencia.
NUMERO	Texto	Número consignado en el registro.	Significado y unicidad pendientes; no se presume clave única.
CANT	Número	Cantidad registrada de adquisición.	Interpretar junto con U#MEDIDA; no es variable objetivo.
U#MEDIDA	Texto o categoría	Unidad de medida registrada.	Homologación pendiente; no sumar cantidades de unidades diferentes.
DESCRIPCION	Texto	Descripción de lo adquirido.	Se homologa a descripcion y descripcion_normalizada; requiere catálogo aprobado.
MONTO	Número monetario	Importe registrado de la adquisición.	Se homologa a importe_nominal en MXN; verificar ceros, moneda y alcance. No asumir CANT por P#UNITARIO sin conciliación.
P#UNITARIO	Número monetario	Precio unitario registrado.	MXN por unidad consignada; definición y consistencia pendientes de revisión.
CLASIFICACION	Categoría	Clasificación de origen.	No sustituye automáticamente al insumo_id aprobado.
SUBCLASIFICACION	Categoría	Subclasificación de origen.	Homologar significado; uso auxiliar para revisar el catálogo.

7.1.1.4 Variables analíticas y controles del pipeline

Esta sección documenta contratos del código, no la aprobación de fuentes ni su incorporación efectiva. Los nombres entre signos angulares representan columnas dinámicas; los nombres agrupados identifican campos con la misma regla. Las participaciones se almacenan como proporciones y sus errores se reportan en puntos porcentuales. La inferencia futura no requiere importes observados de las semanas objetivo.

Campo o familia	Tipo y unidad	Origen o regla	Uso y disponibilidad
fecha	Fecha	FECHA de compras normalizada al día.	Clave temporal; solo registros previos al origen alimentan características.
importe_nominal	Número en MXN	MONTO homologado en compras; importe semanal en contrato de ventas.	Objetivo monetario o predictor según tabla; inválidos no se sustituyen por cero.
descripcion	Texto	DESCRIPCION homologada.	Base del catálogo, no una categoría aprobada por sí misma.
descripcion_normalizada	Texto	Descripción normalizada mediante clean_upper.	Clave de enlace con catálogo; descripción vacía genera incidencia.
registro_id	Entero	Número de fila de origen contado desde 2.	Trazabilidad dentro del archivo y su hash; no identificador universal.
motivo	Texto	Resultado de revisión del registro.	Vacío significa sin incidencia detectada; no prueba cobertura completa.
semana_inicio	Fecha	Lunes de la semana de lunes a domingo.	Clave semanal; agregación después de aprobar cobertura.
insumo_id	Texto	Identificador asignado por catálogo aprobado.	No admite vacío ni nombres reservados total u otros.
aprobado	Booleano	Aprobación de la correspondencia de catálogo.	El código admite true o 1; requiere decisión documentada.
estado	Categoría	Condición de cobertura semanal.	observada o cero_confirmado para datos reales; desconocida o incompleta bloquean el intervalo. Ver nota de procedencia.
evidencia	Texto	Sustento de la revisión de cobertura.	Obligatorio; debe justificar la clasificación semanal.
fecha_revision	Fecha	Fecha de revisión de cobertura.	Obligatoria; no equivale a available_at de un predictor.

Campo o familia	Tipo y unidad	Origen o regla	Uso y disponibilidad
registros_detectados	Entero	Conteo de filas por semana en plantilla.	Cero no confirma ausencia de compras; no establece cobertura.
total	Número en MXN	Suma de importes semanales por insumo.	Objetivo monetario nominal; cero solo interpretable con cobertura validada.
<insumo_id>	Número en MXN	Columnas dinámicas del panel, una por insumo.	Importe semanal agregado; nombres determinados por catálogo, no columnas literales fijas.
otros	MXN o proporción	Residual de insumos no seleccionados, según matriz.	No confundir con Otros de ventas; distinguir matriz de importes de matriz de participaciones.
Participación por insumo	Proporción de 0 a 1	Importe del insumo dividido entre total positivo.	Matriz con columnas por insumo; total cero implica no definido. Multiplicar por 100 solo para porcentaje.
lag_1, lag_2, lag_4, lag_8, lag_12	Número en MXN	Totales de semanas previas al origen.	Predictores; sufijo indica distancia semanal. No usar valores objetivo futuros.
media_4, media_8, media_12	Número en MXN	Media de las últimas semanas cerradas.	Ventana indicada por sufijo; requiere historia anterior al origen.
desv_4, desv_8, desv_12	Número en MXN	Desviación estándar muestral de las semanas previas.	Mismas ventanas que las medias; un solo dato no define dispersión muestral.
cal_sin, cal_cos	Número de -1 a 1	Codificación cíclica de semana objetivo.	Calendario conocido; periodo del código 52.1775 semanas.
ventas_lag_1, ventas_lag_4	Número en MXN	Importe semanal de ventas rezagado.	Opcional; solo si available_at no es posterior al origen; de otro modo faltante.
available_at	Fecha y hora	Momento de disponibilidad de ventas o exógenas.	Debe ser anterior o igual al origen. Ventas semanales: no antes del cierre.
variable	Texto	Nombre de variable exógena.	Obligatorio en contrato opcional; no implica fuente incorporada.

Campo o familia	Tipo y unidad	Origen o regla	Uso y disponibilidad
fecha_referencia	Fecha	Periodo al que corresponde una exógena.	No confundir con fecha de publicación o disponibilidad.
valor	Número	Valor de variable exógena.	Finito; unidad específica a documentar por variable antes de incorporarla.
fuelle, version	Texto	Procedencia y versión de la exógena.	Obligatorias; permiten controlar revisiones de datos.
tipo	Categoría	observada, pronostico o calendario.	Una observación futura no se etiqueta como disponible; pronósticos requieren archivo previo.
exog_<variable>	Número	Valor exógeno admisible en el origen.	Pronóstico o calendario para la fecha objetivo; en su defecto última observación previa; ausente queda faltante.
es_sintetico	Booleano	Indicador de procedencia sintética.	Control, nunca resultado real; la existencia del campo no autoriza usar esos datos.
metodo_sintesis	Texto	Método declarado de generación sintética.	Metadato condicional del código; exige aprobación separada y no acredita observación real.

Nota de procedencia. El código inspeccionado contempla de manera condicional el estado sintetica_entrenamiento y campos de síntesis sujetos a aprobación y corte temporal. Su descripción no aprueba ni incorpora datos sintéticos al estudio. Esas observaciones no deben etiquetarse como reales ni utilizarse como evidencia de evaluación; cualquier diferencia entre el código y el protocolo científico deberá resolverse antes de la corrida definitiva.

Fuente. Elaboración propia a partir de los encabezados de datasets/xlsx/Ventas.xlsx y datasets/xlsx/Compras.xlsx, de los módulos data.py, features.py y composition.py del pipeline y de la información histórica proporcionada sobre Cup&Cake. Las equivalencias semánticas y unidades marcadas como pendientes requieren revisión de la documentación de origen antes de aprobar el conjunto analítico.