



**MODELO HÍBRIDO ESTADÍSTICO Y DE APRENDIZAJE AUTOMÁTICO PARA EL
PRONÓSTICO Y LA DISTRIBUCIÓN DEL PRESUPUESTO SEMANAL DE
ABASTECIMIENTO: ESTUDIO DE CASO EN UNA MICROEMPRESA DE REPOSTERÍA
CREATIVA EN TIZAYUCA, HIDALGO**

**TESIS PARA OBTENER EL GRADO DE MAESTRO EN
INTELIGENCIA ARTIFICIAL**

PRESENTADA POR:

RODRIGO ADRIÁN MARTÍNEZ FLORES

DIRECTOR DE TESIS:

LUIS EDUARDO URBAN RIVERO

Tolcayuca, Hidalgo. 28, agosto 2025.

DEDICATORIA

A mi amada esposa, mi compañera de vida, mi mejor complemento, quien me ha impulsado para alcanzar cada nuevo reto.

A mis hijos que han sido inspiración avanzar en mi formación académica y que con su espontaneidad han llenado mi vida de entusiasmo por seguir adelante.

A mis padres que siempre me han apoyado.

AGRADECIMIENTOS

A la Universidad Politécnica Metropolitana de Hidalgo

ÍNDICE

Contenido

RESUMEN	12
ABSTRACT	1
1. INTRODUCCIÓN.....	2
1.1 Estado del Arte	4
1.1.1 Aplicaciones de la inteligencia artificial en la cadena de suministro	4
1.1.2 Modelos de aprendizaje automático para el pronóstico de demanda.....	5
1.1.3 Demanda intermitente, Small Data y comparación de modelos	5
1.1.4 La repostería creativa como sector económico especializado	7
1.1.5 Innovación y transformación digital en la industria pastelera	8
1.1.6 Adopción de inteligencia artificial en microempresas	9
1.1.7 Investigaciones en México y América Latina.....	9
1.1.8 Síntesis del estado del arte y vacío de investigación	13
1.2 El planteamiento del problema	14
1.2.1 Contexto del caso de estudio	16
1.2.2 Pregunta de Investigación	17
1.2.3 Objetivo	17
1.3 Justificación	18

1.4	Hipótesis.....	20
2	MARCO TEÓRICO	21
2.1	Microempresa y planeación del presupuesto de abastecimiento	21
2.1.1	Recursos de información y conocimiento del negocio.....	21
2.1.2	Pronóstico como información para decidir.....	22
2.2	Compras monetarias y contexto de la repostería	22
2.2.1	Delimitación de la variable objetivo	22
2.2.2	Agregación del importe y niveles de análisis.....	23
2.3	Series temporales semanales y calidad de los registros	23
2.3.1	Frecuencia y continuidad.....	23
2.3.2	Nivel tendencia y estacionalidad	24
2.3.3	Estacionariedad y dependencia temporal	24
2.3.4	Intermitencia y valores extremos.....	25
2.4	Métodos estadísticos y de aprendizaje automático	26
2.4.1	Referencias simples	26
2.4.2	Suavizamiento exponencial y ARIMA.....	26
2.4.3	Bosques aleatorios y potenciación de gradiente	27
2.4.4	Redes neuronales y alcance de los comparadores.....	28
2.5	Fundamentos de integración del modelo híbrido.....	28

2.5.1	Combinación de pronósticos	28
2.5.2	Integración mediante componentes	29
2.6	Distribución porcentual y coherencia de las asignaciones	30
2.6.1	Participaciones como datos composicionales	30
2.6.2	Desagregación del pronóstico total	31
2.6.3	Representación relativa de las participaciones	31
2.7	Datos limitados e ingeniería de características	32
2.7.1	Complejidad y capacidad de generalización	32
2.7.2	Penalizaciones y selección de variables	32
2.7.3	Predictores temporales y calendario	33
2.7.4	Disponibilidad de variables exógenas	34
2.8	Evaluación temporal y métricas de precisión	34
2.8.1	Origen del pronóstico y ventana de entrenamiento	34
2.8.2	Error monetario del importe total	35
2.8.3	Escalamiento y límites de errores porcentuales	35
2.8.4	Error de participaciones y evaluación conjunta	36
2.9	Inteligencia de negocios y comunicación del pronóstico	37
2.9.1	Presentación del presupuesto y su incertidumbre	37
2.9.2	Adopción y límites operativos	37

2.10	Síntesis de fundamentos y relación con la hipótesis	38
3	METODOLOGÍA	39
3.1	Tipo de investigación según el objetivo de ésta	39
3.2	Según el alcance evaluativo del estudio.....	40
3.3	Según el tipo de datos empleados	41
3.4	Según el grado de manipulación de las variables	42
3.5	Diseño evaluativo y comparación contra la línea base	43
3.6	Según el tipo de inferencia	43
3.7	Temporalidad de la investigación	44
3.8	Procedimiento Metodológico	45
3.8.1	Recolección y estructuración de los conjuntos de datos (<i>Datasets</i>).....	45
	Análisis exploratorio de la serie temporal semanal.....	¡Error! Marcador no definido.
3.8.2	Ingeniería de características y variables exógenas	¡Error! Marcador no definido.
3.8.3	Selección y configuración de modelos predictivos	¡Error! Marcador no definido.
3.8.4	Estrategias de partición temporal y validación	¡Error! Marcador no definido.
3.8.5	Métricas de evaluación del desempeño	¡Error! Marcador no definido.
3.8.6	Integración en Inteligencia de Negocios y comunicación del presupuesto de abastecimiento	¡Error! Marcador no definido.
4	DESARROLLO	51

- 4.1 Antecedentes del negocio ¡Error! Marcador no definido.
- 4.1.1 El registro de ventas y compras de insumos ¡Error! Marcador no definido.
- 4.1.2 Antecedentes de los conjuntos de datos existentes¡Error! Marcador no definido.
- 4.1.3 Antecedentes de conjuntos de datos de variables exógenas temporales y comerciales ¡Error! Marcador no definido.
- 4.2 Antecedentes de el proceso de construcción del dataset maestro¡Error! Marcador no definido.
- 4.2.1 Análisis Exploratorio de Datos (EDA) ¡Error! Marcador no definido.
- 4.2.2 Ingeniería de Características (Feature Engineering)¡Error! Marcador no definido.
- Antecedentes de análisis exploratorio de la serie temporal semanal¡Error! Marcador no definido.
- Auditoría de cobertura y selección del bloque continuo..... ¡Error! Marcador no definido.
- Estructura temporal, estacionariedad y dependencia serial¡Error! Marcador no definido.
- Intermitencia, variabilidad y valores atípicos ¡Error! Marcador no definido.
- Implicaciones para los modelos de Inteligencia Artificial ... ¡Error! Marcador no definido.
- 4.3 Antecedentes de diagnóstico de la línea base empírica y evaluación comparativa ¡Error! Marcador no definido.
- 4.4 Estado de la implementación del pipeline híbrido..... ¡Error! Marcador no definido.
- 4.5 Antecedentes del repositorio y de la preparación de datos¡Error! Marcador no definido.

4.6	Antecedentes de auditoría, Depuración e Integración del Conjunto de Datos (Dataset)	
	¡Error! Marcador no definido.	
4.7	Antecedentes de ingeniería de Características (Feature Engineering) y Variables Exógenas	¡Error! Marcador no definido.
4.8	Antecedentes de desarrollo, Configuración y Entrenamiento de los Modelos Predictivos.....	¡Error! Marcador no definido.
4.9	Antecedentes de evaluación comparativa del rendimiento predictivo frente a la línea base	¡Error! Marcador no definido.
4.10	Antecedentes de arquitectura e Integración del Tablero de Inteligencia de Negocios (DSS)	¡Error! Marcador no definido.
	Arquitectura tecnológica	¡Error! Marcador no definido.
	Integración de los resultados predictivos.....	¡Error! Marcador no definido.
	Filtros e indicadores para la decisión.....	¡Error! Marcador no definido.
	Resultados incorporados al DSS	¡Error! Marcador no definido.
	Interpretación operativa y salvaguardas	¡Error! Marcador no definido.
	Alcance actual de la integración	¡Error! Marcador no definido.
4.11	Alcance del apoyo al presupuesto de abastecimiento	¡Error! Marcador no definido.
5	RESULTADOS	63
	Calidad, cobertura e integración de datos.....	¡Error! Marcador no definido.
	Reducción dimensional	¡Error! Marcador no definido.
	Rendimiento comparativo de los modelos.....	¡Error! Marcador no definido.

Resultados de redes neuronales recurrentes.....	¡Error! Marcador no definido.
Contraste de hipótesis.....	¡Error! Marcador no definido.
Resultados del tablero DSS	¡Error! Marcador no definido.
6 DISCUSION.....	69
Interpretación de los hallazgos.....	¡Error! Marcador no definido.
Demanda intermitente y selección de métricas.....	70
Implicaciones operativas y financieras	70
Validez y limitaciones	71
7 CONCLUSIONES	73
Recomendaciones.....	74
Trabajo futuro	74
GLOSARIO	76
REFERENCIAS	77
Anexo A Diccionario de datos.....	87

TABLAS, IMÁGENES Y ECUACIONES

Tabla 1 - Estudios citados en el estado del arte y relación con la presente investigación

[\(1\)](#) ¡Error! Marcador no definido.

[\(2\)](#) ¡Error! Marcador no definido.

[\(3\)](#) ¡Error! Marcador no definido.

[\(4\)](#) ¡Error! Marcador no definido.

[Imagen 1 - Repositorio github](#) ¡Error! Marcador no definido.

[Tabla 2 - Conjuntos de datos de Ventas y Compras](#) ¡Error! Marcador no definido.

[Tabla 3 - Conjunto de datos de variables exógenas \(Contexto Tizayuca, Hgo.\)](#) ¡Error! Marcador no definido.

[Tabla 4 - Inflación histórica en México \(INPC\)](#) ¡Error! Marcador no definido.

[Imagen 2 - Temperatura Media por Entidad Federativa y Nacional, contenido en PDF](#) .. ¡Error! Marcador no definido.

[Tabla 5 - Temperatura mensual \(Tizayuca, Hgo.\)](#) ¡Error! Marcador no definido.

[Figura 27 - Trazabilidad del pipeline analítico de la investigación.](#) ¡Error! Marcador no definido.

[Tabla 6 - Síntesis de fuentes de datos y transformaciones aplicadas](#) ¡Error! Marcador no definido.

[Tabla 7 - Operacionalización de la línea base y la posprueba.](#) ¡Error! Marcador no definido.

[Tabla 8 - Trazabilidad de los conjuntos analíticos](#) ¡Error! Marcador no definido.

[Figura 24 - Expansión dimensional producida por la ingeniería de características.](#)¡Error!
Marcador no definido.

[Tabla 9 - Dimensiones principales de las variables modeladas](#) ¡Error! **Marcador no definido.**

[Figura 25 - Arquitecturas recurrentes consideradas para el modelado temporal](#).....¡Error!
Marcador no definido.

[Tabla 10 - Familias de modelos y configuración evaluada](#) ¡Error! **Marcador no definido.**

[Figura 26 - Esquema de validación temporal Rolling-Origin.](#).... ¡Error! **Marcador no definido.**

[Figura 28 - Arquitectura funcional del sistema de soporte a la decisión.](#)¡Error! **Marcador no definido.**

[Figura 29 - Interfaz funcional del tablero DSS implementado para Cup&Cake.](#)¡Error!
Marcador no definido.

[Figura 30 - Flujo de decisión operativa asistido por el DSS.](#)..... ¡Error! **Marcador no definido.**

[Figura 31 - Mejora relativa del RMSE frente a la línea base empírica.](#)¡Error! **Marcador no definido.**

[Figura 32 - Mejor modelo por objetivo y representación de datos.](#)¡Error! **Marcador no definido.**

[Tabla 11 - Modelos ganadores y desempeño temporal](#) ¡Error! **Marcador no definido.**

RESUMEN

Esta investigación se propone desarrollar un modelo híbrido que integre métodos estadísticos y de aprendizaje automático para estimar el importe total semanal de compras y su distribución porcentual entre los principales insumos de Cup&Cake, una microempresa de repostería creativa ubicada en Tizayuca, Hidalgo. El problema de estudio se enmarca en la planeación del presupuesto de abastecimiento bajo condiciones de datos limitados y variación temporal. Se consideran registros históricos de compras y ventas, junto con variables calendáricas y exógenas que estén disponibles en el momento de emitir cada pronóstico. El importe objetivo se delimita a las categorías presupuestarias elegibles; categorías fuera del alcance, como combustible, muebles, herramienta, imputados y otros, no forman parte del objetivo.

La evaluación se plantea mediante validación temporal rolling-origin, con una ventana de entrenamiento de 52 semanas, avance de tres semanas, un bloque final de 20 semanas para evaluación y horizontes de pronóstico de una a cuatro semanas. El desempeño del modelo híbrido se contrastará con modelos de referencia usando métricas de error monetario; la distribución porcentual se evaluará con métricas de error de participación. El diseño busca determinar la precisión que puede ofrecer el procedimiento en este caso y aportar evidencia para valorar su posible uso como apoyo a la planeación, sin presuponer que la integración híbrida mejore el desempeño ni que sustituya la decisión de la persona responsable.

Palabras clave: pronóstico de compras, presupuesto de abastecimiento, microempresa, series temporales, modelo híbrido, validación temporal.

ABSTRACT

This study proposes the development of a hybrid model combining statistical methods and machine learning to estimate the total weekly purchasing amount and its percentage allocation among the main inputs of Cup&Cake, a creative baking microenterprise in Tizayuca, Hidalgo, Mexico. The research addresses procurement-budget planning under limited-data and time-varying conditions. It considers historical purchasing and sales records, together with calendar and exogenous variables that are available when each forecast is issued. The monetary target is restricted to eligible budget categories; out-of-scope items, including fuel, furniture, tools, imputed categories, and others, are excluded.

The proposed evaluation uses rolling-origin temporal validation, a 52-week training window, a three-week step, a final 20-week evaluation block, and forecast horizons of one to four weeks. The hybrid model is to be compared with reference models using monetary error metrics, while the percentage allocation is to be assessed with share-error metrics. The design aims to determine the accuracy attainable in this case and provide evidence for assessing the method as a possible aid to procurement planning. It does not presuppose that hybrid integration improves forecast performance or replaces the decision-maker.

Keywords: purchasing forecast, procurement budget, microenterprise, time series, hybrid model, temporal validation.

1.INTRODUCCIÓN

Un emprendimiento surge a partir de una idea que resuelve alguna necesidad básica o simplemente permite hacer más sencilla la vida de otras personas ofreciendo productos y/o servicios útiles para alguna comunidad. Suele ser una alternativa para situaciones complejas como la pérdida de empleo o con la intención de generar una utilidad que sirva para mejorar la calidad de vida familiar. El Global Entrepreneurship Monitor (**GEM, 2023**) indica que los emprendimientos contribuyen al bienestar económico y social, generando ingresos y mejorando la calidad de vida tanto de los emprendedores como de sus comunidades.

Los emprendimientos o microempresas enfrentan importantes desafíos dado que en la mayoría de los casos surgen sin una adecuada planeación. Minniti y Bygrave (2018) explican que el proceso emprendedor es dinámico y se basa en el aprendizaje continuo derivado de la interacción con el entorno y la toma de decisiones bajo incertidumbre. Asimismo, Ries (2017), desde la perspectiva del *lean startup*, sostiene que muchos emprendimientos comienzan con supuestos no validados y van ajustando su modelo de negocio mediante prueba y error. El emprendedor va generando experiencia sobre el negocio a partir del conocimiento de su entorno y del mercado.

La Organización para la Cooperación y el Desarrollo Económicos (**OCDE, 2021**) señala que las pequeñas empresas enfrentan restricciones de información y capacidades, lo que dificulta prever la demanda y optimizar la gestión de inventarios. La compra de materia prima se realiza con cautela sin tener certeza de si se logrará vender los productos que se elaboran, en muchos casos el mismo crecimiento orgánico provoca un caos y desperdicio de materia prima y recursos que limitan el crecimiento, todo este aprendizaje se obtiene generalmente de manera empírica conforme va evolucionando el negocio y aumentando las ventas. Kantis, Federico y García (2020) indican que la falta de capacidades de gestión en etapas tempranas puede provocar problemas en la organización interna, uso ineficiente de recursos y limitaciones para escalar el negocio.

Cuando se observa que el producto o servicio ofrecido recibe una aceptación del mercado se presentan nuevos retos, principalmente la alta variabilidad de la demanda, el reto de predecir la compra de materia prima o la creación de planes de crecimiento del negocio que lo lleven hacia un nuevo nivel y participación del mercado, lo anterior genera incertidumbre y poca claridad para el emprendedor. El **Banco Interamericano de Desarrollo (BID, 2019)** destaca que los emprendedores en contextos latinoamericanos suelen aprender haciendo, lo que implica un proceso de mejora progresiva, aunque con costos asociados como errores, desperdicio y baja productividad inicial.

Las microempresas representan el núcleo del aparato productivo en México y América Latina. De acuerdo con el Instituto Nacional de Estadística y Geografía (INEGI), en México existen más de 4.9 millones de micro, pequeñas y medianas empresas, de las cuales el 95% corresponde a microempresas, generando aproximadamente el 41.8% del empleo nacional (INEGI, 2023). A pesar de su relevancia económica y social, estas organizaciones enfrentan serias limitaciones estructurales, particularmente en materia de planeación financiera, gestión de inventarios y administración de la cadena de suministro.

Uno de los principales retos que enfrentan las microempresas es la escasa adopción de tecnologías avanzadas para la toma de decisiones. Según la OCDE (OCDE, 2022), menos del 25% de las microempresas en países en desarrollo utilizan herramientas analíticas avanzadas, lo que implica que la mayoría de ellas basa sus decisiones estratégicas en la experiencia empírica del propietario, en promedios históricos simples o en la intuición. Este enfoque incrementa la incertidumbre financiera, dificulta la previsión de ingresos y eleva el riesgo de sobre inventarios o desabasto, especialmente en sectores con alta variabilidad de la demanda. En el sector alimentario y de productos perecederos, como la repostería, estos desafíos se intensifican.

Una planificación inadecuada de la demanda en el sector de panadería puede generar niveles significativos de merma, con tasas de devolución que oscilan entre el 1.5% y el 19%, lo cual tiene implicaciones económicas y operativas relevantes para las empresas del sector (Hübner et al., 2024). Asimismo, la falta de pronósticos confiables limita la capacidad de las

microempresas para diseñar estrategias de crecimiento, expandirse a nuevos mercados o realizar inversiones con menor riesgo financiero.(Makridakis et al., 2018b; Spiliotis et al., 2025)(Cao et al., 2025)

La literatura reciente muestra que los modelos de aprendizaje automático pueden capturar relaciones no lineales, estacionalidad y variables externas; sin embargo, su desempeño frente a los métodos estadísticos depende de las características de la serie, la disponibilidad de datos, el horizonte de pronóstico y el protocolo de evaluación (Makridakis et al., 2018b; Spiliotis et al., 2022).

Frente a este escenario, el aprendizaje automático (ML por sus siglas en inglés, Machine Learning) como rama de la Inteligencia Artificial ha emergido como herramienta clave para transformar la planeación financiera y la gestión de la cadena de suministro.

1.1 Estado del Arte

1.1.1 Aplicaciones de la inteligencia artificial en la cadena de suministro

El uso de la inteligencia artificial (IA) en la cadena de suministro ha demostrado ser una herramienta eficaz para mejorar la eficiencia operativa y la toma de decisiones, especialmente en industrias con productos perecederos. Distintos estudios han explorado su aplicación desde enfoques variados, ofreciendo evidencia empírica, conceptual y técnica que fundamenta su utilidad en contextos empresariales.

Uno de los estudios más relevantes es el de **Hübner et al. (2024)**, quienes analizaron la implementación de un sistema de aprendizaje automático en la nube denominado *Foodforecast* en panaderías de Berlín, Alemania. **El objetivo del estudio fue evaluar el impacto del uso de modelos predictivos en la reducción del desperdicio de alimentos**. La investigación adoptó un enfoque cuantitativo basado en datos históricos de ventas y producción, **utilizando modelos de aprendizaje automático para pronosticar la demanda diaria de productos**. Los resultados mostraron una **reducción significativa del desperdicio alimentario y una mejora en la precisión de los pronósticos de demanda**. El principal aporte radica en demostrar que los

sistemas de predicción basados en inteligencia artificial pueden contribuir a mejorar la eficiencia operativa y la sostenibilidad en industrias con productos perecederos.

Sin embargo, el modelo *Foodforecast* presenta como limitación el hecho de que fue desarrollado en organizaciones con infraestructura tecnológica avanzada, lo cual dificulta la extrapolación de sus resultados a microempresas con recursos limitados.

1.1.2 Modelos de aprendizaje automático para el pronóstico de demanda

Huber y Stuckenschmidt (2020) desarrollaron un estudio orientado al pronóstico diario de ventas en el sector minorista, utilizando algoritmos de aprendizaje automático capaces de incorporar variables calendáricas y eventos especiales. La metodología consistió en comparar distintos modelos predictivos utilizando datos históricos de ventas de una cadena comercial. Los resultados evidenciaron que los modelos de aprendizaje automático lograron mejorar la precisión de los pronósticos, especialmente en periodos asociados a eventos especiales o festividades.

En la literatura reciente también se observa un creciente interés por el desarrollo de modelos híbridos y técnicas avanzadas de predicción. Un ejemplo de ello es el estudio de Abrar et al. (2024) quienes propusieron un modelo híbrido denominado *Multi-Channel Data Fusion Network (MCDFN)* para el pronóstico de la demanda en cadenas de suministro. Este modelo integra redes neuronales convolucionales, redes LSTM y mecanismos de interpretabilidad basados en inteligencia artificial explicable (XAI). Los resultados del estudio evidencian una mejora significativa en la precisión de los pronósticos.

1.1.3 Demanda intermitente, Small Data y comparación de modelos

Los registros diarios de ventas y compras en negocios de pequeña escala pueden contener numerosos periodos sin movimiento y picos asociados a pedidos extraordinarios o fechas comerciales. Al agregarlos semanalmente, la serie puede reducir su intermitencia y ofrecer una unidad más congruente con la planeación de corto plazo; sin embargo, disminuye el número de observaciones disponibles. Por ello, los modelos de aprendizaje automático deben

compararse con métodos estadísticos establecidos y no asumirse superiores por su mayor complejidad (**Spiliotis et al., 2022**).

La competencia M4 ofrece evidencia comparativa a gran escala: reunió 100 000 series y evaluó 61 métodos (Makridakis et al., 2020). En el análisis inicial, 12 de los 17 métodos mejor posicionados fueron combinaciones, y el de mayor precisión integró elementos estadísticos y de aprendizaje automático; su sMAPE medio fue cercano a 10 % mejor que el benchmark de combinación. Los seis métodos exclusivamente de aprendizaje automático no superaron ese benchmark (Makridakis et al., 2018a). Estos resultados justifican evaluar combinaciones, pero no establecen su superioridad para compras semanales de una microempresa, pues la M4 incluye series de distintos dominios y frecuencias. De manera consistente, Hewamalage et al. (2021) advierten que las redes neuronales recurrentes no son soluciones universales, especialmente con series individuales cortas o heterogéneas.

La revisión de **Giannopoulos et al. (2025)** confirma que la demanda intermitente requiere atención explícita al diseño de características, la partición temporal, el ajuste de hiperparámetros y las métricas de evaluación. Esta literatura sustenta que, en un contexto de Small Data, una validación Rolling-Window y la comparación con líneas base reproducibles son más pertinentes que inferir superioridad a partir de un único modelo o una única partición.

Análisis de series temporales para demanda errática y Small Data

El pronóstico constituye una fase posterior a la caracterización de la serie. Antes de comparar algoritmos es necesario examinar la continuidad de la cobertura, la frecuencia de observación, la proporción de ceros, la tendencia, la autocorrelación y la estabilidad de los patrones estacionales. En Small Data, estos diagnósticos permiten limitar la complejidad del modelo y evitar que una arquitectura de inteligencia artificial aprenda discontinuidades producidas por ausencia de registro como si fueran comportamiento económico real (**Hyndman & Athanasopoulos, 2021**).

En series con semanas sin movimiento, el intervalo promedio entre ocurrencias (ADI) y el cuadrado del coeficiente de variación de los importes positivos (CV^2) permiten distinguir

comportamientos suaves, intermitentes, erráticos e irregulares. Esta clasificación no determina por sí sola el modelo ganador, pero fundamenta la inclusión de métodos especializados como Croston-SBA y TSB, así como transformaciones logarítmicas y modelos de dos etapas (Syntetos & Boylan, 2005).

El análisis temporal también debe separar la descripción retrospectiva de la selección predictiva. Las gráficas pueden mostrar toda la cobertura para fines de auditoría; sin embargo, las pruebas de estacionariedad, autocorrelación y selección de características que influyen en la configuración del modelo deben calcularse sin observar el bloque final de evaluación. Esta separación preserva el carácter fuera de muestra de la comparación entre métodos estadísticos y aprendizaje.

1.1.4 La repostería creativa como sector económico especializado

La industria de la repostería ha experimentado una evolución significativa durante las últimas décadas, pasando de modelos tradicionales de producción a esquemas altamente personalizados orientados a nichos específicos de mercado. Dentro de esta evolución destaca la denominada repostería creativa o *cake design*, caracterizada por la elaboración de productos personalizados para celebraciones, eventos sociales y ocasiones especiales. Esta transformación ha permitido que los productos de repostería trasciendan su función alimentaria para incorporar componentes estéticos, simbólicos y experienciales que agregan valor a la oferta comercial (Borsato, 2023).

La repostería contemporánea combina elementos gastronómicos, artísticos y comerciales, donde la diferenciación mediante el diseño, la personalización y la experiencia del cliente constituyen factores clave para la competitividad empresarial. En este contexto, la creatividad se ha convertido en un recurso estratégico para los profesionales de la pastelería, integrando conocimientos técnicos, innovación estética y comprensión de las preferencias del consumidor (Ab Karim et al., 2020). Asimismo, la innovación en productos representa uno de los principales factores que contribuyen al desempeño y posicionamiento competitivo de las empresas del sector pastelero (Ben Abdallah et al., 2022).

A diferencia de la panadería tradicional, en la repostería creativa la demanda en este tipo de negocios suele presentar una mayor variabilidad debido a factores estacionales, eventos sociales y preferencias particulares de los consumidores. Esta dinámica genera desafíos importantes para la planeación de la producción, la gestión de inventarios y la estimación de ingresos, especialmente en microempresas que operan con recursos limitados y productos altamente perecederos. En consecuencia, la capacidad para anticipar cambios en la demanda y optimizar la toma de decisiones se ha convertido en un factor crítico para la sostenibilidad y competitividad de este tipo de organizaciones.

1.1.5 Innovación y transformación digital en la industria pastelera

La innovación tecnológica ha adquirido un papel relevante dentro de la industria alimentaria y, particularmente, en los sectores de panadería y repostería. La incorporación de herramientas digitales para la gestión de pedidos, control de inventarios, planificación de la producción y análisis de datos ha permitido mejorar la eficiencia operativa y la capacidad de respuesta ante cambios en la demanda. Mikalef et al. (2019) y Dubey et al. (2021) señalan en sus artículos que la digitalización de procesos facilita la optimización de recursos, incrementa la productividad y fortalece la capacidad de adaptación de las organizaciones ante entornos cada vez más dinámicos.

Hübner et al. (2024) demostraron que la implementación de modelos de aprendizaje automático para el pronóstico de la demanda en panaderías permitió disminuir significativamente el desperdicio alimentario y mejorar la planificación de la producción. De manera complementaria, estudios recientes sobre la digitalización del sector panadero destacan que las tecnologías asociadas a la Industria 4.0 facilitan la integración de datos operativos, la automatización de procesos y la mejora continua en la gestión de la cadena de suministro (Aprodu et al., 2025).

No obstante, gran parte de estas innovaciones han sido implementadas en organizaciones medianas y grandes que cuentan con infraestructura tecnológica avanzada y capacidades analíticas consolidadas. En contraste, existe una limitada evidencia sobre la aplicación de

estas herramientas en microempresas dedicadas a la repostería creativa, donde las restricciones financieras, tecnológicas y de personal especializado continúan representando barreras importantes para la adopción de tecnologías basadas en datos (Alekseeva et al., 2021).

1.1.6 Adopción de inteligencia artificial en microempresas

Diversos estudios han analizado los factores que influyen en la adopción de tecnologías basadas en inteligencia artificial dentro de pequeñas y medianas empresas.

Alekseeva, Ginevičius y Stankevičienė (2021) identifican que las principales barreras para la adopción de inteligencia artificial en PYMES están relacionadas con la falta de recursos financieros, infraestructura tecnológica limitada y escasez de capital humano especializado.

De manera similar, Mikalef et al. (2019) señalan que la capacidad de las organizaciones para aprovechar el potencial del análisis de datos depende en gran medida de sus capacidades analíticas y de su orientación hacia la innovación tecnológica.

Por otra parte, Dubey et al. (2021) destacan que la integración de analítica avanzada y herramientas de inteligencia artificial contribuye significativamente al desempeño operativo de las organizaciones cuando se combina con capacidades dinámicas y estrategias de innovación.

1.1.7 Investigaciones en México y América Latina

En el contexto mexicano, diversos estudios han analizado el impacto de la adopción tecnológica y la digitalización en el desempeño de las pequeñas y medianas empresas.

Por ejemplo, Maldonado-Guzmán, Pinzón-Castro y García-Pérez-de-Lema (2018) analizaron la relación entre innovación tecnológica y desempeño empresarial en PYMES mexicanas, encontrando que las empresas que adoptan tecnologías digitales presentan mayores niveles de competitividad y eficiencia organizacional.

De manera similar, **Cuevas-Vargas, Estrada y Larios-Gómez (2016)** examinaron el efecto de la adopción de tecnologías de información y comunicación en pequeñas y medianas empresas mexicanas. Sus resultados indican que la digitalización de procesos y el uso de herramientas analíticas contribuyen significativamente a mejorar el desempeño organizacional.

En la misma línea, **Maldonado-Guzmán y Garza-Reyes (2020)** analizaron los procesos de transformación digital en PYMES mexicanas, concluyendo que la incorporación de tecnologías basadas en datos permite fortalecer los procesos de toma de decisiones y mejorar la capacidad de adaptación al entorno competitivo.

Asimismo, **Saavedra-García y Tapia-Sánchez (2020)** señalan que las tecnologías de información desempeñan un papel clave en la competitividad de las PYMES mexicanas; sin embargo, su adopción se ve limitada por restricciones financieras y por la falta de personal especializado.

Finalmente, **Romero-Hidalgo et al. (2021)** destacan que la gestión del conocimiento y el uso de datos en las organizaciones favorecen los procesos de innovación empresarial, lo que resulta particularmente relevante en el contexto de pequeñas empresas que buscan mejorar su desempeño mediante el uso de tecnologías digitales.

Como complemento regional, **Poveda-Valverde y Fierro Barragán (2026)**, en una revisión sistemática de estudios sobre IA en PYMES latinoamericanas, identifican restricciones de infraestructura, presupuesto y talento especializado, y observan que las aplicaciones se concentran principalmente en logística, manufactura y telecomunicaciones. Este hallazgo refuerza la necesidad de estudios aplicados y reproducibles en microempresas de servicios alimentarios, donde la disponibilidad de datos es más limitada.

Con el propósito de sintetizar las principales contribuciones de la literatura revisada, en la Tabla 1 se presentan los estudios más relevantes relacionados con la aplicación de inteligencia artificial, analítica de datos y adopción tecnológica en la gestión empresarial y el pronóstico de demanda.

Tabla 1 - Investigaciones relevantes sobre inteligencia artificial, analítica de datos y adopción tecnológica en la gestión empresarial

Autor(es) y año	País de origen	Palabras clave	Contexto y datos	Metodología	Hallazgo relevante	Limitación o brecha	Relación con la investigación
Hübner et al. (2024)	Alemania	panadería; ML; pronóstico; desperdicio	Panaderías; ventas, producción y desperdicio	Caso cuantitativo con ML	El pronóstico de demanda puede apoyar la reducción de desperdicio.	Caso con infraestructura superior a la microempresa.	Aporta el antecedente sectorial; justifica evaluar una solución acotada a registros internos.
Huber y Stuckenschmidt (2020)	Alemania	retail; ML; calendario; demanda diaria	Retail diario; ventas y calendario	Comparación de ML con variables calendáricas	Las variables de calendario mejoran pronósticos en eventos.	Contexto minorista de mayor escala.	Sustenta incluir calendario y eventos disponibles en el dataset.
Abrar et al. (2024)	Internacional	cadena de suministro; CNN; LSTM; XAI	Cadena de suministro; demanda multifuente	Modelo híbrido CNN-LSTM con XAI	Los modelos híbridos pueden integrar señales complejas.	Alta complejidad y requisitos de datos.	Sirve como contraste: la tesis evalúa alternativas parsimoniosas en Small Data.
Spiliotis et al. (2022)	Grecia	SKU; demanda diaria; ML; métodos estadísticos	SKU diarios; series irregulares e intermitentes	Comparación de métodos estadísticos y ML	La superioridad de ML depende del objetivo y debe verificarse empíricamente.	Datos minoristas con múltiples SKU.	Fundamenta comparar Random Forest, ARIMA y línea base empírica.
Makridakis et al. (2018)	Internacional	M4; forecasting; ML; métodos híbridos	Competencia M4; múltiples series y horizontes	Benchmark de métodos estadísticos, híbridos y ML	Los modelos complejos no dominan de forma universal.	No estudia microempresas ni compras.	Sustenta una hipótesis condicional y la evaluación comparativa.
Hewamalage et al. (2021)	Australia	RNN; series temporales; ARIMA; ETS	Series temporales con RNN	Estudio empírico frente a ETS y ARIMA	Las RNN son competitivas, pero no son soluciones universales.	No se centra en presupuesto de compras de microempresas.	Justifica reportar RNN/LSTM sin asumir superioridad frente a modelos simples.
Giannopoulos et al. (2025)	Grecia	demanda intermitente; ML; evaluación; Small Data	Demanda intermitente en distintas industrias	Revisión de ML y protocolos de evaluación	La intermitencia exige atención a partición temporal, ajuste y métricas.	Predomina evidencia de SKU y refacciones.	Sustenta Rolling-Origin y el uso cauteloso de MAPE.
Borsato (2023)	Italia	repostería; estética; personalización	Repostería creativa y valor estético	Estudio sectorial cualitativo	La personalización distingue a la repostería creativa.	No evalúa pronósticos ni IA.	Delimita el contexto de negocio del caso Cup&Cake.
Ab Karim et al. (2020)	Malasia	pastelería; creatividad; experiencia	Pastelería; creatividad y experiencia	Estudio de retrato/teoría integrada	La creatividad y personalización influyen en la oferta del sector.	No modela demanda.	Apoya la explicación de la variabilidad comercial del caso.
Ben Abdallah et al. (2022)	Túnez	innovación; pastelería; competitividad	Empresas pasteleras; innovación de producto	Estudio exploratorio	La innovación favorece desempeño y posicionamiento competitivo.	No analiza pronóstico ni ML.	Complementa la caracterización del sector de repostería.
Mikalef et al. (2019)	Noruega	big data; capacidades analíticas; innovación	Organizaciones orientadas a datos	Modelo de capacidades analíticas	Las capacidades analíticas se relacionan con innovación.	No se limita a microempresas ni pronóstico.	Sustenta la adopción de datos como capacidad organizacional.
Dubey et al. (2021)	Reino Unido / India	IA; big data; desempeño operativo	Manufactura; analítica, IA y desempeño	Modelo empírico de desempeño operativo	El valor de IA depende de capacidades y contexto.	Contexto industrial.	Refuerza que el DSS es apoyo y no garantía automática de desempeño.
Aprodu et al. (2025)	Rumania	panadería; Industria 4.0; digitalización	Sector panadero e Industria 4.0	Revisión sistemática	La digitalización integra datos y automatización en panadería.	Evidencia sectorial heterogénea.	Apoya la pertinencia de digitalizar ventas y compras del caso.
Alekseeva et al. (2021)	Lituania	adopción de IA; PYMES; barreras	PYMES europeas; adopción de IA	Estudio sobre barreras de adopción	Recursos, infraestructura y talento limitan la adopción.	No mide pronóstico de compras.	Justifica una solución de bajo requerimiento basada en datos existentes.
Maldonado-Guzmán et al. (2018)	México	innovación tecnológica; PYMES; desempeño	PYMES mexicanas; innovación y desempeño	Estudio empírico cuantitativo	La adopción tecnológica se asocia con competitividad.	No evalúa IA ni pronósticos.	Aporta contexto nacional de transformación tecnológica.
Cuevas-Vargas et al. (2016)	México	TIC; PYMES; innovación	PYMES mexicanas; TIC y desempeño	Estudio cuantitativo	Las TIC favorecen la innovación y el desempeño organizacional.	No incorpora ML.	Sustenta el antecedente mexicano de digitalización.

Autor(es) y año	País de origen	Palabras clave	Contexto y datos	Metodología	Hallazgo relevante	Limitación o brecha	Relación con la investigación
Maldonado-Guzmán y Garza-Reyes (2020)	México	transformación digital; PYMES; datos	PYMES mexicanas; transformación digital	Estudio de procesos de digitalización	Las tecnologías basadas en datos fortalecen decisiones.	No compara modelos predictivos.	Contextualiza la brecha entre digitalización y analítica predictiva.
Saavedra-García y Tapia-Sánchez (2020)	México	TIC; PYMES; competitividad	PYMES mexicanas; adopción de TIC	Análisis de adopción tecnológica	Las restricciones financieras y de talento limitan la adopción.	Enfoque descriptivo.	Respalda la pertinencia de una solución reproducible y accesible.
Romero-Hidalgo et al. (2021)	México	gestión del conocimiento; innovación; datos	Pequeñas empresas; conocimiento e innovación	Modelo de gestión del conocimiento	El uso de datos favorece la innovación organizacional.	No evalúa precisión predictiva.	Complementa el valor de formalizar registros dispersos.
Poveda-Valverde y Fierro Barragán (2026)	Ecuador / América Latina	IA; PYMES; adopción; barreras	PYMES latinoamericanas; adopción de IA	Revisión sistemática	Persisten barreras de infraestructura, presupuesto y talento; logística concentra aplicaciones.	No se centra en microempresas de repostería.	Refuerza el vacío regional y la necesidad de evidencia aplicada en microempresas.
Hyndman y Athanasopoulos (2021)	Australia	series temporales; diagnóstico; pronóstico; validación.	Ejemplos de series reales de distintos sectores	Libro metodológico con aplicaciones en R	El diagnóstico precede al modelado; la evaluación requiere datos fuera de muestra.	No estudia compras de microempresas.	Sustenta el diagnóstico temporal y la evaluación fuera de muestra.
Syntetos y Boylan (2005)	Reino Unido	demanda intermitente; Croston; SBA; precisión	Industria automotriz; 3,000 series intermitentes	Comparación de cuatro métodos y simulación	La modificación de Croston mejora la precisión en las series evaluadas.	No compara ML ni estudia microempresas alimentarias.	Fundamenta incluir Croston-SBA y métricas compatibles con ceros..

Fuente: Elaboración propia con base en las referencias citadas en el Estado del Arte.

1.1.8 Síntesis del estado del arte y vacío de investigación

La literatura revisada destaca el potencial de los modelos híbridos y las combinaciones de métodos para mejorar la precisión del pronóstico. Makridakis et al. (2018a) identificaron en la competencia M4 resultados destacados mediante la integración de componentes estadísticos y de aprendizaje automático. Por su parte, Abrar et al. (2024) presentaron una arquitectura híbrida de redes neuronales con mejoras en el contexto evaluado. Aunque representan formas distintas de integración, estos antecedentes fundamentan el estudio de enfoques complementarios, cuya precisión debe comprobarse según las características de los datos y el horizonte de pronóstico.

Los antecedentes incluyen estudios de demanda por producto y aplicaciones en el sector panadero. **Huber y Stuckenschmidt (2020)** abordaron el pronóstico diario por categoría y establecimiento en una cadena de panaderías, mientras que **Spiliotis et al. (2022)** compararon métodos estadísticos y de aprendizaje automático en series diarias de demanda por producto. Estos contextos difieren del pronóstico del importe semanal de compras de una microempresa. Asimismo, **Poveda-Valverde y Fierro Barragán (2026)** identificaron restricciones de infraestructura, presupuesto y talento especializado para la adopción de IA en PYMES latinoamericanas, lo que refuerza la pertinencia de soluciones adaptadas a sus recursos.

Dentro de los trabajos revisados, se identifica evidencia limitada sobre el desarrollo y la evaluación temporal de modelos híbridos estadísticos y de aprendizaje automático para el pronóstico del importe semanal de compras, junto con un procedimiento de distribución porcentual entre los principales insumos, en microempresas de repostería creativa. El vacío aplicado se sitúa en la articulación de ambos resultados como apoyo al presupuesto de abastecimiento, bajo condiciones de información histórica limitada y variabilidad en las compras.

La investigación aborda este vacío mediante la evaluación de la precisión del importe total pronosticado y de su distribución porcentual frente a modelos de referencia. La distribución se fundamentará en la composición histórica de las compras y su variación temporal, y permitirá

expresar asignaciones presupuestarias por insumo. Su evaluación determinará la capacidad de anticipar el gasto registrado y su composición; establecer cantidades óptimas de compra requeriría información adicional sobre necesidades de producción, existencias y condiciones de suministro.

La contribución consiste en desarrollar un modelo híbrido que integra métodos estadísticos y aprendizaje automático, acompañado de un procedimiento de distribución porcentual del importe semanal entre los principales insumos de Cup&Cake, microempresa de repostería creativa de Tizayuca, Hidalgo. A partir de los registros de ventas y compras, se construirán las series semanales y se evaluará temporalmente la precisión frente a modelos de referencia. Los resultados servirán como apoyo a la planeación del presupuesto de abastecimiento, con un alcance centrado en el pronóstico y la asignación presupuestaria.

1.2 El planteamiento del problema

Las microempresas operan en entornos caracterizados por alta incertidumbre financiera, variabilidad en la demanda y limitaciones en recursos tecnológicos y analíticos (Góngora Chonillo, 2023). En la mayoría de los casos, la planeación financiera y la gestión de la cadena de suministro se sustentan en la experiencia empírica del propietario, en estimaciones intuitivas o en el análisis retrospectivo de resultados históricos, sin el apoyo de modelos predictivos formales que permitan anticipar escenarios futuros con mayor precisión.

Esta situación resulta especialmente crítica en microempresas del sector alimentario, donde la demanda presenta fuertes componentes estacionales y donde una planeación inadecuada impacta directamente en el control de inventarios, la gestión de ingresos y la rentabilidad del negocio. Hyndman y Athanasopoulos (2021) explican que la calidad de los pronósticos impacta directamente en la planificación estratégica, la gestión de inventarios y la toma de decisiones financieras, señalando que errores sistemáticos generan sobrecostos y desabastecimientos.

A pesar de la creciente disponibilidad de soluciones basadas en Inteligencia Artificial (IA) y analítica avanzada, su adopción en micro y pequeñas empresas continúa siendo limitada.

Estudios como el de **Alekseeva et al. (2021)**, evidencian que estas organizaciones enfrentan barreras estructurales asociadas a restricciones financieras y limitaciones en infraestructura tecnológica, lo que dificulta la implementación de herramientas digitales avanzadas.

Asimismo, la literatura señala que la carencia de capital humano especializado y de capacidades analíticas internas reduce significativamente la posibilidad de integrar soluciones basadas en datos en los procesos estratégicos empresariales **(Mikalef et al., 2019)**. Esta limitación se vincula directamente con la baja capacidad de absorción tecnológica característica de las empresas de menor tamaño.

En el ámbito de la gestión operativa y de la cadena de suministro, se ha identificado que la incorporación de tecnologías de analítica avanzada e IA depende del desarrollo de capacidades dinámicas y de una orientación estratégica clara hacia la innovación, condiciones que no siempre están presentes en microempresas **(Dubey et al., 2021)**.

Asimismo, la literatura evidencia que la mayoría de las investigaciones sobre analítica avanzada e Inteligencia Artificial se han desarrollado en organizaciones medianas y grandes o en entornos industriales altamente estructurados, lo que limita la comprensión de su aplicabilidad en microempresas **(Mikalef et al., 2020; Alekseeva et al., 2021)**. Esta concentración ha generado un vacío en el análisis empírico acerca de cómo los modelos de aprendizaje automático pueden incidir en la planeación financiera y operativa de empresas de menor escala.

Dicho vacío se profundiza cuando se examina la integración simultánea del pronóstico de ingresos y la gestión de inventarios como procesos interdependientes dentro de la cadena de suministro, dimensión que la literatura reconoce como crítica para el desempeño organizacional, pero escasamente abordada en microempresas **(Dubey et al., 2021; Hyndman & Athanasopoulos, 2021)**.

1.2.1 Contexto del caso de estudio

En el contexto de las micro, pequeñas y medianas empresas (MIPYMES), la toma de decisiones suele caracterizarse por una fuerte dependencia del conocimiento tácito, la experiencia acumulada del propietario o directivo y prácticas organizacionales poco formalizadas. Este enfoque, predominantemente empírico, si bien aporta flexibilidad y rapidez en entornos de alta incertidumbre, limita la estructuración sistemática del conocimiento y la consolidación de procesos estratégicos basados en información analítica (García-Pérez et al., 2020).

Cup&Cake, es una empresa fundada en 2014, con más de diez años de operación el crecimiento orgánico le ha permitido subsistir gracias a las compras que actualmente se realizan se hacen con base en el empirismo del empresario ya que lo único que conoce son las fechas de eventos importantes como el Día de San Valentín (14 de febrero), el día del niño (30 de abril), el día de la madre (10 de mayo), entre otros que son los picos de venta que año con año se repiten.

Con el paso del tiempo, Cup&Cake ha incrementado sus ventas de manera orgánica, producto de un proceso mercadológico inicial, donde clientes que han depositado su confianza en la empresa recomiendan sus productos por su sabor y alta calidad en la decoración y personalización de sus productos, provocando el aumento constante en las ventas.

El reto de Cup&Cake es fortalecer la planeación semanal del presupuesto de abastecimiento. Para ello, requiere estimar al inicio de cada semana el importe probable de compra semanal así como la distribución entre los principales insumos, considerando el comportamiento histórico, las fechas comerciales y las variables exógenas disponibles.

El pronóstico tendrá como propósito reducir la incertidumbre al reservar y revisar el presupuesto de abastecimiento de corto plazo. La investigación no pretende medir directamente incrementos de utilidad, expansión comercial o reducción de costos, pues dichas conclusiones requerirían información adicional y un diseño de evaluación operativa.

1.2.2 Pregunta de Investigación

¿Qué precisión ofrece un modelo híbrido que integra métodos estadísticos y aprendizaje automático, mediante evaluación temporal de su precisión frente a modelos de referencia, para estimar el importe total semanal de compras y su distribución porcentual entre los principales insumos, como apoyo a la planeación del presupuesto de abastecimiento en una microempresa de repostería creativa de Tizayuca, Hidalgo?

1.2.3 Objetivo

Objetivo general

Desarrollar un modelo híbrido que integra métodos estadísticos y aprendizaje automático, mediante evaluación temporal de su precisión frente a modelos de referencia, para el pronóstico del importe total semanal de compras y su distribución porcentual entre los principales insumos, como apoyo a la planeación del presupuesto de abastecimiento de una microempresa de repostería creativa de Tizayuca, Hidalgo

Objetivos específicos

1. **Analizar** los registros históricos de ventas y compras mediante depuración, agregación semanal y caracterización temporal del importe total y de la participación de los principales insumos.
2. **Desarrollar** la estructura del modelo híbrido mediante la integración de componentes estadísticos y de aprendizaje automático, con variables históricas y exógenas disponibles al momento del pronóstico.
3. **Determinar** la distribución porcentual del importe semanal pronosticado entre los principales insumos, a partir de su composición histórica y variación temporal.
4. **Contrastar** la precisión del modelo híbrido y del procedimiento de distribución porcentual frente a modelos de referencia, mediante evaluación temporal y métricas de error monetario y de participación.

1.3 Justificación

1.1. Relevancia social

Esta investigación propone generar evidencia sobre el uso de herramientas de pronóstico semanal en una microempresa con recursos tecnológicos y analíticos limitados. Las restricciones financieras, tecnológicas y de personal especializado dificultan que las microempresas adopten soluciones basadas en datos. Por ello, evaluar modelos a partir de la información disponible permitirá identificar alternativas cuya pertinencia pueda valorarse en función de sus capacidades operativas (Alekseeva et al., 2021; Poveda-Valverde & Fierro Barragán, 2026).

En Cup&Cake, el estudio buscará determinar si el modelo híbrido mejora la estimación del importe semanal de compras y su distribución porcentual entre los principales insumos frente a modelos de referencia. Los resultados podrían aportar información útil para el responsable de la planeación del presupuesto de abastecimiento. Asimismo, el procedimiento podrá servir como referencia para otras microempresas con condiciones semejantes, aunque su aplicación requerirá evaluar las características y los datos de cada negocio.

1.2. Conveniencia

El estudio atiende una necesidad operativa concreta de Cup&Cake: estimar, con horizontes de una a cuatro semanas, el importe total de las compras y su distribución porcentual entre los principales insumos. Se propone aprovechar los registros históricos de ventas y compras e incorporar variables exógenas disponibles al momento del pronóstico para desarrollar un procedimiento de apoyo a la planeación del presupuesto de abastecimiento.

Se comparará la precisión del modelo híbrido con la de modelos de referencia mediante validación temporal de ventana deslizante. Este contraste permitirá determinar si la integración de métodos estadísticos y aprendizaje automático aporta mejoras en el pronóstico frente a alternativas más sencillas, sin presuponer la superioridad de una mayor complejidad algorítmica (Makridakis et al., 2018b; Spiliotis et al., 2022).

1.3. Valor teórico

El valor teórico esperado de la investigación consiste en **aportar evidencia sobre el desempeño de métodos de pronóstico semanal en un contexto de datos limitados e intermitencia de las compras**. La literatura señala que **la precisión de los modelos depende de la cantidad y calidad de los datos, la granularidad temporal, las variables disponibles y el protocolo de evaluación**; por tanto, su superioridad requiere contrastación empírica **(Hewamalage et al., 2021; Giannopoulos et al., 2025)**.

El estudio permitirá examinar la **precisión de un modelo híbrido que integre métodos estadísticos y aprendizaje automático, así como la de un procedimiento de distribución porcentual del importe semanal entre los principales insumos**. También **se analizará si las variables exógenas disponibles antes de cada pronóstico aportan información adicional**. La contribución prevista será principalmente empírica y metodológica, circunscrita al caso de estudio, y podrá orientar investigaciones posteriores en microempresas con características semejantes.

1.4. Implicaciones prácticas

Se propone **desarrollar para Cup&Cake un procedimiento reproducible para depurar e integrar los registros diarios, agregarlos semanalmente, construir variables predictivas, generar pronósticos y estimar la distribución porcentual del importe entre los principales insumos**. Su precisión se evaluará fuera de muestra mediante métricas de error monetario y de participación. Se prevé presentar los resultados en un tablero de inteligencia de negocios que permita consultar el importe semanal esperado de compras, su consolidado mensual y la distribución presupuestaria entre los principales insumos.

El tablero tendrá como propósito apoyar la planeación y revisión del presupuesto de abastecimiento. No generará órdenes automáticas de compra ni calculará cantidades físicas por insumo, pues estas funciones requerirían información adicional sobre recetas, existencias, merma, costos de faltante, tiempos de entrega y unidades de medida homologadas. Los

posibles beneficios operativos dependerán de los resultados obtenidos y de su posterior aplicación en la empresa.

La investigación se justifica por la necesidad de evaluar si un modelo híbrido que integre métodos estadísticos y aprendizaje automático puede mejorar el pronóstico del importe semanal de compras y su distribución porcentual entre los principales insumos de Cup&Cake. Se propone contrastar su precisión frente a modelos de referencia mediante evaluación temporal, con el propósito de aportar elementos para la planeación del presupuesto de abastecimiento. Su alcance no comprende la medición de efectos sobre inventarios, merma, rentabilidad o expansión comercial.

1.4 Hipótesis

1.5. Hipótesis de investigación (H1)

H1. El modelo híbrido que integre métodos estadísticos y aprendizaje automático, junto con el procedimiento de distribución porcentual entre los principales insumos, presentará menores errores de pronóstico fuera de muestra que los respectivos modelos de referencia para estimar el importe total semanal de compras y su composición porcentual en Cup&Cake, utilizando información disponible al momento del pronóstico y los mismos periodos y horizontes de evaluación.

2 MARCO TEÓRICO

El presente marco teórico desarrolla los fundamentos conceptuales y matemáticos que sustentan la propuesta de un modelo híbrido para pronosticar el importe total semanal de compras y su distribución porcentual entre los principales insumos de Cup&Cake. Para ello, se abordan la planeación del presupuesto de abastecimiento, las características de las series temporales semanales, los métodos estadísticos y de aprendizaje automático, y las estrategias para su integración. Posteriormente, se examinan los fundamentos de la distribución porcentual de las compras, el tratamiento de datos limitados y la evaluación del desempeño predictivo fuera de muestra mediante métricas de error monetario y de participación porcentual. Finalmente, se analiza el uso de los pronósticos como apoyo a la planeación de compras en el contexto de la microempresa (Hyndman & Athanasopoulos, 2021; Power, 2002).

2.1 Microempresa y planeación del presupuesto de abastecimiento

2.1.1 Recursos de información y conocimiento del negocio

Las empresas pequeñas presentan condiciones heterogéneas de digitalización (OECD, 2021). La disponibilidad de registros, las competencias del personal y los recursos para integrar herramientas condicionan el uso de analítica. Estas restricciones justifican procedimientos proporcionales a la información disponible, pero no permiten asumir que toda microempresa carece de registros o que una solución tecnológica tendrá beneficios automáticos. En Cup&Cake, la pertinencia del procedimiento se evaluará respecto de la necesidad de anticipar el presupuesto de compras.

La experiencia del responsable del negocio puede aportar información sobre celebraciones, cambios de proveedores o adquisiciones extraordinarias que no aparece explícitamente en una serie. Ese conocimiento permite interpretar registros y proponer variables, mientras que las reglas de pronóstico hacen reproducible la estimación. La complementariedad requiere distinguir hechos documentados de expectativas y conservar el momento en que cada dato estuvo disponible (Hyndman & Athanasopoulos, 2021).

2.1.2 Pronóstico como información para decidir

Un pronóstico puntual resume una distribución de resultados posibles. Bajo pérdida cuadrática, el valor que minimiza el error esperado es la media condicional. La ecuación (2.1) adapta esta propiedad al importe de compras: la estimación depende de la información existente en el origen del pronóstico, sin utilizar datos posteriores (Hastie et al., 2009).

$$\hat{y}_{t+h|t} = E(y_{t+h}|I_t) \quad (2.1)$$

En esta notación, y representa el importe semanal observado, t es la última semana conocida, h es el horizonte e I representa la información disponible. El sombrero distingue el pronóstico del valor observado y la barra vertical separa el periodo pronosticado del origen de información. Una estimación puntual ayuda a formular expectativas, pero no determina por sí sola la decisión presupuestaria del responsable (Hastie et al., 2009; Power, 2002).

La planeación del presupuesto utilizará esa estimación como un insumo para revisar recursos destinados al abastecimiento. Un sistema de soporte a la decisión organiza datos y modelos para facilitar la valoración de alternativas; la decisión final también puede incorporar restricciones que el modelo no observa. Por ello, el estudio evaluará precisión predictiva y no supondrá que un menor error produce necesariamente un retorno financiero positivo (Power, 2002).

2.2 Compras monetarias y contexto de la repostería

2.2.1 Delimitación de la variable objetivo

Pronosticar requiere definir con precisión qué se observa, con qué frecuencia y para qué horizonte. En esta investigación, la respuesta principal será el importe total semanal registrado de compras. Las ventas, el consumo de ingredientes y las existencias son magnitudes diferentes: pueden aportar contexto, pero no sustituyen la variable definida. La comparación entre modelos deberá mantener la misma respuesta y las mismas unidades monetarias (Hyndman & Athanasopoulos, 2021).

El importe de una adquisición puede variar por cantidad, precio y composición de insumos. Además, la fecha de compra puede diferir de la fecha de consumo o pago. Por tanto, la

interpretación prevista será presupuestaria: se intentará anticipar el registro monetario de compras, sin identificarlo con una cantidad óptima de abastecimiento. Esta delimitación mantiene separado el objetivo de predicción de las inferencias explicativas o causales (Shmueli, 2010).

2.2.2 Agregación del importe y niveles de análisis

Los pronósticos jerárquicos representan series relacionadas mediante sumas. Adaptada al caso, la identidad de agregación expresa el importe semanal total como suma de los importes de las categorías de insumos. La ecuación (2.2) es una aplicación de esa estructura aditiva, no un modelo causal de costos (Hyndman et al., 2011).

$$y_t = \sum_{j=1}^J b_{j,t} \quad (2.2)$$

Aquí, b es el importe del insumo o categoría j y J es el número de categorías mutuamente excluyentes que cubren el total. Si solo se presentan los principales insumos, será necesario conservar una categoría residual para las demás compras o declarar que se trabaja con un subtotal. La suma evita que las asignaciones se interpreten como un total cuando omiten parte de sus componentes (Hyndman et al., 2011).

La **perecibilidad** aporta contexto a la periodicidad de las compras, pero no hace equivalentes el pronóstico monetario y la planificación de inventarios. La frecuencia y el nivel de agregación deben responder a la decisión analizada. En el caso propuesto, la escala semanal facilitará la revisión del presupuesto; la traducción de importes a unidades físicas requeriría precios, recetas, existencias y condiciones de suministro que exceden ese pronóstico (Hyndman & Athanasopoulos, 2021).

2.3 Series temporales semanales y calidad de los registros

2.3.1 Frecuencia y continuidad

Una serie temporal es una secuencia ordenada de observaciones. La agregación semanal debe conservar un calendario consistente y distinguir ausencia de compra de ausencia de registro. Rellenar automáticamente huecos con ceros cambiaría el fenómeno observado. La

continuidad de las fuentes y la identificación de semanas incompletas deberán examinarse antes de interpretar patrones o entrenar modelos (Hyndman & Athanasopoulos, 2021).

2.3.2 Nivel tendencia y estacionalidad

La descomposición aditiva representa una serie mediante tendencia-ciclo, estacionalidad y residuo. Es útil cuando las oscilaciones estacionales se interpretan en la escala original; si aumentan proporcionalmente al nivel, pueden considerarse transformaciones u otras representaciones. La ecuación (2.3) presenta la descomposición con notación adaptada al importe semanal (Hyndman & Athanasopoulos, 2021).

$$y_t = T_t + S_t + R_t \quad (2.3)$$

T representa el componente de tendencia-ciclo, S el patrón estacional y R la variación restante. El residuo no debe interpretarse automáticamente como error de captura: puede contener acontecimientos legítimos o estructura no representada. La descomposición sirve para explorar el comportamiento de la serie, sin demostrar que los componentes conservarán la misma forma en periodos futuros (Hyndman & Athanasopoulos, 2021).

La estacionalidad implica repetición asociada al calendario. Para compras semanales, un patrón anual debe examinarse con la cobertura disponible y con atención a festividades móviles. Contar con un ciclo no permite observar su repetición entre años. La incorporación de componentes estacionales dependerá de evidencia histórica y de su utilidad predictiva, no solo de la existencia de fechas comerciales relevantes (Hyndman & Athanasopoulos, 2021).

2.3.3 Estacionariedad y dependencia temporal

La diferenciación transforma la serie mediante cambios entre observaciones sucesivas, como muestra la ecuación (2.4). Puede ayudar a tratar variaciones persistentes de nivel; la estabilización de varianza, en cambio, puede requerir transformaciones de escala. ADF y KPSS examinan hipótesis distintas sobre estacionariedad, y su interpretación debe considerar el tamaño de muestra y los componentes incluidos en la prueba (Hyndman & Athanasopoulos, 2021).

$$\Delta y_t = y_t - y_{t-1} \quad (2.4)$$

La autocorrelación describe asociación lineal entre observaciones separadas por un rezago. En la ecuación (2.5), k identifica la separación temporal, N el número de semanas y la barra el promedio de la serie. La función ayuda a explorar memoria temporal, sin constituir por sí sola una regla de selección del modelo (Hyndman & Athanasopoulos, 2021).

$$r_k = \frac{\sum_{t=k+1}^N (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^N (y_t - \bar{y})^2} \quad (2.5)$$

La autocorrelación parcial y las pruebas de dependencia conjunta pueden complementar el diagnóstico. Las decisiones sobre rezagos deben respetar el origen temporal: analizar toda la serie para escoger características y luego evaluar sobre una parte de ella puede incorporar información de los periodos reservados. En la evaluación propuesta, los diagnósticos que determinen ajustes se restringirán al historial disponible (Hyndman & Athanasopoulos, 2021).

2.3.4 Intermitencia y valores extremos

Cuando existen periodos con valor cero, resulta útil distinguir tamaño de los eventos positivos y tiempo entre eventos. El método de Croston mantiene estimaciones suavizadas de ambas cantidades y obtiene una tasa por periodo mediante su cociente, representado en la ecuación (2.6). Su traslado de demanda a compras monetarias deberá justificarse por el patrón observado (Hyndman & Athanasopoulos, 2021).

$$\hat{y}_{t+h|t} = \frac{\hat{z}_t}{\hat{a}_t} \quad (2.6)$$

La estimación z corresponde al tamaño de los eventos positivos y a al intervalo entre ellos. El procedimiento es una alternativa de referencia para intermitencia, no una garantía de superioridad. Los picos también deberán distinguirse entre errores de registro y compras extraordinarias; eliminarlos por su magnitud podría retirar información legítima del proceso que se desea pronosticar (Hyndman & Athanasopoulos, 2021; Kuhn & Johnson, 2013).

2.4 Métodos estadísticos y de aprendizaje automático

2.4.1 Referencias simples

Una referencia establece qué precisión puede obtenerse con una regla reproducible. El método ingenuo conserva el último valor conocido para los horizontes futuros, como muestra la ecuación (2.7). Una referencia estacional utiliza el periodo comparable de un ciclo anterior cuando existe historial suficiente. Ninguna de estas reglas representa por sí misma el juicio del propietario (Hyndman & Athanasopoulos, 2021).

$$\hat{y}_{t+h|t} = y_t \quad (2.7)$$

La utilidad de estas referencias es contextualizar el error: una arquitectura compleja puede reducir el error de entrenamiento sin mejorar el de semanas futuras. El estudio deberá comparar al híbrido con referencias previamente definidas para el importe y para la composición, de modo que la mejora se mida respecto de alternativas pertinentes (Hyndman & Athanasopoulos, 2021).

2.4.2 Suavizamiento exponencial y ARIMA

El suavizamiento exponencial simple actualiza una estimación del nivel mediante una combinación de la observación reciente y el nivel previo. En la ecuación (2.8), α controla el peso de la información reciente y toma valores entre cero y uno. Su pronóstico no incorpora por sí mismo tendencia o estacionalidad, por lo que funciona como una representación básica (Hyndman & Athanasopoulos, 2021).

$$\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}, \quad \hat{y}_{t+h|t} = \ell_t \quad (2.8)$$

Los modelos de suavizamiento con tendencia y estacionalidad amplían esta representación. Su pertinencia dependerá de la estructura temporal y de la cantidad de observaciones. No será suficiente seleccionar una variante más compleja: deberá verificarse si sus componentes ayudan a estimar las semanas reservadas para evaluación (Hyndman & Athanasopoulos, 2021).

Un ARIMA combina términos autorregresivos, diferenciación y medias móviles de innovaciones. La ecuación (2.9) usa el operador de rezago B , de modo que B aplicado a y en

t devuelve el valor anterior. Los polinomios phi y theta representan los órdenes autorregresivo y de medias móviles; d es el orden de diferenciación y épsilon la innovación (Hyndman & Athanasopoulos, 2021).

$$\varphi(B)(1 - B)^d y_t = c + \theta(B)\varepsilon_t \quad (2.9)$$

El componente de medias móviles de ARIMA opera sobre innovaciones y no equivale a promediar compras de semanas anteriores. Las variantes estacionales añaden operadores a una periodicidad definida. La selección debe considerar longitud del historial y diagnóstico de residuos; los modelos estadísticos no son inadecuados por definición ante una microempresa (Hyndman & Athanasopoulos, 2021).

2.4.3 Bosques aleatorios y potenciación de gradiente

Random Forest combina árboles construidos con aleatoriedad en muestras y predictores. En regresión, la salida es el promedio de las predicciones, representado en la ecuación (2.10). B es el número de árboles, T identifica cada árbol y x reúne los predictores disponibles. La agregación busca reducir variabilidad respecto de un árbol individual (Breiman, 2001).

$$\hat{f}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x) \quad (2.10)$$

Los árboles permiten representar interacciones y relaciones no lineales. Para series semanales necesitan entradas temporales adecuadas, como rezagos y calendario; no deducen automáticamente qué información estará disponible en el futuro. Su comportamiento depende de profundidad, tamaño de nodos y diversidad de árboles, y no puede describirse como inmunidad a errores de captura o datos faltantes (Breiman, 2001).

La potenciación de gradiente construye una función de manera aditiva. La ecuación (2.11) expresa una actualización con un aprendiz base g, un coeficiente rho y una tasa de aprendizaje nu. La dirección de actualización depende del gradiente negativo de la pérdida; con pérdida cuadrática se relaciona con los residuales (Friedman, 2001).

$$F_m(x) = F_{m-1}(x) + \nu \rho_m g_m(x) \quad (2.11)$$

La tasa de aprendizaje y el número de etapas controlan la magnitud de la adaptación. Estas técnicas pueden aprovechar interacciones entre calendario e historial, pero requieren ajuste temporal. Evaluar más etapas sobre los mismos datos finales usados para reportar precisión introduciría optimismo en la comparación (Friedman, 2001).

2.4.4 Redes neuronales y alcance de los comparadores

Una red autorregresiva aproxima una relación entre rezagos mediante una función no lineal. Las arquitecturas recurrentes añaden estados internos y mecanismos de memoria, pero también parámetros y decisiones de ajuste. En escenarios con pocas observaciones, su inclusión debe justificarse por información suficiente y comparación con métodos más sencillos; no define por sí misma el carácter híbrido del estudio (Hyndman & Athanasopoulos, 2021).

La selección de familias tendrá sentido si permite examinar representaciones distintas del mismo objetivo. Un comparador adicional deberá aportar una pregunta pertinente, como la utilidad de no linealidad o memoria, y no solo ampliar una lista de algoritmos. La configuración final pertenecerá a metodología y se fijará mediante información anterior a las semanas de evaluación (Kuhn & Johnson, 2013).

2.5 Fundamentos de integración del modelo híbrido

2.5.1 Combinación de pronósticos

La combinación de pronósticos parte de que métodos distintos pueden contener información complementaria. Para dos modelos, la ecuación (2.12) pondera un pronóstico estadístico y uno de aprendizaje automático. La notación adapta el principio de combinación al caso; el peso w determina la contribución del primero. Restringirlo entre cero y uno produce una combinación convexa (Bates & Granger, 1969).

$$\hat{y}_{t+h|t}^H = w\hat{y}_{t+h|t}^E + (1-w)\hat{y}_{t+h|t}^A \quad (2.12)$$

Los superíndices H, E y A identifican híbrido, estadístico y aprendizaje automático. Bajo errores insesgados con varianzas finitas, la varianza del error combinado depende de las varianzas individuales y de su covarianza. La ecuación (2.13) explica por qué el grado de dependencia entre errores importa para la combinación (Bates & Granger, 1969). La evidencia de M4 ilustra empíricamente que las combinaciones pueden ser competitivas en conjuntos amplios, aunque su resultado no se traslada automáticamente a otra población, frecuencia u horizonte (Makridakis et al., 2018a, 2020).

$$\sigma_H^2 = w^2\sigma_E^2 + (1-w)^2\sigma_A^2 + 2w(1-w)\sigma_{EA} \quad (2.13)$$

Cuando los errores se parecen mucho, combinar puede aportar poco. Si el denominador es positivo, el peso que minimiza esa varianza sin imponer la restricción convexa se expresa en la ecuación (2.14). Su uso exige estimar varianzas y covarianza sin información futura; la estimación puede ser inestable con pocos errores disponibles (Bates & Granger, 1969).

$$w^* = \frac{\sigma_A^2 - \sigma_{EA}}{\sigma_E^2 + \sigma_A^2 - 2\sigma_{EA}} \quad (2.14)$$

La combinación simple también debe considerarse como referencia, pues estimar pesos no garantiza mejorar un promedio. En el estudio propuesto, el interés será contrastar si integrar representaciones distintas produce menores errores. La evaluación deberá distinguir esa combinación de la mera selección del algoritmo ganador (Hyndman & Athanasopoulos, 2021).

2.5.2 Integración mediante componentes

Otra estrategia híbrida representa la serie como suma de componentes lineal y no lineal. Zhang (2003) propuso modelar con ARIMA la estructura lineal y con una red neuronal la estructura no lineal de los residuales, y reportó potencial de mejora en sus experimentos; el hallazgo no implica una ventaja universal. La ecuación (2.15) resume esa formulación: sus componentes no son observables independientes, sino representaciones estimadas mediante un procedimiento de modelado. La implementación de esta tesis es una adaptación y deberá juzgarse con su propia evaluación temporal.

$$y_t = L_t + N_t, \quad \hat{y}_{t+h|t} = \hat{L}_{t+h|t} + \hat{N}_{t+h|t} \quad (2.15)$$

Si el segundo componente se entrena con errores del primero, debe cuidarse cómo se generan esos errores. Los residuales de entrenamiento pueden presentar un comportamiento distinto del error predictivo. Por ello, cualquier adaptación a Cup&Cake deberá construir y ajustar sus componentes respetando el orden temporal y evaluar la suma sobre semanas no utilizadas para configurar el procedimiento (Hyndman & Athanasopoulos, 2021; Zhang, 2003).

Estas alternativas ofrecen mecanismos plausibles para H1, sin anticipar cuál resultará más preciso. Una combinación puede fallar si los componentes comparten errores, si los pesos se estiman con poca información o si la estructura cambia. La selección de una arquitectura concreta requerirá especificar qué componentes se integran y cómo se contrastará el conjunto (Hyndman & Athanasopoulos, 2021).

2.6 Distribución porcentual y coherencia de las asignaciones

2.6.1 Participaciones como datos composicionales

Las participaciones describen partes de un total y están sujetas a una restricción de suma. Por ello, no se interpretan como variables completamente independientes: aumentar una participación requiere disminuir alguna otra. La ecuación (2.16) adapta la representación composicional a importes no negativos de compras, incluyendo la condición de total positivo (Aitchison, 1982).

$$p_{j,t} = \frac{b_{j,t}}{y_t}, \quad p_{j,t} \geq 0, \quad \sum_{j=1}^J p_{j,t} = 1, \quad y_t > 0 \quad (2.16)$$

Las proporciones se expresan entre cero y uno; su multiplicación por cien produce porcentajes. Si el total observado es cero, las participaciones no quedan definidas por el cociente. Una regla de tratamiento deberá distinguir ese caso de una participación cero dentro de una semana con compras. Las transformaciones logarítmicas requieren además componentes estrictamente positivos (Aitchison, 1982).

2.6.2 Desagregación del pronóstico total

El enfoque descendente pronostica un agregado y lo distribuye mediante proporciones. La ecuación (2.17) adapta esa relación a importes por insumo: cada asignación es el producto del total pronosticado y la participación estimada para el mismo horizonte. Las proporciones deben cumplir las restricciones de suma y no negatividad (Hyndman & Athanasopoulos, 2021).

$$\hat{b}_{j,t+h|t} = \hat{p}_{j,t+h|t} \hat{y}_{t+h|t} \quad (2.17)$$

El procedimiento preserva la suma cuando todas las categorías están representadas. Esa coherencia es aritmética y no demuestra precisión: un total correcto puede repartirse incorrectamente. Por esa razón, la evaluación deberá revisar tanto el importe agregado como las participaciones y, cuando resulte pertinente, las asignaciones monetarias resultantes (Hyndman et al., 2011).

Como referencia, el promedio de proporciones históricas asigna a cada categoría su participación media en las semanas de entrenamiento con total positivo. La ecuación (2.18) adapta el promedio histórico de proporciones a ese conjunto válido V , cuyo tamaño es n . No es equivalente al cociente de sumas, que otorga más peso a las semanas de mayor importe (Hyndman & Athanasopoulos, 2021).

$$\bar{p}_j = \frac{1}{n} \sum_{t \in V} \frac{b_{j,t}}{y_t} \quad (2.18)$$

Una distribución histórica fija puede ser insuficiente si la mezcla cambia. Las proporciones pronosticadas ofrecen una alternativa, aunque requieren información y evaluación propias. Debe mantenerse el mismo conjunto de categorías a lo largo del contraste o documentar sus cambios. Este principio permite diferenciar la mejora de la composición de la mejora del total (Hyndman & Athanasopoulos, 2021).

2.6.3 Representación relativa de las participaciones

El análisis composicional utiliza cocientes para representar información relativa. La transformación logarítmica de una participación respecto de una categoría de referencia aparece en la ecuación (2.19). Su utilidad es mostrar que la información relevante puede

expresarse como relación entre partes, en lugar de tratar porcentajes como respuestas independientes sin restricciones (Aitchison, 1982).

$$z_{j,t} = \log\left(\frac{p_{j,t}}{p_{J,t}}\right), \quad j = 1, \dots, J - 1 \quad (2.19)$$

Esta transformación es una alternativa teórica y no obliga a seleccionarla para el estudio. Los ceros requieren un tratamiento explícito que no distorsione la composición; no deberán sustituirse de manera arbitraria solo para permitir un logaritmo. Una estrategia más simple también podrá ser pertinente si conserva coherencia y obtiene precisión comparable fuera de muestra (Aitchison, 1982).

2.7 Datos limitados e ingeniería de características

2.7.1 Complejidad y capacidad de generalización

La cantidad de observaciones debe valorarse en relación con la complejidad del modelo y la dependencia de los datos. Para pérdida cuadrática, la descomposición sesgo–varianza expresa el error esperado como suma de sesgo al cuadrado, varianza del estimador y ruido irreducible. La ecuación (2.20) resume esa relación para una entrada x (Hastie et al., 2009).

$$E[(Y - \hat{f}(x))^2] = \text{Sesgo}^2[\hat{f}(x)] + \text{Var}[\hat{f}(x)] + \sigma^2 \quad (2.20)$$

Un ajuste flexible puede reducir error de entrenamiento y ser sensible a cambios de muestra. Regularizar busca controlar esa sensibilidad, aunque no elimina toda incertidumbre. La estabilidad deberá examinarse con datos posteriores, especialmente cuando la agregación semanal reduzca el número de observaciones disponibles para estimar parámetros (Hastie et al., 2009).

2.7.2 Penalizaciones y selección de variables

Ridge añade una penalización cuadrática sobre coeficientes y Lasso una penalización absoluta. Las ecuaciones (2.21) y (2.22) presentan sus objetivos en notación común: SSE es la suma de errores cuadrados y beta reúne los coeficientes, excluyendo el intercepto de la

penalización. Lambda controla la intensidad de contracción (Hastie et al., 2009; Tibshirani, 1996).

$$\hat{\beta}^R = \operatorname{argmin}_{\beta} (\text{SSE}(\beta) + \lambda \sum_{j=1}^K \beta_j^2) \quad (2.2 \quad 1)$$

$$\hat{\beta}^L = \operatorname{argmin}_{\beta} (\text{SSE}(\beta) + \lambda \sum_{j=1}^K |\beta_j|) \quad (2.2 \quad 2)$$

Lasso puede llevar coeficientes a cero y producir una representación más reducida. Eso no demuestra que una variable carezca de importancia económica; su selección depende de los datos, la penalización y los demás predictores. La comparación deberá ajustar lambda dentro de entrenamiento y considerar el escalado, pues las unidades de las variables influyen en la penalización (Tibshirani, 1996).

2.7.3 Predictores temporales y calendario

Los rezagos y resúmenes móviles expresan información histórica en una forma utilizable por algoritmos de regresión. Deben construirse únicamente con observaciones conocidas en cada origen. Imputación, escalado y selección de variables forman parte del procedimiento de entrenamiento y no deben estimarse con las semanas finales de evaluación (Kuhn & Johnson, 2013).

Las bases armónicas representan ciclos mediante funciones seno y coseno. La ecuación (2.23) presenta un par de términos con periodicidad m y armónico k . La codificación permite representar continuidad entre el final y el inicio de un ciclo, sin asignar una distancia artificialmente grande a posiciones próximas (Hyndman & Athanasopoulos, 2021).

$$s_{k,t} = \sin\left(\frac{2\pi kt}{m}\right), \quad c_{k,t} = \cos\left(\frac{2\pi kt}{m}\right) \quad (2.2 \quad 3)$$

La periodicidad debe corresponder al índice temporal. En semanas completas, el número de lunes o domingos no varía entre observaciones; un calendario diario tendrá que convertirse en información semanal pertinente, como presencia o proximidad de festividades. El número de armónicos y las interacciones deberá ser compatible con el tamaño del historial (Hyndman & Athanasopoulos, 2021).

2.7.4 Disponibilidad de variables exógenas

Las variables de calendario pueden conocerse anticipadamente, mientras que clima observado, ventas futuras o indicadores publicados con retraso pueden ser desconocidos al pronosticar. Un modelo con regresores necesita sus valores futuros o un procedimiento explícito para estimarlos. Utilizar realizaciones futuras como si estuvieran disponibles produciría una evaluación que no representa el uso previsto (Hyndman & Athanasopoulos, 2021).

En horizontes de varias semanas, tampoco puede incorporarse como rezago una compra futura todavía no observada. La metodología deberá indicar si se generan pronósticos directos por horizonte o se utilizan predicciones recursivas. El análisis de variables exógenas podrá complementar el contraste principal, sin constituir una segunda hipótesis independiente (Hyndman & Athanasopoulos, 2021).

2.8 Evaluación temporal y métricas de precisión

2.8.1 Origen del pronóstico y ventana de entrenamiento

La evaluación fuera de muestra compara pronósticos con observaciones que no participaron en su ajuste. Una ventana deslizante mantiene un historial de tamaño fijo y actualiza su posición; una ventana expansiva conserva el historial previo y añade observaciones. La elección afecta recencia, tamaño de muestra y cantidad de evaluaciones posibles (Tashman, 2000).

La comparación requiere suficientes orígenes y resultados por horizonte, evitando que un único periodo determine la conclusión. Los modelos deberán enfrentar las mismas semanas y condiciones de información. El error de la ecuación (2.24) distingue el valor observado en $t+h$ del pronóstico emitido en t (Hyndman & Athanasopoulos, 2021; Tashman, 2000).

$$e_{t,h} = y_{t+h} - \hat{y}_{t+h|t} \quad (2.24)$$

El ajuste de configuraciones deberá separarse de su evaluación final. Si los pesos híbridos, las variables o el modelo se eligen observando los resultados finales, esos resultados dejan de ser una estimación independiente de la selección. El protocolo temporal permitirá comparar

alternativas sin dar por comprobada la hipótesis antes de obtener evidencia (Hyndman & Athanasopoulos, 2021).

2.8.2 Error monetario del importe total

MAE y RMSE resumen el error en las unidades de la respuesta. MAE promedia magnitudes absolutas; RMSE extrae la raíz del promedio de cuadrados y es más sensible a errores grandes. Las ecuaciones (2.25) y (2.26) se expresan para un horizonte h y un conjunto O de n orígenes evaluados (Hyndman & Athanasopoulos, 2021).

$$MAE_h = \frac{1}{n} \sum_{t \in O} |e_{t,h}| \quad (2.25)$$

$$RMSE_h = \sqrt{\frac{1}{n} \sum_{t \in O} e_{t,h}^2} \quad (2.26)$$

Las medidas se interpretarán en moneda y deberán reportarse por horizonte. Menor RMSE significa menor media de errores cuadrados, no necesariamente menor cantidad de errores extremos. Para dar transparencia a H1, el criterio principal de comparación deberá fijarse antes del análisis final, manteniendo las demás métricas como información complementaria (Hyndman & Athanasopoulos, 2021).

2.8.3 Escalamiento y límites de errores porcentuales

MASE divide el error absoluto por una escala obtenida de diferencias históricas de entrenamiento. La ecuación (2.27) muestra su forma para una partición con N observaciones de entrenamiento, n de prueba y rezago de referencia m . Permite comparar escalas sin dividir cada error por la compra observada de su semana (Hyndman & Koehler, 2006).

$$MASE = \frac{\frac{1}{n} \sum_{i=1}^n |e_i|}{\frac{1}{N-m} \sum_{t=m+1}^N |y_t - y_{t-m}|} \quad (2.27)$$

El denominador debe ser positivo y calcularse sin datos de prueba. Al desplazar la ventana, la regla de escalamiento deberá mantenerse explícita; un historial constante puede hacer indefinida la medida. MASE complementa el contraste directo con referencias y no reemplaza la interpretación de pesos monetarios (Hyndman & Koehler, 2006).

MAPE divide cada error por el valor observado. Aunque produce porcentajes, resulta indefinido con ceros e inestable con importes pequeños. Por ello, no se utilizará como criterio central de contraste de una serie con esas condiciones. Su eventual reporte deberá identificar los casos válidos sin ocultar las semanas excluidas (Hyndman & Koehler, 2006).

2.8.4 Error de participaciones y evaluación conjunta

La precisión de la composición debe medirse separadamente. La ecuación (2.28) adapta MAE a participaciones entre cero y uno y multiplica por cien para expresar el error en puntos porcentuales. O con subíndice positivo representa los orígenes cuyo total observado en el horizonte es positivo y n con el mismo subíndice es su cantidad. Esta adaptación no se presenta como una métrica composicional nueva atribuida a los autores (Aitchison, 1982; Hyndman & Koehler, 2006).

$$\text{MAE}_{p,h} = \frac{100}{n_{+J}} \sum_{t \in O_{+}} \sum_{j=1}^J |p_{j,t+h} - \hat{p}_{j,t+h|t}| \quad (2.28)$$

La ponderación uniforme ofrece igual importancia a las categorías. Si se adoptan otros pesos, deberán justificarse y fijarse antes de evaluar. Además de la medida agregada, revisar errores por insumo permite identificar si una mejora promedio oculta deterioro en categorías concretas. Se informarán por separado las semanas cuyo total cero impida definir una composición observada (Hyndman & Athanasopoulos, 2021).

El contraste de H1 tendrá dos componentes: precisión del importe total y de su distribución. Mejorar solo uno constituirá evidencia parcial respecto de su formulación conjunta. La comparación no se resolverá escogiendo retrospectivamente el horizonte favorable ni interpretando una diferencia de error como efecto financiero. La metodología deberá precisar el criterio de decisión y el tratamiento de incertidumbre de las diferencias observadas (Shmueli, 2010; Tashman, 2000).

2.9 Inteligencia de negocios y comunicación del pronóstico

2.9.1 Presentación del presupuesto y su incertidumbre

Un tablero puede reunir el total esperado, las participaciones y las asignaciones monetarias para que el responsable revise el presupuesto. La presentación deberá identificar origen, horizonte, unidades y referencia comparativa. Esta función corresponde al soporte de decisiones; no transforma automáticamente una asignación monetaria en una orden de compra (Power, 2002).

Los intervalos de predicción comunican incertidumbre adicional al valor puntual. Bajo una aproximación normal de los errores, la ecuación (2.29) utiliza un cuantil z y una estimación de la desviación del error correspondiente al horizonte. Esa aproximación depende de supuestos que deberán verificarse antes de su uso (Hyndman & Athanasopoulos, 2021).

$$\hat{y}_{t+h|t} \pm z_{1-\alpha/2} \hat{\sigma}_h \quad (2.29)$$

Alfa expresa la probabilidad nominal fuera del intervalo y sigma la escala de incertidumbre predictiva. No debe confundirse este intervalo con uno de confianza para una media estimada ni calcularse su amplitud sumando errores sin considerar el horizonte. En series asimétricas o con ceros, otras aproximaciones podrían resultar más pertinentes (Hyndman & Athanasopoulos, 2021).

2.9.2 Adopción y límites operativos

La viabilidad de una herramienta depende también de integración, mantenimiento, competencias y recursos. La digitalización de empresas pequeñas enfrenta barreras diversas, por lo que una solución debe adecuarse a sus capacidades y no justificarse únicamente por sofisticación. El tablero propuesto buscará facilitar interpretación y trazabilidad; no se asumirá que su disponibilidad demuestra adopción efectiva (OECD, 2021).

La evaluación de costos de implementación y beneficios organizacionales es distinta de medir precisión. En consecuencia, la reducción de MAE o RMSE no se denominará retorno de inversión. La comunicación de resultados deberá mantener visible esa diferencia para que el

responsable pueda utilizar el pronóstico junto con la información operativa que posea (Power, 2002).

2.10 Síntesis de fundamentos y relación con la hipótesis

Los fundamentos revisados permiten plantear una integración de métodos que representen señales diferentes y una desagregación que conserve la relación entre total e insumos. La combinación ofrece una razón teórica para esperar mejoras, mientras que la estimación de pesos y la dependencia entre errores explican por qué esa mejora no está asegurada (Hyndman & Athanasopoulos, 2021).

La composición añade un problema propio: conservar proporciones válidas y anticipar su variación. Por tanto, el procedimiento deberá evaluar el importe y las participaciones frente a sus respectivas referencias. La coherencia de suma es una condición de la representación, mientras que la precisión requiere evidencia de semanas posteriores no utilizadas en el ajuste (Hyndman & Athanasopoulos, 2021; Hyndman et al., 2011).

La investigación se desarrollará como una evaluación predictiva del presupuesto semanal de abastecimiento. El capítulo sustenta la elección de variables, métodos y criterios de contraste, sin anticipar resultados de Cup&Cake. El respaldo de H1 requerirá evidencia favorable en el importe total y en las participaciones; una mejora aislada se describirá como un resultado de ese componente y no como confirmación de la hipótesis conjunta (Shmueli, 2010).

3 METODOLOGÍA

Investigar significa llevar a cabo diferentes acciones o estrategias con el fin de descubrir algo. Así, dichos actos se dirigen a obtener y aplicar nuevos conocimientos, explicar una realidad determinada o a obtener maneras de resolver cuestiones y situaciones de interés. La investigación es la base del conocimiento científico, si bien no toda investigación es científica de por sí.

Para que un conocimiento sea científico es necesario que la investigación realizada se haga de forma sistemática, con unos objetivos claros y que a partir de aspectos que puedan ser comprobados y replicados. Los resultados obtenidos deben ser analizados de forma objetiva y teniendo en cuenta las diversas variables que pueden estar afectando al fenómeno estudiado.

Como se ha dicho, se puede investigar desde muy diferentes perspectivas, con diferentes objetivos o teniendo en cuenta diferentes tipos de datos, procedimientos o métodos para obtenerlos.

Tipo de tesis: estudio aplicado, cuantitativo, no experimental y evaluativo, basado en un caso de estudio longitudinal-retrospectivo.

3.1 Tipo de investigación según el objetivo de ésta

Investigación aplicada

En Cup&Cake, la investigación tiene como propósito desarrollar y evaluar un modelo híbrido que integre métodos estadísticos y aprendizaje automático para pronosticar el importe total semanal de compras, junto con un procedimiento para estimar su distribución porcentual entre los principales insumos. Se dispone de una implementación computacional inicial; su precisión con datos reales todavía deberá contrastarse frente a modelos de referencia como apoyo a la planeación del presupuesto de abastecimiento.

La aplicación se delimitará al caso de Cup&Cake. Se prevé comunicar los pronósticos mediante un tablero de inteligencia de negocios, sin sustituir el juicio del responsable ni presuponer mejoras en rentabilidad, inventarios o merma. Los resultados no se generalizarán automáticamente a otras microempresas.

3.2 Según el alcance evaluativo del estudio

La investigación se puede llevar a cabo de diferentes formas y profundizando más o menos en cómo son o el porqué de las cosas.

Se documentará el contexto de planeación de compras de Cup&Cake para interpretar las necesidades de información del responsable. La evaluación cuantitativa se realizará frente a referencias reproducibles. Solo se incluirán estimaciones del propietario como comparador si existen registros fechados antes de conocer los importes observados y compatibles con los mismos horizontes de pronóstico.

Evaluativa y comparativa

Se trata de uno de los tipos de investigación más frecuentes y en los que la ciencia se centra. Es el tipo de investigación que se utiliza con el fin de intentar determinar las causas y consecuencias de un fenómeno concreto. Se busca no solo el qué sino el porqué de las cosas, y cómo han llegado al estado en cuestión.

Para el caso de Cup&Cake no se adoptará el alcance causal descrito en la definición precedente. La aplicación tendrá carácter evaluativo y comparativo: se contrastarán alternativas de pronóstico bajo las mismas condiciones temporales para examinar su precisión fuera de muestra, sin atribuir relaciones de causa y efecto sobre la operación del negocio.

La investigación describirá el comportamiento histórico de ventas y compras y comparará la precisión del modelo híbrido y del procedimiento de distribución porcentual con sus respectivas referencias. La evaluación considerará por separado el importe total semanal y la participación

de los principales insumos. Su inferencia se limitará al desempeño predictivo del caso de estudio.

En consecuencia, el diseño evaluativo busca determinar si la tecnología algorítmica aporta una mejora verificable de precisión respecto de las referencias comparadas. La inteligencia artificial se evalúa como una alternativa de apoyo para anticipar el presupuesto de abastecimiento, sin suponer que sustituye el juicio del responsable ni que genera automáticamente mejoras financieras u operativas.

3.3 Según el tipo de datos empleados

Otra manera de clasificar los diferentes tipos de investigación es según el tipo de datos que recojan. En este sentido nos podemos encontrar con los siguientes tipos.

Cuantitativa

La investigación cuantitativa se basa en el estudio y análisis de la realidad a través de diferentes procedimientos basados en la medición. Permite un mayor nivel de control e inferencia que otros tipos de investigación, siendo posible realizar experimentos y obtener explicaciones contrastadas a partir de hipótesis. Los resultados de estas investigaciones se basan en la estadística y son generalizables.

La semana calendario constituirá la unidad temporal de análisis. Se calcularán el importe total de compras, el importe correspondiente a cada insumo seleccionado y su participación porcentual. Los registros históricos de ventas podrán utilizarse como predictores únicamente cuando su información esté disponible antes de cada origen de pronóstico.

Se integrarán los registros históricos de ventas y compras de Cup&Cake y se agregarán por semana calendario. Las variables exógenas se incorporarán según su pertinencia y disponibilidad documentada. Los eventos de calendario conocidos podrán utilizarse para la semana objetivo; los indicadores económicos y meteorológicos deberán representar la información efectivamente disponible antes del pronóstico.

Las matrices semanales permitirán ajustar y comparar los componentes estadístico y de aprendizaje automático, su integración híbrida y el procedimiento de distribución porcentual. Se evaluará el error monetario del total y el error de participación por insumo. El carácter cuantitativo no implicará generalización estadística a otras empresas: las conclusiones se circunscribirán a los registros y condiciones del caso estudiado.

3.4 Según el grado de manipulación de las variables

Podemos encontrar diferentes tipos de investigaciones según si los datos obtenidos parten de un nivel mayor o menor de manipulación de variables.

No experimental, evaluativa y retrospectiva

En un diseño no experimental se analizan datos observados sin manipular deliberadamente las condiciones de la empresa. La comparación temporal permite estimar desempeño predictivo, pero no inferir causalidad experimental.

Se adoptará un diseño no experimental basado en el análisis retrospectivo de registros históricos de Cup&Cake. No se introducirán intervenciones deliberadas en la operación ni se asignarán grupos experimentales. La evaluación reproducirá situaciones de pronóstico mediante cortes cronológicos y utilizará exclusivamente información disponible hasta cada origen.

Se evaluarán la precisión del importe total semanal y la de su distribución porcentual. Para el importe total, la referencia primaria será el último valor semanal observado; se conservarán como comparadores el promedio móvil de cuatro semanas y, cuando exista cobertura suficiente, el ingenuo estacional de 52 semanas. Para la distribución se utilizará una referencia de participaciones históricas. Todos los métodos se evaluarán sobre fechas objetivo comunes; los ceros observados se distinguirán de la ausencia de registros.

Por consiguiente, el rigor del estudio proviene de la separación temporal estricta, la validación rolling-window (ventana deslizante) y la comparación homogénea contra referencias

reproducibles. Estos elementos permiten evaluar generalización predictiva en condiciones históricas, sin afirmar causalidad experimental.

3.5 Diseño evaluativo y comparación contra la línea base

El diseño cuantitativo, aplicado, no experimental y evaluativo se concretará mediante un estudio de caso longitudinal-retrospectivo. Los registros se organizarán cronológicamente y las decisiones de modelado se documentarán antes de examinar la evaluación final.

La comparación contrastará el modelo híbrido con las referencias monetarias y con sus componentes individuales; el procedimiento de distribución porcentual se contrastará con su propia referencia histórica. Se utilizarán las mismas fechas objetivo y horizontes para cada comparación. No se emplearán preprueba, posprueba ni grupos de control experimentales.

Se propone una validación de ventana deslizante con 52 semanas de entrenamiento y avance de una semana. Su viabilidad se verificará según la cobertura efectiva, los rezagos y el número de observaciones utilizables; cualquier ajuste se justificará en la etapa de desarrollo. Se generarán pronósticos directos para $h=1$, $h=2$, $h=3$ y $h=4$, con $h=1$ como horizonte principal. Las métricas se reportarán por horizonte. La suma de los cuatro pronósticos será un consolidado de cuatro semanas y no equivaldrá necesariamente a un mes calendario.

3.6 Según el tipo de inferencia

Otro tipo de clasificación se puede extraer a partir del método empleado a la hora de inferir cómo funciona la realidad.

De método deductivo

Este tipo de investigación se basa en el estudio de la realidad y la búsqueda de verificación o falsación de unas premisas básicas a comprobar. A partir de la ley general se considera que ocurrirá en una situación particular.

Atendiendo al proceso lógico empleado para inferir y estructurar el conocimiento sobre la realidad, la presente investigación se rige estrictamente por el **método deductivo**. Este enfoque inferencial se caracteriza por guiar el pensamiento de manera sistemática desde

premisas, leyes y teorías universales consolidadas hacia la verificación, contrastación o falsación de una proposición particular aplicable a un escenario específico.

En el marco de este estudio, el proceso deductivo parte de los fundamentos de los modelos de pronóstico y de la evidencia empírica sobre Small Data. La literatura científica indica que el desempeño de los modelos depende de la estructura de la serie, las variables disponibles, el tamaño de la muestra y el protocolo de evaluación. Por ello, no se presupone superioridad de los algoritmos de aprendizaje automático sobre los métodos estadísticos o las reglas empíricas.

Para contrastar H1, se comparará el modelo híbrido y el procedimiento de distribución porcentual con sus respectivos modelos de referencia, utilizando las mismas semanas y horizontes de evaluación y únicamente información disponible antes de cada pronóstico. Se evaluarán por separado el error del importe total semanal y el error de participación de los principales insumos. Los análisis con y sin variables exógenas tendrán carácter complementario y no constituirán una segunda hipótesis. La evidencia favorable deberá abarcar ambos componentes de H1; una mejora aislada en el importe total no será suficiente para respaldarla. El protocolo de contraste, las métricas principales y el tratamiento de comparaciones múltiples se especificarán antes de examinar el conjunto de evaluación final.

3.7 Temporalidad de la investigación

El estudio será longitudinal y retrospectivo porque analizará registros históricos en su secuencia temporal. Se revisarán las fuentes disponibles del periodo 2022–2026 y se documentarán las fechas efectivas de inicio y corte para ventas y compras, sin asumir cobertura completa. El modelado se limitará a los periodos cuya disponibilidad y continuidad puedan verificarse.

La incorporación de variables exógenas se controlará mediante un registro explícito de fuente, disponibilidad y rezago. El pipeline sólo admitirá predictores incluidos en dicho registro; cualquier variable exógena no documentada se bloqueará antes del modelado. El sistema de soporte a la decisión comunicará este inventario como condición para generar pronósticos futuros, evitando utilizar información que no esté disponible ex ante.

Para asegurar la reproducibilidad, las rutas de datos y resultados se resolverán desde la ubicación del proyecto, sin depender de una carpeta fija del equipo. Cada ejecución exportará un manifiesto con las huellas de las fuentes y del código, versiones de las bibliotecas, semilla aleatoria, parámetros de ventana y diccionario de variables. Este diccionario documentará la fuente, el rezago y la disponibilidad temporal de cada predictor; los indicadores publicados u observados se desplazarán para representar únicamente la información disponible antes del pronóstico.

Cuando se identifique una cola de semanas sin cobertura de compras, dichas semanas se tratarán como ausencia de observación y no como importes cero. Cualquier extensión sintética se almacenará en un archivo independiente, con una etiqueta de procedencia, semilla y método de generación. Sus valores podrán utilizarse únicamente en análisis de sensibilidad o pruebas técnicas del sistema de soporte a la decisión; se excluirán del ajuste, la selección de modelos, la evaluación fuera de muestra y el contraste de H1.

3.8 Procedimiento Metodológico

El procedimiento comprende recolección y depuración de registros, agregación semanal, diagnóstico temporal, ingeniería de características, selección de componentes e integración del modelo híbrido, estimación de la distribución porcentual, evaluación fuera de muestra y comunicación de resultados. El pipeline implementa una versión inicial de este flujo. La verificación técnica del software se distingue de la ejecución científica con datos reales, que permanece pendiente de aprobar fuentes, cobertura, catálogo y protocolo de evaluación.

3.8.1 Recolección y estructuración de los conjuntos de datos (*Datasets*)

Se recopilarán y estructurarán los registros históricos disponibles de Cup&Cake. Se verificará su integridad antes de asumir su utilidad para el modelado. La consolidación contemplará principalmente las siguientes fuentes:

1. Histórico de ventas con ingresos diarios.
2. Bitácoras de compra de materia prima.

Se homologarán fechas, identificadores de insumos e importes, documentando duplicados, devoluciones y registros incompletos. Las observaciones se agregarán por semana calendario con una regla uniforme de inicio y cierre. Se obtendrán la serie del importe total, las series monetarias por insumo y sus participaciones, además de predictores compatibles con la frecuencia semanal.

Auditoría de cobertura y construcción del panel semanal

La cobertura se determina con un calendario semanal y una tabla de evidencia revisada. Cada semana se distingue como observada, cero confirmado o desconocida; la ausencia de transacciones no se interpreta por sí sola como gasto cero. En la preparación acordada se completaron mediante promedio simple los huecos del tramo 2021-05-03 a 2024-04-29 para los archivos de ventas y compras de análisis. Esta serie completada se conserva como producto derivado y no sustituye los registros originales. Fuera del tramo autorizado, los periodos sin captura permanecen ausentes y se excluyen del ajuste cuando no hay evidencia suficiente.

El experimento usa evaluación temporal rolling-origin. La configuración aplicada fija una ventana de entrenamiento de 52 semanas, desplaza el origen cada tres semanas y pronostica horizontes directos de una a cuatro semanas. La corrida reciente reserva el tramo final definido por la configuración y registra los folds incompletos o no comparables, en lugar de completar sus valores. La selección interna del modelo ocurre antes de la evaluación final; los resultados finales no se reutilizan para escoger componentes.

Los diagnósticos no se utilizarán para contrastar H1. Su función será fundamentar la selección de rezagos, transformaciones y familias de modelos. Cualquier configuración derivada de estos resultados se ajustará exclusivamente con información anterior a cada origen de pronóstico, preservando la separación temporal y evitando fuga de información.

Cada corrida exporta panel semanal, periodos ausentes, imputaciones realizadas, coberturas, exclusiones, predicciones, métricas, figuras y manifiesto con huellas de las fuentes y del

código. Los diagnósticos exploratorios heredados y sus figuras permanecen identificados como antecedentes, no como evidencia producida por la corrida vigente.

3.8.2 Predictores de compras, ventas y calendario

Se examinará si los registros de compras de Cup&Cake presentan patrones temporales o asociaciones con eventos comerciales que puedan aportar información predictiva. Estas relaciones no se asumirán de antemano ni se equiparará el importe de compras con la demanda de productos. Las características candidatas se evaluarán dentro del conjunto de desarrollo.

El panel modelado incorpora características de compras y ventas agregadas semanalmente, antecedentes temporales y variables calendáricas. Las ventas se usan como predictor histórico: para cada origen solo se admiten los valores ya observables antes del pronóstico. La corrida más reciente registró como variables calendáricas disponibles los indicadores de semana de pago y semana festiva. No se consideran conocidas a futuro variables como ventas realizadas o condiciones observadas posteriormente. La inclusión de una fuente en el flujo no implica que cada columna haya sido seleccionada por todos los modelos.

3.8.3 Modelos de referencia y arquitectura híbrida

Se comparan referencias sencillas y modelos estadísticos y de aprendizaje automático, además de combinaciones híbridas. La selección se realiza por horizonte mediante validación temporal interna y con los mismos datos disponibles en cada origen.

- El componente estadístico contempla suavizamiento exponencial y ARIMA estacional/no estacional según la implementación, además de referencias como último valor, promedio móvil y persistencia estacional cuando la historia necesaria está disponible. La disponibilidad desigual de una referencia estacional se reporta; no se fuerza su resultado en folds sin suficientes observaciones.
- Los componentes de aprendizaje automático incluyen Ridge, Random Forest, HistGradientBoosting y una red neuronal perceptrón multicapa (MLP) de arquitectura

pequeña y semilla fija. Se evalúan tanto como predictores directos como en combinaciones residuales con ARIMA. La MLP se denomina red neuronal; no es una arquitectura recurrente RNN/LSTM.

- Las redes recurrentes RNN y LSTM no forman parte de esta versión. La red neuronal incluida es una MLP acotada, apropiada para el tamaño reducido de la muestra y evaluada bajo las mismas particiones temporales.

El híbrido integra pronósticos estadísticos y de aprendizaje automático mediante ponderación, y también evalúa corrección de residuos del componente ARIMA mediante aprendizaje automático. Se seleccionan familia, combinación y peso por horizonte con validación interna. Los pronósticos monetarios se restringen a valores no negativos; los fallos de ajuste quedan registrados y no se ocultan mediante sustituciones silenciosas.

El conjunto de categorías se define antes de evaluar. Se excluyen las categorías presupuestarias COMBUSTIBLE, MUEBLES, HERRAMIENTA, IMPUTADO, IMPUTADOS y OTROS. Los principales insumos se presentan individualmente y las categorías elegibles restantes se agrupan como RESTO_ELEGIBLE para que la asignación concilie con el total pronosticado. Esta categoría residual no equivale a la categoría presupuestaria OTROS, que está excluida.

La participación de cada categoría principal se calcula respecto del total semanal elegible, sin reescalar las categorías mostradas para que por sí solas sumen 100 %. La porción elegible no mostrada se informa como RESTO_ELEGIBLE. Las participaciones históricas se estiman con ponderación exponencial, cuyo parámetro se selecciona internamente. Las asignaciones monetarias se obtienen multiplicando cada participación por el total pronosticado y se reconcilian a centavos.

Como comparación de composición se utiliza el promedio de participaciones semanales observado en la historia de entrenamiento, únicamente en semanas con total positivo y composición definida. La estimación exige un mínimo de ocho semanas válidas; si no se alcanza, se registra la exclusión y no se crea una distribución arbitraria.

3.8.4 Validación temporal rolling-origin

La configuración aplicada utiliza 52 semanas de entrenamiento, avance de tres semanas y horizontes de una a cuatro semanas. La validación interna utiliza cinco orígenes para elegir componentes; la disponibilidad de historia y cobertura determina qué folds pueden calcularse. Los objetivos de la última partición interna preceden a la evaluación final para evitar contaminación temporal.

En cada origen, los modelos se entrenan únicamente con datos admisibles hasta esa fecha y producen pronósticos directos para cada horizonte. Las características históricas se recalculan respetando su fecha de disponibilidad. Solo se calculan métricas cuando el objetivo tiene captura utilizable; se informan tamaño de muestra y exclusiones por horizonte y modelo.

3.8.5 Métricas y criterios de comparación

La evaluación compara el importe semanal y la composición porcentual con referencias apropiadas para cada variable. La comparación principal utiliza los folds comunes; referencias con menor disponibilidad se muestran por separado con su número de casos. La corrida actual permite analizar el aporte predictivo de ventas como característica disponible, pero una afirmación causal no se deriva de correlaciones ni de la selección de variables.

- ***MAE (Error Absoluto Medio): medirá la magnitud promedio de los errores en el importe semanal de compras, sin considerar su dirección.***
- ***RMSE (Raíz del Error Cuadrático Medio): se utilizará como criterio principal para el importe total semanal; MAE será una medida complementaria. La evaluación de participaciones utilizará un criterio propio y no se combinarán directamente errores monetarios con errores porcentuales.***
- ***Se propone utilizar MASE como medida monetaria complementaria, con el denominador calculado exclusivamente en el conjunto de entrenamiento y una referencia ingenua explícita. Si el denominador es cero, se reportará como no***

definido. MAPE no será un criterio de selección y, si se presenta como diagnóstico, se indicarán las observaciones excluidas por importe cero.

La precisión de la distribución se evaluará mediante el error absoluto medio de las participaciones, expresado en puntos porcentuales. Se calculará por insumo y se presentará un promedio no ponderado entre las categorías previamente definidas. Las semanas con importe total observado igual a cero no tendrán una composición porcentual definida y se excluirán únicamente de esta métrica, informando su número; permanecerán en la evaluación monetaria cuando correspondan a ceros confirmados.

La evidencia estadística se interpreta considerando el número reducido de folds y la cobertura del registro. Los controles automatizados verifican consistencia del software y no sustituyen una prueba de hipótesis. La corrida reciente es exploratoria: los resultados descriptivos no bastan para declarar aceptada H1 ni para afirmar superioridad general del híbrido.

3.8.6 Comunicación del pronóstico para la planeación presupuestaria

El pipeline genera una salida local de soporte a decisiones con pronósticos semanales, participaciones, asignaciones por insumo, métricas y advertencias sobre la cobertura. El consolidado de cuatro horizontes representa 28 días, no necesariamente un mes calendario. Su utilidad es orientar la revisión del presupuesto, no emitir una orden de compra automática.

La herramienta no calcula cantidades físicas ni necesidades netas de inventario. Para ello se requerirían existencias, recetas, mermas, unidades homologadas y tiempos de entrega fiables, que no son variables completas del conjunto empleado.

4 DESARROLLO

Este capítulo documenta el desarrollo realizado para convertir los registros disponibles en un pronóstico semanal del importe de compras y su distribución presupuestaria. Se describen la preparación de datos, la cobertura, los predictores, los modelos, la evaluación temporal y los productos de la corrida real más reciente. Las salidas se interpretan con su fecha de corte; no se presentan como necesidades actuales cuando la fuente termina antes de la fecha de elaboración.

Contexto de los registros y objetivo operativo

Cup&Cake conserva información de compras en un sistema propio y un historial de ventas integrado en hojas de cálculo, incluidos reportes procedentes de KYTE. Para este desarrollo, las compras constituyen la variable objetivo y las ventas se incorporan como predictor histórico cuando sus valores son conocidos antes del origen de pronóstico. El propósito operativo es apoyar la reserva de presupuesto de abastecimiento, no automatizar órdenes ni calcular cantidades físicas.

Preparación de fuentes y cobertura semanal

La corrida utiliza Compras.xlsx, Ventas.xlsx y el archivo contextual indicado en la configuración. Se conservaron los archivos originales y se generaron paneles derivados. Las fechas se alinearon a semanas con inicio en lunes; los importes de compras se agregaron por semana y por categoría presupuestaria. La huella SHA-256 de las fuentes, el código, las versiones de bibliotecas y la configuración quedaron en el manifiesto de la ejecución.

Los huecos del tramo autorizado del 3 de mayo de 2021 al 29 de abril de 2024 se completaron mediante promedio simple en copias de análisis de compras y ventas; cada valor estimado se identifica en los productos de auditoría. El resto de los periodos sin captura permanece ausente. Una semana sin transacciones no se convierte automáticamente en cero semanal: se conserva la diferencia entre cero respaldado y cobertura desconocida. Cinco líneas con

importe \$0 fechadas el 28 de agosto de 2023 se mantuvieron como registros y se exportaron por separado.

El importe semanal objetivo y los promedios simples usados únicamente en el tramo autorizado se expresan en las ecuaciones (2.30) a (2.32). En ellas, C es el conjunto de categorías presupuestarias elegibles, O el conjunto de semanas observadas dentro del tramo autorizado y M sus semanas faltantes.


$$Y_t = \sum_{i \in C} X_{i,t} \quad (2.30)$$

$$\hat{X}_{i,t} = (1/|O_i|) \sum_{s \in O_i} X_{i,s}, \quad t \in M \quad (2.31)$$

$$\hat{V}_t = (1/|O_v|) \sum_{s \in O_v} V_s, \quad t \in M_v \quad (2.32)$$

La media de compras se calcula por categoría a partir de las semanas observadas; el total imputado es la suma de esas medias. En ventas se utiliza el promedio de la serie semanal observada. Estas estimaciones se guardan en archivos derivados y no sustituyen el panel original de evaluación.

Figura 33. Cobertura semanal de los registros de compras en la corrida real.



La figura presenta el estado semanal documentado por la auditoría. Las zonas desconocidas o inciertas no se interpretan como ausencia de gasto comprobada; la extensión del calendario no equivale a cobertura sustantiva completa.


Figura 34. Auditoría de registros de compra y decisiones de inclusión.



Construcción del panel y caracterización exploratoria


Se homologaron los registros, se aplicó el catálogo aprobado y se excluyeron antes de calcular el objetivo las categorías COMBUSTIBLE, MUEBLES, HERRAMIENTA, IMPUTADO, IMPUTADOS y OTROS. El panel semanal mantiene huecos desconocidos, documenta las semanas utilizables y registra las exclusiones. Los importes se expresan en MXN nominales.

Figura 35. Importes semanales de compras y periodos sin registro.



La serie muestra variación elevada y periodos discontinuos. Representa compras utilizables registradas, no una medida completa del gasto real durante semanas cuya cobertura no está verificada.

Figura 36. Distribución del importe semanal y frecuencia de ceros.




Las semanas con cero confirmado y las semanas sin captura se mantienen como estados distintos durante el análisis y la evaluación.

Integración de ventas y variables calendario

Las ventas se agregaron a frecuencia semanal y se alinearon con el calendario de compras. En cada origen se utilizaron únicamente antecedentes de ventas ya observados, evitando usar ventas realizadas después de la fecha de emisión. La corrida registró además indicadores de semana festiva y semana de pago. Variables observadas ex post, como ventas futuras o temperatura realizada, no se consideran conocidas por anticipado.

Figura 37. Ventas semanales registradas y periodos sin captura.



La coincidencia entre ventas y compras puede motivar análisis predictivo, pero no demuestra causalidad ni garantiza por sí misma una mejora del pronóstico.

Definición de categorías y distribución presupuestaria

La variable monetaria se construye con categorías elegibles después de excluir las seis categorías fuera de alcance. Los insumos principales se informan por separado. Las demás categorías elegibles se consolidan en RESTO_ELEGIBLE, que no equivale a la categoría presupuestaria OTROS. Las participaciones se calculan respecto del total elegible; el remanente se conserva en RESTO_ELEGIBLE para conciliar a 100 %. La distribución se

estima con participaciones históricas ponderadas exponencialmente y requiere al menos ocho semanas válidas de composición.

La participación presupuestaria y el remanente de categorías elegibles se definen en las ecuaciones (2.33) y (2.34). El promedio ponderado por antigüedad que utiliza la corrida se muestra en la ecuación (2.35).

$$p_{it} = X_{it} / Y_t \quad \text{si } Y_t > 0 \quad (2.33)$$

$$p^R_{it} = \max(0, 1 - \sum_{i \in K} p_{it}) \quad (2.34)$$

$$\hat{p}_i(T) = [\sum_{t \in \mathcal{V}_T} (1-\alpha)^{(T-t)} p_{it}] / [\sum_{t \in \mathcal{V}_T} (1-\alpha)^{(T-t)}] \quad (2.35)$$

Aquí K contiene las categorías principales mostradas, R representa RESTO_ELEGIBLE, V_t contiene semanas anteriores con composición definida y α es el parámetro de ponderación seleccionado internamente. La normalización conserva el remanente elegible sin redistribuirlo entre los insumos principales.

Figura 38. Composición porcentual observada durante el periodo de desarrollo.





Figura 39. Categorías principales consideradas para la asignación presupuestaria.



Modelos y validación temporal

Se compararon referencias empíricas, modelos estadísticos, métodos de aprendizaje automático y combinaciones híbridas. Los componentes incluyen suavizamiento exponencial, ARIMA, Ridge, Random Forest, HistGradientBoosting y una red neuronal MLP pequeña. También se evaluaron combinaciones ponderadas y corrección de residuos ARIMA mediante aprendizaje automático. La MLP es una red neuronal no recurrente; no se ejecutaron RNN ni LSTM.

La evaluación usa rolling-origin con 52 semanas de entrenamiento, avance cada tres semanas y horizontes directos de una a cuatro semanas. Cinco orígenes internos se utilizaron para seleccionar componentes por horizonte. La corrida final produjo seis folds observados por horizonte; los modelos estacionales de 52 semanas tuvieron menos folds comparables por disponibilidad. Las exclusiones y tamaños muestrales se reportan sin rellenar artificialmente los objetivos faltantes.

La combinación ponderada, la corrección residual ARIMA+MLP y la generación de orígenes rolling se formalizan en las ecuaciones (2.36) a (2.38).

$$\hat{y}_{t+h}^H = w_h \hat{y}_{tatt+h}^S + (1-w_h) \hat{y}_{t+h}^{ML} \quad (2.36)$$

$$\hat{y}_{t+h}^R = \max(0, \hat{y}_{t+h}^{ARIMA} + f^{MLP}(x_t)), \quad e_{t+h} = Y_{t+h} - \hat{y}_{t+h}^{ARIMA} \quad (2.37)$$

$$o_k = o_0 + 3k; \quad T_o = \{t : o-52 \leq t < o\}; \quad \text{objetivo} = Y_{o+h-1} \quad (2.38)$$

El peso w_h se escoge entre los candidatos internos para cada horizonte. En la alternativa residual, la MLP estima el error fuera de muestra del ARIMA y la predicción corregida no puede

ser negativa. Cada entrenamiento usa las 52 semanas calendario previas al origen; los objetivos ausentes no se rellenan para calcular las métricas.

Figura 40. Particiones temporales utilizadas para selección y evaluación.





Figura 41. Desempeño de las configuraciones consideradas en la validación interna.



La selección interna eligió SES+Random Forest para el horizonte 1, SES+HistGradientBoosting para el horizonte 2, ARIMA+MLP residual para el horizonte 3 y ARIMA+Random Forest residual para el horizonte 4. La elección no implica superioridad universal; el desempeño final se resume en la Tabla 13 y se analiza en Resultados.

Tabla 12. Etapas previas de trabajo y su uso en la corrida vigente.

Etapas previas	Qué se realizó	Aplicación vigente
Exploración de fuentes y cobertura	Se revisaron fuentes de compras, ventas y contexto y se ubicaron discontinuidades.	Se aplicó auditoría semanal explícita, diferenciando ceros y datos ausentes.
Preparación e imputación exploratoria	Se evaluaron criterios para completar huecos; se autorizó promedio simple solo en el tramo indicado.	Se preservan originales y se identifican los valores estimados en archivos derivados.
Variables candidatas	Se examinaron ventas, peso comercial, eventos, pedidos y clima.	La última corrida usa ventas históricas y calendarios disponibles ex ante; no implica selección universal de variables.
Alternativas de modelado	Se revisaron métodos estadísticos, de aprendizaje automático y estructuras híbridas.	Se comparan los candidatos en los mismos orígenes, incluida ARIMA+MLP.
Pruebas y demos	Se verificaron el flujo, la interfaz y salidas con ejercicios anteriores.	Las demos no se presentan como evidencia; la suite automatizada valida el código y no el desempeño predictivo.

Tabla 13. Configuración seleccionada y error del híbrido en la evaluación final.

Horizonte	Combinación seleccionada internamente	Folds	MAE	RMSE
h=1	ses + rf (peso estadístico 0.75)	6	\$386.43	\$521.60
h=2	ses + hgb (peso estadístico 0.75)	6	\$439.26	\$695.41
h=3	ss_arima111 + nn_residual__ss_arima111 (peso estadístico 0.75)	6	\$458.80	\$801.62
h=4	ss_arima111 + rf_residual__ss_arima111 (peso estadístico 0.75)	6	\$572.54	\$700.88

Asignación del presupuesto y controles de calidad

El pronóstico total de cada horizonte se distribuye entre insumos usando las participaciones estimadas. Para las próximas cuatro semanas se suman pronósticos semanales directos; el periodo representa 28 días, no necesariamente un mes calendario. La tabla siguiente presenta el total agregado y la participación monetaria de cada categoría elegible exportada por la corrida.

Las métricas monetarias y el consolidado de cuatro semanas se calculan conforme a las ecuaciones (2.39) a (2.41). El conjunto O_h contiene los orígenes evaluables comunes para el horizonte h ; D_o contiene solo pares de semanas calendario consecutivas observadas dentro del entrenamiento.

$$RMSE_h = \sqrt{[(1/|O_h|) \sum_{o \in O_h} (Y_{o+h-1} - \hat{Y}_{o,h})^2]}; \quad MAE_h = (1/|O_h|) \sum_{o \in O_h} |Y_{o+h-1} - \hat{Y}_{o,h}| \quad (2.39)$$

$$MASE_h = MAE_h / [(1/|D_o|) \sum_{t \in D_o} |Y_t - Y_{t-1}|] \quad (2.40)$$

$$B_4 = \sum_{h=1}^4 \hat{Y}_h; \quad p_{i,4} = (\sum_{h=1}^4 A_{i,h}) / B_4 \quad (2.41)$$

El RMSE, MAE y MASE se calculan por separado para cada horizonte; MASE no está definido si la escala de entrenamiento es cero. B_4 suma los cuatro pronósticos semanales directos y $p_{i,4}$ representa la participación de cada asignación A en el presupuesto acumulado de 28 días.

Figura 42. Asignación agregada del presupuesto pronosticado a cuatro semanas.





Tabla 14. Pronóstico agregado de cuatro semanas por categoría elegible.

Categoría / agrupación	Importe estimado (MXN)	Participación
HARINA	\$468.33	25.24%
BASES	\$354.84	19.12%
RESTO ELEGIBLE	\$249.75	13.46%
EMPAQUE	\$212.07	11.43%
HUEVO	\$108.38	5.84%
AMBIANTE	\$103.75	5.59%
CHANTILLY	\$96.81	5.22%
CHOCOLATE	\$87.08	4.69%
FONDANT	\$87.07	4.69%

Categoría / agrupación	Importe estimado (MXN)	Participación
DECORACION	\$56.74	3.06%
CAPACILLOS	\$24.28	1.31%
RELLENO	\$6.51	0.35%

Los controles automáticos verificaron conservación de huecos, conciliación de asignaciones, suma de participaciones, importes no negativos, reproducción de la emisión, generación de cuatro horizontes y exclusión de categorías fuera del objetivo. Todos quedaron aprobados. Estos controles verifican consistencia computacional, no precisión predictiva ni aceptación de la hipótesis.

Figura 43. Resultado de los controles de calidad del pipeline.



Alcance y trazabilidad de la corrida

La corrida `run_20260924T195600Z_86a6f5` finalizó correctamente y dejó métricas, predicciones, auditorías, asignaciones, figuras con datos de respaldo, tablero local y manifiesto con huellas digitales. Los artefactos son reproducibles a partir de la configuración y fuentes registradas.

El origen de emisión fue el 4 de agosto de 2025, pues los registros de compras utilizados llegan hasta el 28 de julio de 2025. El pronóstico de cuatro semanas es retrospectivo y no estima las necesidades del mes actual. Para apoyar decisiones contemporáneas se deben actualizar las compras y su cobertura documentada y volver a ejecutar el protocolo. La interpretación de los errores y su comparación con las referencias se desarrolla en Resultados.

5 RESULTADOS

La presente sección reporta la corrida empírica completa más reciente disponible, identificada como run_20260924T195600Z_86a6f5 y ejecutada el 24 de septiembre de 2026. Se utilizaron Compras.xlsx, Ventas.xlsx y el conjunto contextual de Tizayuca; la evaluación se refiere a importes nominales registrados y utilizables, no a una certificación de captura exhaustiva del gasto.

Calidad, cobertura e integración de datos

El panel cubrió semanas entre el 5 de diciembre de 2016 y el 11 de mayo de 2026. Para el tramo de tres años destinado a completar series (3 de mayo de 2021–29 de abril de 2024), el proceso identificó 128 semanas de compras observadas y estimó 29 semanas faltantes mediante promedio simple; en ventas se reportaron 157 semanas observadas y ninguna semana estimada. Las estimaciones se conservaron identificadas como tales. Los huecos fuera de ese tramo no se rellenaron y se mantuvieron como ausencia de captura, por lo que no se interpretaron como gasto cero.

En el objetivo monetario se excluyeron COMBUSTIBLE, MUEBLES, HERRAMIENTA, IMPUTADO/IMPUTADOS y OTROS. La composición incluyó 11 insumos principales y la categoría RESTO_ELEGIBLE para conciliar el total; esta última no equivale a OTROS. La auditoría de cobertura advierte que la presencia de transacciones no certifica que todos los movimientos de cada semana hayan sido capturados.

Las siete verificaciones automatizadas de la corrida resultaron aprobadas: conservación de huecos, reconciliación de asignaciones con el total, suma de participaciones, no negatividad, reproducción de la emisión, cuatro horizontes y exclusión de categorías fuera de alcance. No se encontraron registros pendientes de resolución en el archivo de pendientes de esta corrida.

Diseño efectivo de evaluación

Se configuró una ventana de entrenamiento de 52 semanas, avance de 3 semanas y horizontes de 1 a 4 semanas, con 20 semanas reservadas como bloque final. Debido a la disponibilidad de objetivos utilizables y al esquema de avance, la evaluación generó seis orígenes efectivos para cada horizonte (24 predicciones objetivo-horizonte); no deben confundirse con 20 folds. No hubo exclusiones de objetivos monetarios en esas seis predicciones por horizonte. Los benchmarks estacionales de 52 semanas sí tuvieron menos casos utilizables (2, 4, 4 y 2, respectivamente), por falta del rezago anual observado; se reportan aparte y no se comparan como si tuvieran la misma disponibilidad.

El ajuste interno utilizó cinco orígenes y seleccionó configuraciones por horizonte: SES + Random Forest (peso estadístico 0.75) para h=1; SES + HistGradientBoosting (0.75) para h=2; ARIMA estacional simplificado + red neuronal residual para h=3; y ARIMA estacional simplificado + Random Forest residual para h=4. Esta selección se efectuó en validación interna y no constituye por sí misma evidencia de superioridad en la evaluación externa.

Rendimiento comparativo del importe semanal

La tabla siguiente resume RMSE y MAE del ensamble denominado híbrido frente al método con menor RMSE entre los comparadores principales disponibles en las mismas fechas. El menor error observado no fue uniforme: el híbrido no obtuvo el menor RMSE en h=1, h=2 ni h=4; sí obtuvo el menor RMSE entre los comparadores principales en h=3. En h=3, la red neuronal residual tuvo menor MAE que el híbrido (420.998 frente a 458.797 MXN), aunque su RMSE fue ligeramente mayor (824.296 frente a 801.619 MXN).

Horizonte	Híbrido RMSE (MXN)	Híbrido MAE (MXN)	Menor comparador principal RMSE	RMSE (MXN)
1 semana	521.60	386.43	Random Forest	446.21
2 semanas	695.41	439.26	HistGradientBoosting	596.17
3 semanas	801.62	458.80	Híbrido	801.62
4 semanas	700.88	572.54	RF residual + ARIMA estacional	578.95

A través de horizontes, el RMSE del híbrido fue 521.60, 695.41, 801.62 y 700.88 MXN, mientras que su MAE fue 386.43, 439.26, 458.80 y 572.54 MXN. La comparación con el

promedio móvil de cuatro semanas y otros métodos aparece en las salidas completas, pero su disponibilidad se etiqueta por separado cuando no comparte exactamente el conjunto principal de fechas. MASE también se calculó; sus valores para el híbrido fueron 28.89, 7.94, 7.51 y 16.68. Como su escala se forma con diferencias observadas de semanas calendario consecutivas y existen huecos, debe leerse con cautela y junto a las métricas monetarias, no como una medida autónoma de éxito.




Figura 46. Errores monetarios por modelo y horizonte en la evaluación temporal. Fuente: salida del pipeline, corrida run_20260924T195600Z_86a6f5.

Distribución porcentual por insumo

La comparación composicional no identifica un único método dominante: la participación histórica fue mejor en los horizontes uno y cuatro, y el promedio temporal ponderado en los horizontes dos y tres. Esta alternancia sugiere que la composición puede cambiar con el horizonte y que una estructura de participaciones relativamente estable no debe suponerse sin evidencia. Los promedios de error fueron calculados sobre pocas observaciones válidas, de modo que pequeñas diferencias no deben interpretarse como superioridad estable.

La evaluación porcentual también tiene un dominio de aplicación distinto al monetario. Cuando el total elegible semanal es cero o falta captura, las participaciones no se definen o no son observables; excluir esos casos de la métrica composicional evita asignarles porcentajes

artificiales, pero reduce aún más la muestra. El MAE en puntos porcentuales facilita la lectura por insumo, aunque el error entre partes está sujeto a la restricción de que las participaciones sumen cien por ciento.

Horizonte	Participación histórica (MAE pp)	Promedio ponderado temporal (MAE pp)	Menor error
1	10.34	11.73	Histórica
2	7.14	6.93	Temporal ponderada
3	10.77	10.37	Temporal ponderada
4	11.80	12.23	Histórica




Figura 47. Error absoluto medio de participación por insumo, comparación de métodos y horizonte. Fuente: salida del pipeline, corrida run_20260924T195600Z_86a6f5.

En el pronóstico emitido desde el origen guardado del 4 de agosto de 2025, el total para las cuatro semanas fue de \$1,855.61 MXN nominales. Las mayores asignaciones fueron HARINA (25.24%; \$468.33), BASES (19.12%; \$354.84), RESTO_ELEGIBLE (13.46%; \$249.75) y EMPAQUE (11.43%; \$212.07). La suma de importes y participaciones se reconcilió con el total. Este pronóstico es una emisión histórica reproducible de esa corrida, no una estimación vigente para el mes actual ni una orden de compra.




Figura 48. Composición observada y estimada en la evaluación temporal. Fuente: salida del pipeline, corrida `run_20260924T195600Z_86a6f5`.

Contraste de hipótesis

La evaluación de H1 fue clasificada como retrospectiva exploratoria. Para el importe del horizonte principal ($h=1$) se obtuvieron seis pares; la diferencia media reportada fue 161,798.64 MXN², calculada como el error cuadrático del último valor menos el del híbrido (un valor positivo favorece al híbrido). El procedimiento no generó intervalo por muestra insuficiente frente al mínimo inferencial configurado. Para la composición se contó con tres pares válidos; la diferencia media fue -1.39 puntos porcentuales en la pérdida (error absoluto de participación del método histórico menos el del promedio temporal ponderado, por lo que un valor negativo favorece a este último), también sin intervalo. El criterio de evidencia favorable en ambos componentes no se cumplió y el resultado se marcó como no confirmatorio. En consecuencia, con esta corrida no se aprueba H1 ni se demuestra que el híbrido mejore conjuntamente el pronóstico monetario y la distribución porcentual; tampoco se concluye equivalencia o rechazo definitivo.

La Figura 49 muestra las diferencias de pérdidas para el contraste principal. La escasez de pares y la ausencia de intervalos válidos obligan a interpretar sus puntos como descriptivos, no como inferencia estadística concluyente.




Figura 49. Diferencias de pérdidas pareadas para H1 en el horizonte principal. Fuente: salida del pipeline, corrida `run_20260924T195600Z_86a6f5`.

Alcance de los resultados

La corrida demuestra que el flujo integra la limpieza y trazabilidad disponibles, produce comparaciones temporales a cuatro horizontes y genera una distribución que reconcilia con el total. En precisión, el desempeño favorable del híbrido dependió del horizonte y no dominó consistentemente a los métodos de referencia. La limitada cantidad de orígenes y de observaciones composicionales, las semanas sin captura, la imputación promedio en el tramo señalado y la falta de certificación de exhaustividad impiden generalizar el ranking o afirmar utilidad predictiva confirmatoria. La salida actual tampoco incorpora intervalos predictivos futuros.

6 DISCUSION

Interpretación de los hallazgos y contraste con antecedentes

La corrida aporta evidencia empírica para comparar el híbrido con referencias, pero no muestra una ventaja uniforme del híbrido en todos los horizontes ni en los dos componentes del objetivo. El hallazgo más defendible es la dependencia del desempeño respecto del horizonte, la métrica y la disponibilidad de observaciones; por tanto, no procede describir al híbrido como superior en términos generales.

Este patrón es compatible con la evidencia amplia de M4: las combinaciones pueden lograr resultados competitivos, pero ese resultado agregado no garantiza que una combinación determinada mejore en cada serie o contexto (Makridakis et al., 2018a, 2020). La M4 cubre numerosas series de dominios y frecuencias diversos, mientras que este estudio aborda importes semanales de una microempresa con huecos de captura. La comparación local debe interpretarse con sus propias condiciones y no como confirmación ni refutación directa de aquella competencia.

La variación entre horizontes también concuerda con el fundamento de combinar pronósticos: la ganancia potencial depende de que los componentes aporten información complementaria y de la relación entre sus errores (Bates & Granger, 1969). En esta corrida, el híbrido fue competitivo en el horizonte de tres semanas, pero no lideró el RMSE en los otros tres. La red neuronal residual tuvo menor MAE en ese mismo horizonte, aunque no menor RMSE. La divergencia entre métricas indica que la elección del criterio de precisión importa; con seis orígenes, sin embargo, no hay base suficiente para elegir un ganador robusto.

El resultado no contradice la motivación de Zhang (2003), quien planteó que ARIMA y una red neuronal pueden representar componentes lineales y no lineales complementarios. Sí precisa el alcance de esa motivación: la arquitectura es una hipótesis de modelado que debe validarse en los datos y horizontes concretos. En la presente evaluación no se observó una mejora consistente que permita atribuir al componente neuronal un beneficio general.

Las ventas se incorporaron como información histórica disponible mediante rezagos, pero esta corrida no incluyó un experimento de ablación controlado que compare el mismo procedimiento con y sin ventas. Por ello, no se puede atribuir a las ventas una reducción específica del error ni afirmar que expliquen por sí solas las compras. Su aporte sigue siendo una pregunta empírica para una comparación dedicada.

En relación con los objetivos, se construyó y caracterizó el panel semanal con las fuentes disponibles; se implementaron los componentes estadísticos, de aprendizaje automático y sus integraciones; se estimó la distribución porcentual y se contrastaron ambos procedimientos con referencias mediante evaluación temporal. El cumplimiento es, no obstante, exploratorio: la precisión observada no demuestra que el procedimiento responda con fiabilidad confirmatoria a la pregunta de investigación.

La selección interna produjo una combinación distinta para cada horizonte, lo que refleja que la utilidad de cada componente depende del plazo evaluado. Como la selección se hizo con cinco orígenes, esas configuraciones son candidatos empíricos del procedimiento, no arquitecturas universalmente óptimas ni evidencia independiente de que la complejidad adicional mejore el pronóstico.

Demanda intermitente y selección de métricas

La métrica monetaria incluyó los importes cero registrados como valores del objetivo. En cambio, las participaciones no se definieron cuando el total elegible fue cero o faltó observación válida; esos casos no aportan un porcentaje interpretable y su exclusión se refleja en el reducido número de pares composicionales.

Implicaciones operativas y financieras

Para la planeación presupuestaria, el procedimiento ofrece una estructura reproducible que distribuye un total pronosticado entre insumos y conserva la conciliación aritmética. Esta coherencia es una condición útil para presentar escenarios, pero no equivale a precisión ni garantiza que el monto cubra las compras reales. La magnitud de los errores monetarios frente

a los importes semanales observados aconseja utilizar la salida como referencia revisable, no como presupuesto autorizado automáticamente.

Además, el pronóstico de cuatro semanas presentado en Resultados corresponde a un origen histórico de agosto de 2025. Su valor ilustra el formato de asignación producido por la corrida, pero no debe usarse para decidir compras en 2026. Una aplicación operativa requiere actualizar datos, cobertura y fecha de emisión, y volver a ejecutar el flujo; actualmente no se reportan intervalos predictivos futuros que cuantifiquen la incertidumbre de cada asignación.

Validez y limitaciones

La interpretación está condicionada por el tamaño efectivo de la evaluación: seis orígenes por horizonte y entre tres y cinco observaciones válidas por horizonte para la composición. La prueba estacional anual tuvo menos casos por falta de rezagos observados; su rendimiento no es directamente comparable con el de los modelos evaluados en todos los orígenes. Asimismo, la escala de MASE se calculó con diferencias de semanas consecutivas observadas, por lo que los huecos del calendario afectan su lectura.

La imputación por promedio simple de 29 semanas de compras en el periodo especificado amplía la serie disponible, pero introduce valores estimados que suavizan la variabilidad y no reemplazan comprobantes faltantes. Aunque se mantuvieron separados de las observaciones originales, esta decisión forma parte del contexto de los resultados. La falta de certificación de captura exhaustiva impide asegurar que el objetivo represente la totalidad de las compras de cada semana; las conclusiones corresponden a importes registrados utilizables y a las categorías incluidas.

El diseño temporal reduce el riesgo de usar información futura para ajustar los modelos, pero la selección interna con cinco orígenes y la evaluación externa con pocos casos dejan incertidumbre sobre la estabilidad de las diferencias. El bootstrap configurado no produjo intervalos para H1 porque la muestra no alcanzó el mínimo fijado. Por ello, el resultado es no confirmatorio: no respalda la superioridad conjunta del híbrido, pero tampoco demuestra equivalencia ni permite un rechazo definitivo de la hipótesis.

Finalmente, la evidencia se limita a este caso, al periodo y a las fuentes examinadas. Una evaluación posterior deberá conservar un bloque final independiente, ampliar la captura de compras, comparar explícitamente la contribución incremental de ventas y otros predictores disponibles, y estimar intervalos predictivos antes de proponer un uso presupuestario más exigente.

7 CONCLUSIONES

La corrida evaluada muestra que el pipeline puede integrar compras, ventas y variables de calendario, generar pronósticos semanales de uno a cuatro pasos y distribuir el importe entre insumos con conciliación aritmética. Sin embargo, el híbrido no obtuvo el menor error en todos los horizontes: entre los comparadores principales, alcanzó el menor RMSE únicamente a tres semanas. Por tanto, la investigación no demuestra una ventaja general del modelo híbrido; la respuesta depende del horizonte y de la métrica.

El objetivo general se cumplió en cuanto al desarrollo y a la evaluación exploratoria del procedimiento, pero no en el sentido de demostrar una mejora confirmatoria de precisión para la planeación. La validación efectiva tuvo seis orígenes monetarios por horizonte y entre tres y cinco observaciones válidas para la composición. El análisis de H1 no alcanzó el tamaño mínimo requerido para estimar intervalos; en consecuencia, no hay evidencia suficiente para afirmar que el híbrido mejore conjuntamente el importe total y su distribución porcentual. Este resultado no equivale a probar que los métodos sean iguales ni a un rechazo definitivo de H1.

Respecto de los objetivos específicos, se depuraron y agregaron semanalmente las fuentes disponibles y se caracterizó el panel, manteniendo identificadas 29 semanas de compras estimadas por promedio simple en el tramo establecido y conservando los huecos restantes como ausencia de captura. Se implementaron combinaciones estadísticas y de aprendizaje automático, con información histórica de ventas y calendario disponible al origen; no se aisló mediante una prueba de ablación cuánto aporta cada predictor. También se estimaron y evaluaron participaciones históricas y ponderadas en el tiempo: su desempeño alternó entre horizontes, sin un método dominante en todos ellos. Finalmente, el contraste temporal frente a referencias se completó en carácter exploratorio, condicionado por la muestra reducida y la cobertura no certificada.

En términos de aplicación, la salida constituye un insumo de consulta y no una orden de compra. El pronóstico de cuatro semanas incluido en los resultados se emitió desde un origen histórico de agosto de 2025, por lo que no representa un presupuesto vigente. Para su uso

operativo se requiere actualizar la ingesta, verificar la cobertura y volver a emitir el pronóstico para la fecha de decisión correspondiente.

Recomendaciones

Antes de emplear el procedimiento para planear compras, se recomienda completar y documentar la auditoría de cobertura, resolver discrepancias de captura y revisar las semanas completadas por promedio simple con los registros primarios disponibles. Deben mantenerse trazables las categorías excluidas y la categoría RESTO_ELEGIBLE, que concilia insumos elegibles menores y no representa OTROS. Cada emisión debe indicar fecha de corte, periodo objetivo, horizonte, supuestos y carácter nominal de los importes.

La comparación futura debe conservar modelos de referencia y evaluación temporal, ampliar el número de orígenes válidos y fijar de antemano un bloque independiente para la evaluación final. Se recomienda contrastar el mismo modelo con y sin rezagos de ventas y con las variables exógenas que realmente estén disponibles en cada origen; así podrá estimarse su contribución incremental sin atribuirle por inferencia. La decisión de adopción debe permanecer bajo revisión humana hasta que el desempeño y la utilidad del tablero sean comprobados con la persona responsable del abastecimiento.

Trabajo futuro

El trabajo posterior deberá priorizar la ampliación de registros primarios de compras y ventas para reducir la proporción imputada y aumentar los periodos evaluables. Con una base más completa, será posible realizar una evaluación confirmatoria con suficientes orígenes y estimar intervalos predictivos para el importe total y las asignaciones por insumo. También será pertinente evaluar por separado el aporte de ventas, calendario y otras variables exógenas mediante experimentos de ablación temporal.

Una vez actualizada la fecha de corte, podrá revisarse la estabilidad de la selección por horizonte y validarse el tablero como herramienta de apoyo mediante pruebas de uso con la microempresa. Estas etapas permitirán determinar si la precisión observada es

suficientemente estable y útil para complementar la planeación presupuestaria, sin presuponer un beneficio financiero antes de medirlo.

GLOSARIO

Inteligencia Artificial (IA): Rama de la informática que diseña sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, como el aprendizaje, la planificación y la predicción.

Cadena de suministro: Conjunto de procesos involucrados en la producción, distribución y entrega de un producto desde su origen hasta el cliente final.

PYMES: Pequeñas y Medianas Empresas, generalmente caracterizadas por tener un número limitado de empleados y recursos, pero con alto potencial de innovación.

Agentes Inteligentes: Programas o sistemas que ejecutan acciones de manera autónoma para alcanzar objetivos específicos, basados en reglas o **aprendizaje automático**.

Pronóstico de demanda: Proceso de estimar la demanda futura de productos o servicios a través de datos históricos y modelos estadísticos o de **aprendizaje automático**.

REFERENCIAS

- Ab Karim, M. S., Ab Rahman, S., Chua, B. L., et al. (2020). The creative minds of extraordinary pastry chefs: an integrated theory of aesthetic expressions – a portraiture study. *International Journal of Contemporary Hospitality Management*, 32(9), 3015–3034. <https://doi.org/10.1108/IJCHM-04-2020-0329>
- Abrar, M., et al. (2024). An Explainable Multi-Channel Data Fusion Network for Demand Forecasting in Supply Chains. *Expert Systems with Applications*.
- Abrar, M., Shahriar, M. A., & Amin, A. (2024). MCDFN: Supply chain demand forecasting via an explainable multi-channel data fusion network model. arXiv preprint arXiv:2405.15598. <https://doi.org/10.48550/arXiv.2405.15598>
- Aitchison, J. (1982). The statistical analysis of compositional data. *Journal of the Royal Statistical Society: Series B (Methodological)*, 44(2), 139–160. <https://doi.org/10.1111/j.2517-6161.1982.tb01195.x>
- Akter, S., Wamba, S. F., Gunasekaran, A., Dubey, R., & Childe, S. J. (2019). How to improve firm performance using big data analytics capability and business strategy alignment. *Journal of Big Data*, 6(1).
- Alekseeva, L., Ginevičius, R., & Stankevičienė, J. (2021). Adoption of artificial intelligence technologies in SMEs: Evidence from Europe. *Sustainability*, 13(19), 10663. <https://doi.org/10.3390/su131910663>
- Alekseeva, L., Ginevičius, R., & Stankevičienė, J. (2021). Factors affecting artificial intelligence adoption in small and medium-sized enterprises. *Sustainability*, 13(21), 12156.
- Alekseeva, M., Gorbunova, N., y Parshina, E. (2021). Digital transformation of small and medium-sized enterprises: Barriers and opportunities. Springer.

- Aprodu, I., Banu, I., Vasilean, I., et al. (2025). The Digital Revolution in the Bakery Sector: A Systematic Review of Industry 4.0 Technologies. *Foods*, 14(2).
- Banco Interamericano de Desarrollo (BID). (2019). *Emprender en América Latina: aprendizajes y desafíos*. <https://www.iadb.org>
- Bates, J. M., & Granger, C. W. J. (1969). The combination of forecasts. *Operational Research Quarterly*, 20(4), 451–468. <https://doi.org/10.2307/3008764>
- Ben Abdallah, H., Ayadi, M., Boujelbene, Y. (2022). The main determinants and effects of product innovation: An exploratory study on the pastry companies of the region of Sfax (in Tunisia). *Technological Forecasting and Social Change*, 185, 122065. DOI: 10.1016/j.techfore.2022.122065.
- Bergmeir, C., & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191, 192-213. <https://doi.org/10.1016/j.ins.2011.12.028>
- Bertsimas, D., & Kallus, N. (2020). From predictive to prescriptive analytics. *Management Science*, 66(3), 1025–1044. <https://doi.org/10.1257/mnsc.2018.3243>
- Bertsimas, D., Dunn, J., & Pawlowski, C. (2021). Artificial intelligence for business decision support systems. *Decision Analytics Journal*, 1, 100003.
- Bontempi, G., Ben Taieb, S., & Le Borgne, Y.-A. (2013). Machine learning strategies for time series forecasting. En M. Aufaure & E. Zimányi (Eds.), *Business intelligence* (pp. 62–77). Springer. https://doi.org/10.1007/978-3-642-36318-4_3
- Borsato, M. (2023). “Edible Aesthetics”: Blurring Boundaries between Pastry and Art. *Humanities*, 12(5), 126. <https://doi.org/10.3390/h12050126>
- Box, G. E. P. (1976). Science and statistics. *Journal of the American Statistical Association*, 71(356), 791–799. <https://doi.org/10.1080/01621459.1976.10480949>

- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). Time series analysis: Forecasting and control (5th ed.). Wiley.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
<https://doi.org/10.1023/A:1010933404324>
- Brynjolfsson, E., & McElheran, K. (2016). The rapid adoption of data-driven decision-making. *American Economic Review*, 106(5), 133–139. <https://doi.org/10.1257/aer.p20161016>
- Brynjolfsson, E., Hitt, L. M., & Kim, H. H. (2011). Strength in numbers: How does data-driven decision making affect firm performance? *SSRN Electronic Journal*.
<https://doi.org/10.2139/ssrn.1819486>
- Cao, G., Duan, Y., Edwards, J. S., & Dwivedi, Y. K. (2025). Future trends in predictive analytics. *Analytics*, 4(1), Article 3. <https://doi.org/10.3390/analytics4010003>
- Cuevas-Vargas, H., Estrada, S., & Larios-Gómez, E. (2016). The effects of ICTs as innovation facilitators for a greater business performance. Evidence from Mexico. *Procedia Computer Science*, 91, 47–56. <https://doi.org/10.1016/j.procs.2016.07.040>
- Davenport, T. H., & Harris, J. G. (2007). *Competing on analytics: The new science of winning*. Harvard Business School Press.
- Dubey, R., Bryde, D., Blome, C., Roubaud, D., & Giannakis, M. (2021). Facilitating artificial intelligence powered supply chain analytics through alliance management during the pandemic crises in the B2B context. *Industrial Marketing Management*, 96, 135–146.
- Dubey, R., Gunasekaran, A., Childe, S. J., Bryde, D. J., Giannakis, M., & Foropon, C. (2021). Big data analytics and artificial intelligence pathway to operational performance under the effects of entrepreneurial orientation and environmental dynamism: A study of manufacturing organisations. *International Journal of Production Economics*, 226, 107599. <https://doi.org/10.1016/j.ijpe.2019.107599>

- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232. <https://doi.org/10.1214/aos/1013203451>
- García-Murillo, M., MacInnes, I., & Bauer, J. (2019). Techno-economic analysis of digital transformation in Latin American SMEs. *Telecommunications Policy*, 43(9). <https://doi.org/10.1016/j.telpol.2019.101820>
- García-Pérez, A., Ghio, A., Occhipinti, Z., & Verona, R. (2020). Knowledge management and intellectual capital in knowledge-based organisations: A review and theoretical perspectives. *Journal of Knowledge Management*, 24(7), 1719–1751. <https://doi.org/10.1108/JKM-12-2019-0682>
- García-Sánchez, A., Fernández, M., & Ruiz, P. (2023). Machine learning techniques for financial forecasting and decision support. *Revista Iberoamericana de Inteligencia Artificial*.
- Giannopoulos, P. G., Dasaklis, T. K., Tsantilis, I., & Patsakis, C. (2025). Machine learning algorithms in intermittent demand forecasting: A review. *International Journal of Production Research*, 1–43. <https://doi.org/10.1080/00207543.2025.2578701>
- Góngora Chonillo, J. T. (2023). Evaluación del riesgo financiero en microempresas a través de inteligencia artificial. *Revista Pulso Científico*, 1(2), 34–49. <https://doi.org/10.70577/rps.v1i2.10>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- Hewamalage, H., Bergmeir, C., & Bandara, K. (2021). Recurrent neural networks for time series forecasting: Current status and future directions. *International Journal of Forecasting*, 37(1), 388–427. <https://doi.org/10.1016/j.ijforecast.2020.06.008>
- Huber, J., & Stuckenschmidt, H. (2020). Daily retail demand forecasting using machine learning with emphasis on calendric special days. *International Journal of Forecasting*, 135, 113322. <https://doi.org/10.1016/j.ijforecast.2020.02.005>.
- Hübner, A., Kuhn, H., & Sternbeck, M. G. (2024). Sales and operations planning in retail and supply chains. Springer.

- Hübner, N., Caspers, J., Coroamă, V. C., & Finkbeiner, M. (2024). Machine-learning-based demand forecasting against food waste: Life cycle environmental impacts and benefits of a bakery case study. *Journal of Industrial Ecology*, 28, 1117–1131. <https://doi.org/10.1111/jiec.13528>
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>
- Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>
- Hyndman, R. J., Ahmed, R. A., Athanasopoulos, G., & Shang, H. L. (2011). Optimal combination forecasts for hierarchical time series. *Computational Statistics & Data Analysis*, 55(9), 2579–2589. <https://doi.org/10.1016/j.csda.2011.03.006>
- Hyndman, R. J., Athanasopoulos, G., Wang, E., & Wang, Y. (2023). Advances in business forecasting methods and applications. *Journal of Forecasting*.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2nd ed.). Springer.
- Kahneman, D. (2011). *Thinking, fast and slow*. Farrar, Straus and Giroux.
- Kahneman, D., & Tversky, A. (1974). Judgment under uncertainty: Heuristics and biases. *Science*, 185(4157), 1124–1131. <https://doi.org/10.1126/science.185.4157.1124>
- Kahneman, D., & Tversky, A. (1979). Prospect theory: An analysis of decision under risk. *Econometrica*, 47(2), 263–291. <https://doi.org/10.2307/1914185>
- Kantis, H., Federico, J., & García, S. (2020). Índice de condiciones sistémicas para el emprendimiento dinámico. Prodem.

Kuhn, M., & Johnson, K. (2013). *Applied predictive modeling*. Springer.

<https://doi.org/10.1007/978-1-4614-6849-3>

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018b). Statistical and machine learning forecasting methods: Concerns and ways forward. *PLOS ONE*, 13(3), e0194889. <https://doi.org/10.1371/journal.pone.0194889>

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018a). The M4 competition: Results, findings, conclusion and way forward. *International Journal of Forecasting*, 34(4), 802–808. <https://doi.org/10.1016/j.ijforecast.2018.06.001>

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1), 54–74. <https://doi.org/10.1016/j.ijforecast.2019.04.014>

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4), 1346–1364. <https://doi.org/10.1016/j.ijforecast.2021.11.013>

Martins-Turner, K., von Massow, M., O'Rourke, S., & Fraser, E. D. G. (2023). Machine learning based demand forecasting against food waste: Life cycle environmental impacts and benefits of a bakery case study. *Journal of Cleaner Production*, 384, 135539. <https://doi.org/10.1016/j.jclepro.2022.135539>

Mikalef, P., Boura, M., Lekakos, G., & Krogstie, J. (2019). Big data analytics capabilities and innovation: The mediating role of dynamic capabilities and moderating effect of the environment. *British Journal of Management*, 30(2), 272–298. <https://doi.org/10.1111/1467-8551.12343>

Mikalef, P., Krogstie, J., Pappas, I., & Pavlou, P. (2019). Investigating the effects of big data analytics capabilities on firm performance. *Information & Management*, 57(2), 103169.

- Minniti, M., & Bygrave, W. (2018). A dynamic model of entrepreneurial learning. *Entrepreneurship Theory and Practice*, 25(3), 5-16. <https://doi.org/10.1177/104225870102500301>
- Nonaka, I., & Takeuchi, H. (1995). *The knowledge-creating company: How Japanese companies create the dynamics of innovation*. Oxford University Press.
- OECD. (2021). *The digital transformation of SMEs*. OECD Publishing. <https://doi.org/10.1787/bdb9256a-en>
- OECD. (2022). *Financing growth and turning data into business: Helping SMEs scale up*. OECD Publishing. <https://doi.org/10.1787/81c738f0-en>
- Organización para la Cooperación y el Desarrollo Económicos (OCDE). (2022). *Financing growth and turning data into business: Helping SMEs scale up*. OECD Publishing. <https://doi.org/10.1787/81c738f0-en>
- Petropoulos, F., Makridakis, S., Assimakopoulos, V., & Nikolopoulos, K. (2020). Forecasting: Theory and practice in a changing world. *Forecasting*, 2(1), 15–28.
- Polanyi, M. (1966). *The Tacit Dimension*. Doubleday & Company.
- Poveda-Valverde, F., & Fierro Barragán, S. E. (2026). AI applications that can support sustainable practices in small and medium-sized enterprises in Latin America: A systematic review. *Sustainability*, 18(7), Article 3603. <https://doi.org/10.3390/su18073603>
- Power, D. J. (2002). *Decision support systems: Concepts and resources for managers*. Quorum Books.
- PraveenaSri, P., Padma, V., Muruguesan, R., & Usha, S. (2023). Business challenges of forecasting sales in the bakery industry: Applications of machine learning algorithms. <https://www.researchgate.net/publication/370666295>

- PraveenaSri, P., Padma, V., Muruguesan, R., & Usha, S. (2023). Business challenges of forecasting sales in the bakery industry: Applications of machine learning algorithms. ResearchGate Publication. <https://www.researchgate.net/publication/370666295>
- Provost, F., & Fawcett, T. (2013). Data science for business: What you need to know about data mining and data-analytic thinking. O'Reilly Media.
- Ramírez-Montoya, M. S., et al. (2022). Data-driven decision making and business intelligence in organizations. RISTI – Revista Ibérica de Sistemas y Tecnologías de Informação.
- Ries, E. (2017). *El método Lean Startup: Cómo crear empresas de éxito utilizando la innovación continua*. Deusto.
- Romero-Hidalgo, J. A., Isiordia-Lachica, P. C., Valenzuela, A., & Rodríguez-Carvajal, R. A. (2021). Knowledge and innovation management model in the organizational environment. *Information* (Switzerland), 12(6), 225. <https://doi.org/10.3390/info12060225>
- Saavedra-García, M., & Tapia-Sánchez, B. (2020). The role of information technologies in Mexican SMEs. *Contaduría y Administración*, 65(2). <https://doi.org/10.22201/fca.24488410e.2020.2215>
- Sánchez, M., & Terrazas, R. (2020). Inteligencia de negocios como herramienta para la toma de decisiones en PYMES mexicanas. *Contaduría y Administración*, 65(3). <https://doi.org/10.22201/fca.24488410e.2020.2314>
- Scuotto, V., Del Giudice, M., Tarba, S., & Bresciani, S. (2021). Digital technologies and SMEs' performance: The role of digital transformation. *Technological Forecasting and Social Change*, 173, 121139. <https://doi.org/10.1016/j.techfore.2021.121139>
- Shmueli, G. (2010). To explain or to predict? *Statistical Science*, 25(3), 289–310. <https://doi.org/10.1214/10-STS330>

- Shmueli, G., & Koppius, O. R. (2011). Predictive analytics in information systems research. *MIS Quarterly*, 35(3), 553–572. <https://doi.org/10.2307/23042796>
- Simon, H. A. (1997). *Administrative behavior: A study of decision-making processes in administrative organizations* (4th ed.). Free Press.
- Spiliotis, E., Makridakis, S., & Assimakopoulos, V. (2025). Continuous business forecasting in modern organizations. *Forecasting*, 7(1), 12–29. <https://doi.org/10.3390/forecast7010012>
- Spiliotis, E., Makridakis, S., Semenoglou, A. A., & Assimakopoulos, V. (2022). Comparison of statistical and machine learning methods for daily SKU demand forecasting. *Operational Research*, 22(3), 3037–3061. <https://doi.org/10.1007/s12351-020-00605-2>
- Syntetos, A. A., & Boylan, J. E. (2005). The accuracy of intermittent demand estimates. *International Journal of Forecasting*, 21(2), 303–314. <https://doi.org/10.1016/j.ijforecast.2004.10.001>
- Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: An analysis and review. *International Journal of Forecasting*, 16(4), 437–450. [https://doi.org/10.1016/S0169-2070\(00\)00065-0](https://doi.org/10.1016/S0169-2070(00)00065-0)
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1), 267–288. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>
- Verhoef, P. C., Broekhuizen, T., Bart, Y., Bhattacharya, A., Dong, J. Q., Fabian, N., & Haenlein, M. (2021). Digital transformation: A multidisciplinary reflection and research agenda. *Journal of Business Research*, 122, 889–901. <https://doi.org/10.1016/j.jbusres.2019.09.022>

- Viteri, C., & Murillo, D. (2022). Inteligencia de negocios para las organizaciones. *Revista Killkana Social*, 6(12). <https://doi.org/10.35381/R.K.V6I12.1291>
- Zhang, G. P. (2003). Time series forecasting using a hybrid ARIMA and neural network model. *Neurocomputing*, 50, 159–175. [https://doi.org/10.1016/S0925-2312\(01\)00702-0](https://doi.org/10.1016/S0925-2312(01)00702-0)
- Ordóñez Bolanos, A. A., Rojas, J. S., Gómez Gómez, J., & Ramírez-Gonzalez, G. (2023). Metodología basada en MLOps (Machine Learning Operations) para apoyo a la gestión en proyectos de ciencia de datos. *Revista Colombiana De Tecnologías De Avanzada*, 1(41), 87-103. <https://doi.org/10.24054/rcta.v1i41.2510>

Anexo A Diccionario de datos

Este diccionario describe los campos de Ventas.xlsx y Compras.xlsx, hoja Hoja1, y las variables principales de entrada y preparación del pipeline inspeccionadas el 13 de septiembre de 2026. Los encabezados se verificaron directamente. Los tipos indicados son los esperados para el análisis, no una certificación de limpieza; las definiciones no confirmadas se señalan expresamente. No se reproducen datos personales ni valores de transacciones.

7.1.1.1 Reglas comunes de interpretación

La existencia de un registro no prueba su integridad ni la cobertura de su semana. Cero, celda vacía y texto null tienen significados distintos: los valores cero se revisan con evidencia y los faltantes no se convierten automáticamente en ceros. Se observaron tipos mixtos y texto null en Ventas.xlsx. Antes de agregar se verificará si cada fila corresponde a una transacción, una línea o una repetición, y se documentará el tratamiento de devoluciones y cancelaciones.

Las fechas de inicio de captura provienen de la información histórica del negocio y no garantizan que los archivos inspeccionados contengan todo ese periodo. Los importes analíticos se expresarán en MXN nominales una vez confirmada la moneda y el alcance. Los campos administrativos y personales se excluyen del conjunto inicial de predictores. La disponibilidad temporal se comprobará antes de cada pronóstico; una fecha de operación no equivale por sí sola a fecha de disponibilidad.

7.1.1.2 Campos de origen de ventas

Campo exacto	Tipo esperado	Definición	Uso y validación
Number	Texto	Identificador registrado de la transacción.	Control; comprobar unicidad, no usar como predictor.
Status	Categoría	Estado registrado de la venta.	Validar categorías y criterio de inclusión; no asumir que todos los estados son ventas concluidas.

Campo exacto	Tipo esperado	Definición	Uso y validación
Fecha/Hora	Fecha y hora	Marca temporal del registro.	Convertir y contrastar con Fecha; no equivale necesariamente a fecha de disponibilidad.
Cantidad	Número	Cantidad consignada en la venta.	Unidad y diferencia respecto de Total de ítems pendientes de verificación.
Total de ítems	Número	Total de ítems consignado.	Verificar si cuenta unidades o líneas del pedido; no asumir equivalencia con Cantidad.
Descri. Items	Texto	Descripción de los productos de la transacción.	Descripción auxiliar; no se modela texto libre en la versión inicial.
Subtotal	Número monetario	Subtotal registrado antes de ajustes.	MXN por confirmar en origen; revisar conciliación, no sumar al Importe.
Descuento	Número	Descuento registrado.	Confirmar si expresa MXN o porcentaje antes de operar con él.
Tasa	Número	Campo de tasa del reporte.	Definición y unidad pendientes; no asumir importe de impuesto.
Envío	Número monetario	Cargo de envío registrado.	Confirmar inclusión en Importe; no duplicar cargos.
Importe	Número monetario	Importe registrado de la venta.	Candidato para agregado nominal semanal; validar concepto, moneda, ceros y estados.
Ganancia	Número	Campo de ganancia registrado.	Cálculo pendiente de verificación; no equivale a utilidad neta demostrada ni es objetivo del estudio.
Nombre	Texto	Nombre asociado al registro.	Rol pendiente de confirmar; dato potencialmente personal, excluido de predictores.
Vendedor	Texto categoría o	Responsable o canal consignado.	Dato administrativo; excluir identificadores personales del modelado.

Campo exacto	Tipo esperado	Definición	Uso y validación
Observación	Texto	Notas de la transacción.	Puede contener datos personales; no publicar valores ni usar como predictor inicial.
Fecha	Fecha	Fecha consignada sin hora.	Normalizar y contrastar con Fecha/Hora; definir fecha válida para agregación.
Año	Entero	Año consignado.	Contrastar con la fecha validada; preferir derivación consistente.
Mes	Entero	Mes consignado.	Valores esperados 1 a 12; contrastar con la fecha.
Día	Entero	Día del mes consignado.	Validar según mes y año.
Pastel	Indicador	Indicador de categoría pastel.	Se observaron 0, 1 y texto null; verificar codificación. No convertir null en 0.
Galletas	Indicador	Indicador de categoría galletas.	Se observaron 0, 1 y texto null; no prueba cantidades vendidas.
Otros	Indicador	Indicador de otros productos de venta.	No confundir con otros de la composición de compras; revisar null.
Cupcakes	Indicador	Indicador de categoría cupcakes.	Se observaron 0, 1 y texto null; verificar codificación.
Pedido	Texto	Referencia interna del pedido.	Contiene tipos mixtos; conservar como identificador y verificar relación con Number.
NumPedido	Texto	Número o referencia del pedido.	Comprobar relación con Pedido y Number; la unicidad no está garantizada.

7.1.1.3 Campos de origen de compras

Campo exacto	Tipo esperado	Definición	Uso y validación
PROVEEDOR	Texto	Proveedor consignado en la compra.	Control administrativo; no es predictor inicial.

Campo exacto	Tipo esperado	Definición	Uso y validación
FECHA	Fecha	Fecha registrada de adquisición.	Se homologa a fecha; fecha inválida genera incidencia.
NUMERO	Texto	Número consignado en el registro.	Significado y unicidad pendientes; no se presume clave única.
CANT	Número	Cantidad registrada de adquisición.	Interpretar junto con U#MEDIDA; no es variable objetivo.
U#MEDIDA	Texto o categoría	Unidad de medida registrada.	Homologación pendiente; no sumar cantidades de unidades diferentes.
DESCRIPCION	Texto	Descripción de lo adquirido.	Se homologa a descripcion y descripcion_normalizada; requiere catálogo aprobado.
MONTO	Número monetario	Importe registrado de la adquisición.	Se homologa a importe_nominal en MXN; verificar ceros, moneda y alcance. No asumir CANT por P#UNITARIO sin conciliación.
P#UNITARIO	Número monetario	Precio unitario registrado.	MXN por unidad consignada; definición y consistencia pendientes de revisión.
CLASIFICACION	Categoría	Clasificación de origen.	No sustituye automáticamente al insumo_id aprobado.
SUBCLASIFICACION	Categoría	Subclasificación de origen.	Homologar significado; uso auxiliar para revisar el catálogo.

7.1.1.4 Variables analíticas y controles del pipeline

Esta sección documenta contratos del código, no la aprobación de fuentes ni su incorporación efectiva. Los nombres entre signos angulares representan columnas dinámicas; los nombres agrupados identifican campos con la misma regla. Las participaciones se almacenan como proporciones y sus errores se reportan en puntos porcentuales. La inferencia futura no requiere importes observados de las semanas objetivo.

Campo o familia	Tipo unidad	y	Origen o regla	Uso y disponibilidad
fecha	Fecha		FECHA de compras normalizada al día.	Clave temporal; solo registros previos al origen alimentan características.
importe_nominal	Número en MXN		MONTO homologado en compras; importe semanal en contrato de ventas.	Objetivo monetario o predictor según tabla; inválidos no se sustituyen por cero.
descripcion	Texto		DESCRIPCION homologada.	Base del catálogo, no una categoría aprobada por sí misma.
descripcion_normalizada	Texto		Descripción normalizada mediante clean_upper.	Clave de enlace con catálogo; descripción vacía genera incidencia.
registro_id	Entero		Número de fila de origen contado desde 2.	Trazabilidad dentro del archivo y su hash; no identificador universal.
motivo	Texto		Resultado de revisión del registro.	Vacío significa sin incidencia detectada; no prueba cobertura completa.
semana_inicio	Fecha		Lunes de la semana de lunes a domingo.	Clave semanal; agregación después de aprobar cobertura.
insumo_id	Texto		Identificador asignado por catálogo aprobado.	No admite vacío ni nombres reservados total u otros.
aprobado	Booleano		Aprobación de la correspondencia de catálogo.	El código admite true o 1; requiere decisión documentada.
estado	Categoría		Condición de cobertura semanal.	observada o cero_confirmado para datos reales; desconocida o incompleta bloquean el intervalo. Ver nota de procedencia.
evidencia	Texto		Sustento de la revisión de cobertura.	Obligatorio; debe justificar la clasificación semanal.
fecha_revision	Fecha		Fecha de revisión de cobertura.	Obligatoria; no equivale a available_at de un predictor.

Campo o familia	Tipo y unidad	Origen o regla	Uso y disponibilidad
registros_detectados	Entero	Conteo de filas por semana en plantilla.	Cero no confirma ausencia de compras; no establece cobertura.
total	Número en MXN	Suma de importes semanales por insumo.	Objetivo monetario nominal; cero solo interpretable con cobertura validada.
<insumo_id>	Número en MXN	Columnas dinámicas del panel, una por insumo.	Importe semanal agregado; nombres determinados por catálogo, no columnas literales fijas.
otros	MXN o proporción	Residual de insumos no seleccionados, según matriz.	No confundir con Otros de ventas; distinguir matriz de importes de matriz de participaciones.
Participación por insumo	Proporción de 0 a 1	Importe del insumo dividido entre total positivo.	Matriz con columnas por insumo; total cero implica no definido. Multiplicar por 100 solo para porcentaje.
lag_1, lag_2, lag_4, lag_8, lag_12	Número en MXN	Totales de semanas previas al origen.	Predictores; sufijo indica distancia semanal. No usar valores objetivo futuros.
media_4, media_8, media_12	Número en MXN	Media de las últimas semanas cerradas.	Ventana indicada por sufijo; requiere historia anterior al origen.
desv_4, desv_8, desv_12	Número en MXN	Desviación estándar muestral de las semanas previas.	Mismas ventanas que las medias; un solo dato no define dispersión muestral.
cal_sin, cal_cos	Número de -1 a 1	Codificación cíclica de semana objetivo.	Calendario conocido; periodo del código 52.1775 semanas.
ventas_lag_1, ventas_lag_4	Número en MXN	Importe semanal de ventas rezagado.	Opcional; solo si available_at no es posterior al origen; de otro modo faltante.
available_at	Fecha y hora	Momento de disponibilidad de ventas o exógenas.	Debe ser anterior o igual al origen. Ventas semanales: no antes del cierre.
variable	Texto	Nombre de variable exógena.	Obligatorio en contrato opcional; no implica fuente incorporada.

Campo o familia	Tipo y unidad	Origen o regla	Uso y disponibilidad
fecha_referencia	Fecha	Periodo al que corresponde una exógena.	No confundir con fecha de publicación o disponibilidad.
valor	Número	Valor de variable exógena.	Finito; unidad específica a documentar por variable antes de incorporarla.
fuelle, version	Texto	Procedencia y versión de la exógena.	Obligatorias; permiten controlar revisiones de datos.
tipo	Categoría	observada, pronostico o calendario.	Una observación futura no se etiqueta como disponible; pronósticos requieren archivo previo.
exog_<variable>	Número	Valor exógeno admisible en el origen.	Pronóstico o calendario para la fecha objetivo; en su defecto última observación previa; ausente queda faltante.
es_sintetico	Booleano	Indicador de procedencia sintética.	Control, nunca resultado real; la existencia del campo no autoriza usar esos datos.
metodo_sintesis	Texto	Método declarado de generación sintética.	Metadato condicional del código; exige aprobación separada y no acredita observación real.

Nota de procedencia. El código inspeccionado contempla de manera condicional el estado sintetica_entrenamiento y campos de síntesis sujetos a aprobación y corte temporal. Su descripción no aprueba ni incorpora datos sintéticos al estudio. Esas observaciones no deben etiquetarse como reales ni utilizarse como evidencia de evaluación; cualquier diferencia entre el código y el protocolo científico deberá resolverse antes de la corrida definitiva.

Fuente. Elaboración propia a partir de los encabezados de datasets/xlsx/Ventas.xlsx y datasets/xlsx/Compras.xlsx, de los módulos data.py, features.py y composition.py del pipeline y de la información histórica proporcionada sobre Cup&Cake. Las equivalencias semánticas y unidades marcadas como pendientes requieren revisión de la documentación de origen antes de aprobar el conjunto analítico.