



**MODELO HÍBRIDO ESTADÍSTICO Y DE APRENDIZAJE AUTOMÁTICO PARA EL
PRONÓSTICO Y LA DISTRIBUCIÓN DEL PRESUPUESTO SEMANAL DE
ABASTECIMIENTO: ESTUDIO DE CASO EN UNA MICROEMPRESA DE REPOSTERÍA
CREATIVA EN TIZAYUCA, HIDALGO**

**TESIS PARA OBTENER EL GRADO DE MAESTRO EN
INTELIGENCIA ARTIFICIAL**

PRESENTADA POR:

RODRIGO ADRIÁN MARTÍNEZ FLORES

**DIRECTOR DE TESIS:
LUIS EDUARDO URBAN RIVERO**

Tolcayuca, Hidalgo, septiembre de 2026.

DEDICATORIA

A mi amada esposa, mi compañera de vida, mi mejor complemento, quien me ha impulsado para alcanzar cada nuevo reto.

A mis hijos que han sido inspiración avanzar en mi formación académica y que con su espontaneidad han llenado mi vida de entusiasmo por seguir adelante.

A mis padres que siempre me han apoyado.

AGRADECIMIENTOS

A la Universidad Politécnica Metropolitana de Hidalgo

ÍNDICE

RESUMEN	14
ABSTRACT	15
1. INTRODUCCIÓN.....	16
1.1 Estado del Arte	18
1.1.1 Aplicaciones de la inteligencia artificial en la cadena de suministro	18
1.1.2 Modelos de aprendizaje automático para el pronóstico de demanda.....	18
1.1.3 Demanda intermitente, <i>small data</i> y comparación de modelos	19
1.1.4 La repostería creativa como sector económico especializado	20
1.1.5 Innovación y transformación digital en la industria pastelera	21
1.1.6 Adopción de inteligencia artificial en microempresas	22
1.1.7 Investigaciones en México y América Latina.....	23
1.1.8 Síntesis del estado del arte y vacío de investigación	28
1.2 El planteamiento del problema	29
1.2.1 Contexto del caso de estudio	30
1.2.2 Pregunta de Investigación	31
1.2.3 Objetivo	31
1.3 Justificación	32
1.4 Hipótesis.....	34

2	MARCO TEÓRICO	36
2.1	Microempresa y planeación del presupuesto de abastecimiento	36
2.1.1	Recursos de información y conocimiento del negocio.....	36
2.1.2	Pronóstico como información para decidir.....	36
2.2	Compras monetarias y contexto de la repostería	37
2.2.1	Delimitación de la variable objetivo	37
2.2.2	Agregación del importe y niveles de análisis.....	38
2.3	Series temporales semanales y calidad de los registros	38
2.3.1	Frecuencia y continuidad.....	38
2.3.2	Nivel tendencia y estacionalidad	39
2.3.3	Estacionariedad y dependencia temporal	39
2.3.4	Intermitencia y valores extremos.....	40
2.4	Métodos estadísticos y de aprendizaje automático	41
2.4.1	Referencias simples	41
2.4.2	Suavizamiento exponencial y ARIMA.....	41
2.4.3	Bosques aleatorios y potenciación de gradiente	42
2.4.4	Redes neuronales y alcance de los comparadores.....	43
2.5	Fundamentos de integración del modelo híbrido.....	43
2.5.1	Combinación de pronósticos	43

2.5.2	Integración mediante componentes	44
2.6	Distribución porcentual y coherencia de las asignaciones	45
2.6.1	Participaciones como datos composicionales	45
2.6.2	Desagregación del pronóstico total	46
2.6.3	Representación relativa de las participaciones	46
2.7	Datos limitados e ingeniería de características	47
2.7.1	Complejidad y capacidad de generalización	47
2.7.2	Penalizaciones y selección de variables	47
2.7.3	Predictores temporales y calendario	48
2.7.4	Disponibilidad de variables exógenas	49
2.8	Evaluación temporal y métricas de precisión	49
2.8.1	Origen del pronóstico y ventana de entrenamiento	49
2.8.2	Error monetario del importe total	50
2.8.3	Escalamiento y límites de errores porcentuales	50
2.8.4	Error de participaciones y evaluación conjunta	51
2.9	Inteligencia de negocios y comunicación del pronóstico	52
2.9.1	Presentación del presupuesto y su incertidumbre	52
2.9.2	Adopción y límites operativos	52
2.10	Síntesis de fundamentos y relación con la hipótesis	53

3	METODOLOGÍA.....	54
3.1	Tipo de investigación según el objetivo de esta	54
3.2	Según el alcance evaluativo del estudio.....	54
3.3	Según el tipo de datos empleados	55
3.4	Según el grado de manipulación de las variables	56
3.5	Diseño evaluativo y comparación contra la línea base	57
3.6	Según el tipo de inferencia	57
3.7	Temporalidad de la investigación	58
3.8	Procedimiento metodológico	59
3.8.1	Recolección y estructuración de los conjuntos de datos (<i>Datasets</i>).....	59
	Auditoría de cobertura y construcción del panel semanal	59
3.8.2	Predictores de compras, ventas y calendario	60
3.8.3	Modelos de referencia y arquitectura híbrida	61
3.8.4	Validación temporal <i>rolling window</i>	62
3.8.5	Métricas y criterios de comparación	63
3.8.6	Comunicación del pronóstico para la planeación presupuestaria.....	64
	Consideraciones éticas y tratamiento de datos	64
4	DESARROLLO	65
	Contexto de los registros y objetivo operativo	65

Preparación de fuentes y cobertura semanal	65
Construcción del panel y caracterización exploratoria	67
Integración de ventas y variables calendario	68
Definición de categorías y distribución presupuestaria	69
Modelos y validación temporal	71
Asignación del presupuesto y controles de calidad	74
Alcance y trazabilidad de la corrida	76
5 RESULTADOS	77
Calidad, cobertura e integración de datos	77
Análisis de sensibilidad de la imputación	77
Diseño efectivo de evaluación	78
Rendimiento comparativo del importe semanal	79
Distribución porcentual por insumo	80
Contraste de hipótesis	82
Alcance de los resultados	83
6 DISCUSIÓN	84
Interpretación de los hallazgos y contraste con antecedentes	84
Demanda intermitente y selección de métricas	85
Implicaciones operativas y financieras	85

Validez y limitaciones	86
7 CONCLUSIONES	88
Recomendaciones.....	89
Trabajo futuro	89
GLOSARIO	91
REFERENCIAS	92
Anexo A Diccionario de datos	97
Anexo B Paquete de reproducibilidad.....	102

ÍNDICE DE TABLAS

Tabla 1. Investigaciones relevantes sobre inteligencia artificial, analítica de datos y adopción tecnológica en la gestión empresarial.....	25
Tabla 2. Etapas previas de trabajo y su uso en la corrida vigente.	73
Tabla 3. Configuración seleccionada y error del híbrido en la evaluación final.....	73
Tabla 4. Pronóstico agregado de cuatro semanas por categoría elegible.	75
Tabla 5. Sensibilidad de las métricas monetarias a la configuración de imputación.....	78

ÍNDICE DE IMÁGENES

Figura 1. Cobertura semanal de los registros de compras en la corrida real.....	66
Figura 2. Auditoría de registros de compra y decisiones de inclusión.	67
Figura 3. Importes semanales de compras y periodos sin registro.	67
Figura 4. Distribución del importe semanal y frecuencia de ceros.	68
Figura 5. Ventas semanales registradas.....	69
Figura 6. Composición porcentual observada durante el periodo de desarrollo.	70
Figura 7. Categorías principales consideradas para la asignación presupuestaria.	71
Figura 8. Particiones temporales utilizadas para selección y evaluación.	72
Figura 9. Desempeño de las configuraciones consideradas en la validación interna.	73
Figura 10. Asignación agregada del presupuesto pronosticado a cuatro semanas.....	75
Figura 11. Resultado de los controles de calidad del pipeline.	76
Figura 12. Errores monetarios por modelo y horizonte en la evaluación temporal.	79
Figura 13. Error absoluto medio de participación por insumo, comparación de métodos y horizonte. Fuente: salida del pipeline, corrida run_20260924T195600Z_86a6f5.	81
Figura 14. Composición observada y estimada en la evaluación temporal. Fuente: salida del pipeline, corrida run_20260924T195600Z_86a6f5.	82
Figura 15. Diferencias de pérdidas pareadas para H1 en el horizonte principal. Fuente: salida del pipeline, corrida run_20260924T195600Z_86a6f5.	83

RESUMEN

Esta investigación desarrolló y evaluó un modelo híbrido que integra métodos estadísticos y de aprendizaje automático para estimar el importe total semanal de compras y su distribución porcentual entre los principales insumos de Cup&Cake, microempresa de repostería creativa de Tizayuca, Hidalgo. Se integraron registros de compras, ventas y variables de calendario disponibles entre el 5 de diciembre de 2016 y el 11 de mayo de 2026. La evaluación final comprendió objetivos entre el 24 de marzo y el 28 de julio de 2025 y utilizó validación temporal rolling window, una ventana de entrenamiento de 52 semanas, avance de tres semanas y horizontes de una a cuatro semanas.

La evaluación produjo seis orígenes monetarios por horizonte y entre tres y cinco observaciones válidas por horizonte para la composición. El modelo híbrido obtuvo RMSE de 521.60, 695.41, 801.62 y 700.88 MXN para los horizontes de una a cuatro semanas, respectivamente, y solo alcanzó el menor RMSE entre los comparadores principales en el horizonte de tres semanas. En la distribución porcentual no existió un método dominante. Un análisis de sensibilidad sin parámetros de imputación reprodujo exactamente métricas, selecciones, predicciones, particiones y contraste de H1; por tanto, las 29 semanas estimadas se conservaron solo como artefactos de auditoría y no intervinieron en el modelado. Debido a la muestra reducida y a la cobertura no certificada, el contraste de H1 fue no confirmatorio. El procedimiento constituye una aportación reproducible de carácter evaluativo exploratorio y un apoyo revisable para la planeación, no una orden automática de compra.

Palabras clave: aprendizaje automático, pronóstico de compras, presupuesto de abastecimiento, microempresa, series temporales, modelo híbrido, validación temporal.

ABSTRACT

This study developed and evaluated a hybrid model combining statistical and machine-learning methods to estimate the total weekly purchasing amount and its percentage allocation among the main inputs of Cup&Cake, a creative baking microenterprise in Tizayuca, Hidalgo, Mexico. Purchase, sales, and calendar records available from December 5, 2016, to May 11, 2026, were integrated. The final evaluation covered targets from March 24 to July 28, 2025, and used rolling-window temporal validation, a 52-week training window, a three-week step, and one- to four-week horizons.

The evaluation produced six monetary forecast origins per horizon and between three and five valid composition observations per horizon. The hybrid model obtained RMSE values of MXN 521.60, 695.41, 801.62, and 700.88 for horizons one through four, respectively, and achieved the lowest RMSE among the main comparators only at the three-week horizon. No single percentage-allocation method dominated. A sensitivity run without imputation parameters reproduced the metrics, selections, predictions, partitions, and H1 assessment exactly; therefore, the 29 estimated weeks remained audit-only artifacts and did not enter model fitting or evaluation. Because of the small evaluation sample and uncertified record coverage, the H1 assessment was non-confirmatory. The procedure is presented as a reproducible exploratory evaluation and a revisable planning aid, not as an automated purchasing order.

Keywords: machine learning, purchasing forecast, procurement budget, microenterprise, time series, hybrid model, temporal validation.

1.INTRODUCCIÓN

Un emprendimiento surge cuando una persona identifica una oportunidad para ofrecer un producto o servicio y organiza recursos para desarrollarla. El Global Entrepreneurship Monitor 2023/2024 sitúa la actividad emprendedora como un componente de la salud de las economías y analiza las condiciones que favorecen o limitan su desarrollo (Global Entrepreneurship Monitor, 2024).

Los emprendimientos o microempresas enfrentan desafíos de planeación y aprendizaje durante sus primeras etapas. Minniti y Bygrave (2001) explican que el proceso emprendedor es dinámico y se nutre del aprendizaje derivado de la interacción con el entorno y de las decisiones bajo incertidumbre. Ries (2017), desde la perspectiva lean startup, describe la validación iterativa de supuestos y el ajuste del modelo de negocio mediante experimentación.

La Organización para la Cooperación y el Desarrollo Económicos documenta brechas de digitalización y capacidades en las pequeñas empresas, las cuales limitan el aprovechamiento sistemático de información para gestionar el negocio (OCDE, 2021). Las consecuencias específicas de esas brechas sobre el pronóstico de compras y el inventario deben evaluarse en cada contexto. Kantis, Federico y García (2020) señalan que las capacidades de gestión durante las etapas tempranas influyen en la organización interna, el uso de recursos y las posibilidades de crecimiento.

Cuando un producto o servicio obtiene aceptación en el mercado aparecen nuevos retos de coordinación, capacidad y planeación. El aprendizaje emprendedor puede desarrollarse de manera progresiva conforme se toman decisiones y se recibe información del entorno (Minniti y Bygrave, 2001). Los efectos concretos sobre desperdicio, productividad y compras requieren evidencia propia del sector y del negocio analizado.

Las microempresas constituyen la mayoría de las unidades económicas de México. Los resultados oportunos de los Censos Económicos 2024 indican que en 2023 operaron 5,451,113 unidades económicas del sector privado y empresas paraestatales; 95.5% eran

microempresas y empleaban 41.5% del personal ocupado (INEGI, 2025). Estas cifras delimitan su importancia económica, pero no demuestran por sí mismas limitaciones específicas en planeación financiera, inventarios o cadena de suministro.

Las pequeñas empresas presentan brechas de adopción digital y de capacidades para aprovechar tecnologías avanzadas (OCDE, 2021). La magnitud de esas brechas y sus efectos sobre decisiones de compras, inventarios e ingresos varían según el país, el sector y la empresa. Por ello, la utilidad de herramientas analíticas para una microempresa de repostería debe evaluarse con datos del caso, sin atribuir a la OCDE una proporción no documentada.

Una planificación inadecuada de la demanda en el sector de panadería puede generar niveles significativos de merma, con tasas de devolución que oscilan entre el 1.5% y el 19%, lo cual tiene implicaciones económicas y operativas relevantes para las empresas del sector (Hübner et al., 2024). En cuanto a la comparación de métodos, la evidencia de competencias de pronóstico muestra que una mayor complejidad no garantiza una precisión superior y que el desempeño debe evaluarse fuera de muestra para cada contexto (Makridakis et al., 2018a; Spiliotis et al., 2025).

La literatura reciente muestra que los modelos de aprendizaje automático pueden capturar relaciones no lineales, estacionalidad y variables externas; sin embargo, su desempeño frente a los métodos estadísticos depende de las características de la serie, la disponibilidad de datos, el horizonte de pronóstico y el protocolo de evaluación (**Makridakis et al., 2018; Spiliotis et al., 2022**).

Frente a este escenario, el aprendizaje automático (*ML* por sus siglas en inglés, *Machine Learning*) como rama de la Inteligencia Artificial ha emergido como herramienta clave para transformar la planeación financiera y la gestión de la cadena de suministro.

1.1 Estado del Arte

1.1.1 Aplicaciones de la inteligencia artificial en la cadena de suministro

El uso de la inteligencia artificial (IA) en la cadena de suministro ha demostrado ser una herramienta eficaz para mejorar la eficiencia operativa y la toma de decisiones, especialmente en industrias con productos perecederos. Distintos estudios han explorado su aplicación desde enfoques variados, ofreciendo evidencia empírica, conceptual y técnica que fundamenta su utilidad en contextos empresariales.

Hübner et al. (2024) analizaron la implementación del servicio de aprendizaje automático *Foodforecast* en panaderías de Alemania. El estudio aplicó una evaluación de ciclo de vida y comparó los impactos directos del sistema con los beneficios asociados a la reducción de devoluciones de productos de panadería. Los autores reportaron una reducción promedio de 30% en devoluciones durante 2022, según los informes de ventas utilizados. El trabajo aporta evidencia sobre reducción de desperdicio e impactos ambientales, pero no realiza una evaluación independiente del error de pronóstico.

Sin embargo, el modelo *Foodforecast* presenta como limitación el hecho de que fue desarrollado en organizaciones con infraestructura tecnológica avanzada, lo cual dificulta la extrapolación de sus resultados a microempresas con recursos limitados.

1.1.2 Modelos de aprendizaje automático para el pronóstico de demanda

Huber y Stuckenschmidt (2020) desarrollaron un estudio orientado al pronóstico diario de ventas en el sector minorista, utilizando algoritmos de aprendizaje automático capaces de incorporar variables calendáricas y eventos especiales. La metodología consistió en comparar distintos modelos predictivos utilizando datos históricos de ventas de una cadena comercial. Los resultados evidenciaron que los modelos de aprendizaje automático lograron mejorar la precisión de los pronósticos, especialmente en periodos asociados a eventos especiales o festividades.

En la literatura reciente también se observa un creciente interés por el desarrollo de modelos híbridos y técnicas avanzadas de predicción. Un ejemplo de ello es el estudio de **Abrar et al. (2024)** quienes propusieron un modelo híbrido denominado *Multi-Channel Data Fusion Network (MCDNF)* para el pronóstico de la demanda en cadenas de suministro. Este modelo integra redes neuronales convolucionales, redes LSTM y mecanismos de interpretabilidad basados en inteligencia artificial explicable (XAI). Los resultados del estudio evidencian una mejora significativa en la precisión de los pronósticos.

1.1.3 Demanda intermitente, *small data* y comparación de modelos

La agregación temporal debe corresponder a la frecuencia de la decisión y modifica tanto la variabilidad como el número de observaciones disponibles (Hyndman & Athanasopoulos, 2021). En series de compras, la conveniencia de resumir registros diarios por semana debe comprobarse con la cobertura y la finalidad de planeación de cada caso. Con independencia de la frecuencia elegida, los modelos de aprendizaje automático deben compararse con métodos estadísticos establecidos y no asumirse superiores por su mayor complejidad (Spiliotis et al., 2022).

La competencia M4 ofrece evidencia comparativa a gran escala: reunió 100,000 series y evaluó 61 métodos (Makridakis et al., 2020). En el análisis inicial, 12 de los 17 métodos mejor posicionados fueron combinaciones, y el de mayor precisión integró elementos estadísticos y de aprendizaje automático; su SMAPE medio fue cercano a 10% mejor que el benchmark de combinación. Los seis métodos exclusivamente de aprendizaje automático no superaron ese benchmark (Makridakis et al., 2018b). Estos resultados justifican evaluar combinaciones, pero no establecen su superioridad para compras semanales de una microempresa, pues la M4 incluye series de distintos dominios y frecuencias. De manera consistente, Hewamalage et al. (2021) advierten que las redes neuronales recurrentes no son soluciones universales, especialmente con series individuales cortas o heterogéneas.

La revisión de **Giannopoulos et al. (2025)** confirma que la demanda intermitente requiere atención explícita al diseño de características, la partición temporal, el ajuste de

hiperparámetros y las métricas de evaluación. Esta literatura sustenta que, en un contexto de *small data*, una validación *rolling window* y la comparación con líneas base reproducibles son más pertinentes que inferir superioridad a partir de un único modelo o una única partición.

Análisis de series temporales para demanda errática y small data

El pronóstico constituye una fase posterior a la caracterización de la serie. Antes de comparar algoritmos conviene examinar la frecuencia, la tendencia, la autocorrelación y la estabilidad de los patrones estacionales (Hyndman & Athanasopoulos, 2021). La validación y el preprocesamiento también deben respetar el orden temporal para evitar que información posterior intervenga en el ajuste (Bergmeir & Benítez, 2012). Cuando existen huecos de captura, primero debe distinguirse una ausencia de registro de un valor económico igual a cero; esta distinción corresponde a la depuración del caso.

En series con periodos sin movimiento, el intervalo promedio entre ocurrencias (ADI) y el cuadrado del coeficiente de variación de los importes positivos (CV^2) permiten clasificar patrones de demanda (Syntetos et al., 2005). Esta clasificación orienta el diagnóstico, pero no determina por sí sola el modelo ganador. Croston-SBA constituye una corrección para demanda intermitente (Syntetos & Boylan, 2005), mientras que TSB incorpora una actualización explícita de la probabilidad de ocurrencia (Teunter et al., 2011).

El análisis temporal también debe separar la descripción retrospectiva de la selección predictiva. Las gráficas pueden mostrar toda la cobertura para fines de auditoría; sin embargo, las pruebas de estacionariedad, autocorrelación y selección de características que influyen en la configuración del modelo deben calcularse sin observar el bloque final de evaluación. Esta separación preserva el carácter fuera de muestra de la comparación entre métodos estadísticos y aprendizaje automático.

1.1.4 La repostería creativa como sector económico especializado

Borsato (2023) examina la repostería como una forma de estética comestible en la que convergen técnicas culinarias y expresión artística. Desde ese alcance, la repostería creativa

o cake design puede caracterizarse por el énfasis en el diseño y la personalización de productos para celebraciones y ocasiones especiales. La fuente no se utiliza para inferir por sí sola una transformación económica de toda la industria.

La repostería contemporánea combina elementos gastronómicos, artísticos y comerciales, donde la diferenciación mediante el diseño, la personalización y la experiencia del cliente constituyen factores clave para la competitividad empresarial. En este contexto, la creatividad se ha convertido en un recurso estratégico para los profesionales de la pastelería, integrando conocimientos técnicos, innovación estética y comprensión de las preferencias del consumidor (Lee et al., 2020). Asimismo, la innovación en productos representa uno de los principales factores que contribuyen al desempeño y posicionamiento competitivo de las empresas del sector pastelero (Ben Abdallah et al., 2022).

A diferencia de la panadería tradicional, en la repostería creativa la demanda en este tipo de negocios suele presentar una mayor variabilidad debido a factores estacionales, eventos sociales y preferencias particulares de los consumidores. Esta dinámica genera desafíos importantes para la planeación de la producción, la gestión de inventarios y la estimación de ingresos, especialmente en microempresas que operan con recursos limitados y productos altamente perecederos. En consecuencia, la capacidad para anticipar cambios en la demanda y optimizar la toma de decisiones se ha convertido en un factor crítico para la sostenibilidad y competitividad de este tipo de organizaciones.

1.1.5 Innovación y transformación digital en la industria pastelera

Las capacidades de analítica de datos pueden relacionarse con innovación y desempeño organizacional, aunque la evidencia de Mikalef et al. (2019) y Dubey et al. (2021) no se limita al sector panadero. Para este sector, Melesse y Orrù (2025) revisan aplicaciones de tecnologías de Industria 4.0. En conjunto, estas fuentes permiten plantear que la digitalización puede apoyar actividades operativas, pero sus efectos sobre pedidos, inventarios y producción deben comprobarse en cada organización.

Hübner et al. (2024) demostraron que la implementación de modelos de aprendizaje automático para el pronóstico de la demanda en panaderías permitió disminuir significativamente el desperdicio alimentario y mejorar la planificación de la producción. De manera complementaria, estudios recientes sobre la digitalización del sector panadero destacan que las tecnologías asociadas a la Industria 4.0 facilitan la integración de datos operativos, la automatización de procesos y la mejora continua en la gestión de la cadena de suministro (Melesse & Orrù, 2025).

Las aplicaciones descritas se han estudiado principalmente en contextos con mayor disponibilidad de datos y capacidades tecnológicas. Para las PYMES latinoamericanas, Poveda-Valverde y Fierro Barragán (2026) identifican barreras de infraestructura, presupuesto y talento especializado. La búsqueda documental realizada para este capítulo encontró poca evidencia directamente referida a microempresas de repostería creativa; este resultado delimita la revisión efectuada y no demuestra la inexistencia de otros estudios.

1.1.6 Adopción de inteligencia artificial en microempresas

Diversos estudios han analizado los factores que influyen en la adopción de tecnologías basadas en inteligencia artificial dentro de pequeñas y medianas empresas.

Poveda-Valverde y Fierro Barragán (2026), mediante una revisión sistemática de aplicaciones de inteligencia artificial en PYMES latinoamericanas, identifican barreras recurrentes relacionadas con infraestructura tecnológica, recursos financieros y disponibilidad de talento especializado.

De manera similar, **Mikalef et al. (2019)** señalan que la capacidad de las organizaciones para aprovechar el potencial del análisis de datos depende en gran medida de sus capacidades analíticas y de su orientación hacia la innovación tecnológica.

Por otra parte, **Dubey et al. (2021)** destacan que la integración de analítica avanzada y herramientas de inteligencia artificial contribuye significativamente al desempeño operativo de

las organizaciones cuando se combina con capacidades dinámicas y estrategias de innovación.

1.1.7 Investigaciones en México y América Latina

En el contexto mexicano, diversos estudios han analizado el impacto de la adopción tecnológica y la digitalización en el desempeño de las pequeñas y medianas empresas.

Valdez-Juárez, García-Pérez-de-Lema y Maldonado-Guzmán (2018) analizaron datos de 412 PYMES industriales y de servicios del noroeste de México. Sus resultados muestran relaciones entre el uso de tecnologías de información y comunicación, la gestión del conocimiento, la innovación y la rentabilidad, por lo que el estudio aporta evidencia nacional sobre capacidades digitales y desempeño empresarial.

De manera similar, **Cuevas Vargas, Estrada y Larios Gómez (2016)** examinaron el efecto de la adopción de tecnologías de información y comunicación en pequeñas y medianas empresas mexicanas. Sus resultados indican que la digitalización de procesos y el uso de herramientas analíticas contribuyen significativamente a mejorar el desempeño organizacional.

Maldonado-Guzmán y Garza-Reyes (2020) estudiaron la adopción de prácticas de ecoinnovación en la industria automotriz. El trabajo aporta evidencia sobre innovación tecnológica y organizacional en un sector industrial, pero no aborda transformación digital ni modelos predictivos en microempresas.

Asimismo, **Saavedra García y Tapia Sánchez (2020)** señalan que las tecnologías de información desempeñan un papel clave en la competitividad de las PYMES mexicanas; sin embargo, su adopción se ve limitada por restricciones financieras y por la falta de personal especializado.

Finalmente, **Romero Hidalgo et al. (2021)** destacan que la gestión del conocimiento y el uso de datos en las organizaciones favorecen los procesos de innovación empresarial, lo que resulta particularmente relevante en el contexto de pequeñas empresas que buscan mejorar su desempeño mediante el uso de tecnologías digitales.

Como complemento regional, Poveda-Valverde y Fierro Barragán (2026), en una revisión sistemática sobre inteligencia artificial en PYMES latinoamericanas, identifican restricciones de infraestructura, presupuesto y talento especializado, además de una distribución heterogénea de aplicaciones entre actividades empresariales. Estos resultados justifican desarrollar estudios aplicados y reproducibles en organizaciones con menor disponibilidad de datos, sin atribuir a la revisión una concentración sectorial más precisa que la informada por sus autores.

Con el propósito de sintetizar las principales contribuciones de la literatura revisada, en la Tabla 1 se presentan los estudios más relevantes relacionados con la aplicación de inteligencia artificial, analítica de datos y adopción tecnológica en la gestión empresarial y el pronóstico de demanda.

Tabla 1. Investigaciones relevantes sobre inteligencia artificial, analítica de datos y adopción tecnológica en la gestión empresarial

Autor(es) y año	País de origen	Palabras clave	Contexto y datos	Metodología	Hallazgo relevante	Limitación o brecha	Relación con la investigación
Hübner et al. (2024)	Alemania	panadería; ML; pronóstico; desperdicio	Panaderías; ventas, producción y desperdicio	Caso cuantitativo con ML	El pronóstico de demanda puede apoyar la reducción de desperdicio.	Caso con infraestructura superior a la microempresa.	Aporta el antecedente sectorial; justifica evaluar una solución acotada a registros internos.
Huber y Stuckenschmidt (2020)	Alemania	retail; ML; calendario; demanda diaria	Retail diario; ventas y calendario	Comparación de ML con variables calendáricas	Las variables de calendario mejoran pronósticos en eventos.	Contexto minorista de mayor escala.	Sustenta incluir calendario y eventos disponibles en el dataset.
Abrar et al. (2024)	Internacional	cadena de suministro; CNN; LSTM; XAI	Cadena de suministro; demanda multifuente	Preprint arXiv; modelo híbrido CNN-LSTM con XAI	Los modelos híbridos pueden integrar señales complejas.	Arquitectura compleja evaluada con mayor disponibilidad de datos; evidencia aún como preprint.	Sirve como contraste: la tesis evalúa alternativas parsimoniosas en <i>small data</i> .
Spiliotis et al. (2022)	Grecia	SKU; demanda diaria; ML; métodos estadísticos	SKU diarios; series irregulares e intermitentes	Comparación de métodos estadísticos y ML	La superioridad de ML depende del objetivo y debe verificarse empíricamente.	Datos minoristas con múltiples SKU.	Fundamenta comparar Random Forest, ARIMA y línea base empírica.
Makridakis et al. (2018)	Internacional	M4; forecasting; ML; métodos híbridos	Competencia M4; múltiples series y horizontes	Benchmark de métodos estadísticos, híbridos y ML	Los modelos complejos no dominan de forma universal.	No estudia microempresas ni compras.	Sustenta una hipótesis condicional y la evaluación comparativa.
Hewamalage et al. (2021)	Australia	RNN; series temporales; ARIMA; ETS	Series temporales con RNN	Estudio empírico frente a ETS y ARIMA	Las RNN son competitivas, pero no son soluciones universales.	No se centra en presupuesto de compras de microempresas.	Justifica reportar RNN/LSTM sin asumir superioridad frente a modelos simples.
Giannopoulos et al. (2025)	Grecia	demanda intermitente; ML; evaluación	Demanda intermitente en distintas industrias	Revisión de ML y protocolos de evaluación	La intermitencia exige atención a partición temporal, ajuste y métricas.	Predomina evidencia de SKU y refacciones.	Sustenta la validación rolling-origin y el uso cauteloso de métricas; <i>small data</i> corresponde a la condición de esta tesis.
Borsato (2023)	Italia	repostería; estética; personalización	Repostería creativa y valor estético	Estudio sectorial cualitativo	La personalización distingue a la repostería creativa.	No evalúa pronósticos ni IA.	Delimita el contexto de negocio del caso <i>Cup&Cake</i> .

Autor(es) y año	País de origen	Palabras clave	Contexto y datos	Metodología	Hallazgo relevante	Limitación o brecha	Relación con la investigación
Lee et al. (2020)	Malasia	pastelería; creatividad; experiencia	Pastelería; creatividad y experiencia	Estudio de retrato/teoría integrada	La creatividad y personalización influyen en la oferta del sector.	No modela demanda.	Apoya la explicación de la variabilidad comercial del caso.
Ben Abdallah et al. (2022)	Túnez	innovación; pastelería; competitividad	Empresas pasteleras; innovación de producto	Estudio exploratorio	La innovación favorece desempeño y posicionamiento competitivo.	No analiza pronóstico ni ML.	Complementa la caracterización del sector de repostería.
Mikalef et al. (2019)	Noruega	big data; capacidades analíticas; innovación	Organizaciones orientadas a datos	Modelo de capacidades analíticas	Las capacidades analíticas se relacionan con innovación.	No se limita a microempresas ni pronóstico.	Sustenta la adopción de datos como capacidad organizacional.
Dubey et al. (2021)	Reino Unido / India	IA; big data; desempeño operativo	Manufactura; analítica, IA y desempeño	Modelo empírico de desempeño operativo	El valor de IA depende de capacidades y contexto.	Contexto industrial.	Refuerza que el DSS es apoyo y no garantía automática de desempeño.
Melesse y Orrù (2025)	Rumania	panadería; Industria 4.0; digitalización	Sector panadero e Industria 4.0	Revisión sistemática	La digitalización integra datos y automatización en panadería.	Evidencia sectorial heterogénea.	Apoya la pertinencia de digitalizar ventas y compras del caso.
Valdez-Juárez et al. (2018)	México	TIC; gestión del conocimiento; innovación; rentabilidad	412 PYMES industriales y de servicios del noroeste de México	Encuesta y modelado PLS-SEM	Las TIC se relacionan con la gestión del conocimiento, la innovación y la rentabilidad.	No evalúa IA ni pronósticos.	Aporta contexto nacional sobre capacidades digitales y desempeño empresarial.
Cuevas-Vargas et al. (2016)	México	TIC; PYMES; innovación	PYMES mexicanas; TIC y desempeño	Estudio cuantitativo	Las TIC favorecen la innovación y el desempeño organizacional.	No incorpora ML.	Sustenta el antecedente mexicano de digitalización.
Maldonado-Guzmán y Garza-Reyes (2020)	México	ecoinnovación; adopción; industria automotriz	Empresas del sector automotriz	Estudio empírico de adopción de prácticas de ecoinnovación	Analiza la adopción de innovaciones tecnológicas y organizacionales en un contexto industrial.	No estudia transformación digital, IA ni pronósticos en microempresas.	Aporta un antecedente mexicano sobre adopción de innovación, con alcance sectorial delimitado.
Saavedra-García y Tapia-Sánchez (2020)	México	TIC; PYMES; competitividad	PYMES mexicanas; adopción de TIC	Análisis de adopción tecnológica	Las restricciones financieras y de talento limitan la adopción.	Enfoque descriptivo.	Respalda la pertinencia de una solución reproducible y accesible.

Autor(es) y año	País de origen	Palabras clave	Contexto y datos	Metodología	Hallazgo relevante	Limitación o brecha	Relación con la investigación
Romero-Hidalgo et al. (2021)	México	gestión del conocimiento; innovación; datos	Pequeñas empresas; conocimiento e innovación	Modelo de gestión del conocimiento	El uso de datos favorece la innovación organizacional.	No evalúa precisión predictiva.	Complementa el valor de formalizar registros dispersos.
Poveda-Valverde y Fierro Barragán (2026)	Ecuador / América Latina	IA; PYMES; adopción; barreras	PYMES latinoamericanas; adopción de IA	Revisión sistemática	Persisten barreras de infraestructura, presupuesto y talento; las aplicaciones revisadas abarcan distintas actividades empresariales.	No se centra en microempresas de repostería.	Refuerza el vacío regional identificado por esta revisión y la necesidad de evidencia aplicada en microempresas.
Hyndman y Athanasopoulos (2021)	Australia	series temporales; diagnóstico; pronóstico; validación.	Ejemplos de series reales de distintos sectores	Libro metodológico con aplicaciones en R	El diagnóstico precede al modelado; la evaluación requiere datos fuera de muestra.	No estudia compras de microempresas.	Sustenta el diagnóstico temporal y la evaluación fuera de muestra.
Syntetos y Boylan (2005)	Reino Unido	demanda intermitente; Croston; SBA; precisión	Industria automotriz; 3,000 series intermitentes	Comparación de cuatro métodos y simulación	La modificación de Croston mejora la precisión en las series evaluadas.	No compara ML ni estudia microempresas alimentarias.	Fundamenta incluir Croston-SBA y métricas compatibles con ceros..

Fuente: Elaboración propia con base en las referencias citadas en el Estado del Arte.

1.1.8 Síntesis del estado del arte y vacío de investigación

La literatura revisada destaca el potencial de los modelos híbridos y las combinaciones de métodos para mejorar la precisión del pronóstico. Makridakis et al. (2018b) identificaron en la competencia M4 resultados destacados mediante la integración de componentes estadísticos y de aprendizaje automático. Por su parte, Abrar et al. (2024) presentaron una arquitectura híbrida de redes neuronales con mejoras en el contexto evaluado. Aunque representan formas distintas de integración, estos antecedentes fundamentan el estudio de enfoques complementarios, cuya precisión debe comprobarse según las características de los datos y el horizonte de pronóstico.

Los antecedentes incluyen estudios de demanda por producto y aplicaciones en el sector panadero. **Huber y Stuckenschmidt (2020)** abordaron el pronóstico diario por categoría y establecimiento en una cadena de panaderías, mientras que **Spiliotis et al. (2022)** compararon métodos estadísticos y de aprendizaje automático en series diarias de demanda por producto. Estos contextos difieren del pronóstico del importe semanal de compras de una microempresa. Asimismo, **Poveda Valverde y Fierro Barragán (2026)** identificaron restricciones de infraestructura, presupuesto y talento especializado para la adopción de IA en PYMES latinoamericanas, lo que refuerza la pertinencia de soluciones adaptadas a sus recursos.

Dentro de los trabajos revisados, se identifica evidencia limitada sobre el desarrollo y la evaluación temporal de modelos híbridos estadísticos y de aprendizaje automático para el pronóstico del importe semanal de compras, junto con un procedimiento de distribución porcentual entre los principales insumos, en microempresas de repostería creativa. El vacío aplicado se sitúa en la articulación de ambos resultados como apoyo al presupuesto de abastecimiento, bajo condiciones de información histórica limitada y variabilidad en las compras.

La investigación aborda este vacío mediante la evaluación de la precisión del importe total pronosticado y de su distribución porcentual frente a modelos de referencia. La distribución se fundamentará en la composición histórica de las compras y su variación temporal, y permitirá

expresar asignaciones presupuestarias por insumo. Su evaluación determinará la capacidad de anticipar el gasto registrado y su composición; establecer cantidades óptimas de compra requeriría información adicional sobre necesidades de producción, existencias y condiciones de suministro.

La contribución consiste en desarrollar un modelo híbrido que integra métodos estadísticos y aprendizaje automático, acompañado de un procedimiento de distribución porcentual del importe semanal entre los principales insumos de *Cup&Cake*, microempresa de repostería creativa de Tizayuca, Hidalgo. A partir de los registros de ventas y compras, se construirán las series semanales y se evaluará temporalmente la precisión frente a modelos de referencia. Los resultados servirán como apoyo a la planeación del presupuesto de abastecimiento, con un alcance centrado en el pronóstico y la asignación presupuestaria.

1.2 El planteamiento del problema

Góngora Chonillo (2023) aborda la evaluación del riesgo financiero en microempresas mediante inteligencia artificial. Esta referencia sustenta la relevancia de analizar información financiera en empresas pequeñas, pero no demuestra afirmaciones generales sobre variabilidad de la demanda, inventarios o gestión de la cadena de suministro.

En empresas del sector alimentario, la perecibilidad y la variación de la demanda vuelven relevante coordinar compras, producción e inventarios. Los pronósticos aportan información para la planeación, pero no eliminan la incertidumbre ni determinan por sí solos los costos o faltantes de inventario (Hyndman & Athanasopoulos, 2021). En esta tesis, los efectos financieros y operativos se mantendrán separados de las métricas de precisión predictiva.

En el ámbito latinoamericano, la adopción de soluciones basadas en inteligencia artificial por parte de las PYMES enfrenta barreras de infraestructura, presupuesto y talento especializado. Estas condiciones limitan la transferencia directa de aplicaciones desarrolladas en organizaciones con mayores capacidades tecnológicas (Poveda-Valverde & Fierro Barragán, 2026).

Asimismo, la literatura señala que la carencia de capital humano especializado y de capacidades analíticas internas reduce significativamente la posibilidad de integrar soluciones basadas en datos en los procesos estratégicos empresariales (Mikalef et al., 2019). Esta limitación se vincula directamente con la baja capacidad de absorción tecnológica característica de las empresas de menor tamaño.

La incorporación de analítica avanzada e inteligencia artificial se relaciona con capacidades organizacionales y orientación estratégica hacia la innovación (Dubey et al., 2021). En las PYMES latinoamericanas también intervienen restricciones de infraestructura, presupuesto y talento especializado (Poveda-Valverde & Fierro Barragán, 2026). Estas condiciones deben considerarse al valorar la adopción tecnológica en una microempresa.

Consideradas conjuntamente, las fuentes muestran que las capacidades analíticas influyen en el aprovechamiento de los datos y que las PYMES latinoamericanas enfrentan barreras de adopción (Mikalef et al., 2019; Poveda-Valverde & Fierro Barragán, 2026). Esta síntesis justifica evaluar la aplicabilidad de las herramientas en empresas de menor escala, sin presentarla como un resultado textual de una sola publicación ni anticipar efectos antes de la evaluación empírica.

La revisión efectuada no identificó estudios directamente comparables que integren, en una microempresa, el pronóstico semanal del importe de compras y la distribución del presupuesto entre insumos. Esta observación se entiende como resultado de la búsqueda realizada y no como evidencia de ausencia total de investigaciones sobre el tema.

1.2.1 Contexto del caso de estudio

En una microempresa, la experiencia del propietario puede concentrar parte del conocimiento utilizado para decidir. Para el caso analizado, la investigación documentó qué decisiones se apoyan en registros y cuáles dependen de conocimiento no formalizado, sin generalizar esta condición a todas las MIPYMES ni atribuirla a una fuente que estudia organizaciones basadas en conocimiento.

Cup&Cake es una empresa mexicana fundada en 2014. Con más de diez años de operación, su crecimiento orgánico le ha permitido subsistir; sin embargo, las compras se realizan principalmente con base en la experiencia del empresario y en el conocimiento de fechas comerciales recurrentes, como el Día de San Valentín (14 de febrero), el Día del Niño (30 de abril) y el Día de la Madre (10 de mayo), entre otras que generan picos de venta cada año.

Para esta investigación, el comportamiento de ventas y compras se determinó a partir de los archivos disponibles y no de una afirmación general de crecimiento. Los registros se utilizaron para construir variables históricas y caracterizar la variación semanal, con las limitaciones de cobertura documentadas en la metodología.

El reto de *Cup&Cake* es fortalecer la planeación semanal del presupuesto de abastecimiento. Para ello, requiere estimar al inicio de cada semana el importe probable de compra semanal, así como la distribución entre los principales insumos, considerando el comportamiento histórico, las fechas comerciales y las variables exógenas disponibles.

El pronóstico tuvo como propósito reducir la incertidumbre al reservar y revisar el presupuesto de abastecimiento de corto plazo. La investigación no pretende medir directamente incrementos de utilidad, expansión comercial o reducción de costos, pues dichas conclusiones requerirían información adicional y un diseño de evaluación operativa.

1.2.2 Pregunta de Investigación

¿Qué precisión ofrece, frente a modelos de referencia y mediante validación temporal, un modelo híbrido que integra métodos estadísticos y aprendizaje automático para estimar el importe total semanal de compras y su distribución porcentual entre los principales insumos registrados de Cup&Cake, microempresa de repostería creativa de Tizayuca, Hidalgo, con los datos disponibles del 5 de diciembre de 2016 al 11 de mayo de 2026 y una evaluación final comprendida entre el 24 de marzo y el 28 de julio de 2025?

1.2.3 Objetivo

Objetivo general

Determinar la precisión que ofrece, frente a modelos de referencia y mediante validación temporal, un modelo híbrido que integra métodos estadísticos y aprendizaje automático para estimar el importe total semanal de compras y su distribución porcentual entre los principales insumos registrados de Cup&Cake, microempresa de repostería creativa de Tizayuca, Hidalgo, con los datos disponibles del 5 de diciembre de 2016 al 11 de mayo de 2026 y una evaluación final comprendida entre el 24 de marzo y el 28 de julio de 2025.

Objetivos específicos

1. Analizar los registros históricos de ventas y compras mediante depuración, agregación semanal y caracterización temporal del importe total y de la participación de los principales insumos.
2. Desarrollar la estructura del modelo híbrido mediante la integración de componentes estadísticos y de aprendizaje automático, con variables históricas y exógenas disponibles al momento del pronóstico.
3. Determinar la distribución porcentual del importe semanal pronosticado entre los principales insumos, a partir de su composición histórica y variación temporal.
4. Contrastar la precisión del modelo híbrido y del procedimiento de distribución porcentual frente a modelos de referencia, mediante evaluación temporal y métricas de error monetario y de participación.

1.3 Justificación

Relevancia social

Poveda-Valverde y Fierro Barragán (2026) documentan restricciones de infraestructura, presupuesto y talento especializado que pueden dificultar la adopción de soluciones basadas en datos en PYMES latinoamericanas. A partir de ese contexto, esta investigación evaluó herramientas de pronóstico semanal con la información disponible en una microempresa y valoró su pertinencia de acuerdo con sus capacidades operativas. Esta última decisión corresponde al diseño del estudio.

En *Cup&Cake*, el estudio buscó determinar si el modelo híbrido mejora la estimación del importe semanal de compras y su distribución porcentual entre los principales insumos frente a modelos de referencia. Los resultados aportaron información útil para el responsable de la planeación del presupuesto de abastecimiento. Asimismo, el procedimiento puede servir como referencia para otras microempresas con condiciones semejantes, aunque su aplicación requiere evaluar las características y los datos de cada negocio.

Conveniencia

El estudio atiende una necesidad operativa concreta de Cup&Cake: estimar, con horizontes de una a cuatro semanas, el importe total de las compras y su distribución porcentual entre los principales insumos. Se aprovecharon los registros históricos de ventas y compras y se incorporaron variables exógenas disponibles al momento del pronóstico para desarrollar un procedimiento de apoyo a la planeación del presupuesto de abastecimiento.

Se comparó la precisión del modelo híbrido con la de modelos de referencia mediante validación temporal de ventana deslizante. Este contraste permitió determinar si la integración de métodos estadísticos y aprendizaje automático aporta mejoras en el pronóstico frente a alternativas más sencillas, sin presuponer la superioridad de una mayor complejidad algorítmica (Makridakis et al., 2018; Spiliotis et al., 2022).

Valor teórico

El valor teórico esperado de la investigación consiste en aportar evidencia sobre el desempeño de métodos de pronóstico semanal en un contexto de datos limitados e intermitencia de las compras. La literatura señala que la precisión de los modelos depende de la cantidad y calidad de los datos, la granularidad temporal, las variables disponibles y el protocolo de evaluación; por tanto, su superioridad requiere contrastación empírica (**Hewamalage et al., 2021; Giannopoulos et al., 2025**).

El estudio permitió examinar la precisión de un modelo híbrido que integre métodos estadísticos y aprendizaje automático, así como la de un procedimiento de distribución porcentual del importe semanal entre los principales insumos. También se analizó si las

variables exógenas disponibles antes de cada pronóstico aportan información adicional. La contribución fue principalmente empírica y metodológica, circunscrita al caso de estudio, y puede orientar investigaciones posteriores en microempresas con características semejantes.

Implicaciones prácticas

Se desarrolló para Cup&Cake un procedimiento reproducible para depurar e integrar los registros diarios, agregarlos semanalmente, construir variables predictivas, generar pronósticos y estimar la distribución porcentual del importe entre los principales insumos. Su precisión se evaluó fuera de muestra mediante métricas de error monetario y de participación. Los resultados se presentaron en un tablero de inteligencia de negocios que permite consultar el importe semanal esperado de compras, su consolidado mensual y la distribución presupuestaria entre los principales insumos.

El tablero tiene como propósito apoyar la planeación y revisión del presupuesto de abastecimiento. No genera órdenes automáticas de compra ni calculará cantidades físicas por insumo, pues estas funciones requieren información adicional sobre recetas, existencias, merma, costos de faltante, tiempos de entrega y unidades de medida homologadas. Los posibles beneficios operativos dependen de los resultados obtenidos y de su posterior aplicación en la empresa.

La investigación se justifica por la necesidad de evaluar si un modelo híbrido que integre métodos estadísticos y aprendizaje automático puede mejorar el pronóstico del importe semanal de compras y su distribución porcentual entre los principales insumos de Cup&Cake. Se contrastó su precisión frente a modelos de referencia mediante evaluación temporal, con el propósito de aportar elementos para la planeación del presupuesto de abastecimiento. Su alcance no comprende la medición de efectos sobre inventarios, merma, rentabilidad o expansión comercial.

1.4 Hipótesis

Hipótesis de investigación (H1)

H1. El modelo híbrido que integre métodos estadísticos y aprendizaje automático, junto con el procedimiento de distribución porcentual entre los principales insumos, presentará menores errores de pronóstico fuera de muestra que los respectivos modelos de referencia para estimar el importe total semanal de compras y su composición porcentual en *Cup&Cake*, utilizando información disponible al momento del pronóstico y los mismos periodos y horizontes de evaluación.

2 MARCO TEÓRICO

El presente marco teórico desarrolla los fundamentos conceptuales y matemáticos de una propuesta híbrida para pronosticar el importe total semanal de compras y su distribución porcentual entre los principales insumos de Cup&Cake. Se revisan la planeación del presupuesto de abastecimiento, las series temporales semanales, los métodos estadísticos y de aprendizaje automático, las estrategias de integración, el análisis composicional y la evaluación fuera de muestra. Las referencias específicas se presentan en los apartados donde se desarrolla cada concepto.

2.1 Microempresa y planeación del presupuesto de abastecimiento

2.1.1 Recursos de información y conocimiento del negocio

Las empresas pequeñas presentan condiciones heterogéneas de digitalización (OCDE, 2021). La disponibilidad de registros, las competencias del personal y los recursos para integrar herramientas condicionan el uso de analítica. Estas restricciones justifican procedimientos proporcionales a la información disponible, pero no permiten asumir que toda microempresa carece de registros o que una solución tecnológica tendrá beneficios automáticos. En *Cup&Cake*, la pertinencia del procedimiento se evaluará respecto de la necesidad de anticipar el presupuesto de compras.

La experiencia del responsable del negocio puede aportar información sobre celebraciones, cambios de proveedores o adquisiciones extraordinarias que no aparece explícitamente en una serie. Ese conocimiento permite interpretar registros y proponer variables, mientras que las reglas de pronóstico hacen reproducible la estimación. Como criterio del estudio, se distinguirán los hechos documentados de las expectativas y se conservará la fecha en que cada dato estuvo disponible.

2.1.2 Pronóstico como información para decidir

Un pronóstico puntual resume una distribución de resultados posibles. Bajo pérdida cuadrática, el valor que minimiza el error esperado es la media condicional. La ecuación (1) adapta esta

propiedad al importe de compras: la estimación depende de la información existente en el origen del pronóstico, sin utilizar datos posteriores (Hastie et al., 2009).

$$\hat{y}_{t+h|t} = E(y_{t+h}|I_t) \quad (1)$$

En esta notación, y representa el importe semanal observado, t es la última semana conocida, h es el horizonte e I representa la información disponible. El sombrero distingue el pronóstico del valor observado y la barra vertical separa el periodo pronosticado del origen de información. Una estimación puntual ayuda a formular expectativas, pero no determina por sí sola la decisión presupuestaria del responsable (Hastie et al., 2009; Power, 2002).

La planeación del presupuesto utilizará esa estimación como un insumo para revisar recursos destinados al abastecimiento. Un sistema de soporte a la decisión organiza datos y modelos para facilitar la valoración de alternativas; la decisión final también puede incorporar restricciones que el modelo no observa. Por ello, el estudio evaluará precisión predictiva y no supondrá que un menor error produce necesariamente un retorno financiero positivo (Power, 2002).

2.2 Compras monetarias y contexto de la repostería

2.2.1 Delimitación de la variable objetivo

Pronosticar requiere definir con precisión qué se observa, con qué frecuencia y para qué horizonte. En esta investigación, la respuesta principal será el importe total semanal registrado de compras. Las ventas, el consumo de ingredientes y las existencias son magnitudes diferentes: pueden aportar contexto, pero no sustituyen la variable definida. La comparación entre modelos deberá mantener la misma respuesta y las mismas unidades monetarias (Hyndman & Athanasopoulos, 2021).

El importe de una adquisición puede variar por cantidad, precio y composición de insumos. Además, la fecha de compra puede diferir de la fecha de consumo o pago. Por tanto, la interpretación prevista será presupuestaria: se intentará anticipar el registro monetario de compras, sin identificarlo con una cantidad óptima de abastecimiento. Esta delimitación

mantiene separado el objetivo de predicción de las inferencias explicativas o causales (Shmueli, 2010).

2.2.2 Agregación del importe y niveles de análisis

Los pronósticos jerárquicos representan series relacionadas mediante sumas. Adaptada al caso, la identidad de agregación expresa el importe semanal total como suma de los importes de las categorías de insumos. La ecuación (2) es una aplicación de esa estructura aditiva, no un modelo causal de costos (Hyndman et al., 2011).

$$y_t = \sum_{j=1}^J b_{j,t} \quad (2)$$

Aquí, b es el importe del insumo o categoría j y J es el número de categorías mutuamente excluyentes que cubren el total. Si solo se presentan los principales insumos, será necesario conservar una categoría residual para las demás compras o declarar que se trabaja con un subtotal. La suma evita que las asignaciones se interpreten como un total cuando omiten parte de sus componentes (Hyndman et al., 2011).

La frecuencia y el nivel de agregación deben responder a la decisión analizada (Hyndman & Athanasopoulos, 2021). En el caso propuesto, la escala semanal se utilizará para revisar el presupuesto de abastecimiento. Esta delimitación no equivale a planificar inventarios físicos: traducir importes a unidades requeriría precios, recetas, existencias y condiciones de suministro que quedan fuera del pronóstico monetario.

2.3 Series temporales semanales y calidad de los registros

2.3.1 Frecuencia y continuidad

Una serie temporal es una secuencia ordenada de observaciones registradas con un índice temporal definido (Hyndman & Athanasopoulos, 2021). Para depurar los datos del caso, la agregación semanal conservará un calendario consistente y distinguirá una semana sin compras de una semana sin registro. Los huecos no se rellenarán automáticamente con cero, porque esa sustitución cambiaría el significado del objetivo; esta es una regla de calidad de datos del estudio.

2.3.2 Nivel tendencia y estacionalidad

La descomposición aditiva representa una serie mediante tendencia-ciclo, estacionalidad y residuo. Es útil cuando las oscilaciones estacionales se interpretan en la escala original; si aumentan proporcionalmente al nivel, pueden considerarse transformaciones u otras representaciones. La ecuación (3) presenta la descomposición con notación adaptada al importe semanal (Hyndman & Athanasopoulos, 2021).

$$y_t = T_t + S_t + R_t \quad (3)$$

T representa el componente de tendencia-ciclo, S el patrón estacional y R la variación restante. El residuo no debe interpretarse automáticamente como error de captura: puede contener acontecimientos legítimos o estructura no representada. La descomposición sirve para explorar el comportamiento de la serie, sin demostrar que los componentes conservarán la misma forma en periodos futuros (Hyndman & Athanasopoulos, 2021).

La estacionalidad implica repetición asociada al calendario. Para compras semanales, un patrón anual debe examinarse con la cobertura disponible y con atención a festividades móviles. Contar con un ciclo no permite observar su repetición entre años. La incorporación de componentes estacionales dependerá de evidencia histórica y de su utilidad predictiva, no solo de la existencia de fechas comerciales relevantes (Hyndman & Athanasopoulos, 2021).

2.3.3 Estacionariedad y dependencia temporal

La diferenciación transforma la serie mediante cambios entre observaciones sucesivas, como muestra la ecuación (4). Puede ayudar a tratar variaciones persistentes de nivel; la estabilización de varianza, en cambio, puede requerir transformaciones de escala. ADF y KPSS examinan hipótesis distintas sobre estacionariedad, y su interpretación debe considerar el tamaño de muestra y los componentes incluidos en la prueba (Hyndman & Athanasopoulos, 2021).

$$\Delta y_t = y_t - y_{t-1} \quad (4)$$

La autocorrelación describe asociación lineal entre observaciones separadas por un rezago. En la ecuación (5), k identifica la separación temporal, N el número de semanas y la barra el

promedio de la serie. La función ayuda a explorar memoria temporal, sin constituir por sí sola una regla de selección del modelo (Hyndman & Athanasopoulos, 2021).

$$r_k = \frac{\sum_{t=k+1}^N (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^N (y_t - \bar{y})^2} \quad (5)$$

La autocorrelación parcial y las pruebas de dependencia conjunta pueden complementar el diagnóstico (Hyndman & Athanasopoulos, 2021). La selección de características y la validación deben respetar el orden temporal; utilizar toda la serie para definir variables antes de evaluar un bloque reservado puede introducir información posterior en el procedimiento (Bergmeir & Benítez, 2012). En este estudio, cualquier diagnóstico que determine ajustes se calculará únicamente con el historial disponible en cada origen.

2.3.4 Intermitencia y valores extremos

Cuando existen periodos con valor cero, resulta útil distinguir tamaño de los eventos positivos y tiempo entre eventos. El método de Croston mantiene estimaciones suavizadas de ambas cantidades y obtiene una tasa por periodo mediante su cociente, representado en la ecuación (6). Su traslado de demanda a compras monetarias deberá justificarse por el patrón observado (Hyndman & Athanasopoulos, 2021).

$$\hat{y}_{t+h|t} = \frac{\hat{z}_t}{\hat{a}_t} \quad (6)$$

Las estimaciones z y a corresponden, respectivamente, al tamaño de los eventos positivos y al intervalo entre ellos. El procedimiento constituye una referencia para demanda intermitente, no una garantía de superioridad (Hyndman & Athanasopoulos, 2021). Como procedimiento de auditoría del caso, los picos se contrastarán con la fuente para distinguir posibles errores de registro de compras extraordinarias; no se eliminarán únicamente por su magnitud (Kuhn & Johnson, 2013).

2.4 Métodos estadísticos y de aprendizaje automático

2.4.1 Referencias simples

Una referencia establece qué precisión puede obtenerse con una regla reproducible. El método ingenuo conserva el último valor conocido para los horizontes futuros, como muestra la ecuación (7). Una referencia estacional utiliza el periodo comparable de un ciclo anterior cuando existe historial suficiente. Ninguna de estas reglas representa por sí misma el juicio del propietario (Hyndman & Athanasopoulos, 2021).

$$\hat{y}_{t+h|t} = y_t \quad (7)$$

La utilidad de estas referencias es contextualizar el error: una arquitectura compleja puede reducir el error de entrenamiento sin mejorar el de semanas futuras. El estudio deberá comparar al híbrido con referencias previamente definidas para el importe y para la composición, de modo que la mejora se mida respecto de alternativas pertinentes (Hyndman & Athanasopoulos, 2021).

2.4.2 Suavizamiento exponencial y ARIMA

El suavizamiento exponencial simple actualiza una estimación del nivel mediante una combinación de la observación reciente y el nivel previo. En la ecuación (8), α controla el peso de la información reciente y toma valores entre cero y uno. Su pronóstico no incorpora por sí mismo tendencia o estacionalidad, por lo que funciona como una representación básica (Hyndman & Athanasopoulos, 2021).

$$\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}, \quad \hat{y}_{t+h|t} = \ell_t \quad (8)$$

Los modelos de suavizamiento con tendencia y estacionalidad amplían esta representación. Su pertinencia dependerá de la estructura temporal y de la cantidad de observaciones. No será suficiente seleccionar una variante más compleja: deberá verificarse si sus componentes ayudan a estimar las semanas reservadas para evaluación (Hyndman & Athanasopoulos, 2021).

Un ARIMA combina términos autorregresivos, diferenciación y medias móviles de innovaciones. La ecuación (9) usa el operador de rezago B , de modo que B aplicado a y en t

devuelve el valor anterior. Los polinomios *phi* (φ) y *theta* (θ) representan los órdenes autorregresivos y de medias móviles; d es el orden de diferenciación y *épsilon* (ε) la innovación (Hyndman & Athanasopoulos, 2021).

$$\varphi(B)(1 - B)^d y_t = c + \theta(B)\varepsilon_t \quad (9)$$

El componente de medias móviles de ARIMA opera sobre innovaciones y no equivale a promediar observaciones anteriores. Las variantes estacionales añaden operadores asociados a una periodicidad definida, y la selección debe considerar la longitud del historial y el diagnóstico de residuos (Hyndman & Athanasopoulos, 2021). Para esta investigación, el tamaño de la empresa no se utilizará por sí solo como criterio para excluir una familia estadística.

2.4.3 Bosques aleatorios y potenciación de gradiente

Random Forest combina árboles contruidos con aleatoriedad en muestras y predictores. En regresión, la salida es el promedio de las predicciones, representado en la ecuación (10). B es el número de árboles, T identifica cada árbol y x reúne los predictores disponibles. La agregación busca reducir variabilidad respecto de un árbol individual (Breiman, 2001).

$$\hat{f}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x) \quad (10)$$

Los árboles y los bosques aleatorios permiten representar interacciones y relaciones no lineales (Breiman, 2001). En pronóstico de series temporales, las entradas deben construirse con información disponible en el origen, como rezagos y variables de calendario (Bontempi et al., 2013). La profundidad, el tamaño mínimo de los nodos y la diversidad de árboles se tratarán como decisiones de diseño; el modelo no se considerará inmune a errores de captura o datos faltantes.

La potenciación de gradiente construye una función de manera aditiva. La ecuación (11) expresa una actualización con un aprendiz base g , un coeficiente ρ y una tasa de aprendizaje η . La dirección de actualización depende del gradiente negativo de la pérdida; con pérdida cuadrática se relaciona con los residuales (Friedman, 2001).

$$F_m(x) = F_{m-1}(x) + \nu \rho_m g_m(x) \quad (11)$$

La tasa de aprendizaje y el número de etapas controlan la magnitud de la adaptación en gradient boosting (Friedman, 2001). Estas técnicas pueden aprovechar interacciones entre calendario e historial, pero su configuración debe realizarse antes de la evaluación final. Ajustar el número de etapas con el mismo bloque utilizado para reportar precisión produciría una comparación optimista (Tashman, 2000).

2.4.4 Redes neuronales y alcance de los comparadores

Una red autorregresiva aproxima mediante una función no lineal la relación entre rezagos de una serie (Hyndman & Athanasopoulos, 2021). Las redes neuronales recurrentes incorporan estados internos y mecanismos de memoria, además de parámetros y decisiones de ajuste; su desempeño depende del tamaño y las características de los datos (Hewamalage et al., 2021). En esta tesis, la presencia de una red recurrente no se utilizará como condición para definir un modelo como híbrido.

Como criterio de diseño, cada familia candidata deberá responder una pregunta pertinente sobre el objetivo, por ejemplo, si aportan valor la no linealidad o la memoria temporal. La selección y el ajuste se realizarán con información anterior a las semanas de evaluación, de acuerdo con el principio de separar entrenamiento, validación y prueba (Kuhn & Johnson, 2013).

2.5 Fundamentos de integración del modelo híbrido

2.5.1 Combinación de pronósticos

La combinación de pronósticos parte de que métodos distintos pueden contener información complementaria. Para dos modelos, la ecuación (12) pondera un pronóstico estadístico y uno de aprendizaje automático. La notación adapta el principio de combinación al caso; el peso w determina la contribución del primero. Restringirlo entre cero y uno produce una combinación convexa (Bates & Granger, 1969).

$$\hat{y}_{t+h|t}^H = w\hat{y}_{t+h|t}^E + (1-w)\hat{y}_{t+h|t}^A \quad (12)$$

Los superíndices H , E y A identifican híbrido, estadístico y aprendizaje automático. Bajo errores insesgados con varianzas finitas, la varianza del error combinado depende de las varianzas individuales y de su covarianza. La ecuación (13) explica por qué el grado de dependencia entre errores importa para la combinación (Bates & Granger, 1969). La evidencia de M4 ilustra empíricamente que las combinaciones pueden ser competitivas en conjuntos amplios, aunque su resultado no se traslada automáticamente a otra población, frecuencia u horizonte (Makridakis et al., 2018, 2020).

$$\sigma_H^2 = w^2\sigma_E^2 + (1-w)^2\sigma_A^2 + 2w(1-w)\sigma_{EA} \quad (13)$$

Cuando los errores se parecen mucho, combinar puede aportar poco. Si el denominador es positivo, el peso que minimiza esa varianza sin imponer la restricción convexa se expresa en la ecuación (14). Su uso exige estimar varianzas y covarianza sin información futura; la estimación puede ser inestable con pocos errores disponibles (Bates & Granger, 1969).

$$w^* = \frac{\sigma_A^2 - \sigma_{EA}}{\sigma_E^2 + \sigma_A^2 - 2\sigma_{EA}} \quad (14)$$

La combinación simple también debe considerarse como referencia, pues estimar pesos no garantiza mejorar un promedio. En el estudio propuesto, el interés será contrastar si integrar representaciones distintas produce menores errores. La evaluación deberá distinguir esa combinación de la mera selección del algoritmo ganador (Hyndman & Athanasopoulos, 2021).

2.5.2 Integración mediante componentes

Otra estrategia híbrida representa la serie como suma de componentes lineal y no lineal. Zhang (2003) propuso modelar con ARIMA la estructura lineal y con una red neuronal la estructura no lineal de los residuales, y reportó potencial de mejora en sus experimentos; el hallazgo no implica una ventaja universal. La ecuación (15) resume esa formulación: sus componentes no son observables independientes, sino representaciones estimadas mediante un procedimiento de modelado. La implementación de esta tesis es una adaptación y deberá juzgarse con su propia evaluación temporal.

$$y_t = L_t + N_t, \quad \hat{y}_{t+h|t} = \hat{L}_{t+h|t} + \hat{N}_{t+h|t} \quad (16)$$

Los modelos híbridos pueden combinar componentes lineales y no lineales, y los errores de ajuste del primer componente no deben confundirse con errores predictivos genuinos (Hyndman & Athanasopoulos, 2021; Zhang, 2003). Como adaptación metodológica para Cup&Cake, los errores usados por el segundo componente se generarán respetando el orden temporal y la suma se evaluará en semanas no utilizadas para configurar el procedimiento.

Estas alternativas ofrecen mecanismos plausibles para H1, sin anticipar cuál resultará más preciso. Una combinación puede fallar si los componentes comparten errores, si los pesos se estiman con poca información o si la estructura cambia. La selección de una arquitectura concreta requerirá especificar qué componentes se integran y cómo se contrastará el conjunto (Hyndman & Athanasopoulos, 2021).

2.6 Distribución porcentual y coherencia de las asignaciones

2.6.1 Participaciones como datos composicionales

Las participaciones describen partes de un total y están sujetas a una restricción de suma. Por ello, no se interpretan como variables completamente independientes: aumentar una participación requiere disminuir alguna otra. La ecuación (16) adapta la representación composicional a importes no negativos de compras, incluyendo la condición de total positivo (Aitchison, 1982).

$$p_{j,t} = \frac{b_{j,t}}{y_t}, \quad p_{j,t} \geq 0, \quad \sum_{j=1}^J p_{j,t} = 1, \quad y_t > 0 \quad (17)$$

Las proporciones se expresan entre cero y uno; su multiplicación por cien produce porcentajes. Si el total observado es cero, las participaciones no quedan definidas por el cociente. Una regla de tratamiento deberá distinguir ese caso de una participación cero dentro de una semana con compras. Las transformaciones logarítmicas requieren además componentes estrictamente positivos (Aitchison, 1982).

2.6.2 Desagregación del pronóstico total

El enfoque descendente pronostica un agregado y lo distribuye mediante proporciones. La ecuación (17) adapta esa relación a importes por insumo: cada asignación es el producto del total pronosticado y la participación estimada para el mismo horizonte. Las proporciones deben cumplir las restricciones de suma y no negatividad (Hyndman & Athanasopoulos, 2021).

$$\hat{b}_{j,t+h|t} = \hat{p}_{j,t+h|t} \hat{y}_{t+h|t} \quad (18)$$

El procedimiento preserva la suma cuando todas las categorías están representadas. Esa coherencia es aritmética y no demuestra precisión: un total correcto puede repartirse incorrectamente. Por esa razón, la evaluación deberá revisar tanto el importe agregado como las participaciones y, cuando resulte pertinente, las asignaciones monetarias resultantes (Hyndman et al., 2011).

Como referencia, el promedio de proporciones históricas asigna a cada categoría su participación media en las semanas de entrenamiento con total positivo. La ecuación (18) adapta el promedio histórico de proporciones a ese conjunto válido V , cuyo tamaño es n . No es equivalente al cociente de sumas, que otorga más peso a las semanas de mayor importe (Hyndman & Athanasopoulos, 2021).

$$\bar{p}_j = \frac{1}{n} \sum_{t \in V} \frac{b_{j,t}}{y_t} \quad (19)$$

Una distribución histórica fija puede ser insuficiente si la mezcla cambia. Las proporciones pronosticadas ofrecen una alternativa, aunque requieren información y evaluación propias. Debe mantenerse el mismo conjunto de categorías a lo largo del contraste o documentar sus cambios. Este principio permite diferenciar la mejora de la composición de la mejora del total (Hyndman & Athanasopoulos, 2021).

2.6.3 Representación relativa de las participaciones

El análisis composicional utiliza cocientes para representar información relativa. La transformación logarítmica de una participación respecto de una categoría de referencia aparece en la ecuación (19). Su utilidad es mostrar que la información relevante puede

expresarse como relación entre partes, en lugar de tratar porcentajes como respuestas independientes sin restricciones (Aitchison, 1982).

$$z_{j,t} = \log\left(\frac{p_{j,t}}{p_{J,t}}\right), \quad j = 1, \dots, J - 1 \quad (20)$$

Esta transformación es una alternativa teórica y no obliga a seleccionarla para el estudio. Los ceros requieren un tratamiento explícito que no distorsione la composición; no deberán sustituirse de manera arbitraria solo para permitir un logaritmo. Una estrategia más simple también podrá ser pertinente si conserva coherencia y obtiene precisión comparable fuera de muestra (Aitchison, 1982).

2.7 Datos limitados e ingeniería de características

2.7.1 Complejidad y capacidad de generalización

La cantidad de observaciones debe valorarse en relación con la complejidad del modelo y la dependencia de los datos. Para pérdida cuadrática, la descomposición sesgo–varianza expresa el error esperado como suma de sesgo al cuadrado, varianza del estimador y ruido irreducible. La ecuación (20) resume esa relación para una entrada x (Hastie et al., 2009).

$$E[(Y - \hat{f}(x))^2] = \text{Sesgo}^2[\hat{f}(x)] + \text{Var}[\hat{f}(x)] + \sigma^2 \quad (21)$$

Un ajuste flexible puede reducir error de entrenamiento y ser sensible a cambios de muestra. Regularizar busca controlar esa sensibilidad, aunque no elimina toda incertidumbre. La estabilidad deberá examinarse con datos posteriores, especialmente cuando la agregación semanal reduzca el número de observaciones disponibles para estimar parámetros (Hastie et al., 2009).

2.7.2 Penalizaciones y selección de variables

Ridge añade una penalización cuadrática sobre coeficientes y Lasso una penalización absoluta. Las ecuaciones (21) y (22) presentan sus objetivos en notación común: SSE es la suma de errores cuadrados y beta reúne los coeficientes, excluyendo el intercepto de la penalización. Lambda controla la intensidad de contracción (Hastie et al., 2009; Tibshirani, 1996).

$$\hat{\beta}^R = \operatorname{argmin}_{\beta} (\operatorname{SSE}(\beta) + \lambda \sum_{j=1}^K \beta_j^2) \quad (22)$$

$$\hat{\beta}^L = \operatorname{argmin}_{\beta} (\operatorname{SSE}(\beta) + \lambda \sum_{j=1}^K |\beta_j|) \quad (23)$$

Lasso puede llevar coeficientes a cero y producir una representación más reducida. Eso no demuestra que una variable carezca de importancia económica; su selección depende de los datos, la penalización y los demás predictores. La comparación deberá ajustar lambda dentro de entrenamiento y considerar el escalado, pues las unidades de las variables influyen en la penalización (Tibshirani, 1996).

2.7.3 Predictores temporales y calendario

Los rezagos y resúmenes móviles expresan información histórica en una forma utilizable por algoritmos de regresión. Deben construirse únicamente con observaciones conocidas en cada origen. Imputación, escalado y selección de variables forman parte del procedimiento de entrenamiento y no deben estimarse con las semanas finales de evaluación (Kuhn & Johnson, 2013).

Las bases armónicas representan ciclos mediante funciones seno y coseno. La ecuación 23) presenta un par de términos con periodicidad m y armónico k . La codificación permite representar continuidad entre el final y el inicio de un ciclo, sin asignar una distancia artificialmente grande a posiciones próximas (Hyndman & Athanasopoulos, 2021).

$$s_{k,t} = \sin\left(\frac{2\pi kt}{m}\right), \quad c_{k,t} = \cos\left(\frac{2\pi kt}{m}\right) \quad (24)$$

La periodicidad debe corresponder al índice temporal y puede representarse mediante términos de Fourier cuando la estacionalidad lo justifique (Hyndman & Athanasopoulos, 2021). Para este estudio, los eventos diarios se convertirán en indicadores semanales de presencia o proximidad. El número de armónicos y de interacciones se limitará de acuerdo con el historial disponible; ambas son decisiones de diseño del caso.

2.7.4 Disponibilidad de variables exógenas

Las variables de calendario pueden conocerse anticipadamente, mientras que clima observado, ventas futuras o indicadores publicados con retraso pueden ser desconocidos al pronosticar. Un modelo con regresores necesita sus valores futuros o un procedimiento explícito para estimarlos. Utilizar realizaciones futuras como si estuvieran disponibles produciría una evaluación que no representa el uso previsto (Hyndman & Athanasopoulos, 2021).

En horizontes de varias semanas, tampoco puede incorporarse como rezago una compra futura todavía no observada. La metodología deberá indicar si se generan pronósticos directos por horizonte o se utilizan predicciones recursivas. El análisis de variables exógenas podrá complementar el contraste principal, sin constituir una segunda hipótesis independiente (Hyndman & Athanasopoulos, 2021).

2.8 Evaluación temporal y métricas de precisión

2.8.1 Origen del pronóstico y ventana de entrenamiento

La evaluación fuera de muestra compara pronósticos con observaciones que no participaron en su ajuste. Una ventana deslizante mantiene un historial de tamaño fijo y actualiza su posición; una ventana expansiva conserva el historial previo y añade observaciones. La elección afecta recencia, tamaño de muestra y cantidad de evaluaciones posibles (Tashman, 2000).

La comparación requiere suficientes orígenes y resultados por horizonte, evitando que un único periodo determine la conclusión. Los modelos deberán enfrentar las mismas semanas y condiciones de información. El error de la ecuación (24) distingue el valor observado en $t+h$ del pronóstico emitido en t (Hyndman & Athanasopoulos, 2021; Tashman, 2000).

$$e_{t,h} = y_{t+h} - \hat{y}_{t+h|t} \quad (25)$$

El ajuste de configuraciones deberá separarse de su evaluación final. Si los pesos híbridos, las variables o el modelo se eligen observando los resultados finales, esos resultados dejan de ser una estimación independiente de la selección. El protocolo temporal permitirá comparar

alternativas sin dar por comprobada la hipótesis antes de obtener evidencia (Hyndman & Athanasopoulos, 2021).

2.8.2 Error monetario del importe total

MAE y RMSE resumen el error en las unidades de la respuesta. MAE promedia magnitudes absolutas; RMSE extrae la raíz del promedio de cuadrados y es más sensible a errores grandes. Las ecuaciones (25) y (26) se expresan para un horizonte h y un conjunto O de n orígenes evaluados (Hyndman & Athanasopoulos, 2021).

$$MAE_h = \frac{1}{n} \sum_{t \in O} |e_{t,h}| \quad (26)$$

$$RMSE_h = \sqrt{\frac{1}{n} \sum_{t \in O} e_{t,h}^2} \quad (27)$$

RMSE y MAE resumen el error en las mismas unidades del objetivo y deben interpretarse por horizonte (Hyndman & Athanasopoulos, 2021). Un RMSE menor representa una menor media de errores cuadrados, pero no implica necesariamente menos errores extremos. Como regla previa del protocolo, H1 tendrá un criterio principal de comparación fijado antes del análisis final y las demás métricas se informarán como evidencia complementaria.

2.8.3 Escalamiento y límites de errores porcentuales

MASE divide el error absoluto por una escala obtenida de diferencias históricas de entrenamiento. La ecuación (27) muestra su forma para una partición con N observaciones de entrenamiento, n de prueba y rezago de referencia m . Permite comparar escalas sin dividir cada error por la compra observada de su semana (Hyndman & Koehler, 2006).

$$MASE = \frac{\frac{1}{n} \sum_{i=1}^n |e_i|}{\frac{1}{N-m} \sum_{t=m+1}^N |y_t - y_{t-m}|} \quad (28)$$

El denominador debe ser positivo y calcularse sin datos de prueba. Al desplazar la ventana, la regla de escalamiento deberá mantenerse explícita; un historial constante puede hacer indefinida la medida. MASE complementa el contraste directo con referencias y no reemplaza la interpretación de pesos monetarios (Hyndman & Koehler, 2006).

MAPE divide cada error por el valor observado. Aunque produce porcentajes, resulta indefinido con ceros e inestable con importes pequeños. Por ello, no se utilizará como criterio central de contraste de una serie con esas condiciones. Su eventual reporte deberá identificar los casos válidos sin ocultar las semanas excluidas (Hyndman & Koehler, 2006).

2.8.4 Error de participaciones y evaluación conjunta

La precisión de la composición debe medirse separadamente. La ecuación (28) adapta MAE a participaciones entre cero y uno y multiplica por cien para expresar el error en puntos porcentuales. O con subíndice positivo representa los orígenes cuyo total observado en el horizonte es positivo y n con el mismo subíndice es su cantidad. Esta adaptación no se presenta como una métrica composicional nueva atribuida a los autores (Aitchison, 1982; Hyndman & Koehler, 2006).

$$\text{MAE}_{p,h} = \frac{100}{n_+J} \sum_{t \in O_+} \sum_{j=1}^J |p_{j,t+h} - \hat{p}_{j,t+h|t}| \quad (29)$$

La ponderación uniforme ofrece igual importancia a las categorías. Si se adoptan otros pesos, deberán justificarse y fijarse antes de evaluar. Además de la medida agregada, revisar errores por insumo permite identificar si una mejora promedio oculta deterioro en categorías concretas. Se informarán por separado las semanas cuyo total cero impida definir una composición observada. Esta regla constituye una decisión de evaluación del estudio.

La evaluación fuera de muestra debe mantenerse separada del ajuste y de la explicación causal (Shmueli, 2010; Tashman, 2000). Como definición previa de esta investigación, el contraste de H1 considerará la precisión del importe total y de su distribución; mejorar solo uno se describirá como evidencia favorable para ese componente. No se escogerá retrospectivamente el horizonte más conveniente ni se interpretará una diferencia de error como efecto financiero.

2.9 Inteligencia de negocios y comunicación del pronóstico

2.9.1 Presentación del presupuesto y su incertidumbre

Un tablero puede reunir el total esperado, las participaciones y las asignaciones monetarias para que el responsable revise el presupuesto. La presentación deberá identificar origen, horizonte, unidades y referencia comparativa. Esta función corresponde al soporte de decisiones; no transforma automáticamente una asignación monetaria en una orden de compra (Power, 2002).

Los intervalos de predicción comunican incertidumbre adicional al valor puntual. Bajo una aproximación normal de los errores, la ecuación (29) utiliza un cuantil z y una estimación de la desviación del error correspondiente al horizonte. Esa aproximación depende de supuestos que deberán verificarse antes de su uso (Hyndman & Athanasopoulos, 2021).

$$\hat{y}_{t+h|t} \pm z_{1-\alpha/2} \hat{\sigma}_h \quad (30)$$

Alfa expresa la probabilidad nominal fuera del intervalo y sigma la escala de incertidumbre predictiva. No debe confundirse este intervalo con uno de confianza para una media estimada ni calcularse su amplitud sumando errores sin considerar el horizonte. En series asimétricas o con ceros, otras aproximaciones podrían resultar más pertinentes (Hyndman & Athanasopoulos, 2021).

2.9.2 Adopción y límites operativos

La viabilidad de una herramienta depende también de integración, mantenimiento, competencias y recursos. La digitalización de empresas pequeñas enfrenta barreras diversas, por lo que una solución debe adecuarse a sus capacidades y no justificarse únicamente por sofisticación. El tablero propuesto buscará facilitar interpretación y trazabilidad; no se asumirá que su disponibilidad demuestra adopción efectiva (OECD, 2021).

La precisión predictiva, los costos de implementación y los beneficios organizacionales corresponden a dimensiones distintas. En esta investigación, una reducción de MAE o RMSE no se denominará retorno de inversión, y los resultados se presentarán como información para apoyar la decisión, no como sustituto de la información operativa del responsable. Esta

separación constituye una delimitación económica del estudio; Power (2002) sustenta el papel complementario de los sistemas de apoyo a decisiones.

2.10 Síntesis de fundamentos y relación con la hipótesis

Los fundamentos revisados permiten plantear una integración de métodos que representen señales diferentes y una desagregación que conserve la relación entre total e insumos. La combinación ofrece una razón teórica para esperar mejoras, mientras que la estimación de pesos y la dependencia entre errores explican por qué esa mejora no está asegurada (Hyndman & Athanasopoulos, 2021).

Los datos composicionales requieren conservar proporciones válidas dentro de un total (Aitchison, 1982). Por ello, el procedimiento evaluará por separado el importe y las participaciones frente a sus respectivas referencias. La coherencia de suma corresponde a la representación jerárquica, mientras que la precisión exige evidencia fuera de muestra (Hyndman & Athanasopoulos, 2021; Hyndman et al., 2011).

Shmueli (2010) distingue los objetivos explicativos de los predictivos. Con base en esa distinción, esta investigación se define como una evaluación predictiva del presupuesto semanal de abastecimiento. Como regla previa del estudio, H1 requería evidencia favorable en el importe total y en las participaciones; una mejora aislada se informará como resultado de ese componente y no como confirmación de la hipótesis conjunta.

3 METODOLOGÍA

Este capítulo describe el diseño evaluativo exploratorio utilizado para desarrollar y comparar el modelo híbrido y el procedimiento de distribución porcentual. Se documentan las fuentes, la unidad semanal de análisis, la auditoría de cobertura, la construcción del panel, los modelos de referencia, la selección interna, la evaluación temporal final y los criterios de interpretación. La reproducibilidad se sustenta en el manifiesto de ejecución, las huellas digitales de las fuentes y el código, y los productos exportados por la corrida `run_20260924T195600Z_86a6f5`.

Tipo de tesis: estudio aplicado, cuantitativo, no experimental y evaluativo exploratorio, basado en un caso de estudio longitudinal-retrospectivo.

3.1 Tipo de investigación según el objetivo de esta

Investigación aplicada

En *Cup&Cake*, la investigación tiene como propósito desarrollar y evaluar un modelo híbrido que integre métodos estadísticos y aprendizaje automático para pronosticar el importe total semanal de compras, junto con un procedimiento para estimar su distribución porcentual entre los principales insumos. Se dispone de una implementación computacional inicial; su precisión con datos reales se contrastó frente a modelos de referencia como apoyo a la planeación del presupuesto de abastecimiento.

La aplicación se delimitó al caso de *Cup&Cake*. Los pronósticos se comunicaron mediante un tablero de inteligencia de negocios, sin sustituir el juicio del responsable ni presuponer mejoras en rentabilidad, inventarios o merma. Los resultados no se generalizaron automáticamente a otras microempresas.

3.2 Según el alcance evaluativo del estudio

Se documentó el contexto de planeación de compras de *Cup&Cake* para interpretar las necesidades de información del responsable. La evaluación cuantitativa se realizó frente a

referencias reproducibles. Solo se incluyeron estimaciones del propietario como comparador si existen registros fechados antes de conocer los importes observados y compatibles con los mismos horizontes de pronóstico.

Evaluativa y comparativa

Para el caso de *Cup&Cake* no se adoptó el alcance causal descrito en la definición precedente. La aplicación tuvo carácter evaluativo y comparativo: se contrastaron alternativas de pronóstico bajo las mismas condiciones temporales para examinar su precisión fuera de muestra, sin atribuir relaciones de causa y efecto sobre la operación del negocio.

La investigación describió el comportamiento histórico de ventas y compras y comparó la precisión del modelo híbrido y del procedimiento de distribución porcentual con sus respectivas referencias. La evaluación consideró por separado el importe total semanal y la participación de los principales insumos. Su inferencia se limitó al desempeño predictivo del caso de estudio.

En consecuencia, el diseño evaluativo determinó si la tecnología algorítmica aporta una mejora verificable de precisión respecto de las referencias comparadas. La inteligencia artificial se evaluó como una alternativa de apoyo para anticipar el presupuesto de abastecimiento, sin suponer que sustituye el juicio del responsable ni que genera automáticamente mejoras financieras u operativas.

3.3 Según el tipo de datos empleados

Cuantitativa

La semana calendario constituyó la unidad temporal de análisis. Se calculó el importe total de compras, el importe correspondiente a cada insumo seleccionado y su participación porcentual. Los registros históricos de ventas se reservaron como predictores únicamente cuando su información estaba disponible antes de cada origen de pronóstico.

Se integraron los registros históricos de ventas y compras de *Cup&Cake* y se agregaron por semana calendario. Las variables exógenas se incorporaron según su pertinencia y

disponibilidad documentada. Los eventos de calendario conocidos se utilizaron para la semana objetivo; los indicadores económicos y meteorológicos debían representar la información efectivamente disponible antes del pronóstico.

Las matrices semanales permitieron ajustar y comparar los componentes estadístico y de aprendizaje automático, su integración híbrida y el procedimiento de distribución porcentual. Se evaluó el error monetario del total y el error de participación por insumo. El carácter cuantitativo no implicó generalización estadística a otras empresas: las conclusiones se circunscribieron a los registros y condiciones del caso estudiado.

3.4 Según el grado de manipulación de las variables

No experimental, evaluativa y retrospectiva

En un diseño no experimental se analizan datos observados sin manipular deliberadamente las condiciones de la empresa. La comparación temporal permitió estimar desempeño predictivo, pero no inferir causalidad experimental.

Se adoptó un diseño no experimental basado en el análisis retrospectivo de registros históricos de Cup&Cake. No se introdujeron intervenciones deliberadas en la operación ni se asignaron grupos experimentales. La evaluación reprodujo situaciones de pronóstico mediante cortes cronológicos y utilizó exclusivamente información disponible hasta cada origen.

Se evaluaron la precisión del importe total semanal y la de su distribución porcentual. Para el importe total, la referencia primaria fue el último valor semanal observado; se conservaron como comparadores el promedio móvil de cuatro semanas y, cuando existió cobertura suficiente, el ingenuo estacional de 52 semanas. Para la distribución se utilizó una referencia de participaciones históricas. Todos los métodos se evaluaron sobre fechas objetivo comunes; los ceros observados se distinguieron de la ausencia de registros.

Por consiguiente, el rigor del estudio proviene de la separación temporal estricta, la validación rolling-window (ventana deslizante) y la comparación homogénea contra referencias

reproducibles. Estos elementos permiten evaluar generalización predictiva en condiciones históricas, sin afirmar causalidad experimental.

3.5 Diseño evaluativo y comparación contra la línea base

El diseño cuantitativo, aplicado, no experimental y evaluativo se concretó mediante un estudio de caso longitudinal-retrospectivo. Los registros se organizaron cronológicamente y las decisiones de modelado se documentaron antes de examinar la evaluación final.

La comparación contrastó el modelo híbrido con las referencias monetarias y con sus componentes individuales; el procedimiento de distribución porcentual se contrastó con su propia referencia histórica. Se utilizaron las mismas fechas objetivo y horizontes para cada comparación. No se emplearon preprueba, posprueba ni grupos de control experimentales.

La corrida aplicó validación de ventana deslizante con 52 semanas de entrenamiento y avance de tres semanas. Se generaron pronósticos directos para $h=1$, $h=2$, $h=3$ y $h=4$, con $h=1$ como horizonte principal, y las métricas se reportaron por horizonte. La suma de los cuatro pronósticos representa un consolidado de 28 días y no equivale necesariamente a un mes calendario.

3.6 Según el tipo de inferencia

De método deductivo

En el marco de este estudio, el proceso deductivo parte de los fundamentos de los modelos de pronóstico y de la evidencia empírica sobre *small data*. La literatura científica indica que el desempeño de los modelos depende de la estructura de la serie, las variables disponibles, el tamaño de la muestra y el protocolo de evaluación. Por ello, no se presupone superioridad de los algoritmos de aprendizaje automático sobre los métodos estadísticos o las reglas empíricas.

Para contrastar H1, se comparó el modelo híbrido y el procedimiento de distribución porcentual con sus respectivos modelos de referencia, utilizando las mismas semanas y horizontes de evaluación y únicamente información disponible antes de cada pronóstico. Se evaluaron por separado el error del importe total semanal y el error de participación de los principales insumos. Los análisis con y sin variables exógenas tuvieron carácter complementario y no

constituyeron una segunda hipótesis. La evidencia favorable debía abarcar ambos componentes de H1; una mejora aislada en el importe total no fue suficiente para respaldarla. El protocolo de contraste, las métricas principales y el tratamiento de comparaciones múltiples se especificaron antes de examinar el conjunto de evaluación final.

3.7 Temporalidad de la investigación

El estudio fue longitudinal-retrospectivo y evaluativo exploratorio. El panel configurado abarcó del 5 de diciembre de 2016 al 11 de mayo de 2026. La validación interna utilizó orígenes del 18 de noviembre de 2024 al 10 de febrero de 2025; la evaluación final empleó seis orígenes del 24 de marzo al 7 de julio de 2025, con fechas objetivo hasta el 28 de julio de 2025. Estas fechas describen el alcance de la corrida y no implican cobertura exhaustiva de todas las semanas.

La incorporación de variables exógenas se controló mediante un registro explícito de fuente, disponibilidad y rezago. El pipeline solo admitió predictores incluidos en dicho registro; cualquier variable exógena no documentada se bloqueó antes del modelado. El sistema de soporte a la decisión comunicó este inventario como condición para generar pronósticos futuros, evitando utilizar información que no esté disponible ex ante.

Para asegurar la reproducibilidad, las rutas de datos y resultados se resolvieron desde la ubicación del proyecto, sin depender de una carpeta fija del equipo. La ejecución exportó un manifiesto con las huellas de las fuentes y del código, versiones de las bibliotecas, semilla aleatoria, parámetros de ventana y diccionario de variables. Este diccionario documentó la fuente, el rezago y la disponibilidad temporal de cada predictor; los indicadores publicados u observados se desplazaron para representar únicamente la información disponible antes del pronóstico.

Las semanas sin cobertura de compras se trataron como ausencia de observación y no como importes cero. Las copias completadas por promedio simple se almacenaron en archivos derivados con su procedencia y método, pero el experimento consumió el panel original sin imputar. En consecuencia, esos valores se excluyeron del ajuste, la selección de modelos, la evaluación fuera de muestra y el contraste de H1.

3.8 Procedimiento metodológico

El procedimiento comprendió recolección y depuración de registros, agregación semanal, diagnóstico temporal, ingeniería de características, selección de componentes e integración del modelo híbrido, estimación de la distribución porcentual, evaluación fuera de muestra y comunicación de resultados. La corrida `run_20260924T195600Z_86a6f5` se ejecutó con fuentes aprobadas y un catálogo y una cobertura trazables. La verificación técnica del software se mantuvo separada de la evaluación de precisión: aprobar controles de consistencia no se interpretó como validación predictiva ni como confirmación de H1.

3.8.1 Recolección y estructuración de los conjuntos de datos (*Datasets*)

Se recopilaron y estructuraron los registros históricos disponibles de Cup&Cake. Se verificó su integridad antes de asumir su utilidad para el modelado. La consolidación contempló principalmente las siguientes fuentes:

1. Histórico de ventas con ingresos diarios.
2. Bitácoras de compra de materia prima.

Se homologaron fechas, identificadores de insumos e importes, documentando duplicados, devoluciones y registros incompletos. Las observaciones se agregaron por semana calendario con una regla uniforme de inicio y cierre. Se obtuvieron la serie del importe total, las series monetarias por insumo y sus participaciones, además de predictores compatibles con la frecuencia semanal.

Auditoría de cobertura y construcción del panel semanal

La cobertura se determinó con un calendario semanal y una tabla de evidencia revisada. Cada semana se distinguió como observada, cero confirmado o desconocida; la ausencia de transacciones no se interpretó por sí sola como gasto cero. En la preparación se generaron, como productos derivados de auditoría, copias completadas mediante promedio simple para el tramo del 3 de mayo de 2021 al 29 de abril de 2024. El experimento utilizó el panel original

sin imputar; fuera del tramo autorizado, los periodos sin captura permanecieron ausentes y se excluyeron cuando no existió evidencia suficiente.

El experimento usa evaluación temporal *rolling window*. La configuración aplicada fija una ventana de entrenamiento de 52 semanas, desplaza el origen cada tres semanas y pronostica horizontes directos de una a cuatro semanas. La corrida reciente reserva el tramo final definido por la configuración y registra los *folds* incompletos o no comparables, en lugar de completar sus valores. La selección interna del modelo ocurre antes de la evaluación final; los resultados finales no se reutilizan para escoger componentes.

Los diagnósticos no se utilizaron para contrastar H1. Su función fue fundamentar la selección de rezagos, transformaciones y familias de modelos. Cualquier configuración derivada de estos resultados se ajustó exclusivamente con información anterior a cada origen de pronóstico, preservando la separación temporal y evitando fuga de información.

Cada corrida exporta panel semanal, periodos ausentes, imputaciones realizadas, coberturas, exclusiones, predicciones, métricas, figuras y manifiesto con huellas de las fuentes y del código. Los diagnósticos exploratorios heredados y sus figuras permanecen identificados como antecedentes, no como evidencia producida por la corrida vigente.

3.8.2 Predictores de compras, ventas y calendario

Se examinó si los registros de compras de Cup&Cake presentan patrones temporales o asociaciones con eventos comerciales que puedan aportar información predictiva. Estas relaciones no se asumieron de antemano ni se equiparó el importe de compras con la demanda de productos. Las características candidatas se evaluaron dentro del conjunto de desarrollo.

El panel modelado incorpora características de compras y ventas agregadas semanalmente, antecedentes temporales y variables calendáricas. Las ventas se usan como predictor histórico: para cada origen solo se admiten los valores ya observables antes del pronóstico. La corrida más reciente registró como variables calendáricas disponibles los indicadores de semana de pago y semana festiva. No se consideran conocidas a futuro variables como ventas

realizadas o condiciones observadas posteriormente. La inclusión de una fuente en el flujo no implica que cada columna haya sido seleccionada por todos los modelos.

3.8.3 Modelos de referencia y arquitectura híbrida

Se comparan referencias sencillas y modelos estadísticos y de aprendizaje automático, además de combinaciones híbridas. La selección se realiza por horizonte mediante validación temporal interna y con los mismos datos disponibles en cada origen.

- El componente estadístico contempla suavizamiento exponencial y ARIMA estacional/no estacional según la implementación, además de referencias como último valor, promedio móvil y persistencia estacional cuando la historia necesaria está disponible. La disponibilidad desigual de una referencia estacional se reporta; no se fuerza su resultado en *folds* sin suficientes observaciones.
- Los componentes de aprendizaje automático incluyen Ridge, Random Forest, HistGradientBoosting y una red neuronal perceptrón multicapa (MLP) de arquitectura pequeña y semilla fija. Se evalúan tanto como predictores directos como en combinaciones residuales con ARIMA. La MLP se denomina red neuronal; no es una arquitectura recurrente RNN/LSTM.
- Las redes recurrentes RNN y LSTM no forman parte de esta versión. La red neuronal incluida es una MLP acotada, apropiada para el tamaño reducido de la muestra y evaluada bajo las mismas particiones temporales.

El híbrido integra pronósticos estadísticos y de aprendizaje automático mediante ponderación, y también evalúa corrección de residuos del componente ARIMA mediante aprendizaje automático. Se seleccionan familia, combinación y peso por horizonte con validación interna. Los pronósticos monetarios se restringen a valores no negativos; los fallos de ajuste quedan registrados y no se ocultan mediante sustituciones silenciosas.

El conjunto de categorías se define antes de evaluar. Se excluyen las categorías presupuestarias COMBUSTIBLE, MUEBLES, HERRAMIENTA, IMPUTADO, IMPUTADOS y

OTROS. Los principales insumos se presentan individualmente y las categorías elegibles restantes se agrupan como RESTO_ELEGIBLE para que la asignación concilie con el total pronosticado. Esta categoría residual no equivale a la categoría presupuestaria OTROS, que está excluida.

La participación de cada categoría principal se calcula respecto del total semanal elegible, sin reescalar las categorías mostradas para que por sí solas sumen 100 %. La porción elegible no mostrada se informa como RESTO_ELEGIBLE. Las participaciones históricas se estiman con ponderación exponencial, cuyo parámetro se selecciona internamente. Las asignaciones monetarias se obtienen multiplicando cada participación por el total pronosticado y se reconcilian a centavos.

Como comparación de composición se utiliza el promedio de participaciones semanales observado en la historia de entrenamiento, únicamente en semanas con total positivo y composición definida. La estimación exige un mínimo de ocho semanas válidas; si no se alcanza, se registra la exclusión y no se crea una distribución arbitraria.

3.8.4 Validación temporal *rolling window*

La configuración aplicada utiliza 52 semanas de entrenamiento, avance de tres semanas y horizontes de una a cuatro semanas. La validación interna utiliza cinco orígenes para elegir componentes; la disponibilidad de historia y cobertura determina qué *folds* pueden calcularse. Los objetivos de la última partición interna preceden a la evaluación final para evitar contaminación temporal.

En cada origen, los modelos se entrenan únicamente con datos admisibles hasta esa fecha y producen pronósticos directos para cada horizonte. Las características históricas se recalculan respetando su fecha de disponibilidad. Solo se calculan métricas cuando el objetivo tiene captura utilizable; se informan tamaño de muestra y exclusiones por horizonte y modelo.

3.8.5 Métricas y criterios de comparación

La evaluación compara el importe semanal y la composición porcentual con referencias apropiadas para cada variable. La comparación principal utiliza los *folds* comunes; referencias con menor disponibilidad se muestran por separado con su número de casos. La corrida actual permite analizar el aporte predictivo de ventas como característica disponible, pero una afirmación causal no se deriva de correlaciones ni de la selección de variables.

- MAE (Error Absoluto Medio): midió la magnitud promedio de los errores en el importe semanal de compras, sin considerar su dirección.
- RMSE (Raíz del Error Cuadrático Medio): se utilizó como criterio principal para el importe total semanal; MAE fue una medida complementaria. La evaluación de participaciones utilizó un criterio propio y no se combinaron directamente errores monetarios con errores porcentuales.
- Se utilizó MASE como medida monetaria complementaria, con el denominador calculado exclusivamente en el conjunto de entrenamiento y una referencia ingenua explícita. Si el denominador es cero, se reportó como no definido. MAPE no fue un criterio de selección y, si se presenta como diagnóstico, se indicaron las observaciones excluidas por importe cero.

La precisión de la distribución se evaluó mediante el error absoluto medio de las participaciones, expresado en puntos porcentuales. Se calculó por insumo y se presentó un promedio no ponderado entre las categorías previamente definidas. Las semanas con importe total observado igual a cero no tuvieron una composición porcentual definida y se excluyeron únicamente de esta métrica, informando su número; permanecieron en la evaluación monetaria cuando correspondieron a ceros confirmados.

La evidencia estadística se interpreta considerando el número reducido de *folds* y la cobertura del registro. Los controles automatizados verifican consistencia del software y no sustituyen

una prueba de hipótesis. La corrida reciente es exploratoria: los resultados descriptivos no bastan para declarar aceptada H1 ni para afirmar superioridad general del híbrido.

3.8.6 Comunicación del pronóstico para la planeación presupuestaria

El *pipeline* genera una salida local de soporte a decisiones con pronósticos semanales, participaciones, asignaciones por insumo, métricas y advertencias sobre la cobertura. El consolidado de cuatro horizontes representa 28 días, no necesariamente un mes calendario. Su utilidad es orientar la revisión del presupuesto, no emitir una orden de compra automática.

La herramienta no calcula cantidades físicas ni necesidades netas de inventario. Para ello se requerirían existencias, recetas, mermas, unidades homologadas y tiempos de entrega fiables, que no son variables completas del conjunto empleado.

Consideraciones éticas y tratamiento de datos

Cup&Cake autorizó el uso académico de sus registros para esta investigación. El tratamiento se limitó a los campos necesarios para construir las variables analíticas y evaluar el procedimiento. Los nombres de clientes, proveedores, responsables y demás identificadores personales o administrativos se excluyeron del conjunto de predictores y de los productos presentados. Los resultados se reportaron de forma agregada por semana y categoría; el acceso a los archivos de origen quedó restringido al proyecto. Esta autorización no elimina la obligación de conservar confidencialidad, trazabilidad y minimización de datos en futuras actualizaciones.

4 DESARROLLO

Este capítulo documenta el desarrollo realizado para convertir los registros disponibles en un pronóstico semanal del importe de compras y su distribución presupuestaria. Se describen la preparación de datos, la cobertura, los predictores, los modelos, la evaluación temporal y los productos de la corrida real más reciente. Las salidas se interpretan con su fecha de corte; no se presentan como necesidades actuales cuando la fuente termina antes de la fecha de elaboración.

Contexto de los registros y objetivo operativo

Cup&Cake conserva información de compras en un sistema propio y un historial de ventas integrado en hojas de cálculo, incluidos reportes procedentes de KYTE. Para este desarrollo, las compras constituyen la variable objetivo y las ventas se incorporan como predictor histórico cuando sus valores son conocidos antes del origen de pronóstico. El propósito operativo es apoyar la reserva de presupuesto de abastecimiento, no automatizar órdenes ni calcular cantidades físicas.

Preparación de fuentes y cobertura semanal

La corrida utiliza *Compras.xlsx*, *Ventas.xlsx* y el archivo contextual indicado en la configuración. Se conservaron los archivos originales y se generaron paneles derivados. Las fechas se alinearon a semanas con inicio en lunes; los importes de compras se agregaron por semana y por categoría presupuestaria. La huella SHA-256 de las fuentes, el código, las versiones de bibliotecas y la configuración quedaron en el manifiesto de la ejecución.

Los huecos del tramo autorizado del 3 de mayo de 2021 al 29 de abril de 2024 se completaron mediante promedio simple únicamente en copias derivadas de auditoría; cada valor estimado quedó identificado. El panel original sin imputar alimentó el ajuste y la evaluación. El resto de los periodos sin captura permaneció ausente. Una semana sin transacciones no se convirtió automáticamente en cero semanal: se conservó la diferencia entre cero respaldado y cobertura

desconocida. Cinco líneas con importe \$0 fechadas el 28 de agosto de 2023 se mantuvieron como registros y se exportaron por separado.

El importe semanal objetivo y los promedios simples usados únicamente en el tramo autorizado se expresan en las ecuaciones (31) a (33). En ellas, C es el conjunto de categorías presupuestarias elegibles, O el conjunto de semanas observadas dentro del tramo autorizado y M sus semanas faltantes.


$$Y_t = \sum_{i \in C} X_{i,t} \quad (31)$$

$$\hat{X}_{i,t} = (1/|O_i|) \sum_{s \in O_i} X_{i,s}, \quad t \in M \quad (32)$$

$$\hat{V}_t = (1/|O_v|) \sum_{s \in O_v} V_s, \quad t \in M_v \quad (33)$$

La media de compras se calcula por categoría a partir de las semanas observadas; el total imputado es la suma de esas medias. En ventas se utiliza el promedio de la serie semanal observada. Estas estimaciones se guardan en archivos derivados y no sustituyen el panel original de evaluación.

Figura 1. Cobertura semanal de los registros de compras en la corrida real.



La figura presenta el estado semanal documentado por la auditoría. Las zonas desconocidas o inciertas no se interpretan como ausencia de gasto comprobada; la extensión del calendario no equivale a cobertura sustantiva completa.


Figura 2. Auditoría de registros de compra y decisiones de inclusión.



Construcción del panel y caracterización exploratoria


Se homologaron los registros, se aplicó el catálogo aprobado y se excluyeron antes de calcular el objetivo las categorías COMBUSTIBLE, MUEBLES, HERRAMIENTA, IMPUTADO, IMPUTADOS y OTROS. El panel semanal mantiene huecos desconocidos, documenta las semanas utilizables y registra las exclusiones. Los importes se expresan en MXN nominales.

Figura 3. Importes semanales de compras y periodos sin registro.



La serie muestra variación elevada y periodos discontinuos. Representa compras utilizables registradas, no una medida completa del gasto real durante semanas cuya cobertura no está verificada.

Figura 4. Distribución del importe semanal y frecuencia de ceros.




Las semanas con cero confirmado y las semanas sin captura se mantienen como estados distintos durante el análisis y la evaluación.

Integración de ventas y variables calendario

Las ventas se agregaron a frecuencia semanal y se alinearon con el calendario de compras. En cada origen se utilizaron únicamente antecedentes de ventas ya observados, evitando usar ventas realizadas después de la fecha de emisión. La corrida registró además indicadores de semana festiva y semana de pago. Variables observadas ex post, como ventas futuras o temperatura realizada, no se consideran conocidas por anticipado.

Figura 5. Ventas semanales registradas.



La coincidencia entre ventas y compras puede motivar análisis predictivo, pero no demuestra causalidad ni garantiza por sí misma una mejora del pronóstico.

Definición de categorías y distribución presupuestaria

La variable monetaria se construye con categorías elegibles después de excluir las seis categorías fuera de alcance. Los insumos principales se informan por separado. Las demás categorías elegibles se consolidan en RESTO_ELEGIBLE, que no equivale a la categoría presupuestaria OTROS. Las participaciones se calculan respecto del total elegible; el remanente se conserva en RESTO_ELEGIBLE para conciliar a 100 %. La distribución se estima con participaciones históricas ponderadas exponencialmente y requiere al menos ocho semanas válidas de composición.

La participación presupuestaria y el remanente de categorías elegibles se definen en las ecuaciones (34) y (35). El promedio ponderado por antigüedad que utiliza la corrida se muestra en la ecuación (36).

$$p_{i,t} = X_{i,t} / Y_t \quad \text{si } Y_t > 0 \quad (34)$$

$$p^R_{i,t} = \max(0, 1 - \sum_{i \in K} p_{i,t}) \quad (35)$$

$$\hat{p}_i(T) = [\sum_{t \in \mathcal{V}_T} (1-\alpha)^{(T-t)} p_{i,t}] / [\sum_{t \in \mathcal{V}_T} (1-\alpha)^{(T-t)}] \quad (36)$$

Aquí K contiene las categorías principales mostradas, R representa RESTO_ELEGIBLE, V_t contiene semanas anteriores con composición definida y α es el parámetro de ponderación seleccionado internamente. La normalización conserva el remanente elegible sin redistribuirlo entre los insumos principales.

Figura 6. Composición porcentual observada durante el periodo de desarrollo.





Figura 7. Categorías principales consideradas para la asignación presupuestaria.



Modelos y validación temporal

Se compararon referencias empíricas, modelos estadísticos, métodos de aprendizaje automático y combinaciones híbridas. Los componentes incluyen suavizamiento exponencial, *ARIMA*, *Ridge*, *Random Forest*, *HistGradientBoosting* y una red neuronal *MLP* pequeña. También se evaluaron combinaciones ponderadas y corrección de residuos *ARIMA* mediante aprendizaje automático. La *MLP* es una red neuronal no recurrente; no se ejecutaron *RNN* ni *LSTM*.

La evaluación usa *rolling window* con 52 semanas de entrenamiento, avance cada tres semanas y horizontes directos de una a cuatro semanas. Cinco orígenes internos se utilizaron para seleccionar componentes por horizonte. La corrida final produjo seis *folds* observados por horizonte; los modelos estacionales de 52 semanas tuvieron menos *folds* comparables por disponibilidad. Las exclusiones y tamaños muestrales se reportan sin rellenar artificialmente los objetivos faltantes.

La combinación ponderada, la corrección residual *ARIMA+MLP* y la generación de orígenes rolling se formalizan en las ecuaciones (37) a (39).

$$\hat{y}_{t+h}^H = w_h \hat{y}_{tatt+h}^s + (1-w_h) \hat{y}_{t+h}^{ML} \quad (37)$$

$$\hat{y}_{t+h}^R = \max(0, \hat{y}_{t+h}^{ARIMA} + f^{MLP}(x_t)), \quad e_{t+h} = Y_{t+h} - \hat{y}_{t+h}^{ARIMA} \quad (38)$$

$$o_k = o_0 + 3k; \quad T_o = \{t : o-52 \leq t < o\}; \quad \text{objetivo} = Y_{o+h-1} \quad (39)$$

El peso w_h se escoge entre los candidatos internos para cada horizonte. En la alternativa residual, la *MLP* estima el error fuera de muestra del *ARIMA* y la predicción corregida no puede ser negativa. Cada entrenamiento usa las 52 semanas calendario previas al origen; los objetivos ausentes no se rellenan para calcular las métricas.

Figura 8. Particiones temporales utilizadas para selección y evaluación.





Figura 9. Desempeño de las configuraciones consideradas en la validación interna.



La selección interna eligió *SES+RandomForest* para el horizonte 1, *SES+HistGradientBoosting* para el horizonte 2, *ARIMA+MLP* residual para el horizonte 3 y *ARIMA+RandomForest* residual para el horizonte 4. La elección no implica superioridad universal; el desempeño final se resume en la Tabla 3 y se analiza en Resultados.

Tabla 2. Etapas previas de trabajo y su uso en la corrida vigente.

Etapla previa	Qué se realizó	Aplicación vigente
Exploración de fuentes y cobertura	Se revisaron fuentes de compras, ventas y contexto y se ubicaron discontinuidades.	Se aplicó auditoría semanal explícita, diferenciando ceros y datos ausentes.
Preparación e imputación exploratoria	Se evaluaron criterios para completar huecos; se autorizó promedio simple solo en el tramo indicado.	Se preservan originales y se identifican los valores estimados en archivos derivados.
Variables candidatas	Se examinaron ventas, peso comercial, eventos, pedidos y clima.	La última corrida usa ventas históricas y calendarios disponibles ex ante; no implica selección universal de variables.
Alternativas de modelado	Se revisaron métodos estadísticos, de aprendizaje automático y estructuras híbridas.	Se comparan los candidatos en los mismos orígenes, incluida ARIMA+MLP.
Pruebas y demos	Se verificaron el flujo, la interfaz y salidas con ejercicios anteriores.	Las demos no se presentan como evidencia; la suite automatizada valida el código y no el desempeño predictivo.

Tabla 3. Configuración seleccionada y error del híbrido en la evaluación final.

Horizonte	Combinación seleccionada internamente	Folds	MAE	RMSE
h=1	ses + rf (peso estadístico 0.75)	6	\$386.43	\$521.60
h=2	ses + hgb (peso estadístico 0.75)	6	\$439.26	\$695.41

Horizonte	Combinación seleccionada internamente	Folds	MAE	RMSE
h=3	ss_arima111 + nn_residual__ss_arima111 (peso estadístico 0.75)	6	\$458.80	\$801.62
h=4	ss_arima111 + rf_residual__ss_arima111 (peso estadístico 0.75)	6	\$572.54	\$700.88

Asignación del presupuesto y controles de calidad

El pronóstico total de cada horizonte se distribuye entre insumos usando las participaciones estimadas. Para las próximas cuatro semanas se suman pronósticos semanales directos; el periodo representa 28 días, no necesariamente un mes calendario. La tabla siguiente presenta el total agregado y la participación monetaria de cada categoría elegible exportada por la corrida.

Las métricas monetarias y el consolidado de cuatro semanas se calculan conforme a las ecuaciones (40) a (42). El conjunto O_h contiene los orígenes evaluables comunes para el horizonte h ; D_o contiene solo pares de semanas calendario consecutivas observadas dentro del entrenamiento.

$$RMSE_h = \sqrt{[(1/|O_h|) \sum_{o \in O_h} (Y_{o+h-1} - \hat{Y}_{o,h})^2]}; \quad MAE_h = (1/|O_h|) \sum_{o \in O_h} |Y_{o+h-1} - \hat{Y}_{o,h}| \quad (40)$$

$$MASE_h = MAE_h / [(1/|D_o|) \sum_{t \in D_o} |Y_t - Y_{t-1}|] \quad (41)$$

$$B_4 = \sum_{h=1}^4 \hat{Y}_h; \quad p_{i,4} = (\sum_{h=1}^4 A_{i,h}) / B_4 \quad (42)$$

El RMSE, MAE y MASE se calculan por separado para cada horizonte; MASE no está definido si la escala de entrenamiento es cero. B_4 suma los cuatro pronósticos semanales directos y $p_{i,4}$ representa la participación de cada asignación A en el presupuesto acumulado de 28 días.

Figura 10. Asignación agregada del presupuesto pronosticado a cuatro semanas.





Tabla 4. Pronóstico agregado de cuatro semanas por categoría elegible.

Categoría / agrupación	Importe estimado (MXN)	Participación
HARINA	\$468.33	25.24%
BASES	\$354.84	19.12%
RESTO_ELEGIBLE	\$249.75	13.46%
EMPAQUE	\$212.07	11.43%
HUEVO	\$108.38	5.84%
AMBIANTE	\$103.75	5.59%
CHANTILLY	\$96.81	5.22%
CHOCOLATE	\$87.08	4.69%
FONDANT	\$87.07	4.69%
DECORACION	\$56.74	3.06%
CAPACILLOS	\$24.28	1.31%
RELLENO	\$6.51	0.35%

Los controles automáticos verificaron conservación de huecos, conciliación de asignaciones, suma de participaciones, importes no negativos, reproducción de la emisión, generación de cuatro horizontes y exclusión de categorías fuera del objetivo. Todos quedaron aprobados.

Estos controles verifican consistencia computacional, no precisión predictiva ni aceptación de la hipótesis.

Figura 11. Resultado de los controles de calidad del pipeline.



Alcance y trazabilidad de la corrida

La corrida `run_20260924T195600Z_86a6f5` finalizó correctamente y dejó métricas, predicciones, auditorías, asignaciones, figuras con datos de respaldo, tablero local y manifiesto con huellas digitales. Los artefactos son reproducibles a partir de la configuración y fuentes registradas.

El origen de emisión fue el 4 de agosto de 2025, pues los registros de compras utilizados llegan hasta el 28 de julio de 2025. El pronóstico de cuatro semanas es retrospectivo y no estima las necesidades del mes actual. Para apoyar decisiones contemporáneas se deben actualizar las compras y su cobertura documentada y volver a ejecutar el protocolo. La interpretación de los errores y su comparación con las referencias se desarrolla en Resultados.

5 RESULTADOS

La presente sección reporta la corrida empírica completa más reciente disponible, identificada como run_20260924T195600Z_86a6f5 y ejecutada el 24 de septiembre de 2026. Se utilizaron Compras.xlsx, Ventas.xlsx y el conjunto contextual de Tizayuca; la evaluación se refiere a importes nominales registrados y utilizables, no a una certificación de captura exhaustiva del gasto.

Calidad, cobertura e integración de datos

El panel cubrió semanas entre el 5 de diciembre de 2016 y el 11 de mayo de 2026. En el tramo del 3 de mayo de 2021 al 29 de abril de 2024, la auditoría identificó 128 semanas de compras observadas y generó 29 semanas estimadas mediante promedio simple en un producto derivado; en ventas reportó 157 semanas observadas y ninguna estimada. Las 29 semanas no se incorporaron al panel utilizado para ajustar o evaluar modelos. Los huecos restantes se mantuvieron como ausencia de captura y no se interpretaron como gasto cero.

En el objetivo monetario se excluyeron COMBUSTIBLE, MUEBLES, HERRAMIENTA, IMPUTADO/IMPUTADOS y OTROS. La composición incluyó 11 insumos principales y la categoría RESTO_ELEGIBLE para conciliar el total; esta última no equivale a OTROS. La auditoría de cobertura advierte que la presencia de transacciones no certifica que todos los movimientos de cada semana hayan sido capturados.

Las siete verificaciones automatizadas de la corrida resultaron aprobadas: conservación de huecos, reconciliación de asignaciones con el total, suma de participaciones, no negatividad, reproducción de la emisión, cuatro horizontes y exclusión de categorías fuera de alcance. No se encontraron registros pendientes de resolución en el archivo de pendientes de esta corrida.

Análisis de sensibilidad de la imputación

Para verificar el posible efecto de las 29 semanas estimadas, se repitió el experimento con la misma semilla (42), fuentes, particiones y parámetros de modelado, pero sin los parámetros

de imputación. La corrida principal run_20260924T195600Z_86a6f5 y la corrida de sensibilidad run_20260928T014913Z_38994f produjeron archivos idénticos, verificados por SHA-256, para métricas monetarias y composicionales, selección interna, predicciones, particiones y contraste de H1. La Tabla 5 resume la igualdad de las métricas monetarias por horizonte.

Tabla 5. Sensibilidad de las métricas monetarias a la configuración de imputación.

Horizonte	RMSE principal	RMSE sin imputación	MAE principal	MAE sin imputación	Diferencia
h=1	521.60	521.60	386.43	386.43	0.00
h=2	695.41	695.41	439.26	439.26	0.00
h=3	801.62	801.62	458.80	458.80	0.00
h=4	700.88	700.88	572.54	572.54	0.00

Nota. Errores en MXN; la diferencia corresponde a la corrida principal menos la corrida sin parámetros de imputación. La igualdad no demuestra que la imputación por promedio sea inocua en general: demuestra que, en esta implementación, las copias imputadas fueron productos de auditoría y no datos de entrenamiento o evaluación. Fuente: elaboración propia con las salidas de ambas corridas.

Diseño efectivo de evaluación

Se configuró una ventana de entrenamiento de 52 semanas, avance de 3 semanas y horizontes de 1 a 4 semanas, con 20 semanas reservadas como bloque final. Debido a la disponibilidad de objetivos utilizables y al esquema de avance, la evaluación generó seis orígenes efectivos para cada horizonte (24 predicciones objetivo-horizonte); no deben confundirse con 20 *folds*. No hubo exclusiones de objetivos monetarios en esas seis predicciones por horizonte. Los *benchmarks* estacionales de 52 semanas sí tuvieron menos casos utilizables (2, 4, 4 y 2, respectivamente), por falta del rezago anual observado; se reportan aparte y no se comparan como si tuvieran la misma disponibilidad.

El ajuste interno utilizó cinco orígenes y seleccionó configuraciones por horizonte: *SES* + *Random Forest* (peso estadístico 0.75) para h=1; *SES* + *HistGradientBoosting* (0.75) para h=2; *ARIMA* estacional simplificado + red neuronal residual para h=3; y *ARIMA* estacional

simplificado + *Random Forest* residual para $h=4$. Esta selección se efectuó en validación interna y no constituye por sí misma evidencia de superioridad en la evaluación externa.


Rendimiento comparativo del importe semanal

La tabla siguiente resume RMSE y MAE del ensamble denominado híbrido frente al método con menor RMSE entre los comparadores principales disponibles en las mismas fechas. El menor error observado no fue uniforme: el híbrido no obtuvo el menor RMSE en $h=1$, $h=2$ ni $h=4$; sí obtuvo el menor RMSE entre los comparadores principales en $h=3$. En $h=3$, la red neuronal residual tuvo menor MAE que el híbrido (420.998 frente a 458.797 MXN), aunque su RMSE fue ligeramente mayor (824.296 frente a 801.619 MXN).

Horizonte	Híbrido RMSE (MXN)	Híbrido MAE (MXN)	Menor RMSE comparador principal	RMSE (MXN)
1 semana	521.60	386.43	Random Forest	446.21
2 semanas	695.41	439.26	HistGradientBoosting	596.17
3 semanas	801.62	458.80	Híbrido	801.62
4 semanas	700.88	572.54	RF residual + ARIMA estacional	578.95

A través de horizontes, el RMSE del híbrido fue 521.60, 695.41, 801.62 y 700.88 MXN, mientras que su MAE fue 386.43, 439.26, 458.80 y 572.54 MXN. La comparación con el promedio móvil de cuatro semanas y otros métodos aparece en las salidas completas, pero su disponibilidad se etiqueta por separado cuando no comparte exactamente el conjunto principal de fechas. MASE también se calculó; sus valores para el híbrido fueron 28.89, 7.94, 7.51 y 16.68. Como su escala se forma con diferencias observadas de semanas calendario consecutivas y existen huecos, debe leerse con cautela y junto a las métricas monetarias, no como una medida autónoma de éxito.

Figura 12. Errores monetarios por modelo y horizonte en la evaluación temporal.



Fuente: salida del pipeline, corrida run_20260924T195600Z_86a6f5.

Distribución porcentual por insumo

La comparación composicional no identifica un único método dominante: la participación histórica fue mejor en los horizontes uno y cuatro, y el promedio temporal ponderado en los horizontes dos y tres. Esta alternancia sugiere que la composición puede cambiar con el horizonte y que una estructura de participaciones relativamente estable no debe suponerse sin evidencia. Los promedios de error fueron calculados sobre pocas observaciones válidas, de modo que pequeñas diferencias no deben interpretarse como superioridad estable.

La evaluación porcentual también tiene un dominio de aplicación distinto al monetario. Cuando el total elegible semanal es cero o falta captura, las participaciones no se definen o no son observables; excluir esos casos de la métrica composicional evita asignarles porcentajes artificiales, pero reduce aún más la muestra. El MAE en puntos porcentuales facilita la lectura por insumo, aunque el error entre partes está sujeto a la restricción de que las participaciones sumen cien por ciento.

Horizonte	Participación histórica (MAE pp)	Promedio temporal ponderado (MAE pp)	Menor error
1	10.34	11.73	Histórica
2	7.14	6.93	Temporal ponderada

Horizonte	Participación histórica (MAE pp)	Promedio temporal ponderado (MAE pp)	Menor error
3	10.77	10.37	Temporal ponderada
4	11.80	12.23	Histórica

Errores de participación




Figura 13. Error absoluto medio de participación por insumo, comparación de métodos y horizonte. Fuente: salida del pipeline, corrida run_20260924T195600Z_86a6f5.

En el pronóstico emitido desde el origen guardado del 4 de agosto de 2025, el total para las cuatro semanas fue de \$1,855.61 MXN nominales. Las mayores asignaciones fueron HARINA (25.24%; \$468.33), BASES (19.12%; \$354.84), RESTO_ELEGIBLE (13.46%; \$249.75) y EMPAQUE (11.43%; \$212.07). La suma de importes y participaciones se reconcilió con el total. Este pronóstico es una emisión histórica reproducible de esa corrida, no una estimación vigente para el mes actual ni una orden de compra.




Figura 14. Composición observada y estimada en la evaluación temporal. Fuente: salida del pipeline, corrida run_20260924T195600Z_86a6f5.

Contraste de hipótesis

La evaluación de H1 fue clasificada como retrospectiva exploratoria. Para el importe del horizonte principal ($h=1$) se obtuvieron seis pares; la diferencia media reportada fue 161,798.64 MXN², calculada como el error cuadrático del último valor menos el del híbrido (un valor positivo favorece al híbrido). El procedimiento no generó intervalo por muestra insuficiente frente al mínimo inferencial configurado. Para la composición se contó con tres pares válidos; la diferencia media fue -1.39 puntos porcentuales en la pérdida (error absoluto de participación del método histórico menos el del promedio temporal ponderado, por lo que un valor negativo favorece a este último), también sin intervalo. El criterio de evidencia favorable en ambos componentes no se cumplió y el resultado se marcó como no confirmatorio. En consecuencia, con esta corrida no se aprueba H1 ni se demuestra que el híbrido mejore conjuntamente el pronóstico monetario y la distribución porcentual; tampoco se concluye equivalencia o rechazo definitivo.

La Figura 15 muestra las diferencias de pérdidas para el contraste principal. La escasez de pares y la ausencia de intervalos válidos obligan a interpretar sus puntos como descriptivos, no como inferencia estadística concluyente.




Figura 15. Diferencias de pérdidas pareadas para H1 en el horizonte principal. Fuente: salida del pipeline, corrida `run_20260924T195600Z_86a6f5`.

Alcance de los resultados

La corrida demuestra que el flujo integra la limpieza y trazabilidad disponibles, produce comparaciones temporales a cuatro horizontes y genera una distribución que reconcilia con el total. En precisión, el desempeño favorable del híbrido dependió del horizonte y no dominó consistentemente a los métodos de referencia. El análisis de sensibilidad confirmó que las copias imputadas no modificaron ninguna salida evaluativa. Aun así, la cantidad limitada de orígenes y observaciones composicionales, las semanas sin captura y la falta de certificación de exhaustividad impiden generalizar el ranking o afirmar utilidad predictiva confirmatoria. La salida actual tampoco incorpora intervalos predictivos futuros.

6 DISCUSIÓN

Interpretación de los hallazgos y contraste con antecedentes

La corrida aporta evidencia empírica para comparar el híbrido con referencias, pero no muestra una ventaja uniforme del híbrido en todos los horizontes ni en los dos componentes del objetivo. El hallazgo más defendible es la dependencia del desempeño respecto del horizonte, la métrica y la disponibilidad de observaciones; por tanto, no procede describir al híbrido como superior en términos generales.

Este patrón es compatible con la evidencia amplia de M4: las combinaciones pueden lograr resultados competitivos, pero ese resultado agregado no garantiza que una combinación determinada mejore en cada serie o contexto (Makridakis et al., 2018b, 2020). La M4 cubre numerosas series de dominios y frecuencias diversos, mientras que este estudio aborda importes semanales de una microempresa con huecos de captura. La comparación local debe interpretarse con sus propias condiciones y no como confirmación ni refutación directa de aquella competencia.

La variación entre horizontes también concuerda con el fundamento de combinar pronósticos: la ganancia potencial depende de que los componentes aporten información complementaria y de la relación entre sus errores (Bates & Granger, 1969). En esta corrida, el híbrido fue competitivo en el horizonte de tres semanas, pero no lideró el RMSE en los otros tres. La red neuronal residual tuvo menor MAE en ese mismo horizonte, aunque no menor RMSE. La divergencia entre métricas indica que la elección del criterio de precisión importa; con seis orígenes, sin embargo, no hay base suficiente para elegir un ganador robusto.

El resultado no contradice la motivación de Zhang (2003), quien planteó que ARIMA y una red neuronal pueden representar componentes lineales y no lineales complementarios. Sí precisa el alcance de esa motivación: la arquitectura es una hipótesis de modelado que debe validarse en los datos y horizontes concretos. En la presente evaluación no se observó una mejora consistente que permita atribuir al componente neuronal un beneficio general.

Las ventas se incorporaron como información histórica disponible mediante rezagos, pero esta corrida no incluyó un experimento de ablación controlado que compare el mismo procedimiento con y sin ventas. Por ello, no se puede atribuir a las ventas una reducción específica del error ni afirmar que expliquen por sí solas las compras. Su aporte sigue siendo una pregunta empírica para una comparación dedicada.

En relación con los objetivos, se construyó y caracterizó el panel semanal con las fuentes disponibles; se implementaron los componentes estadísticos, de aprendizaje automático y sus integraciones; se estimó la distribución porcentual y se contrastaron ambos procedimientos con referencias mediante evaluación temporal. El cumplimiento es, no obstante, exploratorio: la precisión observada no demuestra que el procedimiento responda con fiabilidad confirmatoria a la pregunta de investigación.

La selección interna produjo una combinación distinta para cada horizonte, lo que refleja que la utilidad de cada componente depende del plazo evaluado. Como la selección se hizo con cinco orígenes, esas configuraciones son candidatos empíricos del procedimiento, no arquitecturas universalmente óptimas ni evidencia independiente de que la complejidad adicional mejore el pronóstico.

Demanda intermitente y selección de métricas

La métrica monetaria incluyó los importes cero registrados como valores del objetivo. En cambio, las participaciones no se definieron cuando el total elegible fue cero o faltó observación válida; esos casos no aportan un porcentaje interpretable y su exclusión se refleja en el reducido número de pares composicionales.

Implicaciones operativas y financieras

Para la planeación presupuestaria, el procedimiento ofrece una estructura reproducible que distribuye un total pronosticado entre insumos y conserva la conciliación aritmética. Esta coherencia es una condición útil para presentar escenarios, pero no equivale a precisión ni garantiza que el monto cubra las compras reales. La magnitud de los errores monetarios frente

a los importes semanales observados aconseja utilizar la salida como referencia revisable, no como presupuesto autorizado automáticamente.

Además, el pronóstico de cuatro semanas presentado en Resultados corresponde a un origen histórico de agosto de 2025. Su valor ilustra el formato de asignación producido por la corrida, pero no debe usarse para decidir compras en 2026. Una aplicación operativa requiere actualizar datos, cobertura y fecha de emisión, y volver a ejecutar el flujo; actualmente no se reportan intervalos predictivos futuros que cuantifiquen la incertidumbre de cada asignación.

Validez y limitaciones

La interpretación está condicionada por el tamaño efectivo de la evaluación: seis orígenes por horizonte y entre tres y cinco observaciones válidas por horizonte para la composición. La prueba estacional anual tuvo menos casos por falta de rezagos observados; su rendimiento no es directamente comparable con el de los modelos evaluados en todos los orígenes. Asimismo, la escala de MASE se calculó con diferencias de semanas consecutivas observadas, por lo que los huecos del calendario afectan su lectura.

La auditoría generó 29 semanas estimadas por promedio simple en un producto derivado, pero la inspección del flujo y la corrida de sensibilidad confirmaron que esos valores no entraron al ajuste, a la selección ni a la evaluación: las salidas clave fueron idénticas con y sin la configuración de imputación. Por ello, no se atribuye a esas estimaciones un sesgo en las métricas reportadas. La limitación que permanece es la cobertura original: la falta de certificación de captura exhaustiva impide asegurar que el objetivo represente la totalidad de las compras de cada semana; las conclusiones corresponden a importes registrados utilizables y a las categorías incluidas.

El diseño temporal reduce el riesgo de usar información futura para ajustar los modelos, pero la selección interna con cinco orígenes y la evaluación externa con pocos casos dejan incertidumbre sobre la estabilidad de las diferencias. El *bootstrap* configurado no produjo intervalos para H1 porque la muestra no alcanzó el mínimo fijado. Por ello, el resultado es no

confirmatorio: no respalda la superioridad conjunta del híbrido, pero tampoco demuestra equivalencia ni permite un rechazo definitivo de la hipótesis.

Finalmente, la evidencia se limita a este caso, al periodo y a las fuentes examinadas. Una evaluación posterior deberá conservar un bloque final independiente, ampliar la captura de compras, comparar explícitamente la contribución incremental de ventas y otros predictores disponibles, y estimar intervalos predictivos antes de proponer un uso presupuestario más exigente.

7 CONCLUSIONES

La corrida evaluada muestra que el *pipeline* puede integrar compras, ventas y variables de calendario, generar pronósticos semanales de uno a cuatro pasos y distribuir el importe entre insumos con conciliación aritmética. Sin embargo, el híbrido no obtuvo el menor error en todos los horizontes: entre los comparadores principales, alcanzó el menor RMSE únicamente a tres semanas. Por tanto, la investigación no demuestra una ventaja general del modelo híbrido; la respuesta depende del horizonte y de la métrica.

El objetivo general se cumplió en cuanto al desarrollo y a la evaluación exploratoria del procedimiento, pero no en el sentido de demostrar una mejora confirmatoria de precisión para la planeación. La validación efectiva tuvo seis orígenes monetarios por horizonte y entre tres y cinco observaciones válidas para la composición. El análisis de H1 no alcanzó el tamaño mínimo requerido para estimar intervalos; en consecuencia, no hay evidencia suficiente para afirmar que el híbrido mejore conjuntamente el importe total y su distribución porcentual. Este resultado no equivale a probar que los métodos sean iguales ni a un rechazo definitivo de H1.

Respecto de los objetivos específicos, se depuraron y agregaron semanalmente las fuentes disponibles y se caracterizó el panel. Las 29 semanas estimadas por promedio simple se mantuvieron identificadas en productos derivados de auditoría y se excluyeron del modelado; la repetición sin parámetros de imputación produjo exactamente las mismas salidas clave. Se implementaron combinaciones estadísticas y de aprendizaje automático, con información histórica de ventas y calendario disponible al origen; no se aisló mediante una prueba de ablación cuánto aporta cada predictor. También se estimaron y evaluaron participaciones históricas y ponderadas en el tiempo: su desempeño alternó entre horizontes, sin un método dominante. El contraste temporal frente a referencias se completó con carácter exploratorio, condicionado por la muestra reducida y la cobertura no certificada.

En términos de aplicación, la salida constituye un insumo de consulta y no una orden de compra. El pronóstico de cuatro semanas incluido en los resultados se emitió desde un origen histórico de agosto de 2025, por lo que no representa un presupuesto vigente. Para su uso

operativo se requiere actualizar la ingesta, verificar la cobertura y volver a emitir el pronóstico para la fecha de decisión correspondiente.

Recomendaciones

Antes de emplear el procedimiento para planear compras, se recomienda completar y documentar la auditoría de cobertura y resolver discrepancias de captura con los registros primarios disponibles. Las copias imputadas deben conservarse separadas y trazables como productos de auditoría, sin incorporarse al entrenamiento o a la evaluación salvo que un protocolo futuro lo autorice y lo analice expresamente. También deben mantenerse trazables las categorías excluidas y RESTO_ELEGIBLE, que concilia insumos elegibles menores y no representa OTROS. Cada emisión debe indicar fecha de corte, periodo objetivo, horizonte, supuestos y carácter nominal de los importes.

La comparación futura debe conservar modelos de referencia y evaluación temporal, ampliar el número de orígenes válidos y fijar de antemano un bloque independiente para la evaluación final. Se recomienda contrastar el mismo modelo con y sin rezagos de ventas y con las variables exógenas que realmente estén disponibles en cada origen; así podrá estimarse su contribución incremental sin atribuirle por inferencia. La decisión de adopción debe permanecer bajo revisión humana hasta que el desempeño y la utilidad del tablero sean comprobados con la persona responsable del abastecimiento.

Trabajo futuro

El trabajo posterior deberá priorizar la ampliación y certificación de los registros primarios de compras y ventas para reducir los huecos y aumentar los periodos evaluables. Con una base más completa, será posible realizar una evaluación confirmatoria con suficientes orígenes y estimar intervalos predictivos para el importe total y las asignaciones por insumo. También será pertinente evaluar por separado el aporte de ventas, calendario y otras variables exógenas mediante experimentos de ablación temporal.

Una vez actualizada la fecha de corte, podrá revisarse la estabilidad de la selección por horizonte y validarse el tablero como herramienta de apoyo mediante pruebas de uso con la microempresa. Estas etapas permitirán determinar si la precisión observada es suficientemente estable y útil para complementar la planeación presupuestaria, sin presuponer un beneficio financiero antes de medirlo.

GLOSARIO

Inteligencia Artificial (IA): Rama de la informática que diseña sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, como el aprendizaje, la planificación y la predicción.

Cadena de suministro: Conjunto de procesos involucrados en la producción, distribución y entrega de un producto desde su origen hasta el cliente final.

PYMES: Pequeñas y Medianas Empresas, generalmente caracterizadas por tener un número limitado de empleados y recursos, pero con alto potencial de innovación.

Agentes Inteligentes: Programas o sistemas que ejecutan acciones de manera autónoma para alcanzar objetivos específicos, basados en reglas o **aprendizaje automático**.

Pronóstico de demanda: Proceso de estimar la demanda futura de productos o servicios a través de datos históricos y modelos estadísticos o de **aprendizaje automático**.

REFERENCIAS

- Abrar, M., Shahriar, M. A., & Amin, A. (2024). *MCDFN: Supply chain demand forecasting via an explainable multi-channel data fusion network model*. arXiv preprint arXiv:2405.15598. <https://doi.org/10.48550/arXiv.2405.15598>
- Aitchison, J. (1982). The statistical analysis of compositional data. *Journal of the Royal Statistical Society: Series B (Methodological)*, 44(2), 139–160. <https://doi.org/10.1111/j.2517-6161.1982.tb01195.x>
- Bates, J. M., & Granger, C. W. J. (1969). The combination of forecasts. *Operational Research Quarterly*, 20(4), 451–468. <https://doi.org/10.2307/3008764>
- Ben Abdallah, H., Ayadi, M., & Boujelbene, Y. (2022). The main determinants and effects of product innovation: An exploratory study on the pastry companies of the region of Sfax (in Tunisia). *Technological Forecasting and Social Change*, 185, Article 122065. <https://doi.org/10.1016/j.techfore.2022.122065>
- Bergmeir, C., & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191, 192-213. <https://doi.org/10.1016/j.ins.2011.12.028>
- Bontempi, G., Ben Taieb, S., & Le Borgne, Y.-A. (2013). Machine learning strategies for time series forecasting. En M. Aufaure & E. Zimányi (Eds.), *Business intelligence* (pp. 62–77). Springer. https://doi.org/10.1007/978-3-642-36318-4_3
- Borsato, M. (2023). “Edible Aesthetics”: Blurring Boundaries between Pastry and Art. *Humanities*, 12(5), 126. <https://doi.org/10.3390/h12050126>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Cuevas-Vargas, H., Estrada, S., & Larios-Gómez, E. (2016). The effects of ICTs as innovation facilitators for a greater business performance. Evidence from Mexico. *Procedia Computer Science*, 91, 47–56. <https://doi.org/10.1016/j.procs.2016.07.040>
- Dubey, R., Gunasekaran, A., Childe, S. J., Bryde, D. J., Giannakis, M., & Foropon, C. (2021). Big data analytics and artificial intelligence pathway to operational performance under the effects of entrepreneurial orientation and environmental dynamism: A study of manufacturing

- organisations. *International Journal of Production Economics*, 226, 107599. <https://doi.org/10.1016/j.ijpe.2019.107599>
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232. <https://doi.org/10.1214/aos/1013203451>
- Giannopoulos, P. G., Dasaklis, T. K., Tsantilis, I., & Patsakis, C. (2025). Machine learning algorithms in intermittent demand forecasting: A review. *International Journal of Production Research*, 1–43. <https://doi.org/10.1080/00207543.2025.2578701>
- Global Entrepreneurship Monitor. (2024). *Global Entrepreneurship Monitor 2023/2024 global report: 25 years and growing*. <https://www.gemconsortium.org/report/51377>
- Góngora Chonillo, J. T. (2023). Evaluación del riesgo financiero en microempresas a través de inteligencia artificial. *Revista Pulso Científico*, 1(2), 34–49. <https://doi.org/10.70577/rps.v1i2.10>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction (2nd ed.)*. Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- Hewamalage, H., Bergmeir, C., & Bandara, K. (2021). Recurrent neural networks for time series forecasting: Current status and future directions. *International Journal of Forecasting*, 37(1), 388–427. <https://doi.org/10.1016/j.ijforecast.2020.06.008>
- Huber, J., & Stuckenschmidt, H. (2020). Daily retail demand forecasting using machine learning with emphasis on calendric special days. *International Journal of Forecasting*, 36(4), 1420–1438. <https://doi.org/10.1016/j.ijforecast.2020.02.005>
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice (3rd ed.)*. OTexts. <https://otexts.com/fpp3/>
- Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>
- Hyndman, R. J., Ahmed, R. A., Athanasopoulos, G., & Shang, H. L. (2011). Optimal combination forecasts for hierarchical time series. *Computational Statistics & Data Analysis*, 55(9), 2579–2589. <https://doi.org/10.1016/j.csda.2011.03.006>
- Hübner, N., Caspers, J., Coroamă, V. C., & Finkbeiner, M. (2024). Machine-learning-based demand forecasting against food waste: Life cycle environmental impacts and benefits of a bakery case study. *Journal of Industrial Ecology*, 28, 1117–1131. <https://doi.org/10.1111/jiec.13528>
- Instituto Nacional de Estadística y Geografía (INEGI). (2025, 25 de junio). *Estadísticas a propósito del Día de las Micro, Pequeñas y Medianas Empresas (mipymes) [Comunicado de prensa 71/25]*. https://www.inegi.org.mx/contenidos/saladeprensa/aproposito/2025/EAP_MIPYMES_25.pdf

- Kantis, H., Federico, J., & García, S. (2020). *Índice de condiciones sistémicas para el emprendimiento dinámico*. Prodem.
- Kuhn, M., & Johnson, K. (2013). *Applied predictive modeling*. Springer. <https://doi.org/10.1007/978-1-4614-6849-3>
- Lee, K.-S., Blum, D., Miao, L., & Tomas, S. R. (2020). The creative minds of extraordinary pastry chefs: An integrated theory of aesthetic expressions—A portraiture study. *International Journal of Contemporary Hospitality Management*, 32(9), 3015–3034. <https://doi.org/10.1108/IJCHM-04-2020-0329>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018a). Statistical and machine learning forecasting methods: Concerns and ways forward. *PLOS ONE*, 13(3), e0194889. <https://doi.org/10.1371/journal.pone.0194889>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018b). The M4 competition: Results, findings, conclusion and way forward. *International Journal of Forecasting*, 34(4), 802–808. <https://doi.org/10.1016/j.ijforecast.2018.06.001>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1), 54–74. <https://doi.org/10.1016/j.ijforecast.2019.04.014>
- Maldonado-Guzmán, G., & Garza-Reyes, J. A. (2020). Eco-innovation practices' adoption in the automotive industry. *International Journal of Innovation Science*, 12(1), 80–98. <https://doi.org/10.1108/IJIS-10-2019-0094>
- Melesse, T. Y., & Orrù, P. F. (2025). The digital revolution in the bakery sector: Innovations, challenges, and opportunities from Industry 4.0. *Foods*, 14(3), Article 526. <https://doi.org/10.3390/foods14030526>
- Mikalef, P., Boura, M., Lekakos, G., & Krogstie, J. (2019). Big data analytics capabilities and innovation: The mediating role of dynamic capabilities and moderating effect of the environment. *British Journal of Management*, 30(2), 272–298. <https://doi.org/10.1111/1467-8551.12343>
- Minniti, M., & Bygrave, W. (2001). A dynamic model of entrepreneurial learning. *Entrepreneurship Theory and Practice*, 25(3), 5–16. <https://doi.org/10.1177/104225870102500301>
- OECD. (2021). *The digital transformation of SMEs*. OECD Publishing. <https://doi.org/10.1787/bdb9256a-en>

- Poveda-Valverde, F., & Fierro Barragán, S. E. (2026). AI applications that can support sustainable practices in small and medium-sized enterprises in Latin America: A systematic review. *Sustainability*, 18(7), Article 3603. <https://doi.org/10.3390/su18073603>
- Power, D. J. (2002). *Decision support systems: Concepts and resources for managers*. Quorum Books.
- Ries, E. (2017). *El método Lean Startup: Cómo crear empresas de éxito utilizando la innovación continua*. Deusto.
- Romero-Hidalgo, J. A., Isiordia-Lachica, P. C., Valenzuela, A., & Rodríguez-Carvajal, R. A. (2021). Knowledge and innovation management model in the organizational environment. *Information (Switzerland)*, 12(6), 225. <https://doi.org/10.3390/info12060225>
- Saavedra-García, M., & Tapia-Sánchez, B. (2020). The role of information technologies in Mexican SMEs. *Contaduría y Administración*, 65(2). <https://doi.org/10.22201/fca.24488410e.2020.2215>
- Shmueli, G. (2010). To explain or to predict? *Statistical Science*, 25(3), 289–310. <https://doi.org/10.1214/10-STS330>
- Spiliotis, E., Makridakis, S., & Assimakopoulos, V. (2025). Continuous business forecasting in modern organizations. *Forecasting*, 7(1), 12–29. <https://doi.org/10.3390/forecast7010012>
- Spiliotis, E., Makridakis, S., Semenoglou, A. A., & Assimakopoulos, V. (2022). Comparison of statistical and machine learning methods for daily SKU demand forecasting. *Operational Research*, 22(3), 3037–3061. <https://doi.org/10.1007/s12351-020-00605-2>
- Syntetos, A. A., & Boylan, J. E. (2005). The accuracy of intermittent demand estimates. *International Journal of Forecasting*, 21(2), 303–314. <https://doi.org/10.1016/j.ijforecast.2004.10.001>
- Syntetos, A. A., Boylan, J. E., & Croston, J. D. (2005). On the categorization of demand patterns. *Journal of the Operational Research Society*, 56(5), 495–503. <https://doi.org/10.1057/palgrave.jors.2601841>
- Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: An analysis and review. *International Journal of Forecasting*, 16(4), 437–450. [https://doi.org/10.1016/S0169-2070\(00\)00065-0](https://doi.org/10.1016/S0169-2070(00)00065-0)

- Teunter, R. H., Syntetos, A. A., & Babai, M. Z. (2011). Intermittent demand: Linking forecasting to inventory obsolescence. *European Journal of Operational Research*, 214(3), 606–615. <https://doi.org/10.1016/j.ejor.2011.05.018>
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1), 267–288. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>
- Valdez-Juárez, L. E., García-Pérez-de-Lema, D., & Maldonado-Guzmán, G. (2018). ICT and KM, drivers of innovation and profitability in SMEs. *Journal of Information & Knowledge Management*, 17(1), 1850007. <https://doi.org/10.1142/S0219649218500077>
- Zhang, G. P. (2003). Time series forecasting using a hybrid ARIMA and neural network model. *Neurocomputing*, 50, 159–175. [https://doi.org/10.1016/S0925-2312\(01\)00702-0](https://doi.org/10.1016/S0925-2312(01)00702-0)

Anexo A Diccionario de datos

Este diccionario describe los campos de Ventas.xlsx y Compras.xlsx, hoja Hoja1, y las variables principales de entrada y preparación del *pipeline* inspeccionadas el 13 de septiembre de 2026. Los encabezados se verificaron directamente. Los tipos indicados son los esperados para el análisis, no una certificación de limpieza; las definiciones no confirmadas se señalan expresamente. No se reproducen datos personales ni valores de transacciones.

Reglas comunes de interpretación

La existencia de un registro no prueba su integridad ni la cobertura de su semana. Cero, celda vacía y texto null tienen significados distintos: los valores cero se revisan con evidencia y los faltantes no se convierten automáticamente en ceros. Se observaron tipos mixtos y texto null en Ventas.xlsx. Antes de agregar se verificó si cada fila corresponde a una transacción, una línea o una repetición, y se documentó el tratamiento de devoluciones y cancelaciones.

Las fechas de inicio de captura provienen de la información histórica del negocio y no garantizan que los archivos inspeccionados contengan todo ese periodo. Los importes analíticos se expresaron en MXN nominales una vez confirmada la moneda y el alcance. Los campos administrativos y personales se excluyen del conjunto inicial de predictores. La disponibilidad temporal se comprobó antes de cada pronóstico; una fecha de operación no equivale por sí sola a fecha de disponibilidad.

Campos de origen de ventas

Campo exacto	Tipo esperado	Definición	Uso y validación
Number	Texto	Identificador registrado de la transacción.	Control; comprobar unicidad, no usar como predictor.
Status	Categoría	Estado registrado de la venta.	Validar categorías y criterio de inclusión; no asumir que todos los estados son ventas concluidas.
Fecha/Hora	Fecha y hora	Marca temporal del registro.	Convertir y contrastar con Fecha; no equivale necesariamente a fecha de disponibilidad.
Cantidad	Número	Cantidad consignada en la venta.	Unidad y diferencia respecto de Total de ítems pendientes de verificación.

Campo exacto	Tipo esperado	Definición	Uso y validación
Total de ítems	Número	Total de ítems consignado.	Verificar si cuenta unidades o líneas del pedido; no asumir equivalencia con Cantidad.
Descri. Items	Texto	Descripción de los productos de la transacción.	Descripción auxiliar; no se modela texto libre en la versión inicial.
Subtotal	Número monetario	Subtotal registrado antes de ajustes.	MXN por confirmar en origen; revisar conciliación, no sumar al Importe.
Descuento	Número	Descuento registrado.	Confirmar si expresa MXN o porcentaje antes de operar con él.
Tasa	Número	Campo de tasa del reporte.	Definición y unidad pendientes; no asumir importe de impuesto.
Envío	Número monetario	Cargo de envío registrado.	Confirmar inclusión en Importe; no duplicar cargos.
Importe	Número monetario	Importe registrado de la venta.	Candidato para agregado nominal semanal; validar concepto, moneda, ceros y estados.
Ganancia	Número	Campo de ganancia registrado.	Cálculo pendiente de verificación; no equivale a utilidad neta demostrada ni es objetivo del estudio.
Nombre	Texto	Nombre asociado al registro.	Rol pendiente de confirmar; dato potencialmente personal, excluido de predictores.
Vendedor	Texto categoría o	Responsable o canal consignado.	Dato administrativo; excluir identificadores personales del modelado.
Observación	Texto	Notas de la transacción.	Puede contener datos personales; no publicar valores ni usar como predictor inicial.
Fecha	Fecha	Fecha consignada sin hora.	Normalizar y contrastar con Fecha/Hora; definir fecha válida para agregación.
Año	Entero	Año consignado.	Contrastar con la fecha validada; preferir derivación consistente.
Mes	Entero	Mes consignado.	Valores esperados 1 a 12; contrastar con la fecha.
Día	Entero	Día del mes consignado.	Validar según mes y año.
Pastel	Indicador	Indicador de categoría pastel.	Se observaron 0, 1 y texto null; verificar codificación. No convertir null en 0.
Galletas	Indicador	Indicador de categoría galletas.	Se observaron 0, 1 y texto null; no prueba cantidades vendidas.
Otros	Indicador	Indicador de otros productos de venta.	No confundir con otros de la composición de compras; revisar null.
Cupcakes	Indicador	Indicador de categoría cupcakes.	Se observaron 0, 1 y texto null; verificar codificación.
Pedido	Texto	Referencia interna del pedido.	Contiene tipos mixtos; conservar como identificador y verificar relación con Number.
NumPedido	Texto	Número o referencia del pedido.	Comprobar relación con Pedido y Number; la unicidad no está garantizada.

Campos de origen de compras

Campo exacto	Tipo esperado	Definición	Uso y validación
PROVEEDOR	Texto	Proveedor consignado en la compra.	Control administrativo; no es predictor inicial.
FECHA	Fecha	Fecha registrada de adquisición.	Se homologa a fecha; fecha inválida genera incidencia.
NUMERO	Texto	Número consignado en el registro.	Significado y unicidad pendientes; no se presume clave única.
CANT	Número	Cantidad registrada de adquisición.	Interpretar junto con U#MEDIDA; no es variable objetivo.
U#MEDIDA	Texto o categoría	Unidad de medida registrada.	Homologación pendiente; no sumar cantidades de unidades diferentes.
DESCRIPCION	Texto	Descripción de lo adquirido.	Se homologa a descripcion y descripcion_normalizada; requiere catálogo aprobado.
MONTO	Número monetario	Importe registrado de la adquisición.	Se homologa a importe_nominal en MXN; verificar ceros, moneda y alcance. No asumir CANT por P#UNITARIO sin conciliación.
P#UNITARIO	Número monetario	Precio unitario registrado.	MXN por unidad consignada; definición y consistencia pendientes de revisión.
CLASIFICACION	Categoría	Clasificación de origen.	No sustituye automáticamente al insumo_id aprobado.
SUBCLASIFICACION	Categoría	Subclasificación de origen.	Homologar significado; uso auxiliar para revisar el catálogo.

Variables analíticas y controles del pipeline

Esta sección documenta contratos del código, no la aprobación de fuentes ni su incorporación efectiva. Los nombres entre signos angulares representan columnas dinámicas; los nombres agrupados identifican campos con la misma regla. Las participaciones se almacenan como proporciones y sus errores se reportan en puntos porcentuales. La inferencia futura no requiere importes observados de las semanas objetivo.

Campo o familia	Tipo y unidad	Origen o regla	Uso y disponibilidad
fecha	Fecha	FECHA de compras normalizada al día.	Clave temporal; solo registros previos al origen alimentan características.
importe_nominal	Número en MXN	MONTO homologado en compras; importe semanal en contrato de ventas.	Objetivo monetario o predictor según tabla; inválidos no se sustituyen por cero.
descripcion	Texto	DESCRIPCION homologada.	Base del catálogo, no una categoría aprobada por sí misma.
descripcion_normalizada	Texto	Descripción normalizada mediante clean_upper.	Clave de enlace con catálogo; descripción vacía genera incidencia.

Campo o familia	Tipo y unidad	Origen o regla	Uso y disponibilidad
registro_id	Entero	Número de fila de origen contado desde 2.	Trazabilidad dentro del archivo y su hash; no identificador universal.
motivo	Texto	Resultado de revisión del registro.	Vacío significa sin incidencia detectada; no prueba cobertura completa.
semana_inicio	Fecha	Lunes de la semana de lunes a domingo.	Clave semanal; agregación después de aprobar cobertura.
insumo_id	Texto	Identificador asignado por catálogo aprobado.	No admite vacío ni nombres reservados total u otros.
aprobado	Booleano	Aprobación de la correspondencia de catálogo.	El código admite true o 1; requiere decisión documentada.
estado	Categoría	Condición de cobertura semanal.	observada o cero_confirmado para datos reales; desconocida o incompleta bloquean el intervalo. Ver nota de procedencia.
evidencia	Texto	Sustento de la revisión de cobertura.	Obligatorio; debe justificar la clasificación semanal.
fecha_revision	Fecha	Fecha de revisión de cobertura.	Obligatoria; no equivale a available_at de un predictor.
registros_detectados	Entero	Conteo de filas por semana en plantilla.	Cero no confirma ausencia de compras; no establece cobertura.
total	Número en MXN	Suma de importes semanales por insumo.	Objetivo monetario nominal; cero solo interpretable con cobertura validada.
<insumo_id>	Número en MXN	Columnas dinámicas del panel, una por insumo.	Importe semanal agregado; nombres determinados por catálogo, no columnas literales fijas.
otros	MXN o proporción	Residual de insumos no seleccionados, según matriz.	No confundir con Otros de ventas; distinguir matriz de importes de matriz de participaciones.
Participación por insumo	Proporción de 0 a 1	Importe del insumo dividido entre total positivo.	Matriz con columnas por insumo; total cero implica no definido. Multiplicar por 100 solo para porcentaje.
lag_1, lag_2, lag_4, lag_8, lag_12	Número en MXN	Totales de semanas previas al origen.	Predictores; sufijo indica distancia semanal. No usar valores objetivo futuros.
media_4, media_8, media_12	Número en MXN	Media de las últimas semanas cerradas.	Ventana indicada por sufijo; requiere historia anterior al origen.
desv_4, desv_8, desv_12	Número en MXN	Desviación estándar muestral de las semanas previas.	Mismas ventanas que las medias; un solo dato no define dispersión muestral.
cal_sin, cal_cos	Número de -1 a 1	Codificación cíclica de semana objetivo.	Calendario conocido; periodo del código 52.1775 semanas.
ventas_lag_1, ventas_lag_4	Número en MXN	Importe semanal de ventas rezagado.	Opcional; solo si available_at no es posterior al origen; de otro modo faltante.
available_at	Fecha y hora	Momento de disponibilidad de ventas o exógenas.	Debe ser anterior o igual al origen. Ventas semanales: no antes del cierre.
variable	Texto	Nombre de variable exógena.	Obligatorio en contrato opcional; no implica fuente incorporada.
fecha_referencia	Fecha	Periodo al que corresponde una exógena.	No confundir con fecha de publicación o disponibilidad.

Campo o familia	Tipo y unidad	Origen o regla	Uso y disponibilidad
valor	Número	Valor de variable exógena.	Finito; unidad específica a documentar por variable antes de incorporarla.
fuelle, version	Texto	Procedencia y versión de la exógena.	Obligatorias; permiten controlar revisiones de datos.
tipo	Categoría	observada, pronóstico o calendario.	Una observación futura no se etiqueta como disponible; pronósticos requieren archivo previo.
exog_<variable>	Número	Valor exógeno admisible en el origen.	Pronóstico o calendario para la fecha objetivo; en su defecto última observación previa; ausente queda faltante.
es_sintetico	Booleano	Indicador de procedencia sintética.	Control, nunca resultado real; la existencia del campo no autoriza usar esos datos.
metodo_sintesis	Texto	Método declarado de generación sintética.	Metadato condicional del código; exige aprobación separada y no acredita observación real.

Nota de procedencia. El código inspeccionado contempla de manera condicional el estado `sintetica_entrenamiento` y campos de síntesis sujetos a aprobación y corte temporal. Su descripción no aprueba ni incorpora datos sintéticos al estudio. Esas observaciones no deben etiquetarse como reales ni utilizarse como evidencia de evaluación; cualquier diferencia entre el código y el protocolo científico se resolvió antes de la corrida evaluada.

Fuente. Elaboración propia a partir de los encabezados de `datasets/xlsx/Ventas.xlsx` y `datasets/xlsx/Compras.xlsx`, de los módulos `data.py`, `features.py` y `composition.py` del *pipeline* y de la información histórica proporcionada sobre *Cup&Cake*. Las equivalencias semánticas y unidades marcadas como pendientes requieren revisión de la documentación de origen antes de aprobar el conjunto analítico.

Anexo B Paquete de reproducibilidad

El paquete se conserva dentro de la raíz del proyecto de tesis. Las rutas siguientes son relativas a esa raíz y permiten localizar la configuración, el código y los productos que sustentan los resultados. Los datos transaccionales originales permanecen restringidos por confidencialidad; los manifiestos registran huellas SHA-256, versiones de bibliotecas, parámetros y semilla aleatoria (42).

Repositorio del proyecto: <https://github.com/amartinezcsn/tesis>

Componente	Ruta relativa	Función
Entrada del pipeline	codigos/00_pipeline_hibrido.py	Punto de ejecución reproducible
Dependencias	codigos/requirements_hibrido.txt	Versiones requeridas
Configuración principal	codigos/02_config_hibrido.json	Parámetros de la corrida evaluada
Configuración de sensibilidad	codigos/02_config_hibrido_sensibilidad_sin_imputacion_rev59.json	Mismos parámetros, sin imputación
Manifiesto principal	output/run_20260924T195600Z_86a6f5/manifiesto.json	Huellas, entorno y parámetros
Manifiesto de sensibilidad	output/run_20260928T014913Z_38994f/manifiesto.json	Trazabilidad de la repetición
Métricas y selección	output/run_20260924T195600Z_86a6f5/metricas.csv; seleccion_interna.csv	Resultados monetarios y elección interna
Composición	output/run_20260924T195600Z_86a6f5/metricas_composicion.csv; seleccion_composicion.csv	Resultados de participaciones
Predicciones y particiones	output/run_20260924T195600Z_86a6f5/predicciones.csv; particiones.csv	Observaciones, pronósticos y cortes
Contraste de H1	output/run_20260924T195600Z_86a6f5/hipotesis.json	Resultado del contraste exploratorio

Criterio de reproducción. Una repetición debe conservar las fuentes autorizadas, la configuración, la semilla y las versiones registradas en el manifiesto. Para la sensibilidad se suprimieron únicamente los parámetros de imputación. La identidad SHA-256 de metricas.csv, metricas_composicion.csv, seleccion_interna.csv, seleccion_composicion.csv, predicciones.csv, particiones.csv e hipotesis.json entre ambas corridas demuestra que las copias imputadas no intervinieron en las salidas evaluativas.

Restricción de acceso. Compras.xlsx, Ventas.xlsx y los archivos contextuales contienen información operativa de la empresa y no se incorporan al documento. Su custodia corresponde al proyecto autorizado; la reproducción por terceros requiere acceso legítimo a las mismas fuentes o a una versión anonimizada aprobada.